

Semáforos Inteligentes: Un enfoque con Aprendizaje por Refuerzo Multi Agente

Tesina de Licenciatura en Ciencias de la Computación

Juan Martín Morales

Tutora: Dra Ana Carolina Olivera



UNCUYO
UNIVERSIDAD
NACIONAL DE CUYO



FACULTAD DE
INGENIERÍA

Facultad de Ingeniería
Universidad Nacional de Cuyo

Resumen

En este trabajo se aborda el problema de la congestión vehicular en áreas urbanas, proponiendo una solución basada en el Aprendizaje por Refuerzo Multi-Agente (MARL) Cooperativo para optimizar el control semafórico. Se analiza la evolución del parque automotor en Argentina, destacando el aumento significativo de vehículos y sus consecuencias en la movilidad urbana. Se presentan los desafíos asociados al control semafórico tradicional y se justifica la necesidad de enfoques adaptativos basados en inteligencia artificial. El objetivo principal es desarrollar y evaluar un sistema de control de tráfico que permita mejorar el flujo vehicular mediante políticas coordinadas entre múltiples intersecciones, utilizando simulaciones tanto en escenarios sintéticos como en la red vial real del Gran Mendoza. **Caro: falta completar**

Abstract

In this work, we address the problem of vehicular congestion in urban areas by proposing a solution based on Cooperative Multi-Agent Reinforcement Learning (MARL) to optimize traffic light control. We analyze the evolution of the automotive fleet in Argentina, highlighting the significant increase in vehicles and its consequences on urban mobility. We present the challenges associated with traditional traffic light control and justify the need for adaptive approaches based on artificial intelligence. The main objective is to develop and evaluate a traffic control system that improves vehicular flow through coordinated policies among multiple intersections, using simulations in both synthetic scenarios and the real road network of Greater Mendoza. **Caro: falta completar**

Agradecimientos

Página de agradecimientos

Índice

Resumen	1
1 Introducción	2
1.1 Motivación	3
2 Marco Teórico	4
2.1 Ingeniería de Tránsito y Simulación	4
2.1.1 Terminología de Tránsito	4
2.1.2 Fundamentos de la Dinámica Vehicular	6
2.1.3 Sistemas de Control de Tránsito	9
2.1.4 Simulación de Tránsito	11
2.2 Aprendizaje por Refuerzo (RL)	14
2.2.1 El Proceso de Decisión de Markov (MDP)	15
2.2.2 Métodos Basados en Valor y Basados en Política	16
2.2.3 Aprendizaje Profundo y Redes Neuronales	17
2.2.4 Aprendizaje por Refuerzo Profundo (DRL)	18
2.3 Aprendizaje por Refuerzo Multi-Agente (MARL)	22
2.3.1 Fundamentos Teóricos: Juegos Estocásticos, Equilibrio de Nash y Dec-POMDP	22
2.3.2 Desafíos Fundamentales en MARL	23
2.3.3 Paradigmas de Entrenamiento y Ejecución	24
2.3.4 Multi-Agent Deep Reinforcement Learning (MADRL) y Algoritmos Baseline	24
2.3.5 Multi-Agent Proximal Policy Optimization (MAPPO)	25
2.3.6 Heterogeneous-Agent Proximal Policy Optimization (HAPPO)	27
3 Metodología y Diseño Experimental	32
3.1 Enfoque y Diseño de Investigación	32
3.2 Especificación del Stack Tecnológico	33
3.3 Diseño de Escenarios de Tránsito en SUMO	34
3.3.1 Escenarios Sintéticos: 3×1 , 3×3 y $4 \times 4_H$	34
3.3.2 Escenario Urbano Real: Gran Mendoza (Corredor Vicente Zapata)	35
3.4 Arquitectura de Integración Entorno-Agentes	35
3.4.1 Ciclo Episódico e Interfaz de Simulación	35
3.5 Instanciación del Modelo Dec-POMDP	35
3.5.1 Espacio de Observaciones y Codificación Logarítmica	36
3.5.2 Espacio de Acciones y Enmascaramiento Dinámico	36
3.5.3 Función de Recompensa Compuesta y Coordinación Vecinal	36
3.6 Implementación Algorítmica e Hiperparámetros	37
3.7 Diseño de Experimentos de Búsqueda Hiperparamétrica	37
3.7.1 Infraestructura Computacional de Alto Rendimiento y Orquestación Distribuida	37
3.8 Diseño de Experimentos de Evaluación de Rendimiento	38
4 Análisis y discusión de resultados	39
4.1 Resultados del ajuste de hiperparámetros	39
4.1.1 Diseño del proceso de ajuste	39
4.1.2 Resultados del ajuste y análisis de sensibilidad	39
4.1.3 Configuración seleccionada para la evaluación final	39

4.2	Resultados de los modelos finales	39
4.2.1	Criterios de evaluación y métricas de comparación	39
4.2.2	Desempeño en escenarios sintéticos (3×1 , 3×3 , 4×4 heterogéneo) . . .	39
4.2.3	Desempeño en la red de carreteras de la Ciudad de Mendoza	39
4.3	Discusión e interpretación de resultados	39
5	Conclusiones	40

Índice de códigos

Índice de figuras

1.1	Evolución de la flota vehicular circulante en Argentina (1990–2025). Datos: AFAC.	2
2.1	Convención esquemática de movimientos vehiculares, fases y cruces peatonales concurrentes en una intersección de cuatro accesos, adaptada conceptualmente del manual de temporización semafórica de FHWA [Fed08].	5
2.2	Representación esquemática de movimientos vehiculares y puntos de conflicto en una intersección semaforizada.	5
2.3	Relaciones temporales y espaciales entre vehículos consecutivos de una corriente de tránsito: intervalo (h) y espaciamiento (s).	7
2.4	Comparación esquemática de distribuciones de intervalos temporales entre vehículos en flujo libre y en una corriente con formación de pelotones. Las curvas representan situaciones conceptuales y no una distribución empírica particular. .	9
2.5	Distribución temporal de la tasa de descarga y pérdidas asociadas durante un intervalo de verde en una aproximación semaforizada.	10
2.6	Elementos geométricos y conexiones de una intersección semaforizada en SUMO bajo sentido de circulación por la derecha (Argentina): carriles entrantes (L_{in}), salientes (L_{out}), líneas de detención y enlaces de cruzamiento (<i>links</i>) en verde prioritario (G) y rojo retenido en conflicto (r).	12
2.7	Interacción agente-entorno en un proceso de decisión de Markov [SB18].	15
2.8	Relación entre las familias de algoritmos utilizadas en esta investigación. Los cuatro métodos evaluados son libres de modelo y se derivan de las líneas DQN y PPO.	17
2.9	Interacción Agente-Entorno en un esquema MARL cooperativo. Cada semáforo emite una acción local (a_i) formando una acción conjunta (a) que modifica el estado global del entorno de tráfico.	23
2.10	Paradigma de Entrenamiento Centralizado y Ejecución Descentralizada (CTDE). Durante el entrenamiento, el crítico utiliza información global privilegiada para estimar valores o ventajas que orientan la actualización de los actores locales; durante la ejecución, los actores solo requieren observaciones locales.	25
2.11	Esquema de actualización secuencial de HAPPO. A diferencia de PPO Independiente, la actualización de cada agente está matemáticamente condicionada por el cociente de probabilidad compuesto M_{i_m} , que propaga los cambios efectuados por los agentes que lo precedieron en la secuencia.	30
3.1	Flujo metodológico secuencial de la investigación experimental.	33

Glosario

Actor (Aprendizaje por Refuerzo) Componente de la arquitectura del modelo de aprendizaje responsable de seleccionar y ejecutar la acción en el entorno basándose en el estado actual y la política que está aprendiendo.

Agente Entidad computacional que observa el estado de su entorno y ejecuta acciones según una política determinada con el objetivo de maximizar su recompensa a largo plazo.

Ciclo (Ingeniería de Tránsito) Secuencia completa y repetitiva de todas las fases semafóricas programadas en una intersección particular.

Cola vehicular Fila de vehículos que se detienen o avanzan muy lentamente debido a una restricción en la capacidad de la vía, tal como la luz roja de un semáforo.

Crítico (Aprendizaje por Refuerzo) Componente encargado de estimar la función de valor, prediciendo la recompensa futura esperada para evaluar la calidad de las acciones tomadas por el Actor y así guiar su actualización.

Densidad vehicular Número de vehículos presentes en un tramo o longitud específica de un carril en un instante dado.

Entorno El sistema dinámico con el que interactúa el agente. Responde a las acciones del agente produciendo transiciones de estado y emitiendo señales de recompensa.

Estado Representación cuantitativa o cualitativa de la situación actual del entorno en un instante de tiempo específico. Sirve como base para que el agente seleccione su próxima acción.

Fase (Ingeniería de Tránsito) Estado temporal de un controlador semafórico que habilita el derecho de paso exclusivo a una o más corrientes vehiculares incompatibles para que crucen una intersección de forma segura.

Flujo vehicular Cantidad de vehículos que pasan por una sección transversal específica de un carril o calzada durante un intervalo de tiempo determinado.

Función de Valor Estimación matemática de la cantidad total de recompensa que un agente puede esperar acumular en el futuro, comenzando desde un estado particular y siguiendo una política específica.

Observación Subconjunto de información del estado completo del entorno que es efectivamente visible o medible por un agente individual, especialmente relevante en escenarios de observabilidad parcial.

Política (Aprendizaje por Refuerzo) Estrategia que define el comportamiento del agente en un momento dado, mapeando los estados observados a probabilidades de selección de las acciones disponibles.

Proceso de Decisión de Markov Marco matemático utilizado para modelar la toma de decisiones en situaciones donde los resultados son en parte aleatorios y en parte bajo el control de un agente tomador de decisiones.

Recompensa Señal escalar devuelta por el entorno que evalúa cuán buena o mala fue la acción ejecutada por el agente en un estado particular. El objetivo del agente es maximizar la suma total de estas señales.

Ventaja (Aprendizaje por Refuerzo) Métrica que cuantifica cuánto mejor o peor resulta tomar una acción particular en un estado dado, en comparación con el desempeño promedio esperado según la política actual.

Resumen

Capítulo de resumen

Ejemplo de items

- Item 1
- Item 2

Introducción

En las últimas décadas, en el mundo se ha producido un incremento sostenido del parque automotor a nivel mundial, acompañado por un proceso continuo de urbanización que ha convertido a la congestión vehicular en uno de los principales desafíos para la movilidad y eficiencia en áreas urbanas. Según los reportes de flota vehicular de Argentina, elaborados por la Asociación de Fábricas Argentinas de Componentes (AFAC), y utilizando el año 2012 como línea base, el volumen de vehículos registró un aumento del 21,7% en 2017. Dicha progresión se sostuvo a lo largo de la última década, alcanzando un incremento acumulado del 44,4% para el año 2025 (véase la Figura 1.1).




Figura 1.1: Evolución de la flota vehicular circulante en Argentina (1990–2025). Datos: AFAC.

Las congestiones vehiculares traen consigo múltiples consecuencias: desde importantes pérdidas de productividad por demoras en los tiempos de viaje, hasta un aumento en la cantidad de detenciones vehiculares y la consecuente emisión de gases nocivos para la salud y el medio ambiente, tales como CO , CO_2 , NO_x , HC [ne18]. Este escenario impacta de manera notable en grandes ciudades con una alta densidad de vehículos. En este trabajo se utilizaron casos de estudio sintetizados y como caso de estudio real el Área Metropolitana del Gran Mendoza (GM), comprendida entre Avenida San Martín, Avenida Colón, Avenida Belgrano y Avenida Las Heras.

Frente a un escenario de congestión, una alternativa viable, sin recurrir a reestructuraciones costosas en la infraestructura, consiste en optimizar la gestión del tránsito mediante sistemas de control semafórico adaptativos. Los enfoques tradicionales de control semafórico han demostrado poca capacidad de adaptación ante escenarios con mucha variabilidad de flujos de vehículos. Una alternativa prometedora resulta ser el Aprendizaje por Refuerzo (*Reinforcement Learning*, RL), un paradigma de inteligencia artificial donde los semáforos pueden modelarse como agentes, capaces de aprender políticas de control a partir de la interacción con un entorno (la situación del tránsito) mediante la ejecución de acciones (cambios de fase) con el objetivo de maximizar una recompensa (como, por ejemplo, el valor negativo de la suma de los tiempos de espera). Diversos estudios han demostrado la viabilidad de este enfoque, evolucionando desde la aplicación de algoritmos clásicos y tabulares en una sola intersección [Wie00, APK03], hasta modelos a gran escala de redes coordinadas empleando redes neuronales profundas y control multi-agente [ETAA13, LLW16, W⁺19, CWCL19].

Sin embargo, aplicar este enfoque de manera simultánea sobre múltiples intersecciones introduce desafíos adicionales. Un esquema de control centralizado resulta poco escalable debido al crecimiento exponencial del espacio de acciones conjunto. Una alternativa “ingenua” del Apre-

dizaje por Refuerzo Multi-Agente resulta ser el Aprendizaje Independiente (*Independent Learning* o IL), donde cada semáforo busca descongestionar de forma independiente y egoísta solo su propia intersección [AS22]. Este enfoque tiene dos desventajas críticas: primero, la optimización puramente local conduce a un óptimo global sub-óptimo; segundo, dado que todos los agentes aprenden y cambian sus políticas simultáneamente, el entorno se vuelve no estacionario para cada agente individual, lo cual viola los supuestos de convergencia del aprendizaje [FH21].

Por esta razón, en este trabajo final de carrera se aborda el problema desde el marco del Aprendizaje por Refuerzo Multi-Agente (MARL) Cooperativo. Bajo este paradigma, los controladores (agentes) actúan como un equipo. Aprenden políticas coordinadas, no para maximizar solo una recompensa individual, sino también una recompensa global compartida orientada a la minimización del tiempo de espera promedio de toda la red, evitando así los conflictos que surgen del aprendizaje independiente. La recompensa es un valor numérico que indica cuán efectiva fue la acción conjunta.

En este contexto, el objetivo general de este trabajo fue desarrollar y evaluar un sistema de control de tráfico basado en este enfoque cooperativo para optimizar el flujo vehicular urbano. Para lograrlo, se analizó la convergencia a políticas de control óptimas y la escalabilidad de distintos algoritmos MARL ante entornos no estacionarios mediante simulaciones en escenarios sintéticos y en la red vial real del Gran Mendoza. Esto permitió establecer una línea base de comparación para, posteriormente, validar empíricamente el desempeño de la arquitectura descentralizada y coordinada propuesta frente a los enfoques de control tradicionales y a metodologías recientes de la literatura.

1.1 Motivación

La motivación principal de este trabajo radica en la marcada asimetría entre una demanda vehicular en constante crecimiento y una infraestructura vial que permanece estática. Dado que ensanchar avenidas o modificar físicamente el trazado urbano en cascos densos como el del Gran Mendoza es económica y estructuralmente inviable, la alternativa más sostenible es la optimización lógica de los recursos existentes.

El desarrollo de soluciones basadas en software permite dotar de la adaptabilidad necesaria a la red semafórica actual. De este modo, es posible transformar un sistema rígido en uno inteligente capaz de mitigar las demoras y reducir la contaminación ambiental evitable, maximizando la eficiencia de la infraestructura vial sin requerir obras civiles de gran envergadura.

La presente tesina se organiza de la siguiente manera: en el Capítulo 1 se formula el problema de estudio y se exponen las motivaciones que impulsan esta investigación. A continuación, el Capítulo 2 establece las bases teóricas, abordando los conceptos clave de la ingeniería de tránsito y los fundamentos del *Reinforcement Learning*, particularmente en su vertiente multi-agente. Luego, el Capítulo 3 detalla la metodología de trabajo, describiendo tanto los entornos de simulación empleados como la arquitectura algorítmica de los modelos implementados. Posteriormente, en el Capítulo 4 se lleva a cabo un análisis empírico del desempeño de los distintos controladores, evaluándolos en escenarios controlados y en la red urbana simulada del Gran Mendoza. Finalmente, el Capítulo 5 sintetiza los hallazgos principales, destaca las contribuciones metodológicas y sugiere posibles vías para continuar este trabajo en el futuro.

Marco Teórico

Este capítulo presenta los conceptos necesarios para formular el control semafórico como un problema de decisión secuencial. Primero se describen las variables y los elementos de la operación del tránsito; luego se introduce su representación en un simulador microscópico; finalmente se presentan los fundamentos del aprendizaje por refuerzo (RL) y del aprendizaje por refuerzo multiagente (MARL), que permiten formular políticas de control para la red vial.

2.1 Ingeniería de Tránsito y Simulación

La ingeniería de tránsito se define como aquella fase de la ingeniería de transporte —disciplina que se enmarca tradicionalmente dentro de la ingeniería civil— que se ocupa de la planeación segura y eficiente, el proyecto geométrico y la operación del tránsito por calles y carreteras, sus redes, terminales, tierras adyacentes y su relación con otros modos de transporte [CyMR18]. Asimismo, el *Traffic Engineering Handbook* la describe formalmente como la subdisciplina enfocada en la planificación, el diseño geométrico y la operación de redes viales [PW16]. En este trabajo, sus conceptos se abordan desde la perspectiva del modelado computacional y la gestión adaptativa: permiten describir el funcionamiento físico de la red vial, caracterizar la oferta y demanda de circulación, e identificar las variables operacionales sobre las cuales puede intervenir un sistema de control inteligente.

Históricamente, la práctica de la ingeniería de tránsito puso un fuerte énfasis en proveer y ampliar la capacidad física vial mediante la construcción de nuevas obras o el ensanche de calzadas [PW16]. Sin embargo, el crecimiento sostenido del parque automotor evidenció que la ampliación de la infraestructura no constituye una solución definitiva al problema de la congestión. En áreas urbanas consolidadas, además, modificar el trazado vial resulta costoso y geométricamente inviable [CyMR18]. Por ello, la práctica contemporánea complementa la infraestructura física con estrategias de control dinámico del tránsito, priorizando la optimización de los recursos existentes mediante dispositivos de control semafórico.

La operación de una red vial puede analizarse a partir de la relación entre la demanda vehicular y la capacidad disponible. La demanda vehicular (D) corresponde a la cantidad de vehículos que requieren desplazarse por un determinado sistema vial en un lapso dado, mientras que la oferta vial o capacidad (c) representa la cantidad máxima de vehículos que pueden circular por dicho espacio físico bajo determinadas condiciones de operación [CyMR18]. Cuando la demanda se aproxima a la capacidad, el tránsito se vuelve inestable; cuando la supera ($D > c$), se presentan condiciones de sobresaturación o flujo forzado, caracterizadas por detenciones frecuentes y grandes demoras. En este sentido, la congestión no se entiende solo como una percepción general de mal funcionamiento, sino como un fenómeno con manifestaciones físicas medibles: demoras, colas y detenciones [FA11].

Estas magnitudes cumplen una función doble en el modelo computacional: pueden formar parte de las observaciones y de la señal de recompensa de los agentes, y también se utilizan para evaluar el desempeño del controlador. Su definición permite vincular la descripción física del tránsito con la formulación posterior del problema de aprendizaje.

2.1.1 Terminología de Tránsito

Antes de formular el problema de control, es necesario distinguir algunos términos operativos que se utilizarán a lo largo del capítulo. En particular, se diferencian los movimientos que realizan los vehículos, las fases que habilitan esos movimientos y los intervalos durante los cuales se mantienen las indicaciones semafóricas [Fed08, W⁺19].

En este contexto, se emplearán las siguientes nociones:

- **Intersección, acceso y carril:** una intersección es el área física y operacional en la que confluyen dos o más corrientes de tránsito. Cada una de las calzadas de aproximación que ingresan a ella constituye un acceso [PW16], organizándose internamente en uno o más carriles destinados a canalizar los flujos vehiculares [CyMR18].
- **Movimiento vehicular y movimientos en conflicto:** un movimiento vehicular representa la trayectoria específica que describe un vehículo al cruzar la intersección hacia una salida determinada, por ejemplo, un giro o un movimiento directo [W⁺19]. Dos movimientos se consideran en conflicto o incompatibles cuando sus trayectorias se intersectan y generan puntos de conflicto en la intersección (véase la Figura 2.2), lo que impide su servicio simultáneo por razones de seguridad [FA11].
- **Fase, ciclo e intervalo:** una fase es una configuración de señales que habilita simultáneamente un conjunto de movimientos compatibles [PW16]. El ciclo corresponde a la secuencia completa de fases necesaria para atender los movimientos de la intersección. Un intervalo es el período durante el cual las indicaciones semafóricas permanecen constantes [CyMR18].

La Figura 2.1 ilustra estos conceptos en una intersección de cuatro accesos. La numeración sigue de manera esquemática una convención habitual de los manuales de temporización semafórica; no representa una configuración obligatoria para el caso de estudio. La figura permite distinguir entre movimiento físico, fase semafórica y usuarios servidos por una misma indicación [Fed08].




Figura 2.1: Convención esquemática de movimientos vehiculares, fases y cruces peatonales concurrentes en una intersección de cuatro accesos, adaptada conceptualmente del manual de temporización semafórica de FHWA [Fed08].



Figura 2.2: Representación esquemática de movimientos vehiculares y puntos de conflicto en una intersección semaforizada.

En arterias urbanas, el tránsito se desarrolla bajo condiciones de flujo interrumpido: los vehículos no avanzan únicamente por su interacción con otros vehículos, sino también por la presencia de intersecciones, señales y dispositivos de control de tránsito [PW16]. Las intersecciones son puntos críticos de la red porque allí confluyen distintos accesos y movimientos vehiculares de cruce, convergencia y divergencia que pueden resultar incompatibles entre sí. Por ello, su operación requiere ordenar estos movimientos y asignar la prioridad de paso de manera segura y eficiente.

El semáforo es uno de los dispositivos de control de tránsito utilizados para regular la circulación en intersecciones. Su función es asignar la prioridad de paso en forma alternada entre corrientes vehiculares incompatibles, evitando que distintos movimientos intenten ocupar simultáneamente el mismo espacio de cruce [FA11]. Desde el punto de vista del modelado algorítmico, esta capacidad de modificar la prioridad de paso convierte al semáforo en el actuador mediante el cual un sistema de control puede intervenir sobre la operación de la intersección y afectar, directa o indirectamente, las demoras y colas observadas en la red.

2.1.2 Fundamentos de la Dinámica Vehicular

Para modelar y optimizar la operación de una red vial, es necesario caracterizar físicamente el movimiento de los vehículos. La ingeniería de tránsito estudia este fenómeno a partir de las características fundamentales de la corriente de tránsito, que permiten describir las condiciones de operación de una vía o intersección mediante magnitudes observables como el flujo, la velocidad y la densidad [PW16]. Cal y Mayor distingue estas magnitudes entre variables principales, que describen el comportamiento agregado del flujo vehicular, y variables asociadas, que expresan relaciones temporales y espaciales entre vehículos consecutivos [CyMR18].

A nivel macroscópico, la corriente de tránsito se representa mediante variables agregadas como la tasa de flujo, la densidad y los promedios de velocidad. A nivel microscópico, se analizan magnitudes propias de vehículos individuales e interacciones entre pares consecutivos, como la velocidad puntual, el intervalo y el espaciamiento [CyMR18]. Esta separación entre escalas es fundamental para el modelado computacional: las variables macroscópicas resumen el estado operacional de los accesos de la red, mientras que las variables microscópicas describen el comportamiento de cada vehículo dentro del simulador [FA11]. La correspondencia y las relaciones de conversión entre las variables de ambas escalas se resumen en la Tabla 2.1.

En el nivel macroscópico, las variables principales de la corriente de tránsito son:

- **Flujo o tasa de flujo (q):** representa la cantidad de vehículos que atraviesan una sección transversal de la vía por unidad de tiempo. Si el período de observación es menor a una hora, se proyecta como una tasa horaria equivalente en vehículos por hora (veh/h), calculada como $q = N/T$, donde N es el número de vehículos observados y T es la duración del intervalo de medición expresado en horas [CyMR18].
- **Densidad o concentración (k):** indica el número de vehículos que ocupan simultáneamente una longitud específica de vía, expresada en vehículos por kilómetro (veh/km), calculada como $k = N/d$, donde d representa la longitud del tramo de vía analizado [CyMR18]. En la práctica, se suele estimar indirectamente a través del porcentaje de ocupación temporal registrado por detectores inductivos [PW16].
- **Velocidad media espacial (v_s):** es la velocidad media de los vehículos que ocupan un tramo de vía en un instante determinado. Corresponde al promedio armónico de las velocidades puntuales de los vehículos individuales y representa la magnitud de velocidad consistente con la dinámica del flujo espacial [CyMR18].
- **Velocidad media temporal (v_t):** representa el promedio aritmético de las velocidades de los vehículos que cruzan una sección transversal fija de la vía durante un período de tiempo determinado [CyMR18].

En el nivel microscópico, las variables asociadas describen el movimiento del vehículo individual y la separación entre vehículos consecutivos (véase la Figura 2.3):

- **Velocidad puntual (v_i):** es la velocidad instantánea a la que un vehículo individual (i) atraviesa una sección transversal específica de la vía.
- **Intervalo temporal (h):** es el tiempo transcurrido entre el paso de dos vehículos consecutivos por una sección fija de la calzada, medido respecto a puntos homólogos, por ejemplo, los parachoques delanteros [CyMR18]. El intervalo promedio en segundos (h_{prom}) se relaciona con la tasa de flujo como $h_{\text{prom}} = 3600/q$.
- **Espaciamiento simple (s):** es la distancia física entre puntos homólogos de dos vehículos consecutivos en un instante de tiempo [CyMR18]. El espaciamiento promedio en metros (s_{prom}) se relaciona de forma inversa con la densidad de la corriente de tránsito como $s_{\text{prom}} = 1000/k$.

Cuadro 2.1: Comparación y correspondencia de variables de tránsito en escalas macroscópica y microscópica.

Escala	Variable Principal	Relación / Conversión
Macroscópica	Flujo (q , veh/h)	$q = 3600/h_{\text{prom}}$
	Densidad (k , veh/km)	$k = 1000/s_{\text{prom}}$
	Velocidad media espacial (v_s , km/h)	$q = k \cdot v_s$
	Velocidad media temporal (v_t , km/h)	$v_t = v_s + \frac{\sigma_s^2}{v_s}$ (Relación de Wardrop)
Microscópica	Velocidad puntual (v_i , km/h)	Variable individual de cada vehículo
	Intervalo temporal (h , s)	Tiempo entre pasos de vehículos sucesivos
	Espaciamiento simple (s , m)	Distancia espacial entre parachoques homólogos




Figura 2.3: Relaciones temporales y espaciales entre vehículos consecutivos de una corriente de tránsito: intervalo (h) y espaciamiento (s).

Estas variables macroscópicas se relacionan de manera directa a través de la ecuación fundamental del flujo de tránsito:

$$q = k \cdot v_s \quad (2.1)$$

donde q es la tasa de flujo, k es la densidad y v_s es la velocidad media espacial. Esta ecuación utiliza la velocidad media espacial, ya que relaciona el flujo y la cantidad de vehículos presentes en un tramo. La velocidad media temporal (v_t) difiere de ella porque asigna mayor peso a los

vehículos más rápidos que cruzan un punto de medición durante un intervalo dado. La relación entre ambas variables se expresa mediante la relación de Wardrop [FA11]:

$$v_t = v_s + \frac{\sigma_s^2}{v_s} \quad (2.2)$$

donde σ_s^2 representa la varianza de la distribución de las velocidades de los vehículos en el espacio. Dado que la varianza es no negativa ($\sigma_s^2 \geq 0$), se cumple que $v_t \geq v_s$, con igualdad únicamente cuando todos los vehículos circulan a la misma velocidad. En una intersección semaforizada, una indicación roja puede reducir localmente la velocidad media y aumentar la acumulación de vehículos en los accesos. Estos efectos se manifiestan en la formación de colas y en el incremento de las demoras [CyMR18].

Métricas de Ineficiencia Operativa

La interrupción del flujo causada por semáforos o saturación genera efectos adversos que los sistemas de control buscan mitigar. Siguiendo la terminología de la ingeniería de tránsito, las principales manifestaciones medibles de esta ineficiencia son las demoras, las colas y las detenciones [FA11]:

- **Demoras:** Representan el tiempo adicional que un vehículo debe invertir para atravesar una intersección respecto del tiempo que le tomaría circular a velocidad de flujo libre. En intersecciones semaforizadas, una parte de esa demora aparece por la espera normal durante la luz roja. Otras demoras se producen cuando las llegadas de vehículos varían, cuando la demanda se acerca o supera la capacidad de la intersección, o cuando quedan colas sin disiparse al finalizar el verde, de modo que algunos vehículos deben esperar más de un ciclo para cruzar.
- **Colas:** Corresponden al número de vehículos acumulados detrás de una línea de detención a la espera de ser servidos. Esta medida espacial es especialmente relevante porque, cuando la cola supera la longitud del arco de aproximación, puede bloquear la intersección aguas arriba y propagar la congestión al resto de la red.
- **Detenciones:** Cuantifican la cantidad de veces que un vehículo debe reducir su velocidad hasta cero durante el recorrido. Una alta frecuencia de detenciones deteriora la continuidad operativa del flujo y suele asociarse con mayores procesos de aceleración y desaceleración.

Estas magnitudes permiten describir el desempeño operacional de una intersección y de la red. En la formulación computacional, también pueden utilizarse para construir observaciones, señales de recompensa o criterios de evaluación del controlador.

Descripción Probabilística del Flujo y Pelotones Vehiculares

En el modelado de tránsito, las llegadas vehiculares no siempre pueden representarse adecuadamente como una secuencia determinista y constante. Para flujos vehiculares bajos y medios, y cuando las llegadas no están fuertemente condicionadas por semáforos previos, es habitual aproximar el número de vehículos que llega a una sección durante un intervalo de tiempo mediante un proceso de Poisson [CyMR18].

Esta aproximación supone independencia estadística entre llegadas y permite describir la variabilidad observada en la demanda de acceso a una intersección [CyMR18]. La probabilidad discreta $P(X)$ de que lleguen exactamente X vehículos en un intervalo de tiempo se define como:

$$P(X) = \frac{m^X \cdot e^{-m}}{X!} \quad (2.3)$$

donde $X \in \mathbb{N}_0$ es la variable aleatoria discreta que representa el número de arribos vehiculares, $m > 0$ representa el valor esperado o media de llegadas en dicho intervalo, y e es la base del logaritmo natural. Bajo el mismo supuesto, los intervalos de tiempo continuos (h) medidos entre vehículos sucesivos se describen mediante una distribución de probabilidad exponencial negativa [CyMR18]:

$$P(h \geq t) = e^{-\frac{q}{3600} \cdot t} \quad (2.4)$$

donde h es el intervalo temporal en segundos, q es el flujo en veh/h, y t es el umbral de tiempo analizado.

Esta representación probabilística asume independencia entre arribos sucesivos, siendo una aproximación válida únicamente para flujos vehiculares bajos o moderados bajo condiciones de flujo libre, donde no exista la influencia de semáforos cercanos aguas arriba [CyMR18]. Sin embargo, este supuesto de independencia decae en condiciones de congestión o en redes viales urbanas semaforizadas. En estos casos, la operación de los semáforos interrumpe periódicamente el flujo y agrupa a los vehículos en pelotones (*platoons*), induciendo una fuerte dependencia espacio-temporal y correlación entre arribos consecutivos. La Figura 2.4 presenta una comparación conceptual de la distribución resultante de los intervalos temporales entre vehículos bajo estas dos condiciones operativas.

Esta limitación de los modelos analíticos tradicionales justifica el uso de simulación microscópica para estudiar el control semafórico bajo condiciones variables. En SUMO, la formación, dispersión e interacción de los pelotones emergen de la dinámica simulada de los vehículos y de sus cambios de carril. El uso de distintos perfiles de demanda y semillas de simulación permite evaluar el comportamiento del controlador frente a variaciones en las condiciones de operación.




Figura 2.4: Comparación esquemática de distribuciones de intervalos temporales entre vehículos en flujo libre y en una corriente con formación de pelotones. Las curvas representan situaciones conceptuales y no una distribución empírica particular.

2.1.3 Sistemas de Control de Tránsito

Para ordenar los movimientos en conflicto y regular el paso en las intersecciones urbanas se utilizan sistemas de control de tránsito [PW16]. El semáforo asigna el derecho de paso de manera alternada mediante indicaciones luminosas rojas, amarillas y verdes [CyMR18].

En el modelo computacional, el semáforo actúa como el mecanismo mediante el cual el controlador interviene sobre la red. La selección de fases, la duración del verde efectivo y la coordinación entre intersecciones modifican la prioridad de paso y afectan la evolución de las colas y las demoras.

Sobre esta base terminológica, la programación temporal de un semáforo se describe mediante la duración de las fases, la longitud de ciclo y la definición de los intervalos de transición y despeje.

Estos parámetros determinan cuánto tiempo recibe prioridad cada conjunto de movimientos compatibles y condicionan directamente la capacidad de descarga, las demoras y la seguridad operacional de la intersección [PW16].

En relación con los giros izquierdos, los manuales de temporización distinguen entre operación permisiva, protegida y protegida-permisiva. En una fase permisiva, el giro se ejecuta aprovechando brechas en la corriente opuesta; en una fase protegida, el giro recibe una indicación exclusiva y los movimientos conflictivos permanecen detenidos; en una fase protegida-permisiva, ambas condiciones se combinan durante distintos intervalos del ciclo [Fed08]. Para el presente trabajo, la distinción resulta útil porque muestra que una fase no es solo un color del semáforo, sino una regla operacional que habilita ciertos movimientos, impone cesión de paso en otros y restringe los movimientos en conflicto.

Para garantizar la seguridad vial, las transiciones entre fases no pueden ejecutarse de manera instantánea, sino que deben respetar intervalos de cambio y despeje ($t_{\text{amarillo}} + t_{\text{rojo_todo}}$) [PW16]. En esta investigación, esos tiempos se consideran restricciones operativas de seguridad previamente definidas en la configuración del simulador y del sistema semafórico. En consecuencia, su determinación no forma parte del proceso de decisión del agente, cuyo control se limita a la selección o extensión de fases dentro de un esquema temporal compatible con dichas restricciones.

Modelado de la Capacidad y el Verde Efectivo

Desde el punto de vista operativo, la capacidad de descarga de un acceso semaforizado depende del tiempo efectivo de servicio que recibe cada fase y de la tasa con la que la fila puede disiparse cuando el movimiento tiene prioridad [FA11]. En la práctica, la descarga observada no depende solo de la duración nominal del verde, sino también de pérdidas de arranque, transiciones y otras restricciones temporales del control, como se ilustra conceptualmente en la Figura 2.5. En este trabajo, estos efectos no se modelan mediante fórmulas analíticas de capacidad, sino mediante la dinámica microscópica del simulador y la configuración temporal del sistema semafórico, ya que esas interacciones determinan las colas, demoras y detenciones que el controlador busca mejorar.




Figura 2.5: Distribución temporal de la tasa de descarga y pérdidas asociadas durante un intervalo de verde en una aproximación semaforizada.

Clasificación de los Controladores de Semáforos

De acuerdo con su mecanismo operativo y su grado de respuesta a la demanda vehicular, los controladores de semáforos se clasifican clásicamente en control de tiempo fijo y control accionado por el tránsito [PW16]. En el primero, los planes de señales se repiten de manera preprogramada a partir de datos históricos y no cambian en respuesta a la demanda instantánea. En el segundo,

la intersección utiliza detectores en los accesos para variar dinámicamente el inicio o la duración de las fases según la demanda observada en tiempo real.

Incluso en los esquemas accionados, la operación permanece sujeta a parámetros límite de seguridad y funcionamiento, como el verde mínimo ($g_{\min}$) y el verde máximo ($g_{\max}$) [PW16]. Estos parámetros restringen cuánto puede sostenerse o finalizarse una fase y, en este trabajo, forman parte de las condiciones operativas dentro de las cuales el controlador toma decisiones.

2.1.4 Simulación de Tránsito

Debido a la densidad y complejidad de la red urbana moderna, la sincronización y optimización de los tiempos de semáforos no pueden resolverse adecuadamente con modelos estáticos bajo condiciones dinámicas, por lo que se recurre a aproximaciones computacionales basadas en simulación de tránsito [PW16]. De acuerdo con la taxonomía clásica [FA11], estos modelos pueden organizarse en tres niveles de resolución. Los modelos macroscópicos describen el tránsito de manera agregada mediante variables como flujo, densidad y velocidad; los modelos mesoscópicos representan entidades intermedias, como grupos o pelotones de vehículos. Ambos niveles son útiles para estudiar fenómenos de red, pero no ofrecen el detalle necesario para observar cómo las decisiones semafóricas afectan, paso a paso, la formación de colas y la interacción local entre vehículos en una intersección.

Para el presente trabajo, el nivel de mayor interés es el microscópico, ya que representa explícitamente a cada vehículo, su ruta y su movimiento dentro de la red [FA11]. SUMO (*Simulation of Urban MObility*) se ubica en esta categoría: es un simulador de tránsito microscópico, multimodal y de código abierto, diseñado para representar demandas vehiculares sobre redes viales y evaluar problemas de gestión del tránsito [ALBBW⁺18, DLR25]. En SUMO, la evolución vehicular es continua en el espacio y discreta en el tiempo; además, el entorno permite modelar calles con múltiples carriles, cambios de carril, distintos tipos de vehículos, rutas individuales, semáforos y salidas de simulación a nivel de vehículo, carril, arco o detector [DLR25]. Esta granularidad vuelve a la simulación microscópica especialmente adecuada para estudiar control semafórico mediante aprendizaje por refuerzo. Las decisiones sobre fases y tiempos de servicio no se evalúan mediante una fórmula cerrada de demora, sino observando sus consecuencias sobre la dinámica simulada: colas, tiempos de espera, detenciones, ocupación de carriles y propagación de congestión. Por ello, la simulación microscópica constituye el puente natural entre el problema de tránsito y su formulación computacional, al permitir que el controlador interactúe con un entorno dinámico y medible durante la ejecución.

Modelos Microscópicos de Comportamiento Vehicular

En este contexto, el simulador de tránsito constituye el entorno operativo sobre el cual se formaliza el problema de control semafórico. En SUMO, una intersección semaforizada se estructura mediante tres componentes geométricos y lógicos principales bajo el sentido de circulación por la derecha (véase la Figura 2.6) [DLR25]:

- **Carriles entrantes (L_{in}) y salientes (L_{out}):** Los carriles entrantes conducen el flujo vehicular hacia la línea de detención de la intersección por la derecha de cada acceso, mientras que los carriles salientes reciben el flujo descargado tras cruzar el nodo.
- **Líneas de detención (*stop lines*):** Delimitación física continua en color blanco en el límite de los carriles entrantes L_{in} con el área interna de cruzamiento (*junction*).
- **Enlaces de conexión (*links*):** Rutas internas que conectan un carril entrante específico con un carril saliente de destino. A cada enlace se le asigna un estado semafórico instantáneo (G para verde prioritario, g para verde permisivo, y r para rojo o detención). Como se ilustra en la Figura 2.6, mientras los movimientos directos se encuentran habilitados en verde (G),

el giro a la izquierda en conflicto (representado por el enlace en rojo salmón) se mantiene retenido en luz roja (r) para prevenir colisiones.

Esta representación es compatible con la formulación algorítmica del problema, donde una acción consiste en seleccionar una fase que habilita un conjunto de enlaces compatibles mientras mantiene en rojo (r) los movimientos en conflicto.




Figura 2.6: Elementos geométricos y conexiones de una intersección semaforizada en SUMO bajo sentido de circulación por la derecha (Argentina): carriles entrantes (L_{in}), salientes (L_{out}), líneas de detención y enlaces de cruzamiento ($links$) en verde prioritario (G) y rojo retenido en conflicto (r).

Componentes y Configuración de SUMO

Para la generación, edición y control en tiempo real de los escenarios de simulación microscópica, el entorno SUMO se complementa con un conjunto integrado de herramientas y librerías auxiliares [ALBBW⁺18, DLR25]:

- **netedit**: Herramienta gráfica que permite proyectar y editar la geometría y la lógica operacional de la red vial de forma interactiva. Facilita la creación y modificación bidireccional de nodos, accesos, carriles, restricciones de giro, conexiones internas ($links$), sensores inductivos y programas de temporización semafórica.
- **osmWebWizard**: Herramienta automatizada con interfaz web que permite importar áreas geográficas reales desde OpenStreetMap (OSM) y transformarlas al formato nativo de SUMO, extrayendo información de la red como la topología urbana y los límites de velocidad.
- **TraCI (Traffic Control Interface)**: Protocolo de comunicación cliente-servidor mediante sockets TCP que habilita la interacción dinámica a paso discreto entre la simulación y scripts externos de control [DLR25]. A través de TraCI, los agentes de aprendizaje por refuerzo recolectan observaciones del estado del tránsito (colas, velocidades, ocupación) e imponen decisiones sobre las fases del semáforo.

Desde la perspectiva del modelado computacional, la ejecución de una simulación microscópica en SUMO se organiza mediante archivos de configuración en formato XML [DLR25]. En los escenarios considerados, sus componentes principales se resumen en la Tabla 2.2:

- **Archivo de red (.net.xml):** Define la estructura física e infraestructura de la red vial, incluyendo las coordenadas nodales, la geometría de arcos, los carriles por acceso, las conexiones de cruzamiento y la lógica de accionamiento semafórico.
- **Archivo de rutas (.rou.xml):** Especifica las características de la flota vehicular (dimensiones, aceleración, velocidad deseada y modelo de seguimiento) junto con los itinerarios o flujos de origen a destino.
- **Archivo TAZ (.taz.xml, *Traffic Analysis Zones*):** Delimita las zonas de análisis de tráfico para asignar espacialmente las matrices de origen y destino de los desplazamientos.
- **Archivo de elementos adicionales (.add.xml):** Incorpora dispositivos de medición (como detectores de bucle inductivo E1 y E2), paradas de transporte público o programas semafóricos personalizados.
- **Archivo maestro de configuración (.sumocfg):** Integra las referencias a los archivos de red, rutas y adicionales, y fija los parámetros del horizonte temporal de simulación (duración del paso Δt , tiempos de inicio y fin, e indicadores de salida).

Cuadro 2.2: Archivos de configuración empleados en los escenarios de simulación en SUMO [DLR25].

Archivo XML	Extensión	Función en el Modelo Computacional
Red Vial	.net.xml	Topología física, accesos, carriles, enlaces y semáforos.
Rutas y Demanda	.rou.xml	Tipos de vehículos, modelos de seguimiento e itinerarios.
Zonas TAZ	.taz.xml	Zonas de origen y destino para matrices de demanda.
Elementos Adicionales	.add.xml	Sensores inductivos E1/E2, telemetría y programas auxiliares.
Configuración Maestra	.sumocfg	Unificación de archivos, resolución temporal (Δt) y registros.

Métricas de Evaluación Operacional y Aprendizaje

Para evaluar rigurosamente el impacto de las estrategias de control semafórico tanto desde la perspectiva de la ingeniería de tránsito como del aprendizaje automático, este trabajo distingue cuatro tipos de indicadores para la evaluación y el diagnóstico del entrenamiento:

- **Emisión de gases CO₂:** Cuantifica el impacto ambiental y la ineficiencia energética del flujo vehicular. En SUMO, las emisiones se estiman mediante modelos microscópicos como HBEFA o PHEMlight [DLR25], relacionando la masa de CO₂ emitida en gramos con los perfiles de velocidad, aceleración y tiempo en ralentí (*idling*) de cada vehículo. Una reducción de la masa total de CO₂ puede asociarse con una operación más fluida y una menor frecuencia de detenciones.
- **Tiempo de Espera Promedio Global y por Agente:** Métrica operacional primaria en ingeniería de tránsito [CyMR18]. El tiempo de espera cuantifica la acumulación en segundos que un vehículo permanece detenido (velocidad $v < 0.1$ m/s) antes de cruzar la intersección. Se evalúa a nivel local por cada agente i (intersección) y de forma agregada a nivel global de la red vial, permitiendo medir la reducción directa de la demora operacional.

- **Recompensa Acumulada Descontada:** Métrica interna de RL/MARL definida como el retorno episódico $G_0 = \sum_{t=0}^T \gamma^t R_t$. Expresa la capacidad del agente para maximizar de forma persistente su objetivo escalar proyectado en el tiempo [SB18].
- **Valores de pérdida (*loss values*):** Indicadores de diagnóstico durante el entrenamiento en DRL/MADRL [YVV⁺22]. Incluyen la pérdida de política o actor ($\mathcal{L}^{\text{CLIP}}$), la pérdida de error cuadrático medio de la función de valor del crítico ($\mathcal{L}^{\text{VF}}$) y el término de entropía de la política ($S[\pi]$). Su seguimiento permite identificar inestabilidades del gradiente y cambios en el proceso de optimización; por sí solo, no demuestra la calidad operacional del controlador.

En este marco, SUMO no solo permite reproducir la evolución microscópica de la red, sino también interactuar con ella mediante TraCI. La posibilidad de observar el estado del tránsito y modificar las fases semafóricas en pasos discretos convierte el control semafórico en un problema de decisión secuencial, lo que motiva la introducción del aprendizaje por refuerzo en la siguiente sección [DLR25].

2.2 Aprendizaje por Refuerzo (RL)

Dentro del aprendizaje automático suelen distinguirse tres paradigmas principales. En el aprendizaje supervisado, el modelo se entrena a partir de ejemplos etiquetados que indican la salida esperada para cada entrada. En el aprendizaje no supervisado, en cambio, se busca descubrir estructura en datos no etiquetados, por ejemplo mediante agrupamiento o reducción de dimensionalidad. El aprendizaje por refuerzo (*Reinforcement Learning*, RL) aborda un problema distinto: una entidad que toma decisiones debe aprender, mediante interacción con un entorno, qué acciones elegir para maximizar una señal de recompensa acumulada a largo plazo [SB18].

Esta diferencia es central. En RL no existe, en general, un supervisor que indique cuál era la acción correcta en cada situación. El agente aprende por experiencia, ensayando acciones, observando sus consecuencias y ajustando su comportamiento a partir de las recompensas obtenidas. Además, las consecuencias relevantes de una acción no siempre se manifiestan de forma inmediata: una decisión puede producir una recompensa baja en el corto plazo, pero conducir a estados favorables en el futuro. Por este motivo, el aprendizaje por refuerzo se ocupa explícitamente del problema de la recompensa diferida y de la asignación de crédito a decisiones pasadas [SB18].

La formulación básica distingue entre el *agente* (*agent*), que aprende y toma decisiones, y el *entorno* (*environment*), que representa todo aquello externo al agente con lo cual este interactúa. En cada paso temporal, el agente observa una situación del entorno, selecciona una acción y recibe como respuesta una nueva situación junto con una recompensa. El comportamiento del agente está determinado por una *política* (*policy*), denotada por π , que especifica cómo se eligen las acciones a partir de los estados u observaciones disponibles. La *señal de recompensa* (*reward signal*) define el objetivo inmediato del problema, mientras que la *función de valor* estima la conveniencia de estados o acciones en términos de recompensa futura esperada. Sutton y Barto también distinguen el *modelo* del entorno, entendido como una descripción que permite predecir sus transiciones y recompensas; cuando dicho modelo no se conoce o no se utiliza explícitamente, se habla de métodos libres de modelo (*model-free*).

En el control semafórico, el controlador de una intersección puede interpretarse como el agente y la red vial simulada en SUMO como el entorno. La selección de una fase constituye la acción, mientras que la evolución posterior del tránsito produce nuevas observaciones y una señal de recompensa que orienta el aprendizaje [DLR25].

Un aspecto característico de RL es el dilema entre exploración y explotación. El agente debe explotar acciones que, según su experiencia, producen buenos resultados, pero también debe explorar alternativas menos conocidas que podrían conducir a políticas superiores. Si explora demasiado, desperdicia oportunidades de obtener recompensa; si explota demasiado pronto, puede

converger a comportamientos subóptimos. Este equilibrio es especialmente relevante en problemas de control, donde las acciones modifican la experiencia futura disponible para el aprendizaje [SB18].

2.2.1 El Proceso de Decisión de Markov (MDP)

El marco matemático estándar para estudiar problemas de aprendizaje por refuerzo de un solo agente es el Proceso de Decisión de Markov (*Markov Decision Process*, MDP). En un MDP finito, el agente y el entorno interactúan en una secuencia de pasos temporales discretos $t = 0, 1, 2, \dots$. En cada instante t , el agente recibe una representación del estado del entorno $S_t \in \mathcal{S}$ y selecciona una acción $A_t \in \mathcal{A}(S_t)$. Como consecuencia de esa acción, el entorno emite una recompensa numérica $R_{t+1} \in \mathcal{R}$ y transita a un nuevo estado S_{t+1} [SB18]. Este ciclo se representa en la Figura 2.7.




Figura 2.7: Interacción agente-entorno en un proceso de decisión de Markov [SB18].

De forma compacta, un MDP finito queda caracterizado por la tupla $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$, donde $\mathcal{S}$ es el espacio de estados, $\mathcal{A}$ el espacio de acciones, P la dinámica de transición probabilística, R la función de recompensa y $\gamma \in [0, 1)$ el factor de descuento.

La dinámica del entorno queda definida por la función $p(s', r | s, a)$, que especifica la probabilidad condicional conjunta de observar el próximo estado s' y la recompensa r al ejecutar la acción a en el estado s :

$$p(s', r | s, a) \doteq \Pr\{S_{t+1} = s', R_{t+1} = r | S_t = s, A_t = a\} \quad (2.5)$$

donde $S_t \in \mathcal{S}$ representa el estado en el instante t , $A_t \in \mathcal{A}$ es la acción seleccionada, $R_{t+1} \in \mathbb{R}$ es la recompensa escalar recibida y $S_{t+1} \in \mathcal{S}$ es el nuevo estado resultante.

La propiedad de Markov establece que, dado el estado y la acción actuales, la distribución del próximo estado y recompensa no depende explícitamente de la historia completa de estados y acciones anteriores. En otras palabras, el estado debe contener toda la información relevante del pasado para predecir la evolución futura del proceso [SB18].

Una suposición habitual del MDP es que el agente observa un estado suficientemente informativo del entorno. Sin embargo, en muchas aplicaciones reales el agente solo recibe observaciones parciales o ruidosas. En estos casos, el marco se generaliza a un Proceso de Decisión de Markov Parcialmente Observable (POMDP), donde el historial de observaciones puede ser necesario para inferir el estado subyacente [ACS24].

Para formalizar la meta de maximizar la recompensa a largo plazo se define el retorno descontado G_t , que incorpora un factor $\gamma \in [0, 1)$ para ponderar la importancia de las recompensas futuras [SB18]:

$$G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \quad (2.6)$$

donde G_t representa la suma acumulada descontada de recompensas futuras a partir del instante t , y γ es el factor de descuento. Un valor de γ cercano a cero prioriza recompensas inmediatas, mientras que un valor cercano a uno otorga un peso significativo a recompensas futuras de largo plazo [ACS24].

2.2.2 Métodos Basados en Valor y Basados en Política

Los algoritmos de RL pueden agruparse, a grandes rasgos, en métodos basados en valor y métodos basados en política. Esta distinción no agota la taxonomía del campo, pero permite introducir las familias de algoritmos más relevantes para este trabajo.

En los *métodos basados en valor*, la estrategia consiste en estimar qué tan conveniente es encontrarse en un estado o ejecutar una acción determinada. Esto se formaliza mediante la *función de valor de estado* $v_\pi(s) \doteq \mathbb{E}_\pi[G_t \mid S_t = s]$ y la *función de valor de acción* $q_\pi(s, a) \doteq \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$. Ambas funciones satisfacen ecuaciones recursivas conocidas como *ecuaciones de Bellman*, que expresan la relación entre el valor de una situación actual y el valor esperado de sus posibles sucesores [SB18].

Para una política fija, las ecuaciones de Bellman permiten evaluar el valor esperado de los estados y acciones. Cuando el objetivo es encontrar la mejor acción disponible, se utilizan las ecuaciones de optimalidad de Bellman:

$$q_*(s, a) = \mathbb{E} \left[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a \right]. \quad (2.7)$$

Esta relación justifica el objetivo de actualización de Q-learning y, posteriormente, de DQN. La maximización sobre las acciones futuras convierte el problema de evaluación de una política en un problema de control orientado a aproximar la función de acción-valor óptima q_* [SB18].

Cuando la dinámica del entorno no se conoce completamente, estas funciones pueden estimarse a partir de la experiencia. Los métodos de Diferencia Temporal (*Temporal-Difference*, TD) combinan el muestreo de transiciones reales con actualizaciones basadas en estimaciones previas, mecanismo conocido como *bootstrapping*. Un ejemplo central es *Q-learning*, que actualiza la función de acción-valor hacia una estimación de la función óptima $q_*(s, a)$:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t) \right] \quad (2.8)$$

donde $Q(S_t, A_t)$ es la estimación del valor de la acción A_t en el estado S_t , $\alpha \in (0, 1]$ representa la tasa de aprendizaje (*learning rate*), R_{t+1} es la recompensa observada, γ es el factor de descuento, y $\max_a Q(S_{t+1}, a)$ estima el valor máximo alcanzable en el siguiente estado S_{t+1} .

Q-learning es un método *off-policy*: la política que genera las transiciones puede diferir de la política cuyo valor óptimo se estima. En cambio, los métodos de gradiente de política utilizan, en principio, muestras generadas por la política que se está optimizando y se consideran *on-policy*. Esta distinción resulta central para comparar IDQN con IPPO, MAPPO y HAPPO, especialmente en entornos multiagente donde las políticas de los demás agentes cambian durante el entrenamiento.

Por el contrario, los *métodos basados en política* parametrizan directamente la política $\pi(a \mid s, \theta) = \Pr\{A_t = a \mid S_t = s, \theta_t = \theta\}$, donde $\theta \in \mathbb{R}^d$ representa el vector de parámetros ajustables (pesos neuronales). En lugar de derivar la acción exclusivamente de una función de valor, ajustan los parámetros θ para maximizar una medida de rendimiento escalar $J(\theta)$. Para ello aplican ascenso de gradiente sobre el rendimiento esperado:

$$\theta_{t+1} = \theta_t + \alpha \nabla J(\theta_t) \quad (2.9)$$

donde $\nabla J(\theta_t)$ representa el gradiente de la función de rendimiento respecto a los parámetros de la política. El Teorema del Gradiente de Política (*Policy Gradient Theorem*) proporciona la

base teórica para estimar este gradiente sin derivar explícitamente la distribución de estados inducida por la política [SB18]. En la práctica, muchos algoritmos modernos combinan ambas ideas mediante arquitecturas actor-crítico: un actor representa la política y un crítico estima valores para guiar sus actualizaciones.




Figura 2.8: Relación entre las familias de algoritmos utilizadas en esta investigación. Los cuatro métodos evaluados son libres de modelo y se derivan de las líneas DQN y PPO.

2.2.3 Aprendizaje Profundo y Redes Neuronales

La Unidad Neuronal y Redes *Feedforward*

En problemas de control complejos, los métodos tabulares se vuelven impracticables debido a las restricciones de memoria y cómputo que impone la maldición de la dimensionalidad [SB18]. La aproximación de funciones soluciona esta limitación al representar funciones mediante una forma parametrizada, permitiendo que el aprendizaje en un estado se generalice a otros estados con características similares. El aprendizaje profundo (*Deep Learning*) emplea redes neuronales artificiales como aproximadores de funciones continuas y no lineales [ACS24].

El componente básico de estas arquitecturas es la unidad neuronal individual. Computacionalmente, una neurona en una capa k ejecuta dos operaciones secuenciales sobre el vector de características de entrada $\mathbf{x}$. Primero, calcula una combinación lineal utilizando un vector de pesos $\mathbf{w}$ y un sesgo (*bias*) escalar b . Luego, el resultado se somete a una función de activación no lineal g_k :

$$f_{k,u}(\mathbf{x}; \theta_k^u) = g_k(\mathbf{w}^\top \mathbf{x} + b) \quad (2.10)$$

donde $\mathbf{x} \in \mathbb{R}^d$ es el vector de entrada, $\mathbf{w} \in \mathbb{R}^d$ representa los pesos asociativos, $b \in \mathbb{R}$ es el sesgo, y g_k es una función de activación no lineal apta para la optimización mediante gradientes. La inclusión de una función no lineal es necesaria; componer múltiples capas lineales resultaría en una transformación lineal, limitando la capacidad de representación de la red [ACS24]. Entre las opciones comunes destacan ReLU (Unidad Lineal Rectificada, $g(z) = \max(0, z)$), que es no diferenciable en cero pero admite subgradiientes, *leaky* ReLU ($g(z) = \max(\alpha z, z)$ con $\alpha \ll 1$) y Tanh (tangente hiperbólica, con salidas en $[-1, 1]$).

Las redes neuronales de propagación hacia adelante (*feedforward* o perceptrones multicapa) estructuran estas unidades en secuencias de múltiples capas: una capa de entrada, capas intermedias u ocultas, y una capa de salida. La computación de una capa entera se puede vectorizar:

$$\mathbf{h}_k = g_k(\mathbf{W}_k^\top \mathbf{x}_{k-1} + \mathbf{b}_k) \quad (2.11)$$

donde $\mathbf{W}_k$ es la matriz de pesos de la capa k , $\mathbf{x}_{k-1}$ es la salida activada de la capa previa y $\mathbf{b}_k$ es el vector de sesgos. El Teorema de Aproximación Universal establece que una red con una única capa oculta suficientemente ancha puede aproximar cualquier función continua en un dominio compacto. Esto no implica que una red ancha sea equivalente, en términos de entrenamiento o

generalización, a una red profunda; bajo presupuestos comparables de parámetros, una mayor profundidad puede facilitar la representación jerárquica de funciones complejas [ACS24].

El Proceso de Optimización

Dado que las redes neuronales carecen de una solución de forma cerrada, sus parámetros θ se ajustan utilizando métodos de optimización iterativa. El proceso se fundamenta en tres componentes técnicos [ACS24]:

- **Función de Pérdida (*Loss Function*):** Un objetivo matemático diferenciable $\mathcal{L}(\theta)$ que cuantifica la discrepancia entre las predicciones de la red y los valores objetivo. Frecuentemente se emplea el Error Cuadrático Medio (MSE).
- **Descenso de Gradiente:** El optimizador actualiza los parámetros moviéndose en la dirección del gradiente negativo $-\nabla_{\theta}\mathcal{L}(\theta)$, ponderado por una tasa de aprendizaje α . En la práctica se utiliza el Descenso de Gradiente por Mini-lotes (*Mini-batch Gradient Descent*), que muestrea un subconjunto aleatorio de datos para ofrecer un equilibrio óptimo entre la estabilidad del gradiente y el costo computacional. Optimizadores modernos como Adam adaptan dinámicamente las tasas de aprendizaje para acelerar la convergencia.
- **Retropropagación (*Backpropagation*):** Para que el descenso de gradiente sea posible en arquitecturas profundas, es necesario computar las derivadas parciales de la función de pérdida respecto a cada parámetro. El algoritmo de *backpropagation* logra esto aplicando eficientemente la regla de la cadena de derivadas, propagando los gradientes desde la capa de salida hacia las capas de entrada.

2.2.4 Aprendizaje por Refuerzo Profundo (DRL)

El Aprendizaje por Refuerzo Profundo (DRL) combina los algoritmos de RL con la capacidad de generalización del aprendizaje profundo. Esta integración es fundamental cuando los espacios de estado son continuos o de alta dimensionalidad, donde es estadísticamente improbable que un agente visite el mismo estado múltiples veces. Sin embargo, el DRL exige aproximadores robustos capaces de procesar flujos de datos correlacionados temporalmente y de rastrear objetivos no estacionarios [ACS24].

El Problema de la Tríada Mortal (*Deadly Triad*)

La aplicación de aproximadores de funciones al aprendizaje por refuerzo introduce dificultades de estabilidad. Sutton y Barto [SB18] denominan *Tríada Mortal* a la combinación de tres elementos que puede producir inestabilidad o divergencia en las estimaciones de valor, especialmente cuando no se cumplen condiciones suficientes de representación y actualización:

- **Aproximación de Funciones:** Uso de aproximadores potentes y escalables, como las redes neuronales, que extienden el aprendizaje generalizando a través del espacio de estados.
- **Bootstrapping:** La práctica de actualizar estimaciones de valor apoyándose en otras estimaciones aprendidas previamente (como en los métodos TD), en lugar de esperar la consecución de retornos reales completos.
- **Entrenamiento *Off-Policy*:** Optimizar la función de valor utilizando una distribución de datos o transiciones generadas por una política de comportamiento distinta a la política objetivo que se desea evaluar o mejorar.

La tríada no implica divergencia inevitable ni obliga a conservar sus tres componentes. La aproximación de funciones suele ser necesaria para escalar a espacios de estados grandes o continuos, mientras que el *bootstrapping* y el aprendizaje *off-policy* pueden evitarse mediante métodos Monte Carlo y métodos *on-policy*, respectivamente. Estos intercambios modifican la varianza, el sesgo y la eficiencia de muestras del aprendizaje; por ello, los algoritmos profundos incorporan mecanismos de estabilización en lugar de asumir que la divergencia es inevitable [SB18, ACS24].

Deep Q-Networks (DQN)

En los métodos basados en valor, DRL sustituye la tabla clásica por una red neuronal $Q(s, a; \theta)$. En espacios de acción discretos, el algoritmo *Deep Q-Networks* (DQN) procesa el estado s como vector de entrada y computa simultáneamente las estimaciones de valor para todas las acciones en su capa de salida [ACS24, MKS⁺15].

La inestabilidad descrita por la Tríada Mortal se manifiesta en DQN como el “problema del blanco móvil”: al generalizar, una actualización que incrementa el valor de un estado puede modificar también los valores estimados para otros estados. Además, las transiciones consecutivas presentan correlación temporal y pueden inducir sobreajuste a la experiencia reciente. Para mitigar estos efectos y estabilizar empíricamente la optimización, DQN emplea dos componentes estructurales [ACS24, MKS⁺15]:

- **Redes Objetivo (*Target Networks*):** Se emplea una red neuronal secundaria separada cuyos parámetros θ^- se congelan temporalmente. Esta red se utiliza exclusivamente para calcular los valores objetivo en el error TD, amortiguando las oscilaciones y estabilizando el blanco de aprendizaje.
- **Búferes de Repetición (*Replay Buffers*):** Se almacenan las transiciones históricas del agente (s, a, r, s') . El entrenamiento se realiza extrayendo mini-lotes aleatorios de esta memoria, lo cual reduce la correlación temporal intrínseca de las trayectorias y aproxima el entrenamiento a la hipótesis de muestras independientes. Este mecanismo no constituye, por sí mismo, una garantía de convergencia con aproximadores no lineales.

La función de pérdida minimizada por DQN es:

$$\mathcal{L}(\theta) = \mathbb{E}_{(s_j, a_j, r_j, s_{j+1}) \sim \mathcal{D}} \left[\left(\underbrace{r_j + \gamma \max_{a'} \hat{Q}(s_{j+1}, a'; \theta^-)}_{\text{Valor Objetivo de TD}} - \underbrace{Q(s_j, a_j; \theta)}_{\text{Predicción Actual}} \right)^2 \right] \quad (2.12)$$

donde $\mathcal{D}$ es el búfer de repetición de experiencias, (s_j, a_j, r_j, s_{j+1}) representa una transición muestreada, θ indica los parámetros de la red Q actual y θ^- representa los parámetros congelados de la red objetivo.

El procedimiento conceptual de DQN combina la recolección de transiciones, la selección de acciones mediante una política ϵ -greedy y la actualización de la red a partir de mini-lotes extraídos del búfer de experiencias. La siguiente descripción resume el algoritmo sin imponer decisiones particulares de implementación:

Algorithm 1 Deep Q-Network con repetición de experiencias

```
1: Inicializar el búfer de experiencias  $\mathcal{D}$  con capacidad  $N$ 
2: Inicializar la red de acción-valor  $Q(s, a; \theta)$  con parámetros aleatorios
3: Inicializar la red objetivo  $\hat{Q}(s, a; \theta^-)$  con  $\theta^- \leftarrow \theta$ 
4: for episodio = 1, 2, ... do
5:   Inicializar el estado  $s_t$ 
6:   for  $t = 1, 2, \dots, T$  do
7:     Seleccionar  $a_t$  mediante una política  $\epsilon$ -greedy basada en  $Q(s_t, a; \theta)$ 
8:     Ejecutar  $a_t$  y observar la recompensa  $r_{t+1}$ , el estado  $s_{t+1}$  y si el episodio terminó
9:     Almacenar  $(s_t, a_t, r_{t+1}, s_{t+1}, d_{t+1})$  en  $\mathcal{D}$ 
10:    Muestrear un mini-lote de transiciones desde  $\mathcal{D}$ 
11:    Calcular  $y_j = r_{j+1} + \gamma(1 - d_{j+1}) \max_{a'} \hat{Q}(s_{j+1}, a'; \theta^-)$ 
12:    Actualizar  $\theta$  minimizando  $(y_j - Q(s_j, a_j; \theta))^2$ 
13:    Actualizar periódicamente la red objetivo:  $\theta^- \leftarrow \theta$ 
14:     $s_t \leftarrow s_{t+1}$ 
15:   end for
16: end for
```

En esta expresión, d_{j+1} es un indicador que toma el valor uno cuando la transición conduce a un estado terminal y cero en caso contrario.

Aproximación de Políticas, Función de Ventaja y *Policy Gradient*

Como alternativa a derivar la política de forma indirecta a partir de una función de valor (como en DQN), DRL permite parametrizar directamente la política del agente mediante una red neuronal $\pi(a|s; \theta)$ [ACS24].

Para cuantificar el desempeño marginal de una acción tomada en un estado específico respecto a la expectativa promedio de la política, se define la **Función de Ventaja** (*Advantage Function*) $A^\pi(s, a)$ [SB18]:

$$A^\pi(s, a) \doteq Q^\pi(s, a) - V^\pi(s) \quad (2.13)$$

donde $Q^\pi(s, a)$ representa el retorno esperado al tomar la acción a en el estado s bajo la política π , y $V^\pi(s)$ es el valor promedio de estado. Conceptualmente, la ventaja mide cuánto mejor ($A^\pi(s, a) > 0$) o peor ($A^\pi(s, a) < 0$) resulta la acción a en comparación con el desempeño medio del agente en el estado s .

En arquitecturas actor-crítico, la ventaja se estima habitualmente mediante la Estimación Generalizada de la Ventaja (*Generalized Advantage Estimation*, GAE) desarrollada por Schulman et al. [SML⁺16]:

$$\hat{A}_t^{\text{GAE}(\gamma, \lambda)} \doteq \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l}^V \quad (2.14)$$

donde $\delta_t^V = R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$ representa el error de diferencia temporal (TD) estimado por la red del crítico V , $\gamma \in [0, 1)$ es el factor de descuento y $\lambda \in [0, 1]$ es el hiperparámetro de suavizado GAE que equilibra el sesgo y la varianza del estimador.

En lugar de minimizar un error cuadrático de predicción, la optimización paramétrica del actor se rige por el Teorema del Gradiente de Política (*Policy Gradient Theorem*), que establece la actualización de los parámetros θ ascendiendo por el gradiente del rendimiento esperado [SB18, SML⁺16]:

$$\nabla_\theta J(\theta) = \hat{\mathbb{E}}_t \left[\nabla_\theta \log \pi_\theta(A_t | S_t) \hat{A}_t \right] \quad (2.15)$$

donde $\nabla_\theta J(\theta)$ representa el gradiente del desempeño esperado, $\pi_\theta(A_t | S_t)$ es la probabilidad otorgada a la acción ejecutada A_t en el estado S_t , y $\hat{A}_t$ es la ventaja estimada. Esta formu-

lación incrementa la probabilidad de elegir acciones con ventaja positiva ($\hat{A}_t > 0$) y reduce la probabilidad de aquellas con ventaja negativa.

Proximal Policy Optimization (PPO) y control de las actualizaciones

Una dificultad conocida de los métodos de gradiente de política tradicionales (como REINFORCE o A2C) es su sensibilidad a la tasa de aprendizaje: actualizaciones de parámetros con pasos demasiado grandes pueden modificar la distribución de la política de forma abrupta, provocando un colapso catastrófico del desempeño del cual el agente raramente se recupera.

Para limitar el riesgo de actualizaciones demasiado grandes, Kakade y Langford [KL02] y Schulman et al. (TRPO [SLA⁺15]) estudiaron métodos de región de confianza. Bajo supuestos específicos y una optimización que respeta la restricción de divergencia entre políticas, el procedimiento teórico de TRPO puede establecer una mejora monótona del retorno:

$$J(\pi_{k+1}) \geq J(\pi_k) \quad (2.16)$$

donde $J(\pi_k)$ representa el desempeño esperado de la política en la iteración k . TRPO implementa esta idea mediante una restricción explícita sobre la divergencia Kullback–Leibler (KL). Por su parte, *Proximal Policy Optimization* (PPO) [SWD⁺17] aproxima el comportamiento de una región de confianza mediante un objetivo sustituto recortado (*clipped surrogate objective*) computable con métodos de primer orden. El recorte limita cambios excesivos en la política, pero no constituye una garantía estricta de mejora monótona en cada actualización.

Dada la razón de probabilidad entre la política actual y la anterior:

$$r_t(\theta) \doteq \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)} \quad (2.17)$$

donde $\pi_\theta(a_t | s_t)$ es la probabilidad de la acción a_t bajo los nuevos parámetros θ , y $\pi_{\theta_{\text{old}}}(a_t | s_t)$ es la probabilidad registrada durante la recolección del lote, PPO maximiza el siguiente objetivo recortado:

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2.18)$$

donde $\epsilon > 0$ es un hiperparámetro de recorte (típicamente $\epsilon \approx 0.1\text{--}0.2$), y $\text{clip}(r, 1 - \epsilon, 1 + \epsilon)$ acota la razón r al intervalo $[1 - \epsilon, 1 + \epsilon]$. El operador $\min$ toma el valor más pesimista entre la ventaja ponderada simple y la ventaja recortada, eliminando el incentivo a realizar actualizaciones que modifiquen excesivamente la política si la ventaja es positiva, y acotando la penalización si la ventaja es negativa.

En la práctica, el objetivo del actor de PPO se combina con una pérdida de valor y, opcionalmente, con un término de entropía para favorecer la exploración. Si se expresa todo como un objetivo a maximizar, una forma compacta es:

$$J^{\text{PPO}}(\theta, \phi) = L^{\text{CLIP}}(\theta) - c_1 \hat{\mathbb{E}}_t \left[\left(V_\phi(s_t) - V_t^{\text{target}} \right)^2 \right] + c_2 \hat{\mathbb{E}}_t [S[\pi_\theta](s_t)] \quad (2.19)$$

donde ϕ representa los parámetros de la red del crítico V_ϕ , V_t^{target} son los retornos observados objetivo, $S[\pi_\theta]$ denota la entropía de la distribución de la política, y $c_1, c_2 > 0$ son coeficientes de ponderación escalar.

PPO es un algoritmo predominantemente *on-policy* que reutiliza de forma limitada el lote recolectado con la política vigente. En esta investigación constituye la base conceptual de IPPO, MAPPO y HAPPO; las diferencias entre estas variantes se explican en la sección multiagente.

El siguiente pseudocódigo resume el ciclo conceptual de PPO. La recolección de trayectorias se realiza con la política vigente y el lote se reutiliza durante un número limitado de épocas; posteriormente se descarta para obtener nuevas muestras con la política actualizada:

Algorithm 2 Proximal Policy Optimization (PPO)

```
1: Inicializar los parámetros del actor  $\theta$  y del crítico  $\phi$ 
2: for iteración = 1, 2, ... do
3:   Recolectar trayectorias con la política  $\pi_{\theta_{\text{old}}}$ 
4:   Calcular los retornos objetivo y las ventajas estimadas  $\hat{A}_t$ 
5:   for época = 1 hasta  $K$  do
6:     Muestrear mini-lotes del conjunto de trayectorias recolectado
7:     Calcular  $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$ 
8:     Actualizar  $\theta$  maximizando  $L^{\text{CLIP}}(\theta)$ 
9:     Actualizar  $\phi$  minimizando el error cuadrático del valor
10:    Incorporar, si corresponde, un término de entropía para favorecer la exploración
11:  end for
12:   $\theta_{\text{old}} \leftarrow \theta$ 
13: end for
```

2.3 Aprendizaje por Refuerzo Multi-Agente (MARL)

El aprendizaje por refuerzo multi-agente (*Multi-Agent Reinforcement Learning*, MARL) generaliza los principios del RL hacia sistemas donde múltiples entidades aprenden e interactúan simultáneamente en un entorno compartido [ACS24]. A diferencia del caso individual, las acciones de cada agente modifican el estado global del sistema, lo que induce una dinámica no estacionaria desde la perspectiva local de cualquier participante. En el contexto de sistemas dinámicos cooperativos, múltiples controladores coordinan sus decisiones para optimizar un objetivo común.

En una intersección aislada, el control puede analizarse mediante un único agente. Sin embargo, en una red vial la fase seleccionada en una intersección modifica las corrientes que llegan a otras, por lo que los controladores quedan acoplados por la dinámica del tránsito. Esta dependencia espacial motiva la extensión del aprendizaje por refuerzo hacia un escenario multi-agente.

2.3.1 Fundamentos Teóricos: Juegos Estocásticos, Equilibrio de Nash y Dec-POMDP

La formalización matemática de los entornos multi-agente requiere extender el MDP individual incorporando nociones de la Teoría de Juegos. El modelo matemático fundamental para representar decisiones secuenciales con múltiples participantes es el Juego Estocástico o Juego Markoviano (*Stochastic Game* o *Markov Game*), introducido por Shapley [Sha53] y adaptado al aprendizaje por refuerzo por Albrecht et al. [ACS24].

Un Juego Estocástico para n agentes se define mediante la tupla:

$$\langle \mathcal{N}, \mathcal{S}, \{\mathcal{A}_i\}_{i=1}^n, P, \{R_i\}_{i=1}^n, \gamma \rangle \quad (2.20)$$

donde $\mathcal{N} = \{1, \dots, n\}$ representa el conjunto de agentes, $\mathcal{S}$ es el espacio de estados globales, $\mathcal{A}_i$ es el espacio de acciones del agente i , $P(s' | s, \mathbf{a})$ representa la función de transición de estados condicionada a la acción conjunta $\mathbf{a} = (a_1, \dots, a_n) \in \mathcal{A} \equiv \mathcal{A}_1 \times \dots \times \mathcal{A}_n$, y $R_i(s, \mathbf{a})$ representa la función de recompensa asignada al agente i . En un entorno estrictamente cooperativo, todos los agentes comparten exactamente la misma señal de recompensa ($R_1 = R_2 = \dots = R_n = R$), de modo que el objetivo de cada agente es maximizar el retorno global esperado del sistema.

En el control semafórico de una red, el conjunto de agentes puede corresponder a las intersecciones controladas, mientras que cada espacio de acciones contiene las fases válidas de una intersección. El estado global y la transición representan la evolución conjunta de la red, que

puede ser simulada en SUMO, y R_i resume la señal de aprendizaje asociada con el desempeño del controlador i .

En la teoría de juegos, el **Equilibrio de Nash** es un concepto de solución que caracteriza la estabilidad frente a desviaciones unilaterales [ACS24]. Una política conjunta $\pi^* = (\pi_1^*, \dots, \pi_n^*)$ constituye un Equilibrio de Nash si ningún agente $i \in \mathcal{N}$ puede incrementar unilateralmente su retorno esperado desviándose de su política π_i^* , asumiendo que los demás agentes mantienen sus políticas fijas en π_{-i}^* :

$$J(\pi_i, \pi_{-i}^*) \leq J(\pi_i^*, \pi_{-i}^*), \quad \forall \pi_i \in \Pi_i, \quad \forall i \in \mathcal{N} \quad (2.21)$$

donde $\pi^* = (\pi_1^*, \dots, \pi_n^*)$ es la combinación de políticas individuales en equilibrio, π_i representa cualquier política alternativa ejecutable por el agente i , Π_i denota el espacio de políticas válidas del agente i , y $\pi_{-i}^* = (\pi_1^*, \dots, \pi_{i-1}^*, \pi_{i+1}^*, \dots, \pi_n^*)$ es el vector de políticas fijas de los demás agentes. En un problema cooperativo de recompensa común, este concepto describe estabilidad, pero no garantiza por sí mismo que la política conjunta maximice el retorno global. Por esa razón, el objetivo operativo de este trabajo se formula como la maximización del retorno conjunto, mientras que el equilibrio de Nash se utiliza como concepto de análisis de convergencia.

En escenarios reales de control distribuido, ningún agente dispone de visibilidad completa del estado global del sistema. Cada participante recopila información únicamente de sus sensores locales. Por consiguiente, los entornos cooperativos multi-agente con observabilidad parcial se formalizan matemáticamente mediante el marco de los Procesos de Decisión de Markov Parcialmente Observables Descentralizados (Dec-POMDP) [ACS24, AOS20].

Un Dec-POMDP para n agentes se define como una tupla:

$$\langle \mathcal{N}, \mathcal{S}, \{\mathcal{A}_i\}_{i=1}^n, P, R, \{\Omega_i\}_{i=1}^n, O, \gamma \rangle \quad (2.22)$$

donde Ω_i denota el conjunto de observaciones individuales del agente i , regidas por la función de observación probabilística $O(o_1, \dots, o_n \mid s', \mathbf{a}) = \Pr\{O_1 = o_1, \dots, O_n = o_n \mid S' = s', \mathbf{A} = \mathbf{a}\}$. En este esquema, cada agente i basa sus decisiones en su observación local $o_i \in \Omega_i$ o en una representación de su historial de observaciones, con el propósito de aprender una política descentralizada $\pi_i(a_i \mid o_i)$ que, al combinarse con las políticas de los demás agentes en la política conjunta $\pi = (\pi_1, \dots, \pi_n)$, maximice el retorno acumulado conjunto del sistema [AOS20].




Figura 2.9: Interacción Agente-Entorno en un esquema MARL cooperativo. Cada semáforo emite una acción local (a_i) formando una acción conjunta ($\mathbf{a}$) que modifica el estado global del entorno de tráfico.

2.3.2 Desafíos Fundamentales en MARL

La aplicación práctica de métodos de aprendizaje por refuerzo en escenarios multi-agente enfrenta obstáculos analíticos y computacionales significativos que no existen en el caso individual

[ACS24]. A medida que aumenta el número de agentes, el espacio de acciones conjunto $\mathcal{A}$ crece de forma exponencial con el número de agentes ($|\mathcal{A}| = \prod_{i=1}^n |\mathcal{A}_i|$), lo que se conoce como la maldición de la dimensionalidad multi-agente. Sin embargo, los desafíos teóricos más severos radican en la dinámica propia de la interacción:

- **No Estacionariedad:** Desde la perspectiva de un agente individual i , las políticas de los demás agentes actúan como parte de la dinámica de transición del entorno. Como todos los agentes aprenden y adaptan sus pesos neuronales de manera concurrente, la función de transición efectiva percibida localmente por el agente i :

$$\mathcal{P}_i(s' | s, a_i) = \sum_{\mathbf{a}_{-i}} P(s' | s, a_i, \mathbf{a}_{-i}) \pi_{-i}(\mathbf{a}_{-i} | s) \quad (2.23)$$

cambia a lo largo del entrenamiento. Aquí $\mathbf{a}_{-i}$ representa las acciones conjuntas del resto de los agentes y π_{-i} sus respectivas políticas. Aunque el sistema global puede continuar describiéndose mediante un juego markoviano, la dinámica percibida por un agente local se vuelve no estacionaria cuando las políticas de los demás agentes cambian y no forman parte de su observación. En consecuencia, las condiciones de convergencia de los algoritmos de agente único dejan de ser suficientes [ACS24, FNF⁺17].

- **Observabilidad Parcial:** Dado el modelo Dec-POMDP inherente, la falta de telemetría global restringe la visión de cada agente a variables locales. Esta información incompleta aumenta la incertidumbre de las estimaciones y dificulta el aprendizaje preciso de las funciones de valor.
- **Asignación de Crédito Multi-Agente (*Credit Assignment*):** En juegos de recompensa común, resulta complejo discernir analíticamente la contribución o el demérito marginal que la acción de un agente aislado produjo sobre el desempeño sistémico global. Una decisión local subóptima podría recibir un refuerzo positivo si el resto del sistema operó de manera sumamente eficiente, sesgando las actualizaciones de la política [ACS24].

2.3.3 Paradigmas de Entrenamiento y Ejecución

Para abordar estas patologías en escenarios Dec-POMDP, la literatura clasifica los algoritmos en función de cómo fluye la información durante el proceso de optimización. Se distinguen fundamentalmente dos enfoques: el Aprendizaje Independiente (*Independent Learning*, IL) y el Entrenamiento Centralizado con Ejecución Descentralizada (*Centralized Training with Decentralized Execution*, CTDE) [ZLYZ23, ACS24].

En el primero, los agentes se entrenan localmente utilizando métodos de agente único, tratando empíricamente al resto de los agentes como parte de la dinámica del entorno. En el segundo, durante el entrenamiento, los algoritmos pueden explotar información global privilegiada (historiales conjuntos o concatenación de observaciones) para guiar y estabilizar la optimización de las funciones de valor. Durante la ejecución, el componente centralizado no participa en la selección de acciones y los actores utilizan únicamente sus observaciones locales. Esta separación entre información disponible durante el entrenamiento y durante la ejecución constituye la característica central de CTDE.

En la implementación empleada, esta separación se concreta mediante un crítico compartido que procesa las observaciones de los agentes durante el entrenamiento, mientras que cada actor conserva su observación local para seleccionar acciones durante la ejecución.

2.3.4 Multi-Agent Deep Reinforcement Learning (MADRL) y Algoritmos Baseline

La integración de los formalismos Dec-POMDP con la capacidad de aproximación generalizada del aprendizaje profundo ha dado origen al campo del *Multi-Agent Deep Reinforcement Learn-*

ing (MADRL) [LWT⁺17, ACS24]. Esta área agrupa los enfoques prevalentes para el control adaptativo de sistemas complejos a gran escala.

En esta investigación, para evaluar rigurosamente el desempeño de las arquitecturas de entrenamiento centralizado (MAPPO y HAPPO), resulta metodológicamente indispensable establecer **líneas de base (baselines) de aprendizaje independiente (IL)**. En los algoritmos independientes, cada coordinador actúa como un agente aislado que ignora la presencia explícita de los demás participantes.

Aprendizaje Independiente (IL): IDQN e IPPO como Algoritmos Baseline

- **Independent DQN (IDQN) como línea de base basada en valor:** Representa una extensión directa de DQN en la que cada agente mantiene su propia función de acción-valor [TMK⁺17]. Como método *off-policy*, puede reutilizar transiciones históricas mediante un *replay buffer*; en MARL, esas transiciones fueron generadas mientras los demás agentes seguían políticas posiblemente distintas. Este desfase puede agravar la no estacionariedad y las dificultades de estabilidad del aprendizaje basado en valor [FNF⁺17]. En la evaluación experimental de este trabajo, IDQN sirve como línea de base independiente para los métodos basados en valor.
- **Independent PPO (IPPO) como línea de base basada en política:** Asigna una instancia de PPO a cada agente. Al utilizar lotes recolectados con las políticas vigentes y descartar la memoria histórica acumulativa, reduce la exposición a transiciones generadas bajo políticas antiguas, aunque no elimina la no estacionariedad causada por el aprendizaje simultáneo [dWGM⁺20]. El recorte de PPO limita cambios excesivos en cada actualización, pero no ofrece una garantía general de convergencia. IPPO constituye la línea de base independiente principal frente a los algoritmos coordinados.




Figura 2.10: Paradigma de Entrenamiento Centralizado y Ejecución Descentralizada (CTDE). Durante el entrenamiento, el crítico utiliza información global privilegiada para estimar valores o ventajas que orientan la actualización de los actores locales; durante la ejecución, los actores solo requieren observaciones locales.

2.3.5 Multi-Agent Proximal Policy Optimization (MAPPO)

Para estudiar cómo una configuración de PPO puede funcionar en tareas cooperativas, Yu et al. [YVV⁺22] evaluaron empíricamente la variante conocida como *Multi-Agent Proximal Policy Optimization* (MAPPO), adaptando PPO al entorno multiagente bajo el paradigma CTDE (véase

la Figura 2.10). Su contribución principal fue sistematizar prácticas de implementación y evaluar su efecto, no proponer desde cero un algoritmo independiente de PPO.

En MAPPO, la estructura distingue entre actores descentralizados y un crítico centralizado:

- **Actores descentralizados** ($\pi_{\theta_i}(a_i | o_i)$): Cada agente i mantiene una política que procesa su observación local o_i y produce una distribución sobre las acciones locales a_i . En entornos homogéneos puede utilizarse compartición de parámetros para mejorar la eficiencia de aprendizaje, pero esta práctica no constituye un requisito conceptual de MAPPO.
- **Crítico centralizado** ($V_\phi(s)$): Durante el entrenamiento, una red de función de valor puede recibir el estado global s del entorno o una representación construida a partir de observaciones conjuntas. El crítico estima el retorno y proporciona valores para calcular ventajas mediante GAE; durante la ejecución no es necesario disponer de este componente [YVV⁺22].

En la formulación práctica de MAPPO, el objetivo del actor se expresa como un promedio de términos PPO individuales. La política conjunta se factoriza en políticas locales, pero la pérdida no debe interpretarse como una única razón de probabilidad conjunta:

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\frac{1}{n} \sum_{i=1}^n \min \left(r_t^i(\theta) \hat{A}_t(s_t, \mathbf{a}_t), \text{clip}(r_t^i(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t(s_t, \mathbf{a}_t) \right) \right] \quad (2.24)$$

donde $r_t^i(\theta) = \frac{\pi_{\theta_i}(a_t^i | o_t^i)}{\pi_{\theta_{i,\text{old}}}(a_t^i | o_t^i)}$ es la razón de probabilidad individual del agente i , n es el número total de agentes, $\hat{A}_t$ es la ventaja utilizada por la implementación y ϵ es el hiperparámetro de recorte. En entornos con recompensa común, esta ventaja puede calcularse utilizando un crítico centralizado; la forma exacta depende de la definición del estado y de la implementación.

Por su parte, el crítico centralizado se actualiza minimizando el error cuadrático medio respecto al retorno objetivo descontado normalizado:

$$\mathcal{L}^{\text{VF}}(\phi) = \hat{\mathbb{E}}_t \left[\left(V_\phi(s_t) - R_t^{\text{target}} \right)^2 \right] \quad (2.25)$$

donde ϕ son los parámetros del crítico centralizado y R_t^{target} representa el retorno empírico objetivo.

Factores Críticos de Diseño y Optimización en MAPPO

A pesar de su simplicidad conceptual, Yu et al. [YVV⁺22] demostraron empíricamente que la efectividad de MAPPO depende fuertemente de varias decisiones de diseño e hiperparámetros:

1. **Normalización del valor:** La normalización de los retornos puede mejorar el ajuste del crítico cuando la escala de las recompensas cambia durante el aprendizaje. Yu et al. analizan esta decisión junto con otras prácticas de implementación; PopArt es una alternativa posible, no una condición necesaria de MAPPO [YVV⁺22, HSE⁺19].
2. **Representación del Estado Global en el Crítico:** Yu et al. [YVV⁺22] evaluaron distintas opciones para estructurar la entrada s del crítico centralizado:
 - Concatenación de Observaciones Locales (*Concatenated Local, CL*): forma el estado uniendo las observaciones locales de todos los agentes $s = (o_1, \dots, o_n)$.
 - Estado Global del Entorno (*Environment Provided, EP*): utiliza un vector de estado global provisto directamente por el simulador.
 - Estado Específico por Agente (*Agent-Specific State, AS*): combina el estado del entorno con la información local del agente i ($AS_i = EP \cup o_i$).

- Filtrado de Características Redundantes (*Feature Pruning, FP*): remueve variables locales duplicadas o de baja varianza en el vector AS_i .

El estudio encuentra que las representaciones específicas por agente y el filtrado de redundancias pueden ser útiles en determinados bancos de prueba. Esta evidencia debe trasladarse al escenario de tránsito mediante evaluación, no como una regla universal.

3. **Reutilización restringida de datos:** En los experimentos de Yu et al., pocas épocas y una o dos particiones del lote resultaron favorables en varios entornos cooperativos. Son recomendaciones empíricas sensibles a la dificultad del problema, no garantías de estabilidad para cualquier red vial.
4. **Rango de recorte y tamaño de lote:** Valores de ϵ inferiores a 0.2 y lotes suficientemente grandes tendieron a favorecer la estabilidad en sus experimentos. La selección final debe justificarse con la búsqueda hiperparamétrica de esta investigación.

Algorithm 3 Algoritmo *Multi-Agent Proximal Policy Optimization* (MAPPO)

- 1: Inicializar los parámetros de la política (actor) θ y del valor (crítico) ϕ
 - 2: Inicializar el búfer de datos $\mathcal{D} \leftarrow \emptyset$
 - 3: **for** iteración = 1, 2, ... **do**
 - 4: Recolectar trayectorias *on-policy* para todos los agentes utilizando la política conjunta π_θ
 - 5: Calcular las ventajas conjuntas $\hat{A}_t(s_t, \mathbf{a}_t)$ mediante GAE a partir del crítico centralizado $V_\phi(s_t)$
 - 6: Calcular los retornos objetivos R_t^{target} normalizados para el crítico
 - 7: Almacenar las transiciones $(s_t, o_t, \mathbf{a}_t, \hat{A}_t, R_t^{\text{target}})$ en $\mathcal{D}$
 - 8: **for** época = 1 hasta K **do**
 - 9: Muestrear minilotes de datos desde $\mathcal{D}$
 - 10: Actualizar la política maximizando el objetivo de recorte PPO por agente:

$$\mathcal{L}^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\frac{1}{n} \sum_{i=1}^n \min \left(r_t^i(\theta) \hat{A}_t, \text{clip}(r_t^i(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$
 - 11: Actualizar el crítico ϕ minimizando el error cuadrático medio del valor:

$$\mathcal{L}^{\text{VF}}(\phi) = \hat{\mathbb{E}}_t \left[\left(V_\phi(s_t) - R_t^{\text{target}} \right)^2 \right]$$
 - 12: **end for**
 - 13: Vaciar el búfer de datos $\mathcal{D} \leftarrow \emptyset$
 - 14: **end for**
-

2.3.6 Heterogeneous-Agent Proximal Policy Optimization (HAPPO)

En sistemas de control complejos, los agentes pueden presentar asimetrías físicas y operacionales: diferencias en la configuración de actuadores, distintos espacios de acciones o demandas regionales contrapuestas. En entornos homogéneos, compartir parámetros puede mejorar la eficiencia de aprendizaje; en entornos heterogéneos, esa práctica puede limitar la especialización. Además, las actualizaciones independientes no poseen una garantía general de convergencia debido al aprendizaje simultáneo no coordinado [KCW⁺22].

Kuba et al. [KCW⁺22] propusieron HATRPO y HAPPO como algoritmos que permiten políticas heterogéneas sin exigir compartición de parámetros ni una descomposición monótona de la función de valor conjunta. Cada agente i puede mantener su propia arquitectura y parámetros θ^i , adaptados a su espacio de acciones local $\mathcal{A}_i$. Los resultados teóricos de mejora monótona y convergencia se refieren al procedimiento de región de confianza bajo supuestos explícitos; la variante práctica HAPPO sustituye la restricción KL por un objetivo recortado y debe interpretarse como una aproximación [KCW⁺22, ZKF⁺24].

Compartición de Parámetros y Políticas Heterogéneas

Una distinción central entre MAPPO y HAPPO radica en la homogeneidad de las políticas y en el orden de actualización:

- **Compartición de parámetros:** En MAPPO se utiliza habitualmente cuando los agentes poseen espacios de observación y acción compatibles. Todos los agentes pueden compartir los mismos pesos $\theta_1 = \dots = \theta_n = \theta$, aunque la formulación de MAPPO también puede implementarse sin esta restricción.
- **Políticas heterogéneas y actualización secuencial:** HAPPO permite que cada agente mantenga una política independiente $\pi_{\theta_i}(a_i \mid o_i)$ y actualiza los actores siguiendo una permutación. El lote de trayectorias de la iteración actual se reutiliza de forma limitada; esto no equivale a un búfer histórico de *experience sharing* como el empleado por algoritmos específicos de compartición de experiencia.

Lema de Descomposición de la Ventaja Multi-Agente

El soporte matemático de HAPPO se fundamenta en el Lema de Descomposición de la Ventaja Multi-Agente propuesto por Kuba et al. [KCW⁺22].

En cualquier juego markoviano cooperativo, para una política conjunta π y una permutación ordenada arbitraria de los agentes $i_{1:n} = (i_1, i_2, \dots, i_n) \in \text{Sym}(n)$, la ventaja de una acción conjunta $\mathbf{a} = (a_{i_1}, \dots, a_{i_n})$ en el estado s se descompone exactamente como la suma de las ventajas marginales de cada agente tomadas secuencialmente, condicionadas por las acciones de los agentes que lo preceden en el ordenamiento:

$$A^\pi(s, \mathbf{a}) = \sum_{m=1}^n A_{i_m}^\pi(s, \mathbf{a}_{i_{1:m-1}}, a_{i_m}) \quad (2.26)$$

donde $A^\pi(s, \mathbf{a})$ representa la ventaja conjunta global, y la ventaja marginal del agente i_m se define formalmente como:

$$A_{i_m}^\pi(s, \mathbf{a}_{i_{1:m-1}}, a_{i_m}) \doteq Q_{i_{1:m}}^\pi(s, \mathbf{a}_{i_{1:m-1}}, a_{i_m}) - Q_{i_{1:m-1}}^\pi(s, \mathbf{a}_{i_{1:m-1}}) \quad (2.27)$$

donde $Q_{i_{1:m}}^\pi(s, \mathbf{a}_{i_{1:m-1}}, a_{i_m})$ representa el valor esperado de la acción conjunta considerando las acciones fijadas por los primeros m agentes en la secuencia, y $Q_{i_{1:m-1}}^\pi(s, \mathbf{a}_{i_{1:m-1}})$ es el valor marginalizado sobre los agentes restantes.

En esta formulación, las acciones de los agentes que aún no han actualizado su política en la secuencia ($\mathbf{a}_{i_{m+1:n}}$) se marginalizan por esperanza matemática bajo la política conjunta vigente. La gran relevancia teórica de este lema es que se cumple para cualquier juego cooperativo de recompensa común sin requerir ningún supuesto de aditividad o monotonía sobre la función de valor, a diferencia de los esquemas de descomposición de valor como VDN [SLG⁺18] o QMIX [RSDW⁺18].

Esquema de Actualización Secuencial y Factor de Razón Compuesto M

Para explotar la descomposición de la ventaja sin incurrir en la inestabilidad del entrenamiento simultáneo, HAPPO actualiza las políticas de los agentes de manera secuencial dentro de cada iteración de optimización k .

En cada iteración de entrenamiento k , se genera una permutación de agentes $i_{1:n} \in \text{Sym}(n)$. En el análisis teórico, asignar probabilidad no nula a los órdenes posibles es una condición que interviene en el resultado asintótico de convergencia; en una implementación finita, la aleatorización del orden reduce sesgos de prioridad, pero no constituye por sí sola una garantía [KCW⁺22, WZK⁺23].

Cuando le corresponde el turno de optimización al agente i_m , los agentes anteriores en la secuencia ($i_{1:m-1}$) ya han actualizado sus parámetros a $\theta_{k+1}^{i_j}$, mientras que los agentes posteriores ($i_{m+1:n}$) conservan sus parámetros originales $\theta_k^{i_j}$. Para guiar la actualización del agente i_m respetando la modificación sufrida por la distribución conjunta debido a los agentes precedentes, Kuba et al. [KCW⁺22] demostraron que no es necesario entrenar un crítico separado por cada subgrupo, sino que la ventaja marginal ajustada se puede calcular multiplicando la ventaja conjunta $A^{\pi_k}(s, \mathbf{a})$ por la productoria de los ratios de probabilidad de los agentes que ya se actualizaron.

Se define así la ventaja conjunta ponderada por los ratios de los agentes ya actualizados:

$$M_{i_{1:m}}(s, \mathbf{a}) \doteq \left(\prod_{j=1}^{m-1} \frac{\pi_{\theta_{k+1}^{i_j}}^{i_j}(a^{i_j} | o^{i_j})}{\pi_{\theta_k^{i_j}}^{i_j}(a^{i_j} | o^{i_j})} \right) A^{\pi_k}(s, \mathbf{a}) \quad (2.28)$$

Donde $\pi_{\theta_{k+1}^{i_j}}^{i_j}$ es la política recién optimizada del agente precedido i_j , $\pi_{\theta_k^{i_j}}^{i_j}$ es su política previa, y $A^{\pi_k}(s, \mathbf{a})$ es la ventaja conjunta. Para el primer agente de la secuencia ($m = 1$), la productoria es vacía y se define como $M_{i_1}(s, \mathbf{a}) \equiv A^{\pi_k}(s, \mathbf{a})$. Por tanto, M no es únicamente un cociente de probabilidades: es una señal de ventaja reponderada.

El factor $M_{i_{1:m}}(s, \mathbf{a})$ actúa como un modificador de importancia que ajusta la señal de ventaja para el agente i_m , absorbiendo analíticamente el desfase en la distribución de la acción conjunta provocado por las actualizaciones precedentes sin necesidad de realizar nuevas simulaciones en el entorno.

De este modo, para optimizar la política del agente i_m , HAPPO maximiza el objetivo sustituto recortado de PPO ponderado por la razón compuesta $M_{i_{1:m}}$:

$$L^{\text{HAPPO}}(\theta^{i_m}) = \mathbb{E}_t \left[\min \left(r_t^{i_m}(\theta^{i_m}) M_{i_{1:m}}(s_t, \mathbf{a}_t), \text{clip} \left(r_t^{i_m}(\theta^{i_m}), 1 - \epsilon, 1 + \epsilon \right) M_{i_{1:m}}(s_t, \mathbf{a}_t) \right) \right] \quad (2.29)$$

donde $r_t^{i_m}(\theta^{i_m}) = \frac{\pi_{\theta^{i_m}}^{i_m}(a_t^{i_m} | o_t^{i_m})}{\pi_{\theta_k^{i_m}}^{i_m}(a_t^{i_m} | o_t^{i_m})}$ representa la razón de probabilidad individual del agente i_m .

Una vez realizada la actualización de descenso de gradiente sobre θ^{i_m} , es indispensable recalculan la razón de probabilidad post-optimización $\rho_{\text{post}}^{i_m} = \frac{\pi_{\theta_{k+1}^{i_m}}^{i_m}(a_t^{i_m} | o_t^{i_m})}{\pi_{\theta_k^{i_m}}^{i_m}(a_t^{i_m} | o_t^{i_m})}$ y actualizar recursivamente el factor M para los agentes restantes:

$$M_{i_{1:m+1}}(s_t, \mathbf{a}_t) \leftarrow \rho_{\text{post}}^{i_m} \cdot M_{i_{1:m}}(s_t, \mathbf{a}_t) \quad (2.30)$$

Garantía de Mejora Monótona

El trabajo de Kuba et al. demuestra una propiedad de mejora monótona para un procedimiento de iteración de políticas multiagente con restricciones de región de confianza y bajo supuestos explícitos [KCW⁺22]. La variante práctica HAPPO reemplaza la restricción KL por un objetivo recortado, por lo que esta garantía no se transfiere automáticamente a cada actualización de una implementación neuronal:

En el procedimiento teórico, la actualización secuencial satisface:

$$J(\pi_{k+1}) \geq J(\pi_k) \quad (2.31)$$

donde $J(\pi_k)$ representa el rendimiento esperado de la política conjunta en el paso k . El resultado depende de las hipótesis del procedimiento analítico y no significa que HAPPO-clip elimine las oscilaciones ni que una ejecución finita con redes neuronales converja necesariamente a un equilibrio de Nash. En esta investigación, HAPPO se evalúa como una estrategia que busca mejorar la coordinación y la estabilidad frente a actualizaciones independientes.




Figura 2.11: Esquema de actualización secuencial de HAPPO. A diferencia de PPO Independiente, la actualización de cada agente está matemáticamente condicionada por el cociente de probabilidad compuesto M_{i_m} , que propaga los cambios efectuados por los agentes que lo precedieron en la secuencia.

Algorithm 4 Algoritmo *Heterogeneous-Agent Proximal Policy Optimization* (HAPPO)

- 1: Inicializar los parámetros de las políticas individuales $\{\theta^i, \forall i \in \mathcal{N}\}$ y del crítico centralizado $V_\phi(s)$
 - 2: **for** iteración = 1, 2, ... **do**
 - 3: Recolectar un conjunto de trayectorias $\mathcal{D}$ utilizando la política conjunta π_θ
 - 4: Calcular el estimador de ventaja conjunta $\hat{A}(s, \mathbf{a})$ con GAE a partir del crítico $V_\phi(s)$
 - 5: Sorteo aleatorio de una permutación de los agentes $i_{1:n} \in \text{Sym}(n)$
 - 6: Inicializar los factores $M_{i_m}(s, \mathbf{a}) \leftarrow \hat{A}(s, \mathbf{a})$ para todo $m \in \{1, \dots, n\}$
 - 7: **for** $m = 1 \dots n$ **do**
 - 8: Obtener el agente actual i_m y su factor modificador $M_{i_m}(s, \mathbf{a})$
 - 9: Actualizar θ^{i_m} a $\theta_{k+1}^{i_m}$ maximizando la pérdida recortada HAPPO:

$$L^{\text{HAPPO}}(\theta^{i_m}) = \hat{\mathbb{E}}_t \left[\min \left(r_t^{i_m}(\theta^{i_m}) M_{i_m}(s_t, \mathbf{a}_t), \text{clip} \left(r_t^{i_m}(\theta^{i_m}), 1 - \epsilon, 1 + \epsilon \right) M_{i_m}(s_t, \mathbf{a}_t) \right) \right]$$
 - 10: Recalcular la razón post-optimización: $\rho_{\text{post}}^{i_m} \leftarrow \frac{\pi_{\theta_{k+1}^{i_m}}(a_t^{i_m} | o_t^{i_m})}{\pi_{\theta_k^{i_m}}(a_t^{i_m} | o_t^{i_m})}$
 - 11: **for** $j = m + 1 \dots n$ **do**
 - 12: Actualizar el factor modificador para agentes subsecuentes:

$$M_{i_j}(s_t, \mathbf{a}_t) \leftarrow \rho_{\text{post}}^{i_m} \cdot M_{i_j}(s_t, \mathbf{a}_t)$$
 - 13: **end for**
 - 14: **end for**
 - 15: Actualizar el crítico centralizado ϕ mediante descenso de gradiente:

$$\mathcal{L}^{\text{VF}}(\phi) = \hat{\mathbb{E}}_t \left[\left(V_\phi(s_t) - R_t^{\text{target}} \right)^2 \right]$$
 - 16: **end for**
-

Para finalizar el estudio comparativo de los algoritmos basados en Optimización de Política Próxima en escenarios MARL, la Tabla 2.3 sintetiza sus principales propiedades operativas, arquitectónicas y teóricas.

Cuadro 2.3: Comparación sintética de familias algorítmicas PPO en entornos multi-agente cooperativos.

Eje de análisis	PPO de agente único	IPPO independiente	MAPPO / CTDE	HAPPO / HARL
Paradigma	Agente Único	IL (Descentralizado)	CTDE (Centralizado/Desc.)	CTDE / HARL
Actores	Único $\pi_\theta(a s)$	n políticas locales	Actores locales; puede compartir parámetros	n políticas heterogéneas
Arquitectura del Crítico	Único $V_\phi(s)$	n Críticos locales $V_{\phi_i}(o_i)$	Un Crítico Centralizado $V_\phi(s)$	Un Crítico Centralizado $V_\phi(s)$
Optimización	PPO estándar	PPO local simultáneo	PPO local con crítico global	Actualización secuencial $i_{1:n}$
Señal de Ventaja	Ventaja local $\hat{A}(s, a)$	Ventaja local $\hat{A}_i(o_i, a_i)$	Ventaja conjunta $\hat{A}(s, \mathbf{a})$	Factor compuesto $M_{i_{1:m}}(s, \mathbf{a})$
Mejora monótona	No estricta para PPO	Sin garantía general	Sin garantía estricta	Teórica bajo supuestos; HAPPO-clip es aproximado
Tipo de agente	No aplica	Depende de la implementación	Compatible; compartir parámetros es opcional	Diseñada para agentes heterogéneos

La correspondencia anterior permite interpretar IPPO como una referencia de aprendizaje independiente y MAPPO y HAPPO como arquitecturas que incorporan información conjunta durante el entrenamiento. El capítulo siguiente especifica cómo se instancian las observaciones, las acciones y las señales de recompensa en el entorno utilizado para la evaluación experimental.

Metodología y Diseño Experimental

En este capítulo se detalla el marco metodológico de la investigación, la operacionalización de las variables, el diseño de los escenarios de simulación, la arquitectura de los componentes computacionales y los protocolos experimentales adoptados para evaluar las hipótesis planteadas. El estudio se encuadra dentro de un enfoque ****cuantitativo, aplicado y experimental puro****, donde la simulación microscópica de tránsito actúa como el laboratorio controlado para evaluar la capacidad de aprendizaje, coordinación y robustez de las distintas arquitecturas de Aprendizaje por Refuerzo Multi-Agente (MARL).

3.1 Enfoque y Diseño de Investigación

De acuerdo con la tipología metodológica de investigación en ciencias computacionales [ACS24], este trabajo adopta un ****diseño experimental cuantitativo de medidas repetidas****. Se manipulan sistemáticamente variables independientes (familias algorítmicas, grado de cooperación espacial y escenarios de demanda vial) en entornos computacionales controlados para medir sus efectos sobre variables dependientes primarias (demora acumulada W_{net} , tasa de completitud CR y emisiones contaminantes de CO_2).

La utilización de la simulación microscópica (mediante el simulador SUMO) como plataforma experimental primaria responde a tres razones científicas:

1. **Seguridad y Viabilidad Operacional:** Probar algoritmos estocásticos de control semafórico en tiempo real sobre una red urbana real implica un riesgo inaceptable para la seguridad vial y la fluidez del tránsito.
2. **Aislamiento de Variables Extrañas:** La simulación permite neutralizar perturbaciones estocásticas no controladas (condiciones meteorológicas, incidentes viales o fluctuaciones aleatorias fuera de modelo), garantizando la validez interna del estudio.
3. **Replicabilidad Exacta:** Permite someter a todas las familias de control (algoritmos independientes, coordinados y de tiempo fijo) exactamente a la misma secuencia determinista de demanda mediante la fijación rigurosa de semillas aleatorias.

La Figura 3.1 ilustra la secuencia metodológica estructurada en siete fases interconectadas que rige esta investigación.




Figura 3.1: Flujo metodológico secuencial de la investigación experimental.

3.2 Especificación del Stack Tecnológico

Para garantizar la reproducibilidad científica, la Tabla 3.1 detalla el ecosistema de software y hardware sobre el cual se desarrolló y ejecutó el marco computacional *mar1TLC*.

Cuadro 3.1: Especificación del stack tecnológico utilizado en la investigación.

Componente	Herramienta / Versión	Función Metodológica
Lenguaje de Programación	Python 3.12	Núcleo del sistema y orquestación.
Simulador de Tránsito	SUMO 1.20+ / TraCI	Simulación microscópica y telemetría de red.
Binding de Simulación	libsumo (C++)	Ejecución de simulación de alta velocidad en memoria.
Framework MARL	Ray RLLib 2.x	Abstracción de entornos multi-agente y algoritmos CTDE.
Aprendizaje Profundo	PyTorch 2.x	Arquitectura de redes neuronales (Actor-Crítico MLP).
Optimización Automática	Optuna 3.x	Muestreo Bayesiano TPE y poda asíncrona ASHA.
Infraestructura HPC	Clusters Toko y Mendieta	Cómputo distribuido multinúcleo gestionado vía SLURM.

3.3 Diseño de Escenarios de Tránsito en SUMO

La evaluación de los algoritmos se realiza sobre cuatro escenarios de red en SUMO, construidos mediante la herramienta gráfica `netedit` y scripts en Python, cubriendo un espectro representativo de complejidades topológicas y dinámicas de flujo.

3.3.1 Escenarios Sintéticos: 3×1 , 3×3 y $4 \times 4_H$

Todas las redes sintéticas comparten reglas operacionales estandarizadas:

- **Límite de Velocidad:** 13.89 m/s (50 km/h) en todas las arterias urbanas.
- **Mezcla Vehicular Heterogénea:** Calibrada para representar un parque automotor urbano realista mediante tres clases de vehículos en el archivo `urban_vehicle_mix.add.xml`:
 1. **SLOWVEHTYPE** (25%): Conductores cautelosos o vehículos pesados ($a = 1.9 \text{ m/s}^2$, $b = 4.0 \text{ m/s}^2$, $v_{\max} = 30 \text{ km/h}$).
 2. **MEDVEHTYPE** (60%): Vehículo de pasajeros promedio ($a = 2.6 \text{ m/s}^2$, $b = 4.5 \text{ m/s}^2$, $v_{\max} = 50 \text{ km/h}$).
 3. **FASTVEHTYPE** (15%): Conductores agresivos ($a = 3.1 \text{ m/s}^2$, $b = 5.0 \text{ m/s}^2$, $v_{\max} = 70 \text{ km/h}$ acotado a 50 km/h por el límite del carril).

Las tres topologías sintéticas cumplen funciones analíticas complementarias:

- **Corredor Arterial 3×1 :** Tres nodos dispuestas en línea recta con flujo bidireccional dominante (3.260 veh/h). Permite evaluar la capacidad de los agentes para sincronizar olas verdes sin interferencia de lazos cerrados.
- **Malla Simétrica 3×3 :** Nueve intersecciones organizadas en cuadrícula cerrada (7.087 veh/h). Al contener lazos de dependencia circular, constituye el escenario crítico para evaluar la resiliencia de los algoritmos frente al colapso por desbordamiento de cola (*gridlock*).
- **Cuadrícula Heterogénea $4 \times 4_H$:** Dieciséis intersecciones asimétricas (7.202 veh/h) con arterias principales de mayor capacidad que actúan como vías de escape para drenar la congestión.

3.3.2 Escenario Urbano Real: Gran Mendoza (Corredor Vicente Zapata)

Para evaluar la transferibilidad de las políticas entrenadas hacia un entorno urbano real, se construyó el escenario del Gran Mendoza a partir de datos geoespaciales de OpenStreetMap y calibración física.

- **Procesamiento Topológico:** La geometría de la red fue procesada mediante la herramienta `netconvert` y parches PlainXML (`.con.xml`) para preservar la conectividad de giros y prohibiciones de maniobra observadas en terreno.
- **Calibración de Flujos Empíricos:** Se utilizaron los datos de aforo vehicular continuo registrados por la Cámara 169 en el corredor Vicente Zapata.
- **Matriz Origen-Destino Híbrida:** La demanda vehicular combina un componente fijo espacialmente explícito (60% de la demanda distribuida en 476 pares OD calibrados) con un remanente estocástico (40% restante) generado por `randomRoutesTaz` con la semilla congelada 104773.
- **Calibración Dinámica:** El escenario simula un horizonte operacional continuo de 12 horas (06 : 00–18 : 00), alcanzando un estadístico de calidad de flujo $GEH < 5$ en más del 85% de las mediciones de volumen en los enlaces comparables.

—

3.4 Arquitectura de Integración Entorno-Agentes

El marco computacional `mar1TLC` integra el simulador SUMO con la librería Ray RLlib a través de la interfaz `SumoRllibEnv`.

3.4.1 Ciclo Episódico e Interfaz de Simulación

Para acelerar la recolección de experiencias, las simulaciones se ejecutan mediante la abstracción C++ `libsumo` (configurada mediante la variable de entorno `LIBSUMO_AS_TRACI=1`).

Cada episodio inyecta un período de **calentamiento físico** (*warmup*) de **600 segundos** bajo control semafórico de tiempo fijo. Al finalizar el *warmup*, el estado microscópico completo de la simulación se congela en memoria. Los llamados a la función `reset()` restauran directamente dicho punto de control (*checkpoint*), garantizando que el entrenamiento de los agentes MARL inicie siempre en un régimen de tránsito saturado realista.

Las decisiones se ejecutan en pasos discretos de $\Delta t = 5.0$ s. Si un agente decide cambiar la fase activa, el entorno intercala automáticamente la secuencia de seguridad física obligatoria:

$$t_{\text{transición}} = t_{\text{amarillo}}(3 \text{ s}) + t_{\text{rojo_todo}}(2 \text{ s}) \quad (3.1)$$

—

3.5 Instanciación del Modelo Dec-POMDP

La interacción distribuida entre las intersecciones semaforizadas se formaliza mediante la tupla Dec-POMDP instanciada en la librería `mar1TLC`.

3.5.1 Espacio de Observaciones y Codificación Logarítmica

La observación $o_i^{(t)}$ de la intersección i en el paso t combina la longitud de cola por carril entrante (q_t), la velocidad media (v_t), el estado de la fase activa y el tiempo de espera acumulado cuantizado (w_t).

Para evitar que valores extremos de tiempo de espera distorsionen la escala del vector de entrada en las redes neuronales, se aplica la clase `Encoder` (`src/marlTLC/utils/encoder.py`).

En esta formulación:

- **Número de Intervalos (I):** Corresponde al hiperparámetro `encoder_intervals`, el cual define la resolución del espacio discreto de observación y es optimizado automáticamente mediante exploración Bayesiana en Optuna.
- **Cota de Saturación del Carril (M):** Corresponde al parámetro `max_lane_value`, el cual se determina empíricamente antes del entrenamiento mediante el script de calibración `scripts/calibrate_encoder_m.py`. El procedimiento ejecuta simulaciones preliminares del escenario objetivo y calcula el percentil 99 de los tiempos de espera acumulados observados en todos los carriles controlados. Los valores calibrados consolidados (almacenados en `.encoder_M.json`) son $M = 1184$ s para el escenario 3×1 , $M = 1136$ s para 3×3 , $M = 712$ s para $4 \times 4_H$ y $M = 1494$ s para Gran Mendoza.

La función cuantiza la variable continua x mediante la regla logarítmica:

$$e(x) = \text{ceil} \left(F \cdot \log_2 \left(\frac{x}{M \cdot L} + 1 \right) + L^2 \cdot x \right) \quad (3.2)$$

donde $L = \frac{I-1}{M}$ y $F = (1-L) \frac{I-1}{\log_2(1/L+1)}$, mapeando el valor continuo x al rango discreto $[0, I-1]$.

3.5.2 Espacio de Acciones y Enmascaramiento Dinámico

El espacio de acciones $\mathcal{A}_i = \{0, 1, \dots, K_i - 1\}$ representa el conjunto de fases verdes seleccionables por la intersección i . En cruces con geometrías asimétricas, la capa `ActionMaskingTorchRLModule` aplica un enmascaramiento sobre los *logits* $z_i(a)$ emitida por el actor:

$$\text{logit}_i(a) = \begin{cases} z_i(a) & \text{si la fase } a \text{ es geométricamente válida} \\ -10^9 & \text{si la fase } a \text{ es inválida} \end{cases} \quad (3.3)$$

3.5.3 Función de Recompensa Compuesta y Coordinación Vecinal

La función de recompensa implementada en este trabajo resuelve el compromiso entre el rendimiento local y la cooperación distribuida sin recurrir a términos heurísticos adicionales.

1. **Recompensa Local Diferencial Normalizada (L_i):** Mide la variación en el tiempo de espera acumulado por vehículo entre pasos temporales consecutivos:

$$L_i^{(t)} = \frac{W_{\text{acc},i}(t-1) - W_{\text{acc},i}(t)}{\max(N_{\text{veh},i}(t), 1)} \quad (3.4)$$

2. **Recompensa Compartida Vecinal (N_i):** Corresponde al promedio de las recompensas locales obtenidas por los nodos pertenecientes al vecindario topológico directo $N(i)$:

$$N_i^{(t)} = \frac{1}{|N(i)|} \sum_{j \in N(i)} L_j^{(t)} \quad (3.5)$$

3. **Mezcla Convexa λ -mix (NeighborMixReward)**: Combina ambas señales mediante el parámetro de cooperación $\lambda \in [0, 1]$:

$$R_i^{(t)} = (1 - \lambda)L_i^{(t)} + \lambda N_i^{(t)} \quad (3.6)$$

donde $\lambda = \frac{w}{1+w}$, siendo $w \geq 0$ el peso de ponderación vecinal.

3.6 Implementación Algorítmica e Hiperparámetros

Los algoritmos de aprendizaje independiente (IDQN e IPPO) y de entrenamiento centralizado (MAPPO y HAPPO) se implementaron en PyTorch e integraron en la API de Ray RLlib mediante el módulo `algo_factory.py`. La Tabla 3.2 resume la parametrización utilizada.

Cuadro 3.2: Especificación de hiperparámetros algorítmicos finales.

Hiperparámetro	Valor Seleccionado	Ámbito de Aplicación
Arquitectura Neuronal	MLP [256, 256]	Redes de Actor y Crítico.
Tasa de Aprendizaje (α)	3×10^{-4}	Optimizador Adam.
Factor de Descuento (γ)	0.99	Retorno descontado episódico.
Parámetro GAE (λ_{GAE})	0.95	Estimación de ventaja (PPO/MAPPO/HAPPO).
Rango de Recorte PPO (ϵ)	0.19	Pérdida recortada L^{CLIP} .
Tamaño de Lote de Entrenamiento	4000 muestras	Buffer por iteración.
Tamaño de Minilote	128 muestras	Subdivisión para gradiente.
Épocas por Iteración (K)	10	Reutilización de datos <i>on-policy</i> .

3.7 Diseño de Experimentos de Búsqueda Hiperparamétrica

La exploración de hiperparámetros se ejecutó en dos fases utilizando la integración entre Optuna, Ray Tune y el algoritmo de poda ASHA:

1. **Fase 1 (Exploración Bayesiana)**: Búsqueda amplia con muestreo TPE sobre 40 configuraciones por escenario.
2. **Fase 2 (Refinamiento Bayesiano)**: Expansión de los rangos de búsqueda tras detectar censura de frontera en el peso de mezcla vecinal ($w \in [1.0, 5.0]$).

Para evitar políticas inestables, la función objetivo optimiza el **Retorno Robusto al Riesgo** (inspirado en CVaR):

$$\text{Robust_Return} = \mathbb{E}[\mathcal{R}] - 0.5 \cdot (\mathbb{E}[\mathcal{R}] - \min(\mathcal{R})) \quad (3.7)$$

3.7.1 Infraestructura Computacional de Alto Rendimiento y Orquestación Distribuida

Dada la elevada dimensionalidad del espacio de búsqueda y el costo computacional intrínseco de la simulación microscópica a paso fino en SUMO, la exploración hiperparamétrica y el entrenamiento final de los agentes MARL requirieron el despliegue de una infraestructura de cómputo de alto rendimiento (HPC).

Las simulaciones se ejecutaron en los clusters de supercómputo **Toko** y **Mendieta** del Centro de Cómputo de Alto Rendimiento. La orquestación y asignación de recursos fue gestionada mediante el sistema de colas de trabajos SLURM (*Simple Linux Utility for Resource Management*), coordinando la ejecución paralela de múltiples instancias de simulación mediante los siguientes mecanismos:

- **Asignación Dinámica de Recursos:** Cada trabajo de simulación se dimensionó asignando núcleos de procesamiento (CPU) e intervalos de memoria RAM dedicados, optimizando la ejecución de múltiples procesos concurrentes de TraCI/`libsumo` y *workers* de Ray RLlib.
- **Gestión Eficiente de Entrada/Salida (I/O):** La simulación continua de redes viales genera un volumen crítico de eventos temporales por segundo. Para evitar cuellos de botella en el ancho de banda del sistema de archivos distribuido compartido en red (NFS), las simulaciones y la recolección de trayectorias se ejecutaron en las unidades de almacenamiento volátil local de alta velocidad de cada nodo de cómputo. Al finalizar cada prueba episódica, un proceso de sincronización transfiere únicamente las métricas agregadas y los puntos de control (*checkpoints*) consolidados.
- **Escalabilidad de la Exploración:** Esta arquitectura permitió procesar cientos de miles de iteraciones de entrenamiento y evaluar de forma automatizada las distintas fases de exploración Bayesiana (Optuna TPE) y la evaluación final en semillas no vistas.

—

3.8 Diseño de Experimentos de Evaluación de Rendimiento

El protocolo de evaluación final de los modelos se rigió por las siguientes condiciones:

1. **Semillas No Vistas (OOD):** Evaluación sobre $N = 20$ semillas aleatorias independientes disjuntas del proceso de entrenamiento (101, 137, 179, ..., 563), habiéndose excluido la semilla 42 por uso previo en pruebas piloto.
2. **Pruebas de Hipótesis:** Comparación de distribuciones de demora W_{net} mediante la prueba no paramétrica de Wilcoxon y cuantificación del tamaño del efecto mediante $\hat{A}_{12}$ de Vargha-Delaney.
3. **Guardias de Validación (*Fail-Closed Guards*):** Descarte automático de políticas candidatas que presenten una degradación de throughput superior al 5%, un incremento en teletransportes o una regresión de equidad (*fairness*) mayor al 10% respecto al control de tiempo fijo.

Análisis y discusión de resultados

En este capítulo se presentan y analizan los resultados obtenidos de las ejecuciones de entrenamiento de los algoritmos de estudio mencionados. Con el objetivo de distinguir con claridad las etapas metodológicas del entrenamiento de los agentes, la sección se organiza en tres partes.

En primer lugar, se reportan los resultados del proceso de ajuste de hiperparámetros. En segundo lugar, se evalúan los modelos finales seleccionados en los escenarios planteados, desde redes sintéticas hasta el escenario ubicado en Ciudad de Mendoza. Finalmente, se desarrolla una discusión integradora de los hallazgos, sus implicancias y las principales limitaciones del estudio.

4.1 Resultados del ajuste de hiperparámetros

En esta sección se resume el proceso de ajuste de hiperparámetros y se justifica la configuración utilizada en la evaluación posterior de los modelos.

4.1.1 Diseño del proceso de ajuste

4.1.2 Resultados del ajuste y análisis de sensibilidad

4.1.3 Configuración seleccionada para la evaluación final

4.2 Resultados de los modelos finales

Esta sección reúne los resultados obtenidos con los modelos finales una vez fijada la configuración experimental. La exposición se organiza según el tipo de escenario analizado.

4.2.1 Criterios de evaluación y métricas de comparación

4.2.2 Desempeño en escenarios sintéticos (3×1 , 3×3 , 4×4 heterogéneo)

4.2.3 Desempeño en la red de carreteras de la Ciudad de Mendoza

4.3 Discusión e interpretación de resultados

En esta sección se integran los resultados presentados y se discuten sus principales implicancias en relación con los objetivos del trabajo.

Conclusiones

Por último las conclusiones.

Bibliografía

- [ACS24] Albrecht, Stefano V., Filippas Christianos y Lukas Schäfer: *Multi-Agent Reinforcement Learning: Foundations and Modern Approaches*. MIT Press, 2024. <https://www.mar1-book.com/>, Consultado en 2025.
- [ALBBW⁺18] Alvarez Lopez, Pablo, Michael Behrisch, Laura Bieker-Walz, Jakob Erdmann, Yun Pang Flötteröd, Robert Hilbrich, Leonhard Lücken, Johannes Rummel, Peter Wagner y Evamarie Wießner: *Microscopic Traffic Simulation using SUMO*. En *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, páginas 2575–2582. IEEE, 2018.
- [AOS20] Amato, Christopher, Frans A. Oliehoek y Matthijs T.J. Spaan: *A Survey of Decentralized Partially Observable Markov Decision Processes and Applications*. Journal of Artificial Intelligence Research, 69:1–72, 2020.
- [APK03] Abdulhai, Baher, Rob Pringle y Grigoris J Karakoulas: *Reinforcement learning for true adaptive traffic signal control*. Journal of Transportation Engineering, 129(3):278–285, 2003.
- [AS22] Ault, James y Guni Sharon: *Cooperative Multi-agent Reinforcement Learning Applied to Multi-intersection Traffic Signal Control*. En *Proceedings of the 31st ACM International Conference on Information & Knowledge Management (CIKM '22)*, 2022. <https://people.engr.tamu.edu/guni/papers/CIKM22-MATCS.pdf>, Fuente: [7, 8] Destaca el "éxito limitado" de SARL y los enfoques independientes en redes.
- [CWCL19] Chu, Tianshu, Jie Wang, Lara Codecà y Zhaojian Li: *Multi-agent deep reinforcement learning for large-scale traffic signal control*. IEEE Transactions on Intelligent Transportation Systems, 21(3):1086–1095, 2019.
- [CyMR18] Mayor R., Rafael Cal y: *Ingeniería de tránsito: Fundamentos y aplicaciones*. Alfaomega, 9na edición, 2018.
- [DLR25] DLR – Institute of Transportation Systems: *SUMO User Documentation*, 2025. <https://sumo.dlr.de/docs/>, Consultado en 2025.
- [dWGM⁺20] Witt, Christian Schroeder de, Tarun Gupta, Denys Makoviichuk, Viktor Maksimov, Edward Ivanov, Michael Schmid, Gregory Yakovlev, Philip Torr y cols.: *Is independent learning all you need in the starcraft multi-agent challenge?* arXiv preprint arXiv:2011.09533, 2020.
- [ETAA13] El-Tantawy, Samah, Baher Abdulhai y Hossam Abdulbaqi: *Multiagent reinforcement learning for integrated network of adaptive traffic signal controllers (MARLIN-ATSC): methodology and large-scale application on downtown Toronto*. IEEE Transactions on Intelligent Transportation Systems, 14(3):1140–1150, 2013.
- [FA11] Fernández A., Rodrigo: *Elementos de la teoría del tráfico vehicular*. Fondo Editorial de la Pontificia Universidad Católica del Perú, 2011.
- [Fed08] Federal Highway Administration: *Traffic Signal Timing Manual*. Informe técnico FHWA-HOP-08-024, Federal Highway Administration, Office of Operations, 2008. Capítulo 4: Traffic Signal Design. Disponible en: <https://ops.fhwa.dot.gov/publications/fhwahop08024/chapter4.htm>.

- [FH21] Feriani, Amal y Ekram Hossain: *Multi-Agent Reinforcement Learning: Key Differences from Single-Agent RL*. arXiv preprint arXiv:2508.07001, 2021. Fuente: [9] Define la no estacionariedad como una diferencia clave de MARL vs SARL.
- [FNF⁺17] Foerster, Jakob, Nantas Nardelli, Gregory Farquhar, Philip H.S. Torr, Pushmeet Kohli y Shimon Whiteson: *Stabilising Experience Replay for Deep Multi-Agent Reinforcement Learning*. En *Proceedings of the 34th International Conference on Machine Learning (ICML)*, páginas 1146–1155. PMLR, 2017.
- [HSE⁺19] Hessel, Matteo, Hubert Soyer, Lasse Espeholt, Joseph Modayil, Hado van Hasselt, Tom Schaul, Georg Ostrovski, Will Dabney, Dan Horgan, John Young, Csaba Szepesvári y David Silver: *Multi-task deep reinforcement learning with PopArt*. En *Proceedings of the AAAI Conference on Artificial Intelligence*, volumen 33, páginas 3794–3801, 2019.
- [KCW⁺22] Kuba, Jakub Grudzien, Ruiqing Chen, Muning Wen, Ying Wen, Fuchun Sun, Jun Wang y Yaodong Yang: *Trust region policy optimisation in multi-agent reinforcement learning*. En *International Conference on Learning Representations (ICLR)*, 2022. <https://arxiv.org/abs/2109.11251>.
- [KL02] Kakade, Sham y John Langford: *Approximately optimal reinforcement learning*. En *International Conference on Machine Learning (ICML)*, páginas 267–274, 2002.
- [LLW16] Li, Li, Yisheng Lv y Fei Yue Wang: *Traffic signal timing via deep reinforcement learning*. IEEE/CAA Journal of Automatica Sinica, 3(3):247–254, 2016.
- [LWT⁺17] Lowe, Ryan, Yi Wu, Aviv Tamar, Jean Harb, Pieter Abbeel y Igor Mordatch: *Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments*. En *Advances in Neural Information Processing Systems (NeurIPS)*, páginas 6379–6390, 2017.
- [MKS⁺15] Mnih, V., K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg y D. Hassabis: *Human-level control through deep reinforcement learning*. Nature, 518(7540):529–533, 2015. <https://doi.org/10.1038/nature14236>.
- [ne18] especificados, Autores no: *Traffic congestion cost Americans over \$160 billion in lost productivity*. Citado en arXiv:2406.13693 (Reporte original de UN 2018), 2018. Fuente: [1] Costos de congestión y emisiones de CO2.
- [PW16] Pande, Anurag y Brian Wolshon: *Traffic Engineering Handbook*. John Wiley & Sons, Inc., 7th edición, 2016.
- [RSDW⁺18] Rashid, Tabish, Mikayel Samvelyan, Christian Schroeder De Witt, Gregory Farquhar, Jakob Foerster y Shimon Whiteson: *QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning*. En *Proceedings of the 35th International Conference on Machine Learning (ICML)*, páginas 4295–4304. PMLR, 2018.
- [SB18] Sutton, R.S. y A.G. Barto: *Reinforcement learning: An introduction*. The MIT Press, Cambridge, MA, 2nd edición, 2018.
- [Sha53] Shapley, Lloyd S: *Stochastic games*. Proceedings of the National Academy of Sciences, 39(10):1095–1100, 1953.

- [SLA⁺15] Schulman, John, Sergey Levine, Pieter Abbeel, Michael Jordan y Philipp Moritz: *Trust region policy optimization*. En *International Conference on Machine Learning (ICML)*, páginas 1889–1897. PMLR, 2015.
- [SLG⁺18] Sunehag, Peter, Guy Lever, Audrunas Gruslys, Wojciech M. Czarnecki, Vinicius Zambaldi, Max Jaderberg, Marc Lanctot, Nicolas Sonnerat, Joel Z. Leibo, Karl Tuyls y Thore Graepel: *Value-Decomposition Networks For Cooperative Multi-Agent Learning*. En *Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems (AAMAS)*, páginas 2085–2087. International Foundation for Autonomous Agents and Multiagent Systems, 2018.
- [SML⁺16] Schulman, John, Philipp Moritz, Sergey Levine, Michael Jordan y Pieter Abbeel: *High-dimensional continuous control using generalized advantage estimation*. En *International Conference on Learning Representations (ICLR)*, 2016.
- [SWD⁺17] Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford y Oleg Klimov: *Proximal policy optimization algorithms*. arXiv preprint arXiv:1707.06347, 2017.
- [TMK⁺17] Tampuu, Ardi, Taimet Matiisen, Dorian Kodelja, Ilya Zauss, Kristjan Korjus, Juhan Aru, Jaan Birk y Raul Vicente: *Multiagent cooperation and competition with deep reinforcement learning*. PloS one, 12(4):e0172395, 2017.
- [W⁺19] Wei, H. y cols.: *A survey on traffic signal control methods*, 2019. Available at: <https://arxiv.org/abs/1904.08117>.
- [Wie00] Wiering, Marco A: *Multi-agent reinforcement learning for traffic light control*. Machine learning, 2000.
- [WZK⁺23] Wang, Xihuai, Lingpan Zheng, Jakub Grudzien Kuba, Ruiqing Chen, Li Shen, Yidong Cao, Jun Wang y Yaodong Yang: *Order matters: Agent-by-agent policy optimization*. En *International Conference on Learning Representations (ICLR)*, 2023.
- [YVV⁺22] Yu, Chao, Akash Velu, Eugene Vinitzky, Jiaxuan Gao, Yu Wang, Alexandre Bayen y Yi Wu: *The surprising effectiveness of ppo in cooperative multi-agent games*. Advances in Neural Information Processing Systems, 35:24611–24624, 2022.
- [ZKF⁺24] Zhong, Yifan, Jakub Grudzien Kuba, Xidong Feng, Siyi Hu, Jiaming Ji y Yaodong Yang: *Heterogeneous-Agent Reinforcement Learning*. Journal of Machine Learning Research, 25:1–67, 2024.
- [ZLYZ23] Zhou, Mengdi, Xiaoteng Li, Yaodong Yang y Weinan Zhang: *A Survey on Centralized Training for Decentralized Execution in Multi-Agent Reinforcement Learning*. Artificial Intelligence Review, 2023.