

Semáforos Inteligentes: Un enfoque con Aprendizaje por Refuerzo Multi Agente

Tesina de Licenciatura en Ciencias de la Computación

Juan Martín Morales

Tutora: Dra Ana Carolina Olivera



UNCUYO
UNIVERSIDAD
NACIONAL DE CUYO



FACULTAD DE
INGENIERÍA

Facultad de Ingeniería
Universidad Nacional de Cuyo

Resumen

En este trabajo se aborda el problema de la congestión vehicular en áreas urbanas, proponiendo una solución basada en el Aprendizaje por Refuerzo Multi-Agente (MARL) Cooperativo para optimizar el control semafórico. Se analiza la evolución del parque automotor en Argentina, destacando el aumento significativo de vehículos y sus consecuencias en la movilidad urbana. Se presentan los desafíos asociados al control semafórico tradicional y se justifica la necesidad de enfoques adaptativos basados en inteligencia artificial. El objetivo principal es desarrollar y evaluar un sistema de control de tráfico que permita mejorar el flujo vehicular mediante políticas coordinadas entre múltiples intersecciones, utilizando simulaciones tanto en escenarios sintéticos como en la red vial real del Gran Mendoza. **Caro: falta completar**

Abstract

In this work, we address the problem of vehicular congestion in urban areas by proposing a solution based on Cooperative Multi-Agent Reinforcement Learning (MARL) to optimize traffic light control. We analyze the evolution of the automotive fleet in Argentina, highlighting the significant increase in vehicles and its consequences on urban mobility. We present the challenges associated with traditional traffic light control and justify the need for adaptive approaches based on artificial intelligence. The main objective is to develop and evaluate a traffic control system that improves vehicular flow through coordinated policies among multiple intersections, using simulations in both synthetic scenarios and the real road network of Greater Mendoza. **Caro:**
falta completar

Agradecimientos

Página de agradecimientos

Índice

Resumen	1
1 Introducción	2
1.1 Motivación	3
2 Marco Teórico	4
2.1 Ingeniería de Tránsito	4
2.1.1 Terminología de Tránsito	4
2.1.2 Fundamentos de la Dinámica Vehicular	5
2.1.3 Sistemas de Control de Tránsito	9
2.1.4 Simulación de Tránsito	10
2.2 Aprendizaje por Refuerzo (RL)	12
2.2.1 El Proceso de Decisión de Markov (MDP)	12
2.2.2 Métodos Basados en Valor y Basados en Política	13
2.2.3 Aprendizaje Profundo y Redes Neuronales	14
2.2.4 Aprendizaje por Refuerzo Profundo (DRL)	15
2.3 Aprendizaje por Refuerzo Multi-Agente (MARL)	19
2.3.1 Procesos de Decisión de Markov Parcialmente Observables Descentraliza- dos (Dec-POMDP)	19
2.3.2 Desafíos Fundamentales en MARL	19
2.3.3 Paradigmas de Entrenamiento y Ejecución	20
2.3.4 <i>Multi-Agent Deep Reinforcement Learning</i> (MADRL)	20
2.4 Control de Tráfico Urbano mediante MARL	24
2.4.1 Entorno de Simulación para Control Semafórico	24
2.4.2 Modelado del Problema del Control de Semáforos (Espacio de Estados, Acciones y Recompensas)	24
2.4.3 Coordinación entre Intersecciones y Mitigación de Congestión	25
3 Metodología	26
3.1 Integración de SUMO y el Agente de Aprendizaje por Refuerzo	26
3.2 Herramientas y Configuración	26
3.2.1 Edición de Redes y Tránsito	26
4 Análisis y discusión de resultados	28
4.1 Resultados del ajuste de hiperparámetros	28
4.1.1 Diseño del proceso de ajuste	28
4.1.2 Resultados del ajuste y análisis de sensibilidad	28
4.1.3 Configuración seleccionada para la evaluación final	28
4.2 Resultados de los modelos finales	28
4.2.1 Criterios de evaluación y métricas de comparación	28
4.2.2 Desempeño en escenarios sintéticos (3×1 , 3×3 , 4×4 heterogéneo) . . .	28
4.2.3 Desempeño en la red de carreteras de la Ciudad de Mendoza	28
4.3 Discusión e interpretación de resultados	28
5 Conclusiones	29

Índice de códigos

3.1	ejemplo1.sh	26
3.2	Salida del ejemplo1.sh	26

Índice de figuras

1.1	Evolución de la flota vehicular circulante en Argentina (1990–2025). Datos: AFAC.	2
2.1	Representación esquemática de movimientos vehiculares y puntos de conflicto en una intersección semaforizada.	5
2.2	Relaciones temporales y espaciales entre vehículos consecutivos de una corriente de tránsito: intervalo (h) y espaciamiento (s).	7
2.3	Comparación esquemática de la distribución de intervalos temporales entre vehículos en flujo libre (exponencial negativa, consistente con el proceso de Poisson) y en flujo coordinado por semáforos (distribución desplazada con zona de exclusión física $t_{\min}$ y pico característico de pelotón).	9
2.4	Distribución temporal de la tasa de descarga y pérdidas asociadas durante un intervalo de verde en una aproximación semaforizada.	10
2.5	Representación en SUMO de carriles entrantes (en azul), carriles salientes (en negro) y enlaces (<i>links</i>) que definen las conexiones de giro y cruce.	11
2.6	Interacción agente-entorno en un proceso de decisión de Markov [SB18].	13
2.7	Taxonomía no exhaustiva de algoritmos de Aprendizaje por Refuerzo, enfocada en métodos <i>Model-Free</i> (adaptada de OpenAI <i>Spinning Up</i> [Ach18]).	14
3.1	Bucle de control cerrado entre el simulador microscópico SUMO, la interfaz TraCI y el agente de Aprendizaje por Refuerzo en la metodología de entrenamiento. . .	26

Glosario

Actor (Aprendizaje por Refuerzo) Componente de la arquitectura del modelo de aprendizaje responsable de seleccionar y ejecutar la acción en el entorno basándose en el estado actual y la política que está aprendiendo.

Agente Entidad computacional que observa el estado de su entorno y ejecuta acciones según una política determinada con el objetivo de maximizar su recompensa a largo plazo.

Ciclo (Ingeniería de Tránsito) Secuencia completa y repetitiva de todas las fases semafóricas programadas en una intersección particular.

Cola vehicular Fila de vehículos que se detienen o avanzan muy lentamente debido a una restricción en la capacidad de la vía, tal como la luz roja de un semáforo.

Crítico (Aprendizaje por Refuerzo) Componente encargado de estimar la función de valor, prediciendo la recompensa futura esperada para evaluar la calidad de las acciones tomadas por el Actor y así guiar su actualización.

Densidad vehicular Número de vehículos presentes en un tramo o longitud específica de un carril en un instante dado.

Entorno El sistema dinámico con el que interactúa el agente. Responde a las acciones del agente produciendo transiciones de estado y emitiendo señales de recompensa.

Estado Representación cuantitativa o cualitativa de la situación actual del entorno en un instante de tiempo específico. Sirve como base para que el agente seleccione su próxima acción.

Fase (Ingeniería de Tránsito) Estado temporal de un controlador semafórico que habilita el derecho de paso exclusivo a una o más corrientes vehiculares incompatibles para que crucen una intersección de forma segura.

Flujo vehicular Cantidad de vehículos que pasan por una sección transversal específica de un carril o calzada durante un intervalo de tiempo determinado.

Función de Valor Estimación matemática de la cantidad total de recompensa que un agente puede esperar acumular en el futuro, comenzando desde un estado particular y siguiendo una política específica.

Observación Subconjunto de información del estado completo del entorno que es efectivamente visible o medible por un agente individual, especialmente relevante en escenarios de observabilidad parcial.

Política (Aprendizaje por Refuerzo) Estrategia que define el comportamiento del agente en un momento dado, mapeando los estados observados a probabilidades de selección de las acciones disponibles.

Proceso de Decisión de Markov Marco matemático utilizado para modelar la toma de decisiones en situaciones donde los resultados son en parte aleatorios y en parte bajo el control de un agente tomador de decisiones.

Recompensa Señal escalar devuelta por el entorno que evalúa cuán buena o mala fue la acción ejecutada por el agente en un estado particular. El objetivo del agente es maximizar la suma total de estas señales.

Ventaja (Aprendizaje por Refuerzo) Métrica que cuantifica cuánto mejor o peor resulta tomar una acción particular en un estado dado, en comparación con el desempeño promedio esperado según la política actual.

Resumen

Capítulo de resumen

Ejemplo de items

- Item 1
- Item 2

Introducción

En las últimas décadas, en el mundo se ha producido un incremento sostenido del parque automotor a nivel mundial, acompañado por un proceso continuo de urbanización que ha convertido a la congestión vehicular en uno de los principales desafíos para la movilidad y eficiencia en áreas urbanas. Según los reportes de flota vehicular de Argentina, elaborados por la Asociación de Fábricas Argentinas de Componentes (AFAC), y utilizando el año 2012 como línea base, el volumen de vehículos registró un aumento del 21,7% en 2017. Dicha progresión se sostuvo a lo largo de la última década, alcanzando un incremento acumulado del 44,4% para el año 2025 (véase la Figura 1.1).




Figura 1.1: Evolución de la flota vehicular circulante en Argentina (1990–2025). Datos: AFAC.

Las congestiones vehiculares traen consigo múltiples consecuencias: desde importantes pérdidas de productividad por demoras en los tiempos de viaje, hasta un aumento en la cantidad de detenciones vehiculares y la consecuente emisión de gases nocivos para la salud y el medio ambiente, tales como CO , CO_2 , NO_x , HC [ne18]. Este escenario impacta de manera notable en grandes ciudades con una alta densidad de vehículos. En este trabajo se utilizaron casos de estudio sintetizados y como caso de estudio real el Área Metropolitana del Gran Mendoza (GM), comprendida entre Avenida San Martín, Avenida Colón, Avenida Belgrano y Avenida Las Heras.

Frente a un escenario de congestión, una alternativa viable, sin recurrir a reestructuraciones costosas en la infraestructura, consiste en optimizar la gestión del tránsito mediante sistemas de control semafórico adaptativos. Los enfoques tradicionales de control semafórico han demostrado poca capacidad de adaptación ante escenarios con mucha variabilidad de flujos de vehículos. Una alternativa prometedora resulta ser el Aprendizaje por Refuerzo (*Reinforcement Learning*, RL), un paradigma de inteligencia artificial donde los semáforos pueden modelarse como agentes, capaces de aprender políticas de control a partir de la interacción con un entorno (la situación del tránsito) mediante la ejecución de acciones (cambios de fase) con el objetivo de maximizar una recompensa (como, por ejemplo, el valor negativo de la suma de los tiempos de espera). Diversos estudios han demostrado la viabilidad de este enfoque, evolucionando desde la aplicación de algoritmos clásicos y tabulares en una sola intersección [Wie00, APK03], hasta modelos a gran escala de redes coordinadas empleando redes neuronales profundas y control multi-agente [ETAA13, LLW16, W⁺19, CWCL19].

Sin embargo, aplicar este enfoque de manera simultánea sobre múltiples intersecciones introduce desafíos adicionales. Un esquema de control centralizado resulta poco escalable debido al crecimiento exponencial del espacio de acciones conjunto. Una alternativa “ingenua” del Apre-

dizaje por Refuerzo Multi-Agente resulta ser el Aprendizaje Independiente (*Independent Learning* o IL), donde cada semáforo busca descongestionar de forma independiente y egoísta solo su propia intersección [AS22]. Este enfoque tiene dos desventajas críticas: primero, la optimización puramente local conduce a un óptimo global sub-óptimo; segundo, dado que todos los agentes aprenden y cambian sus políticas simultáneamente, el entorno se vuelve no estacionario para cada agente individual, lo cual viola los supuestos de convergencia del aprendizaje [FH21].

Por esta razón, en este trabajo final de carrera se aborda el problema desde el marco del Aprendizaje por Refuerzo Multi-Agente (MARL) Cooperativo. Bajo este paradigma, los controladores (agentes) actúan como un equipo. Aprenden políticas coordinadas, no para maximizar solo una recompensa individual, sino también una recompensa global compartida orientada a la minimización del tiempo de espera promedio de toda la red, evitando así los conflictos que surgen del aprendizaje independiente. La recompensa es un valor numérico que indica cuán efectiva fue la acción conjunta.

En este contexto, el objetivo general de este trabajo fue desarrollar y evaluar un sistema de control de tráfico basado en este enfoque cooperativo para optimizar el flujo vehicular urbano. Para lograrlo, se analizó la convergencia a políticas de control óptimas y la escalabilidad de distintos algoritmos MARL ante entornos no estacionarios mediante simulaciones en escenarios sintéticos y en la red vial real del Gran Mendoza. Esto permitió establecer una línea base de comparación para, posteriormente, validar empíricamente el desempeño de la arquitectura descentralizada y coordinada propuesta frente a los enfoques de control tradicionales y a metodologías recientes de la literatura.

1.1 Motivación

La motivación principal de este trabajo radica en la marcada asimetría entre una demanda vehicular en constante crecimiento y una infraestructura vial que permanece estática. Dado que ensanchar avenidas o modificar físicamente el trazado urbano en cascos densos como el del Gran Mendoza es económica y estructuralmente inviable, la alternativa más sostenible es la optimización lógica de los recursos existentes.

El desarrollo de soluciones basadas en software permite dotar de la adaptabilidad necesaria a la red semafórica actual. De este modo, es posible transformar un sistema rígido en uno inteligente capaz de mitigar las demoras y reducir la contaminación ambiental evitable, maximizando la eficiencia de la infraestructura vial sin requerir obras civiles de gran envergadura.

La presente tesina se organiza de la siguiente manera: en el Capítulo 1 se formula el problema de estudio y se exponen las motivaciones que impulsan esta investigación. A continuación, el Capítulo 2 establece las bases teóricas, abordando los conceptos clave de la ingeniería de tránsito y los fundamentos del *Reinforcement Learning*, particularmente en su vertiente multi-agente. Luego, el Capítulo 3 detalla la metodología de trabajo, describiendo tanto los entornos de simulación empleados como la arquitectura algorítmica de los modelos implementados. Posteriormente, en el Capítulo 4 se lleva a cabo un análisis empírico del desempeño de los distintos controladores, evaluándolos en escenarios controlados y en la red urbana simulada del Gran Mendoza. Finalmente, el Capítulo 5 sintetiza los hallazgos principales, destaca las contribuciones metodológicas y sugiere posibles vías para continuar este trabajo en el futuro.

Marco Teórico

2.1 Ingeniería de Tránsito

La ingeniería de tránsito se define como aquella fase de la ingeniería de transporte —disciplina que se enmarca tradicionalmente dentro de la ingeniería civil— que tiene que ver con la planeación segura y eficiente, el proyecto geométrico y la operación del tránsito por calles y carreteras, sus redes, terminales, tierras adyacentes y su relación con otros modos de transporte, tanto motorizados como no motorizados [CyMR18]. Asimismo, el *Traffic Engineering Handbook* la describe formalmente como la subdisciplina enfocada en la planificación, el diseño geométrico y la operación de calles, carreteras y redes viales [PW16]. En este trabajo, sus conceptos se abordan principalmente desde la perspectiva de la operación del tránsito urbano: permiten describir el funcionamiento físico de la red vial, caracterizar la oferta y demanda de circulación, e identificar las variables operacionales clave sobre las cuales puede intervenir de manera adaptativa un sistema de control.

Históricamente, la práctica de la ingeniería de tránsito puso un fuerte énfasis en proveer y ampliar la capacidad física vial mediante la construcción de nuevas obras o el ensanche de calzadas [PW16]. Sin embargo, el crecimiento sostenido de la congestión evidenció que la ampliación de infraestructura no constituye una solución definitiva al problema. En áreas urbanas consolidadas, además, modificar el trazado vial resulta costoso y geoméricamente inviable [CyMR18]. Por ello, la práctica contemporánea complementa la provisión de infraestructura con estrategias de gestión de la demanda y control dinámico del tránsito, priorizando la optimización de los recursos existentes mediante dispositivos de control semafórico.

La operación de una red vial puede analizarse a partir de la relación entre la demanda vehicular y la capacidad disponible. La demanda vehicular corresponde a la cantidad de vehículos que requieren desplazarse por un determinado sistema vial, mientras que la oferta vial o capacidad representa la cantidad máxima de vehículos que pueden circular por dicho espacio físico bajo determinadas condiciones de operación [CyMR18]. Cuando la demanda se aproxima a la capacidad, el tránsito se vuelve inestable; cuando la supera, se presentan condiciones de sobresaturación o flujo forzado, caracterizadas por detenciones frecuentes y grandes demoras. En este sentido, la congestión no se entiende solo como una percepción general de mal funcionamiento, sino como un fenómeno con manifestaciones físicas medibles: demoras, colas y detenciones [FA11].

2.1.1 Terminología de Tránsito

Antes de introducir los mecanismos de control y su formulación computacional, conviene precisar algunos términos operativos que se utilizarán de manera recurrente en este documento. Esta aclaración inicial también es habitual en estudios recientes sobre control semafórico basados en aprendizaje por refuerzo, donde los conceptos de movimientos, fases y señales se explicitan antes de formular el problema de control [W⁺19].

En este contexto, se emplearán las siguientes nociones:

- **Intersección, acceso y carril:** una intersección es el área física y operacional en la que confluyen dos o más corrientes de tránsito. Cada una de las calzadas de aproximación que ingresan a ella constituye un acceso [PW16], organizándose internamente en uno o más carriles destinados a canalizar los flujos vehiculares [CyMR18].
- **Movimiento vehicular y movimientos en conflicto:** un movimiento vehicular representa la trayectoria específica que describe un vehículo al cruzar la intersección hacia una

salida determinada (e.g., giros o movimientos directos) [W⁺19]. Dos movimientos se consideran en conflicto o incompatibles cuando sus trayectorias se intersectan y generan puntos de conflicto en la intersección (véase la Figura 2.1), lo que impide su servicio simultáneo por razones de seguridad [FA11].

- **Fase, ciclo e intervalo:** una fase representa el estado operativo del semáforo que otorga el derecho de paso a un grupo de movimientos compatibles de manera simultánea [PW16]. La secuencia completa de fases requerida para servir a todos los movimientos de la intersección constituye el ciclo semaforico, mientras que un intervalo es la fracción temporal del ciclo durante la cual las indicaciones del semáforo no varían [CyMR18].



Figura 2.1: Representación esquemática de movimientos vehiculares y puntos de conflicto en una intersección semaforizada.

En arterias urbanas, el tránsito se desarrolla bajo condiciones de flujo interrumpido: los vehículos no avanzan únicamente por su interacción con otros vehículos, sino también por la presencia de intersecciones, señales y dispositivos de control de tránsito [PW16]. Las intersecciones son puntos críticos de la red porque allí confluyen distintos accesos y movimientos vehiculares de cruce, convergencia y divergencia que pueden resultar incompatibles entre sí. Por ello, su operación requiere ordenar estos movimientos y asignar la prioridad de paso de manera segura y eficiente.

El semáforo es uno de los dispositivos de control de tránsito utilizados para regular la circulación en intersecciones. Su función es asignar la prioridad de paso en forma alternada entre corrientes vehiculares incompatibles, evitando que distintos movimientos intenten ocupar simultáneamente el mismo espacio de cruce [FA11]. Desde el punto de vista del modelado algorítmico, esta capacidad de modificar la prioridad de paso convierte al semáforo en el actuador mediante el cual un sistema de control puede intervenir sobre la operación de la intersección y afectar, directa o indirectamente, las demoras y colas observadas en la red.

2.1.2 Fundamentos de la Dinámica Vehicular

Para modelar y optimizar la operación de una red vial, es necesario caracterizar físicamente el movimiento de los vehículos. La ingeniería de tránsito estudia este fenómeno a partir de las características fundamentales de la corriente de tránsito, que permiten describir las condiciones de operación de una vía o intersección mediante magnitudes observables como el flujo, la velocidad y la densidad [PW16]. Cal y Mayor distingue estas magnitudes entre variables principales, que describen el comportamiento agregado del flujo vehicular, y variables asociadas, que expresan relaciones temporales y espaciales entre vehículos consecutivos [CyMR18].

A nivel macroscópico, la corriente de tránsito se representa mediante variables agregadas como la tasa de flujo, la densidad y los promedios de velocidad. A nivel microscópico, se analizan magnitudes propias de vehículos individuales e interacciones entre pares consecutivos, como la velocidad puntual, el intervalo y el espaciamiento [CyMR18]. Esta separación entre escalas es relevante para el modelado computacional: las variables macroscópicas resumen el estado operacional de los accesos de la red, mientras que las variables microscópicas describen el comportamiento de cada vehículo dentro del simulador [FA11]. La correspondencia y las relaciones de conversión entre las variables de ambas escalas se resumen en la Tabla 2.1.

En el nivel macroscópico, las variables principales de la corriente de tránsito son:

- **Flujo o tasa de flujo (q):** representa la cantidad de vehículos que atraviesen una sección transversal de la vía por unidad de tiempo. Si el período de observación es menor a una hora, se proyecta como una tasa horaria equivalente en vehículos por hora (veh/h), $q = N/T$ [CyMR18].
- **Densidad o concentración (k):** indica el número de vehículos que ocupan simultáneamente una longitud específica de vía, expresada en vehículos por kilómetro (veh/km), $k = N/d$ [CyMR18]. En la práctica, se suele estimar indirectamente a través del porcentaje de ocupación temporal registrado por detectores inductivos [PW16].
- **Velocidad media espacial (v_s):** es la velocidad media de los vehículos que ocupan un tramo de vía en un instante determinado. Corresponde al promedio armónico de las velocidades puntuales de los vehículos individuales y representa la magnitud de velocidad consistente con la dinámica del flujo espacial [CyMR18].
- **Velocidad media temporal (v_t):** representa el promedio aritmético de las velocidades de los vehículos que cruzan una sección transversal fija de la vía durante un período de tiempo determinado [CyMR18].

En el nivel microscópico, las variables asociadas describen el movimiento del vehículo individual y la separación entre vehículos consecutivos (véase la Figura 2.2):

- **Velocidad puntual (v_i):** es la velocidad a la que un vehículo individual (i) atraviesa una sección transversal específica de la vía.
- **Intervalo temporal (h):** es el tiempo transcurrido entre el paso de dos vehículos consecutivos por una sección fija de la calzada, medido respecto a puntos homólogos (e.g., parachoques delanteros) [CyMR18]. El intervalo promedio en segundos se relaciona con la tasa de flujo como $h_{prom} = 3600/q$.
- **Espaciamiento simple (s):** es la distancia física entre puntos homólogos de dos vehículos consecutivos en un instante de tiempo [CyMR18]. El espaciamiento promedio se relaciona de forma inversa con la densidad de la corriente de tránsito ($s_{prom} = 1/k$).

Cuadro 2.1: Comparación y correspondencia de variables de tránsito en escalas macroscópica y microscópica.

Escala	Variable Principal	Relación / Conversión
Macroscópica	Flujo (q , veh/h)	$q = 3600/h_{prom}$
	Densidad (k , veh/km)	$k = 1000/s_{prom}$
	Velocidad media espacial (v_s , km/h)	$q = k \cdot v_s$
	Velocidad media temporal (v_t , km/h)	$v_t = v_s + \frac{\sigma_s^2}{v_s}$ (Relación de Wardrop)
Microscópica	Velocidad puntual (v_i , km/h)	Variable individual de cada vehículo
	Intervalo temporal (h , s)	Tiempo entre pasos de vehículos sucesivos
	Espaciamiento simple (s , m)	Distancia espacial entre parachoques homólogos




Figura 2.2: Relaciones temporales y espaciales entre vehículos consecutivos de una corriente de tránsito: intervalo (h) y espaciamento (s).

Estas variables macroscópicas y agregadas se relacionan de manera directa a través de la ecuación fundamental del flujo de tránsito:

$$q = k \cdot v_s \quad (2.1)$$

Cabe destacar que la velocidad media espacial (v_s) es la única físicamente consistente con esta ecuación fundamental. La velocidad media temporal (v_t) difiere de esta debido a que asigna mayor peso a los vehículos más rápidos que cruzan el punto de medición en un lapso dado. La vinculación analítica entre ambas variables se establece formalmente mediante la relación de Wardrop [FA11]:

$$v_t = v_s + \frac{\sigma_s^2}{v_s} \quad (2.2)$$

donde σ_s^2 es la varianza de la distribución de velocidades en el espacio. Dado que la varianza es siempre no negativa, se cumple que $v_t \geq v_s$, igualándose únicamente en el caso hipotético en que todos los vehículos circulen exactamente a la misma velocidad. En intersecciones semaforizadas, esta relación dinámica permite modelar cómo las interrupciones del semáforo durante la luz roja detienen el flujo ($v_s \rightarrow 0$), provocando una acumulación de vehículos que eleva la densidad ($k \rightarrow k_{max}$) y genera colas y demoras asociadas a condiciones de flujo forzado [CyMR18].

Para un sistema de control de tránsito, estas variables son relevantes porque pueden medirse o estimarse a partir de sensores, detectores o registros del simulador. A partir de ellas es posible construir una representación del estado de la red y evaluar cómo evoluciona la operación ante distintas decisiones de control.

Métricas de Ineficiencia Operativa

La interrupción del flujo causada por semáforos o saturación genera efectos adversos que los sistemas de control buscan mitigar. Siguiendo la terminología de la ingeniería de tránsito, las principales manifestaciones medibles de esta ineficiencia son las demoras, las colas y las detenciones [FA11]:

- **Demoras:** Representan el tiempo adicional que un vehículo debe invertir para atravesar una intersección respecto del tiempo que le tomaría circular a velocidad de flujo libre. En intersecciones semaforizadas, una parte de esa demora aparece por la espera normal durante la luz roja. Otras demoras se producen cuando las llegadas de vehículos varían, cuando la demanda se acerca o supera la capacidad de la intersección, o cuando quedan colas sin disiparse al finalizar el verde, de modo que algunos vehículos deben esperar más de un ciclo para cruzar.
- **Colas:** Corresponden al número de vehículos acumulados detrás de una línea de detención a la espera de ser servidos. Esta medida espacial es especialmente relevante porque, cuando la cola supera la longitud del arco de aproximación, puede bloquear la intersección aguas arriba y propagar la congestión al resto de la red.

- **Detenciones:** Cuantifican la cantidad de veces que un vehículo debe reducir su velocidad hasta cero durante el recorrido. Una alta frecuencia de detenciones deteriora la continuidad operativa del flujo y suele asociarse con mayores procesos de aceleración y desaceleración.

Estas tres métricas constituyen indicadores directos del desempeño operativo de la red. En este trabajo, se adoptan como criterios de evaluación del controlador, ya que permiten cuantificar los efectos de la asignación dinámica de prioridad entre movimientos en conflicto en las intersecciones.

Descripción Probabilística del Flujo

En el modelado de tránsito, las llegadas vehiculares no siempre pueden representarse adecuadamente como una secuencia determinista y constante. Para flujos vehiculares bajos y medios, y cuando las llegadas no están fuertemente condicionadas por semáforos previos, es habitual aproximar el número de vehículos que llega a una sección durante un intervalo de tiempo mediante un proceso de Poisson [CyMR18].

Esta aproximación supone independencia estadística entre llegadas y permite describir la variabilidad observada en la demanda de acceso a una intersección [CyMR18]. La probabilidad discreta $P(X)$ de que lleguen exactamente X vehículos en un intervalo de tiempo se define como:

$$P(X) = \frac{m^X \cdot e^{-m}}{X!} \quad (2.3)$$

donde m representa el valor esperado o media de llegadas en dicho intervalo. Bajo el mismo supuesto, los intervalos de tiempo continuos (h) medidos entre vehículos sucesivos se describen mediante una distribución de probabilidad exponencial negativa [CyMR18]:

$$P(h \geq t) = e^{-\frac{q}{3600} \cdot t} \quad (2.4)$$

Esta representación probabilística asume independencia entre arribos sucesivos, siendo una aproximación válida únicamente para flujos vehiculares bajos o moderados bajo condiciones de flujo libre, donde no exista la influencia de semáforos cercanos aguas arriba [CyMR18]. Sin embargo, este supuesto de independencia decae en condiciones de congestión o en redes viales urbanas semaforizadas. En estos casos, la operación de los semáforos interrumpe periódicamente el flujo y agrupa a los vehículos en pelotones (*platoons*), induciendo una fuerte dependencia espacio-temporal y correlación entre arribos consecutivos. La Figura 2.3 presenta una comparación conceptual de la distribución resultante de los intervalos temporales entre vehículos bajo estas dos condiciones operativas.

Esta limitación de los modelos analíticos tradicionales (como los de Poisson o teoría de colas clásica) justifica la necesidad de recurrir a la simulación microscópica de tránsito. En un simulador como SUMO, la formación, dispersión e interacción de pelotones vehiculares emergen de manera natural a partir de los modelos de seguimiento de vehículos y cambio de carril, permitiendo evaluar el control semafórico bajo flujos dinámicos realistas. Asimismo, incorporar arribos estocásticos no Poissonianos, perfiles de demanda variables y la inicialización de múltiples corridas con diferentes semillas aleatorias en el simulador es un procedimiento estándar para evaluar la robustez y capacidad de adaptación de cualquier esquema de control dinámico ante la incertidumbre operativa [CyMR18]; esto permite asegurar que los algoritmos sean capaces de responder ante fluctuaciones dinámicas del tráfico en tiempo real, en lugar de optimizarse para una secuencia de flujo determinista y artificial [PW16].




Figura 2.3: Comparación esquemática de la distribución de intervalos temporales entre vehículos en flujo libre (exponencial negativa, consistente con el proceso de Poisson) y en flujo coordinado por semáforos (distribución desplazada con zona de exclusión física $t_{\min}$ y pico característico de pelotón).

2.1.3 Sistemas de Control de Tránsito

Para mitigar los conflictos de tránsito e incrementar la seguridad en las intersecciones urbanas de flujo interrumpido, se emplean sistemas de control de tránsito [PW16]. El dispositivo de control por excelencia en estos nodos es el semáforo, definido como un dispositivo electrónico que regula la circulación de vehículos asignando el derecho de paso alternado mediante indicaciones luminosas rojas, amarillas y verdes [CyMR18].

En el modelado algorítmico, los semáforos y sus parámetros de configuración constituyen los elementos actuadores de la red. La modificación de la duración del verde efectivo, la secuencia de fases y la sincronización entre nodos define el conjunto de intervenciones dinámicas mediante las cuales el sistema de control busca optimizar el paso vehicular.

Sobre esta base terminológica, la programación temporal de un semáforo se describe mediante la duración de las fases, la longitud de ciclo y la definición de los intervalos de transición y despeje. Estos parámetros determinan cuánto tiempo recibe prioridad cada conjunto de movimientos compatibles y condicionan directamente la capacidad de descarga, las demoras y la seguridad operacional de la intersección [PW16].

Para garantizar la seguridad vial, las transiciones entre fases no pueden ejecutarse de manera instantánea, sino que deben respetar intervalos de cambio y despeje [PW16]. En este trabajo, esos tiempos se consideran restricciones operativas de seguridad previamente definidas en la configuración del simulador y del sistema semaforico. En consecuencia, su determinación no forma parte del proceso de decisión del agente, cuyo control se limita a la selección de fases dentro de un esquema temporal compatible con dichas restricciones.

Modelado de la Capacidad y el Verde Efectivo

Desde el punto de vista operativo, la capacidad de descarga de un acceso semaforizado depende del tiempo efectivo de servicio que recibe cada fase y de la tasa con la que la fila puede disiparse cuando el movimiento tiene prioridad [FA11]. En la práctica, la descarga observada no depende solo de la duración nominal del verde, sino también de pérdidas de arranque, transiciones y otras restricciones temporales del control, como se ilustra conceptualmente en la Figura 2.4. En este trabajo, estos efectos no se modelan mediante fórmulas analíticas de capacidad, sino mediante la dinámica microscópica del simulador y la configuración temporal del sistema semaforico, ya que esas interacciones determinan las colas, demoras y detenciones que el controlador busca mejorar.




Figura 2.4: Distribución temporal de la tasa de descarga y pérdidas asociadas durante un intervalo de verde en una aproximación semaforizada.

Clasificación de los Controladores de Semáforos

De acuerdo con su mecanismo operativo y su grado de respuesta a la demanda vehicular, los controladores de semáforos se clasifican clásicamente en control de tiempo fijo y control accionado por el tránsito [PW16]. En el primero, los planes de señales se repiten de manera preprogramada a partir de datos históricos y no cambian en respuesta a la demanda instantánea. En el segundo, la intersección utiliza detectores en los accesos para variar dinámicamente el inicio o la duración de las fases según la demanda observada en tiempo real.

Incluso en los esquemas accionados, la operación permanece sujeta a parámetros límite de seguridad y funcionamiento, como el verde mínimo y el verde máximo [PW16]. Estos parámetros restringen cuánto puede sostenerse o finalizarse una fase y, en este trabajo, forman parte de las condiciones operativas dentro de las cuales el controlador toma decisiones.

2.1.4 Simulación de Tránsito

Debido a la densidad y complejidad de la red urbana moderna, la sincronización y optimización de los tiempos de semáforos no pueden resolverse adecuadamente con modelos estáticos bajo condiciones dinámicas, por lo que se recurre a aproximaciones computacionales basadas en simulación de tránsito [PW16]. De acuerdo con la taxonomía clásica [FA11], estos modelos pueden organizarse en tres niveles de resolución. Los modelos macroscópicos describen el tránsito de manera agregada mediante variables como flujo, densidad y velocidad; los modelos mesoscópicos representan entidades intermedias, como grupos o pelotones de vehículos. Ambos niveles son útiles para estudiar fenómenos de red, pero no ofrecen el detalle necesario para observar cómo las decisiones semaforísticas afectan, paso a paso, la formación de colas y la interacción local entre vehículos en una intersección.

Para este trabajo, el nivel de mayor interés es el microscópico, ya que representa explícitamente a cada vehículo, su ruta y su movimiento dentro de la red [FA11]. SUMO (*Simulation of Urban MObility*) se ubica en esta categoría: es un simulador de tránsito microscópico, multimodal y de código abierto, diseñado para representar demandas vehiculares sobre redes viales y evaluar problemas de gestión del tránsito [ALBBW⁺18, DLR25]. En SUMO, la evolución vehicular es continua en el espacio y discreta en el tiempo; además, el entorno permite modelar calles con múltiples carriles, cambios de carril, distintos tipos de vehículos, rutas individuales, semáforos y salidas de simulación a nivel de vehículo, carril, arco o detector [DLR25].

Esta granularidad vuelve a la simulación microscópica especialmente adecuada para estudiar control semaforístico mediante aprendizaje por refuerzo. Las decisiones sobre fases y tiempos de

servicio no se evalúan mediante una fórmula cerrada de demora, sino observando sus consecuencias sobre la dinámica simulada: colas, tiempos de espera, detenciones, ocupación de carriles y propagación de congestión. Por ello, la simulación microscópica constituye el puente natural entre el problema de tránsito y su formulación computacional, al permitir que el controlador interactúe con un entorno dinámico y medible durante la ejecución.

Modelos Microscópicos de Comportamiento Vehicular

En la simulación microscópica, la evolución de cada vehículo se describe mediante mecanismos internos como el seguimiento vehicular [FA11] y el cambio de carril [PW16]. En SUMO, estos mecanismos se parametrizan a través de los tipos de vehículo y determinan cómo cada unidad ajusta su velocidad, mantiene separaciones de seguridad, cambia de carril y avanza sobre su ruta dentro de la red [DLR25].

Modelado de Intersecciones y Semáforos en SUMO

En este contexto, el simulador de tránsito constituye el entorno operativo sobre el cual se formaliza el problema de control semafórico. En SUMO, los programas semafóricos se definen mediante fases que especifican, para cada instante, el estado de las señales asociadas a los enlaces controlados de la intersección; por ello, una fase no se interpreta solo como un color general del semáforo, sino como una configuración de permisos para movimientos concretos entre carriles de entrada y salida, cuyos elementos geométricos asociados (carriles y conexiones de cruce) se representan en la Figura 2.5 [DLR25]. Esta representación es compatible con la formulación algorítmica del problema, donde una acción puede consistir en seleccionar una fase, mantener la fase actual o modificar la duración de servicio dentro de restricciones predefinidas.




Figura 2.5: Representación en SUMO de carriles entrantes (en azul), carriles salientes (en negro) y enlaces (*links*) que definen las conexiones de giro y cruce.

2.2 Aprendizaje por Refuerzo (RL)

Dentro del aprendizaje automático suelen distinguirse tres paradigmas principales. En el aprendizaje supervisado, el modelo se entrena a partir de ejemplos etiquetados que indican la salida esperada para cada entrada. En el aprendizaje no supervisado, en cambio, se busca descubrir estructura en datos no etiquetados, por ejemplo mediante agrupamiento o reducción de dimensionalidad. El aprendizaje por refuerzo (*Reinforcement Learning*, RL) aborda un problema distinto: una entidad que toma decisiones debe aprender, mediante interacción con un entorno, qué acciones elegir para maximizar una señal de recompensa acumulada a largo plazo [SB18].

Esta diferencia es central. En RL no existe, en general, un supervisor que indique cuál era la acción correcta en cada situación. El agente aprende por experiencia, ensayando acciones, observando sus consecuencias y ajustando su comportamiento a partir de las recompensas obtenidas. Además, las consecuencias relevantes de una acción no siempre se manifiestan de forma inmediata: una decisión puede producir una recompensa baja en el corto plazo, pero conducir a estados favorables en el futuro. Por este motivo, el aprendizaje por refuerzo se ocupa explícitamente del problema de la recompensa diferida y de la asignación de crédito a decisiones pasadas [SB18].

La formulación básica distingue entre el *agente* (*agent*), que aprende y toma decisiones, y el *entorno* (*environment*), que representa todo aquello externo al agente con lo cual este interactúa. En cada paso temporal, el agente observa una situación del entorno, selecciona una acción y recibe como respuesta una nueva situación junto con una recompensa. El comportamiento del agente está determinado por una *política* (*policy*), denotada por π , que especifica cómo se eligen las acciones a partir de los estados u observaciones disponibles. La *señal de recompensa* (*reward signal*) define el objetivo inmediato del problema, mientras que la *función de valor* estima la conveniencia de estados o acciones en términos de recompensa futura esperada. Sutton y Barto también distinguen el *modelo* del entorno, entendido como una descripción que permite predecir sus transiciones y recompensas; cuando dicho modelo no se conoce o no se utiliza explícitamente, se habla de métodos libres de modelo (*model-free*).

Un aspecto característico de RL es el dilema entre exploración y explotación. El agente debe explotar acciones que, según su experiencia, producen buenos resultados, pero también debe explorar alternativas menos conocidas que podrían conducir a políticas superiores. Si explora demasiado, desperdicia oportunidades de obtener recompensa; si explota demasiado pronto, puede converger a comportamientos subóptimos. Este equilibrio es especialmente relevante en problemas de control, donde las acciones modifican la experiencia futura disponible para el aprendizaje [SB18].

2.2.1 El Proceso de Decisión de Markov (MDP)

El marco matemático estándar para estudiar problemas de aprendizaje por refuerzo de un solo agente es el Proceso de Decisión de Markov (*Markov Decision Process*, MDP). En un MDP finito, el agente y el entorno interactúan en una secuencia de pasos temporales discretos $t = 0, 1, 2, \dots$. En cada instante t , el agente recibe una representación del estado del entorno $S_t \in \mathcal{S}$ y selecciona una acción $A_t \in \mathcal{A}(S_t)$. Como consecuencia de esa acción, el entorno emite una recompensa numérica $R_{t+1} \in \mathcal{R}$ y transita a un nuevo estado S_{t+1} [SB18]. Este ciclo se representa en la Figura 2.6.




Figura 2.6: Interacción agente-entorno en un proceso de decisión de Markov [SB18].

De forma compacta, un MDP finito puede describirse mediante los conjuntos de estados $\mathcal{S}$, acciones $\mathcal{A}$ y recompensas $\mathcal{R}$, junto con una dinámica probabilística p y un factor de descuento γ .

La dinámica del entorno queda caracterizada por la función $p(s', r | s, a)$, que define la probabilidad de observar el siguiente estado s' y la recompensa r al ejecutar la acción a en el estado s :

$$p(s', r | s, a) \doteq \Pr\{S_{t+1} = s', R_{t+1} = r | S_t = s, A_t = a\} \quad (2.5)$$

La propiedad de Markov establece que, dado el estado y la acción actuales, la distribución del próximo estado y recompensa no depende explícitamente de la historia completa de estados y acciones anteriores. En otras palabras, el estado debe contener la información relevante del pasado para predecir la evolución futura del proceso [SB18].

Una suposición habitual del MDP es que el agente observa un estado suficientemente informativo del entorno. Sin embargo, en muchas aplicaciones reales el agente solo recibe observaciones parciales o ruidosas. En estos casos, el marco se generaliza a un Proceso de Decisión de Markov Parcialmente Observable (POMDP), donde el historial de observaciones puede ser necesario para inferir el estado subyacente [ACS24]. Esta distinción resulta importante para el control semafórico: una simulación puede poseer un estado global bien definido, pero cada controlador suele operar con mediciones locales, como colas, ocupación o tiempos de espera observados en sus aproximaciones.

Para formalizar la meta de maximizar la recompensa a largo plazo se define el retorno G_t . En tareas episódicas, el retorno puede calcularse hasta alcanzar un estado terminal. En tareas continuas o con horizonte indefinido, se utiliza con frecuencia el retorno descontado, incorporando un factor $\gamma \in [0, 1]$ que pondera las recompensas futuras [SB18]:

$$G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \quad (2.6)$$

El factor de descuento admite dos interpretaciones complementarias. Matemáticamente, puede asociarse con la probabilidad de continuidad del proceso; desde el punto de vista del objetivo de control, regula la importancia relativa de las recompensas futuras. Un valor cercano a cero induce un comportamiento más miope, mientras que un valor cercano a uno otorga mayor peso a consecuencias de largo plazo [ACS24]. En simulación de tráfico, aun cuando los experimentos se ejecuten en episodios de duración finita, el uso de descuento permite representar que las decisiones semafóricas actuales inciden sobre colas y demoras futuras.

2.2.2 Métodos Basados en Valor y Basados en Política

Los algoritmos de RL pueden agruparse, a grandes rasgos, en métodos basados en valor y métodos basados en política. Esta distinción no agota la taxonomía del campo, pero permite introducir las familias de algoritmos más relevantes para este trabajo.

En los *métodos basados en valor*, la estrategia consiste en estimar qué tan conveniente es encontrarse en un estado o ejecutar una acción determinada. Esto se formaliza mediante la *función de valor de estado* $v_\pi(s) \doteq \mathbb{E}_\pi[G_t \mid S_t = s]$ y la *función de valor de acción* $q_\pi(s, a) \doteq \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$. Ambas funciones satisfacen ecuaciones recursivas conocidas como *ecuaciones de Bellman*, que expresan la relación entre el valor de una situación actual y el valor esperado de sus posibles sucesores [SB18].

Cuando la dinámica del entorno no se conoce completamente, estas funciones pueden estimarse a partir de la experiencia. Los métodos de Diferencia Temporal (*Temporal-Difference*, TD) combinan el muestreo de transiciones reales con actualizaciones basadas en estimaciones previas, mecanismo conocido como *bootstrapping*. Un ejemplo central es *Q-learning*, que actualiza la función de acción-valor hacia una estimación de la función óptima $q_*(s, a)$:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t) \right] \quad (2.7)$$

Por el contrario, los *métodos basados en política* parametrizan directamente la política $\pi(a \mid s, \theta) = \Pr\{A_t = a \mid S_t = s, \theta_t = \theta\}$. En lugar de derivar la acción exclusivamente de una función de valor, ajustan los parámetros θ para maximizar una medida de rendimiento escalar $J(\theta)$. Para ello aplican ascenso de gradiente sobre el rendimiento esperado:

$$\theta_{t+1} = \theta_t + \alpha \nabla J(\theta_t) \quad (2.8)$$

El Teorema del Gradiente de Política (*Policy Gradient Theorem*) proporciona la base teórica para estimar este gradiente sin derivar explícitamente la distribución de estados inducida por la política [SB18]. En la práctica, muchos algoritmos modernos combinan ambas ideas mediante arquitecturas actor-crítico: un actor representa la política y un crítico estima valores para guiar sus actualizaciones.




Figura 2.7: Taxonomía no exhaustiva de algoritmos de Aprendizaje por Refuerzo, enfocada en métodos *Model-Free* (adaptada de OpenAI *Spinning Up* [Ach18]).

2.2.3 Aprendizaje Profundo y Redes Neuronales

La Unidad Neuronal y Redes *Feedforward*

En problemas de control complejos, los métodos tabulares se vuelven impracticables debido a las restricciones de memoria y cómputo que impone la maldición de la dimensionalidad [SB18]. La aproximación de funciones soluciona esta limitación al representar funciones mediante una forma parametrizada, permitiendo que el aprendizaje en un estado se generalice a otros estados

con características similares. El aprendizaje profundo (*Deep Learning*) emplea redes neuronales artificiales como aproximadores de funciones continuas y no lineales [ACS24].

El componente básico de estas arquitecturas es la unidad neuronal individual. Computacionalmente, una neurona en una capa k ejecuta dos operaciones secuenciales sobre el vector de características de entrada $\mathbf{x}$. Primero, calcula una combinación lineal utilizando un vector de pesos $\mathbf{w}$ y un sesgo (*bias*) escalar b . Luego, el resultado se somete a una función de activación no lineal g_k :

$$f_{k,u}(\mathbf{x}; \theta_k^u) = g_k(\mathbf{w}^\top \mathbf{x} + b) \quad (2.9)$$

La inclusión de una función de activación es estrictamente necesaria; componer múltiples capas sin funciones no lineales resultaría analíticamente en una simple transformación lineal, anulando la capacidad de representación de la red [ACS24]. Entre las opciones no lineales más comunes destacan ReLU (Unidad Lineal Rectificada, que emite la entrada directamente si es positiva y cero en caso contrario), *leaky* ReLU (una variante que permite un gradiente pequeño para entradas negativas, previniendo la parálisis de la neurona) y Tanh (tangente hiperbólica, que comprime la salida continua en el rango $[-1, 1]$).

Las redes neuronales de propagación hacia adelante (conocidas por su término en inglés *feed-forward* o como perceptrones multicapa) estructuran estas unidades en secuencias de múltiples capas: una capa de entrada, capas intermedias u ocultas, y una capa de salida. La computación de una capa entera se puede vectorizar:

$$\mathbf{h}_k = g_k(\mathbf{W}_k^\top \mathbf{x}_{k-1} + \mathbf{b}_k) \quad (2.10)$$

donde $\mathbf{W}_k$ es la matriz de pesos y $\mathbf{b}_k$ el vector de sesgos. El Teorema de Aproximación Universal establece que una red con una única capa oculta suficientemente ancha puede aproximar cualquier función continua; sin embargo, arquitecturas más profundas logran una mejor generalización y una extracción jerárquica de características progresivamente más abstractas [ACS24, SB18].

El Proceso de Optimización

Dado que las redes neuronales carecen de una solución de forma cerrada, sus parámetros θ se ajustan utilizando métodos de optimización iterativa. El proceso se fundamenta en tres componentes técnicos [ACS24]:

- **Función de Pérdida (*Loss Function*):** Un objetivo matemático diferenciable $\mathcal{L}(\theta)$ que cuantifica la discrepancia entre las predicciones de la red y los valores objetivo. Frecuentemente se emplea el Error Cuadrático Medio (MSE).
- **Descenso de Gradiente:** El optimizador actualiza los parámetros moviéndose en la dirección del gradiente negativo $-\nabla_{\theta} \mathcal{L}(\theta)$, ponderado por una tasa de aprendizaje α . En la práctica se utiliza el Descenso de Gradiente por Mini-lotes (*Mini-batch Gradient Descent*), que muestrea un subconjunto aleatorio de datos para ofrecer un equilibrio óptimo entre la estabilidad del gradiente y el costo computacional. Optimizadores modernos como Adam adaptan dinámicamente las tasas de aprendizaje para acelerar la convergencia.
- **Retropropagación (*Backpropagation*):** Para que el descenso de gradiente sea posible en arquitecturas profundas, es necesario computar las derivadas parciales de la función de pérdida respecto a cada parámetro. El algoritmo de *backpropagation* logra esto aplicando eficientemente la regla de la cadena de derivadas, propagando los gradientes desde la capa de salida hacia las capas de entrada.

2.2.4 Aprendizaje por Refuerzo Profundo (DRL)

El Aprendizaje por Refuerzo Profundo (DRL) combina los algoritmos de RL con la capacidad de generalización del aprendizaje profundo. Esta integración es fundamental cuando los espacios

de estado son continuos o de alta dimensionalidad, donde es estadísticamente improbable que un agente visite el mismo estado múltiples veces. Sin embargo, el DRL exige aproximadores robustos capaces de procesar flujos de datos correlacionados temporalmente y de rastrear objetivos no estacionarios [ACS24].

El Problema de la Tríada Mortal (*Deadly Triad*)

La aplicación directa de redes neuronales al aprendizaje por refuerzo introduce vulnerabilidades analíticas. Sutton y Barto [SB18] establecen que la inestabilidad de los parámetros y la divergencia de los valores están garantizadas matemáticamente si un algoritmo combina simultáneamente tres elementos fundamentales:

- **Aproximación de Funciones:** Uso de aproximadores potentes y escalables, como las redes neuronales, que extienden el aprendizaje generalizando a través del espacio de estados.
- **Bootstrapping:** La práctica de actualizar estimaciones de valor apoyándose en otras estimaciones aprendidas previamente (como en los métodos TD), en lugar de esperar la consecución de retornos reales completos.
- **Entrenamiento *Off-Policy*:** Optimizar la función de valor utilizando una distribución de datos o transiciones generadas por una política de comportamiento distinta a la política objetivo que se desea evaluar o mejorar.

El análisis de la Tríada Mortal argumenta que es fácticamente imposible prescindir de cualquiera de estos tres vértices en sistemas de control escalables [SB18]. Renunciar a la aproximación de funciones restringiría el control a problemas tabulares diminutos. Descartar el *bootstrapping* mitigaría la inestabilidad, pero paralizaría la eficiencia de datos y la viabilidad computacional al requerir almacenar secuencias episódicas enteras. Finalmente, sacrificar el aprendizaje *off-policy* anularía la capacidad del agente de aprender de forma concurrente múltiples modelos predictivos a partir de un único flujo de experiencia. Por consiguiente, resulta imperativo tolerar la Tríada Mortal e incorporar mitigaciones algorítmicas estructurales.

Deep Q-Networks (DQN)

En los métodos basados en valor, DRL sustituye la tabla clásica por una red neuronal $Q(s, a; \theta)$. En espacios de acción discretos, el algoritmo *Deep Q-Networks* (DQN) procesa el estado s como vector de entrada y computa simultáneamente las estimaciones de valor para todas las acciones en su capa de salida [ACS24, MKS⁺15].

La inestabilidad descrita por la Tríada Mortal se manifiesta en DQN como el “problema del blanco móvil”: al generalizar, una actualización que incrementa el valor de un estado modifica de forma inadvertida los valores de otros estados. Si además las secuencias de entrenamiento presentan una alta correlación temporal, la red sufre de olvido catastrófico, sobreajustándose a la experiencia más reciente. Para lograr convergencia, DQN introduce dos innovaciones estructurales imperativas [ACS24]:

- **Redes Objetivo (*Target Networks*):** Se emplea una red neuronal secundaria separada cuyos parámetros θ^- se congelan temporalmente. Esta red se utiliza exclusivamente para calcular los valores objetivo en el error TD, amortiguando las oscilaciones y estabilizando el blanco de aprendizaje.
- **Búferes de Repetición (*Replay Buffers*):** Se almacenan las transiciones históricas del agente (s, a, r, s') . El entrenamiento se realiza extrayendo mini-lotes aleatorios de esta memoria, lo cual destruye la correlación temporal intrínseca de los procesos de decisión de Markov y estabiliza la varianza del gradiente.

La función de pérdida minimizada por DQN es:

$$\mathcal{L}(\theta) = \mathbb{E}_{(s_j, a_j, r_j, s_{j+1}) \sim \mathcal{D}} \left[\left(\underbrace{r_j + \gamma \max_{a'} \hat{Q}(s_{j+1}, a'; \theta^-)}_{\text{Valor Objetivo de TD}} - \underbrace{Q(s_j, a_j; \theta)}_{\text{Predicción Actual}} \right)^2 \right] \quad (2.11)$$

Algorithm 1 Algoritmo *Deep Q-Networks* (DQN) con *Replay Buffer*

- 1: Inicializar la memoria de repetición $\mathcal{D}$ con capacidad N
 - 2: Inicializar la red de acción-valor Q con pesos aleatorios θ
 - 3: Inicializar la red objetivo $\hat{Q}$ con pesos $\theta^- = \theta$
 - 4: **for** episodio = 1 hasta M **do**
 - 5: Inicializar secuencia y obtener estado inicial s_1
 - 6: **for** $t = 1$ hasta T **do**
 - 7: Seleccionar una acción a_t mediante política ϵ -greedy a partir de $Q(s_t, a; \theta)$
 - 8: Ejecutar acción a_t , observar recompensa r_t y siguiente estado s_{t+1}
 - 9: Almacenar transición (s_t, a_t, r_t, s_{t+1}) en $\mathcal{D}$
 - 10: Muestrear un minilote aleatorio de transiciones (s_j, a_j, r_j, s_{j+1}) desde $\mathcal{D}$
 - 11: Calcular objetivo $y_j = \begin{cases} r_j & \text{si } s_{j+1} \text{ es terminal} \\ r_j + \gamma \max_{a'} \hat{Q}(s_{j+1}, a'; \theta^-) & \text{en otro caso} \end{cases}$
 - 12: Realizar un paso de descenso de gradiente respecto a la pérdida $(y_j - Q(s_j, a_j; \theta))^2$ para ajustar θ
 - 13: Cada C pasos, sincronizar la red objetivo: $\theta^- \leftarrow \theta$
 - 14: **end for**
 - 15: **end for**
-

Aproximación de Políticas (Gradiente de Política)

Como alternativa a derivar la política de forma indirecta a partir de una función de valor (por ejemplo, mediante la selección ϵ -greedy detallada en DQN), DRL permite parametrizar de manera directa la política del agente mediante una red neuronal $\pi(a|s; \phi)$ [ACS24].

Para espacios de acción discretos, la red recibe el estado s como entrada y emite un valor escalar de preferencia para cada acción. Estas preferencias se transforman de forma analítica en una distribución de probabilidad mediante una función *softmax*. Parametrizar directamente la política resulta indispensable en entornos donde la política óptima es inherentemente probabilística (como equilibrios de Nash en juegos de suma cero o bajo observabilidad parcial), y habilita la extensión nativa del control a espacios de acción continuos modelando parámetros de distribuciones estadísticas [ACS24].

En lugar de minimizar un error de predicción temporal, la optimización paramétrica se rige por el Teorema del Gradiente de Política (*Policy Gradient Theorem*). Este teorema proporciona la justificación formal para actualizar los parámetros ϕ ascendiendo por el gradiente del rendimiento esperado [SB18]:

$$\nabla_{\phi} J(\phi) \propto \sum_s \Pr(s|\pi) \sum_a Q^{\pi}(s, a) \nabla_{\phi} \pi(a|s; \phi) \quad (2.12)$$

Esta actualización incrementa la probabilidad de ejecutar aquellas acciones que están asociadas a mayores retornos esperados, normalizadas por su probabilidad actual [ACS24].

Proximal Policy Optimization (PPO)

DQN pertenece a la familia de métodos basados en valor y resulta natural para espacios de acción discretos. Sin embargo, una parte importante del DRL moderno utiliza métodos actor-

crítico, que combinan aprendizaje directo de políticas con estimación de valores. En este esquema se mantienen dos componentes, implementados como redes separadas o como cabezales de una misma arquitectura:

- **Actor** ($\pi_\theta(a | s)$): representa la política paramétrica y produce una distribución de probabilidad sobre las acciones disponibles.
- **Crítico** ($V_\phi(s)$): estima el valor esperado de los estados y proporciona una señal para reducir la varianza de las actualizaciones del actor.

Dentro de esta familia, *Proximal Policy Optimization* (PPO) se consolidó como uno de los algoritmos de referencia del estado del arte práctico en aprendizaje por refuerzo profundo, debido a su balance entre estabilidad, simplicidad de implementación y rendimiento empírico [SWD⁺17]. Su motivación parte de una dificultad conocida de los métodos de gradiente de política: actualizaciones demasiado grandes pueden modificar la política de forma abrupta y degradar el desempeño.

PPO aborda este problema mediante un objetivo sustituto recortado (*clipped surrogate objective*), que limita cuánto puede alejarse la nueva política de la política que generó los datos. Dada la razón de probabilidad

$$r_t(\theta) = \frac{\pi_\theta(a_t | s_t)}{\pi_{\theta_{\text{old}}}(a_t | s_t)} \quad (2.13)$$

entre la política actual y la política anterior, PPO optimiza el siguiente objetivo:

$$L^{CLIP}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (2.14)$$

Aquí, $\hat{A}_t$ es una estimación de la ventaja, es decir, una medida de cuánto mejor o peor resultó una acción respecto de lo esperado por el crítico. El operador clip restringe la razón $r_t(\theta)$ al intervalo $[1 - \epsilon, 1 + \epsilon]$, reduciendo el incentivo a realizar actualizaciones que cambien excesivamente la política en una sola iteración.

En la práctica, la función objetivo utilizada en PPO suele combinar tres términos: el objetivo de política, una pérdida del crítico para ajustar la función de valor y un término de entropía que favorece la exploración:

$$\mathcal{L}^{PPO}(\theta, \phi) = \hat{\mathbb{E}}_t \left[L^{CLIP}(\theta) - c_1 \left(V_\phi(s_t) - V_t^{\text{target}} \right)^2 + c_2 S[\pi_\theta](s_t) \right] \quad (2.15)$$

PPO es esencialmente un método *on-policy*: recolecta trayectorias con la política vigente, estima ventajas y realiza varias épocas de optimización sobre ese bloque de experiencia. En el contexto de este trabajo, su importancia no radica solo en su desempeño como algoritmo de agente único, sino también en que sirve como base para extensiones multi-agente utilizadas como líneas de investigación actuales, entre ellas IPPO, MAPPO y HAPPO.

Algorithm 2 Algoritmo *Proximal Policy Optimization* (PPO) - Variante *Actor-Critic*

- 1: Inicializar parámetros de política (actor) θ y función de valor (crítico) ϕ
 - 2: **for** iteración = 1, 2, ... **do**
 - 3: Recolectar un conjunto de trayectorias $\mathcal{D}_k = \{\tau_i\}$ ejecutando la política actual π_θ en el entorno
 - 4: Calcular las recompensas acumuladas esperadas para cada paso temporal
 - 5: Calcular las estimaciones de la ventaja $\hat{A}_t$ basándose en los valores del crítico $V_\phi(s)$
 - 6: Optimizar el objetivo $L^{CLIP}(\theta)$ respecto a θ durante K épocas (*epochs*) sobre minilotes de $\mathcal{D}_k$
 - 7: Optimizar la función de pérdida del crítico $L^V(\phi) = (V_\phi(s_t) - \hat{V}_t)^2$ respecto a ϕ
 - 8: **end for**
-

2.3 Aprendizaje por Refuerzo Multi-Agente (MARL)

El aprendizaje por refuerzo multi-agente (*Multi-Agent Reinforcement Learning*, MARL) generaliza los principios del RL hacia sistemas donde múltiples entidades aprenden e interactúan simultáneamente en un entorno compartido [ACS24]. A diferencia del caso individual, las acciones de cada agente modifican el estado global del sistema, lo que induce una dinámica no estacionaria desde la perspectiva local de cualquier participante. En el contexto del control de tráfico urbano, las intersecciones vecinas comparten un objetivo común —maximizar la eficiencia vehicular—, configurando un escenario estrictamente cooperativo.

2.3.1 Procesos de Decisión de Markov Parcialmente Observables Descentralizados (Dec-POMDP)

Los entornos cooperativos multi-agente suelen formalizarse matemáticamente mediante el marco de los Procesos de Decisión de Markov Parcialmente Observables Descentralizados (Dec-POMDP). Este modelo para n agentes se define como una tupla $\langle \mathcal{S}, \{\mathcal{A}_i\}_{i=1}^n, T, R, \{\Omega_i\}_{i=1}^n, O, \gamma \rangle$, donde:

- $\mathcal{S}$ es el conjunto de estados globales del entorno.
- $\mathcal{A}_i$ corresponde al espacio de acciones disponibles para el agente i .
- $T(s' \mid s, a_{1:n})$ representa la función de transición conjunta.
- $R(s, a_{1:n})$ es la función de recompensa compartida.
- Ω_i denota el conjunto de observaciones individuales del agente i , regidas por la función de observación $O(o_{1:n} \mid s', a_{1:n})$.

En este esquema, cada agente basa sus decisiones en su historia local de observaciones τ_i , con el propósito de aprender una política descentralizada $\pi_i(a_i \mid \tau_i)$ que, al combinarse con las demás, maximice el retorno conjunto del sistema [AOS20].

2.3.2 Desafíos Fundamentales en MARL

La aplicación práctica de los métodos descritos en entornos de control interactivos enfrenta obstáculos analíticos significativos que no existen en el RL de agente único [ACS24]. A medida que aumenta el número de intersecciones gestionadas, el espacio conjunto de observaciones y acciones experimenta un crecimiento exponencial, pero los desafíos teóricos más severos radican en la dinámica de la interacción:

- **No Estacionariedad:** Desde la perspectiva de un controlador individual, las políticas de los demás semáforos actúan como parte de la dinámica de transición del entorno. Como todos los agentes aprenden y adaptan sus pesos neuronales de manera concurrente, las probabilidades de transición subyacentes cambian de forma continua. Esta co-adaptación rompe la Propiedad de Markov base e induce dinámicas de aprendizaje inestables u oscilatorias [ACS24, FNF⁺17].
- **Observabilidad Parcial:** Dado el modelo Dec-POMDP inherente, la falta de telemetría global restringe la visión de cada agente a variables puramente locales. Esto introduce incertidumbre y estocasticidad en la varianza de los gradientes evaluados, dificultando la estimación precisa de las funciones de valor.

- **Asignación de Crédito Multi-Agente (*Credit Assignment*):** En juegos de recompensa común, resulta complejo discernir analíticamente la contribución o el demérito marginal que la acción de un semáforo aislado produjo sobre el desempeño sistémico global. Una decisión local subóptima podría recibir un refuerzo positivo si el resto de la red operó eficientemente, sesgando las actualizaciones de la política [ACS24].

2.3.3 Paradigmas de Entrenamiento y Ejecución

Para abordar estas patologías en escenarios Dec-POMDP, la literatura clasifica a los algoritmos en función de cómo fluye la información durante el proceso de optimización. Se distinguen fundamentalmente dos enfoques: el Aprendizaje Independiente (*Independent Learning*, IL) y el Entrenamiento Centralizado con Ejecución Descentralizada (CTDE, por sus siglas en inglés) [ZLYZ23].

En el primero, los agentes se entrenan localmente utilizando métodos de agente único, asumiendo empíricamente al resto de la red como parte de las dinámicas inherentes del entorno. En el segundo, durante la fase de entrenamiento simulado (*offline*), los algoritmos explotan información global privilegiada (historiales conjuntos, congestión total de la red) para estabilizar la convergencia de las funciones de valor. Una vez finalizado el entrenamiento, extraen políticas condicionadas estrictamente a observaciones locales para su ejecución descentralizada (*online*) en la infraestructura urbana.

2.3.4 *Multi-Agent Deep Reinforcement Learning* (MADRL)

La integración de los formalismos Dec-POMDP con la capacidad de aproximación generalizada del aprendizaje profundo ha dado origen al campo del *Multi-Agent Deep Reinforcement Learning* (MADRL) [LWT⁺17]. Esta área agrupa los enfoques prevalentes para el control adaptativo de redes de semáforos a gran escala, en las que el crecimiento exponencial del espacio de estados y acciones vuelve inviables a los algoritmos tabulares.

Aprendizaje Independiente (IL): IDQN e IPPO

En el Aprendizaje Independiente, cada intersección semafórica actúa como un agente aislado.

- ***Independent DQN* (IDQN):** Representa la extensión multi-agente más directa de Q-Learning profundo [TMK⁺17]. Su principal vulnerabilidad metodológica radica en que, al ser un algoritmo *off-policy*, depende críticamente del remuestreo de transiciones desde un *Replay Buffer*. En un entorno MARL no estacionario, estas memorias corresponden a configuraciones históricas donde los demás agentes operaban bajo políticas que ya han cambiado. Entrenar repetidamente sobre estos datos obsoletos agrava la no estacionariedad y precipita la inestabilidad matemática descrita por la Tríada Mortal, llevando con frecuencia a la divergencia del algoritmo [FNF⁺17].
- ***Independent PPO* (IPPO):** Asigna una instancia del algoritmo PPO a cada agente. A diferencia de IDQN, la literatura ha demostrado empíricamente que IPPO exhibe una mayor robustez técnica frente a la no estacionariedad del tránsito [dWGM⁺20]. Esta resiliencia se fundamenta en su naturaleza inherentemente *on-policy*: al descartar memorias pasadas y extraer gradientes únicamente de datos muestreados en proximidad temporal directa con la política conjunta actual, asegura que las actualizaciones respondan de manera empírica a la dinámica vigente de la red. Adicionalmente, el recorte paramétrico (*clipping*) previene saltos perjudiciales en el espacio de la política.

Paradigma CTDE: MAPPO y HAPPO

Para abordar rigurosamente la asignación de crédito y la no estacionariedad sin sacrificar la escalabilidad de la ejecución descentralizada, los métodos actor-crítico bajo el paradigma de Entrenamiento Centralizado con Ejecución Descentralizada (CTDE) constituyen esquemas ampliamente adoptados. A diferencia de los métodos de descomposición de valor diseñados para espacios de acción discretos (como VDN [SLG⁺17] o QMIX [RSS⁺18]), que factorizan la función de acción-valor conjunta mediante restricciones de monotonicidad, los enfoques basados en gradiente de política aproximan y optimizan directamente la política de los agentes. En este contexto, el uso de aproximadores basados en optimización de política proximal (PPO) se ha extendido al ámbito cooperativo multiagente a través de dos variantes principales: MAPPO [YVV⁺22] y HAPPO [KCW⁺21, ZKF⁺24].

Multi-Agent Proximal Policy Optimization (MAPPO) MAPPO adapta el algoritmo PPO de agente único al entorno multiagente conservando la estructura de actores descentralizados y un crítico centralizado global [YVV⁺22]. Durante la fase de entrenamiento, el crítico centralizado $V_\phi(s)$ tiene acceso al estado global s de la simulación (o a la concatenación de las observaciones locales de todos los agentes), lo que le permite estimar el valor esperado del retorno conjunto con mayor precisión y reducir la varianza de los gradientes de la política. Durante la ejecución, el crítico se descarta y cada agente selecciona sus acciones basándose únicamente en su política local $\pi_{\theta_i}(a_i | o_i)$, alimentada por su observación individual o_i .

A pesar de la simplicidad de esta extensión, la investigación de Yu et al. [YVV⁺22] demostró que el rendimiento práctico de MAPPO es altamente sensible a la configuración de determinados factores de diseño y parámetros. Los autores identificaron cinco aspectos críticos para estabilizar el aprendizaje en entornos cooperativos:

1. **Normalización del valor:** Debido a que las políticas conjuntas cambian a lo largo del entrenamiento, los objetivos de la función de valor experimentan fluctuaciones severas, induciendo inestabilidad en la regresión del crítico. MAPPO mitiga esta patología estandarizando los objetivos del valor mediante estimaciones móviles de su media y desviación estándar. Al calcular la ventaja mediante el método GAE, las salidas del crítico se desnormalizan para preservar la escala física del retorno. Este procedimiento resulta crucial para estabilizar la actualización del crítico en escenarios con recompensas de magnitud variable.
2. **Representación de la entrada de la función de valor:** La elección del estado global provisto al crítico centralizado define la calidad de la estimación. La concatenación directa de observaciones locales (CL) incrementa la dimensionalidad del espacio de entrada, dificultando el aprendizaje del crítico en redes con múltiples intersecciones. Por otro lado, un estado provisto por el entorno (EP) que solo contenga métricas globales puede omitir información local relevante para cada nodo (como fases activas o identidades de los carriles). MAPPO propone construir un estado global específico para cada agente (AS) mediante la unión de EP y la observación local o_i , aplicando un filtrado de características redundantes (FP) para limitar la dimensionalidad del vector de entrada sin perder información crítica.
3. **Uso y reutilización de datos:** En aprendizaje de agente único, es habitual reutilizar los datos recolectados durante decenas de épocas de entrenamiento dividiendo el lote en múltiples minilotes (e.g., 32 o 64). Sin embargo, en el escenario multiagente, la no estacionariedad del entorno provoca que una reutilización excesiva de la experiencia degrade el aprendizaje de la política conjunta. Por ello, MAPPO restringe la optimización a un máximo de 10 épocas en tareas complejas (y 15 en entornos simples), y recomienda evitar la división en minilotes (utilizando solo 1 o 2 subdivisiones) para evitar actualizaciones desalineadas con la política que recolectó los datos.

4. **Recorte en PPO (Clipping):** El parámetro de recorte ϵ de PPO limita la magnitud del cambio de la política en una sola iteración. Para contrarrestar la no estacionariedad inducida por el aprendizaje concurrente de los semáforos, MAPPO requiere mantener $\epsilon \leq 0.2$ (típicamente entre 0.05 y 0.1). Un valor de recorte pequeño ralentiza la velocidad de convergencia inicial, pero acota las desviaciones en la distribución de acciones conjuntas, asegurando transiciones estables hacia políticas coordinadas.
5. **Tamaño del lote (Batch Size):** La precisión del gradiente estimado por el actor y el crítico depende del tamaño del lote de trayectorias *on-policy*. Existe un umbral de tamaño de lote por debajo del cual el estimador de la ventaja presenta una varianza que impide al sistema descubrir patrones de coordinación eficientes. Una vez superado este umbral, aumentar el tamaño del lote no mejora el rendimiento y penaliza la eficiencia de muestreo.

Algorithm 3 Algoritmo *Multi-Agent Proximal Policy Optimization* (MAPPO)

- 1: Inicializar los parámetros de la política (actor) θ y del valor (crítico) ϕ
 - 2: Inicializar el búfer de datos $\mathcal{D} \leftarrow \emptyset$
 - 3: **for** iteración = 1, 2, ... **do**
 - 4: Recolectar trayectorias *on-policy* para todos los agentes utilizando la política conjunta π_θ
 - 5: Calcular las ventajas conjuntas $\hat{A}_t$ mediante GAE a partir del crítico $V_\phi(s_t)$
 - 6: Calcular los retornos objetivos R_t^{target} para actualizar el crítico
 - 7: Almacenar las transiciones $(s_t, o_t, a_t, \hat{A}_t, R_t^{\text{target}})$ en $\mathcal{D}$
 - 8: **for** época = 1 hasta K **do**
 - 9: Muestrear minilotes de datos desde $\mathcal{D}$
 - 10: Actualizar la política minimizando la pérdida de recorte PPO conjunta:
 $\mathcal{L}^{\text{CLIP}}(\theta) = \mathbb{E}_t \left[\min \left(r_t^i(\theta_i) \hat{A}_t, \text{clip}(r_t^i(\theta_i), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$
 - 11: Actualizar el crítico ϕ minimizando el error cuadrático medio del valor:
 $\mathcal{L}^{\text{VF}}(\phi) = \mathbb{E}_t \left[\left(V_\phi(s_t) - R_t^{\text{target}} \right)^2 \right]$
 - 12: **end for**
 - 13: Vaciar el búfer de datos $\mathcal{D} \leftarrow \emptyset$
 - 14: **end for**
-

Heterogeneous-Agent Proximal Policy Optimization (HAPPO) En redes urbanas complejas, las intersecciones presentan asimetrías físicas y operacionales marcadas, tales como diferencias en el número de accesos, demandas vehiculares contrapuestas y capacidades geométricas disímiles. En estos escenarios, la práctica habitual de compartir parámetros entre los agentes (Parameter Sharing) impone una homogeneización que restringe la especialización táctica necesaria para cada intersección. No obstante, entrenar políticas independientes sin compartir parámetros (como en IPPO) elimina las garantías teóricas de convergencia y suele conducir a la divergencia del aprendizaje debido a la actualización simultánea de todos los agentes, lo que provoca que ninguno pueda anticipar la dirección de cambio de sus cooperadores.

HAPPO resuelve esta limitación mediante el paradigma de Aprendizaje Multiagente Heterogéneo (HARL), proporcionando un marco analítico con garantías de mejora monótona y convergencia a un equilibrio de Nash [KCW⁺21, ZKF⁺24]. El núcleo matemático de HAPPO se fundamenta en dos contribuciones fundamentales:

1. Lema de Descomposición de la Ventaja Multiagente: En cualquier juego markoviano cooperativo, para una política conjunta π y cualquier permutación ordenada de agentes $i_{1:n}$, la ventaja de una acción conjunta a en un estado s puede descomponerse exactamente como la suma de las ventajas marginales de cada agente tomadas secuencialmente, condicionadas por

las acciones de los agentes precedentes en el ordenamiento v.g.:

$$A^\pi(s, a) = \sum_{j=1}^n A_{i_j}^\pi(s, a_{i_{1:j-1}}, a_{i_j}) \quad (2.16)$$

donde la ventaja marginal de un agente individual i_m se define formalmente como:

$$A_{i_m}^\pi(s, a_{i_{1:m-1}}, a_{i_m}) \doteq Q_{i_{1:m}}^\pi(s, a_{i_{1:m-1}}, a_{i_m}) - Q_{i_{1:m-1}}^\pi(s, a_{i_{1:m-1}}) \quad (2.17)$$

En esta formulación, las acciones de los agentes que aún no han sido evaluados en la secuencia $(i_{m+1:n})$ se marginalizan por esperanza matemática bajo la política conjunta actual π . La relevancia de este lema radica en que no requiere supuestos sobre la estructura o aditividad de la función de valor conjunta, a diferencia de los esquemas de factorización clásicos como VDN o QMIX.

2. Esquema de Actualización Secuencial: Para explotar analíticamente esta descomposición, HAPPO propone un proceso en el cual los agentes actualizan sus políticas de manera secuencial y no simultánea dentro de cada paso de optimización. En cada iteración de aprendizaje k , se selecciona al azar una permutación de los agentes $i_{1:n} \in \text{Sym}(n)$. El sorteo aleatorio de la secuencia asegura que ningún agente monopolice la prioridad de actualización, lo que garantiza la convergencia hacia un equilibrio de Nash [ZKF⁺24].

Bajo este esquema, cuando llega el turno de actualización del agente i_m , los agentes precedentes $i_{1:m-1}$ ya han modificado sus políticas a sus nuevos valores $\pi_{\theta_{k+1}}^{i_{1:m-1}}$, mientras que los agentes sucesores $i_{m+1:n}$ conservan sus políticas de la iteración anterior $\pi_{\theta_k}^{i_{m+1:n}}$. La optimización de la política del agente i_m se guía entonces por la ventaja marginal $A_{i_m}^{\pi_{\theta_k}}(s, a_{i_{1:m-1}}, a_{i_m})$.

Kuba et al. [KCW⁺21] demostraron que esta ventaja marginal puede estimarse de manera eficiente a partir del estimador de ventaja conjunta de la política anterior $A^{\pi_{\theta_k}}(s, a)$, sin necesidad de entrenar o almacenar un crítico centralizado para cada agente individual. Esto se logra multiplicando la ventaja conjunta por el producto de las razones de probabilidad de las políticas de los agentes que ya se han actualizado en la secuencia, definiendo la razón de política compuesta $M_{i_{1:m}}(s, a)$:

$$M_{i_{1:m}}(s, a) \doteq \left(\prod_{j=1}^{m-1} \frac{\pi_{\theta_{k+1}}^{i_j}(a^{i_j} | s)}{\pi_{\theta_k}^{i_j}(a^{i_j} | s)} \right) A^{\pi_{\theta_k}}(s, a) \quad (2.18)$$

donde para el primer agente en la secuencia ($m = 1$), el término de la productoria se define como la unidad, de modo que $M_{i_1}(s, a)$ equivale a la ventaja conjunta $A^{\pi_{\theta_k}}(s, a)$. La razón de política compuesta actúa como un factor de muestreo de importancia que corrige el desfase provocado por las actualizaciones ya efectuadas por los agentes precedentes.

De este modo, para actualizar la política del agente i_m bajo restricciones de optimización proximal, HAPPO maximiza de forma iterativa el objetivo sustituto recortado ponderado por la razón compuesta:

$$L^{HAPPO}(\theta^{i_m}) = \mathbb{E}_t \left[\min \left(r_t^{i_m}(\theta^{i_m}) M_{i_{1:m}}(s_t, a_t), \text{clip} \left(r_t^{i_m}(\theta^{i_m}), 1 - \epsilon, 1 + \epsilon \right) M_{i_{1:m}}(s_t, a_t) \right) \right] \quad (2.19)$$

donde $r_t^{i_m}(\theta^{i_m}) \doteq \frac{\pi_{\theta^{i_m}}^{i_m}(a_t^{i_m} | s_t)}{\pi_{\theta_k}^{i_m}(a_t^{i_m} | s_t)}$ corresponde a la razón de probabilidad de la política individual bajo los nuevos parámetros θ^{i_m} respecto a la política anterior.

Esta formulación proporciona dos ventajas fundamentales para el control semafórico en redes urbanas heterogéneas:

- **Eficiencia de datos:** A pesar de emplear un esquema de actualización secuencial y permitir políticas asimétricas para cada intersección, HAPPO solo requiere la estimación de una única función de valor conjunta $V(s)$ (un único crítico centralizado) para calcular la

ventaja de la red $A(s, a)$. La influencia y co-adaptación de las intersecciones vecinas se resuelve de manera endógena mediante el cálculo de la razón compuesta $M_{i_{1:m}}(s, a)$ durante el paso de optimización.

- **Progreso monótono y estabilidad:** Al integrar la descomposición de la ventaja con el recorte de la razón de probabilidad de PPO, HAPPO acota el cambio en la política conjunta de tal forma que se garantiza un progreso monótono en el retorno esperado del sistema, es decir, $J(\pi_{k+1}) \geq J(\pi_k)$ en cada iteración, mitigando las dinámicas oscilatorias destructivas características del aprendizaje independiente.

Algorithm 4 Algoritmo *Heterogeneous-Agent Proximal Policy Optimization* (HAPPO)

```

1: Inicializar los parámetros de las políticas individuales  $\{\theta^i, \forall i \in \mathcal{N}\}$  y del crítico centralizado  $V_\phi(s)$ 
2: for iteración = 1, 2, ... do
3:   Recolectar un conjunto de trayectorias  $\mathcal{D}$  utilizando la política conjunta  $\pi_\theta$ 
4:   Calcular el estimador de ventaja conjunta  $\hat{A}(s, a)$  con GAE a partir del crítico  $V_\phi(s)$ 
5:   Sorteo aleatorio de una permutación de los agentes  $i_{1:n} \in \text{Sym}(n)$ 
6:   Inicializar la razón de política conjunta  $M_{i_1}(s, a) \leftarrow \hat{A}(s, a)$ 
7:   for  $m = 1 \dots n$  do
8:     Actualizar  $\theta^{i_m}$  a  $\theta_{k+1}^{i_m}$  maximizando el objetivo:

$$L^{\text{HAPPO}}(\theta^{i_m}) = \hat{\mathbb{E}}_t \left[ \min \left( r_t^{i_m}(\theta^{i_m}) M_{i_{1:m}}(s_t, a_t), \text{clip} \left( r_t^{i_m}(\theta^{i_m}), 1 - \epsilon, 1 + \epsilon \right) M_{i_{1:m}}(s_t, a_t) \right) \right]$$

9:     Calcular la razón compuesta para el próximo agente (si  $m < n$ ):

$$M_{i_{1:m+1}}(s_t, a_t) \leftarrow \frac{\pi_{\theta_{k+1}^{i_m}}(a_t^{i_m} | o_t^{i_m})}{\pi_{\theta_k^{i_m}}(a_t^{i_m} | o_t^{i_m})} M_{i_{1:m}}(s_t, a_t)$$

10:   end for
11:   Actualizar el crítico centralizado  $\phi$  mediante descenso de gradiente:

$$\mathcal{L}^{\text{VF}}(\phi) = \hat{\mathbb{E}}_t \left[ \left( V_\phi(s_t) - R_t^{\text{target}} \right)^2 \right]$$

12: end for
```

2.4 Control de Tráfico Urbano mediante MARL

2.4.1 Entorno de Simulación para Control Semafórico

La interfaz TraCI (*Traffic Control Interface*) permite consultar valores de una simulación en ejecución y modificar su estado de forma externa durante el avance paso a paso [DLR25]. A través de esta interfaz, un controlador puede obtener telemetría de vehículos, carriles, detectores, arcos o semáforos, y también aplicar cambios sobre el estado o la fase de los semáforos. Esta capacidad convierte a SUMO en un entorno experimental adecuado para evaluar decisiones secuenciales de control y para integrarlo con bibliotecas orientadas a aprendizaje por refuerzo, como SUMO-RL [ALBBW⁺18, Ale].

En este sentido, la integración entre el simulador y la política de control establece un bucle cerrado en el que el simulador actúa como el entorno (u *environment*) y la interfaz de programación expone la telemetría y los actuadores necesarios para guiar el proceso de aprendizaje, permitiendo que el controlador interactúe dinámicamente paso a paso.

2.4.2 Modelado del Problema del Control de Semáforos (Espacio de Estados, Acciones y Recompensas)

Desde la perspectiva del aprendizaje por refuerzo, la formulación del control semafórico establece una correspondencia directa entre los conceptos físicos del dominio del tránsito y los componentes

de un problema de decisión secuencial. Las variables que definen el estado del tránsito en la intersección se traducen en observaciones para el agente, el control de las indicaciones luminosas define el espacio de acciones, y el desempeño operativo del sistema se utiliza para guiar el aprendizaje mediante la función de recompensa:

- **Espacio de observaciones (estados):** variables como la longitud de cola, el número de vehículos detenidos, el flujo de entrada o el tiempo de espera acumulado en los accesos de la intersección.
- **Espacio de acciones:** la selección o permanencia de fases semafóricas, respetando los tiempos mínimos y máximos de seguridad física de la intersección.
- **Función de recompensa:** métricas que cuantifican la calidad del flujo, tales como la reducción de la demora total, la disminución de detenciones consecutivas o la mitigación del crecimiento de colas en accesos críticos.

Esta formulación no implica que el algoritmo aprenda ni sustituya los modelos físicos del simulador: la dinámica vehicular permanece como parte del entorno, mientras el controlador aprende una política que asigna acciones a observaciones con el objetivo de mejorar el desempeño operativo de forma empírica [W⁺19, Ale, SB18].

2.4.3 Coordinación entre Intersecciones y Mitigación de Congestión

En una red urbana semaforizada, el comportamiento de cada intersección no puede analizarse de manera aislada. Las decisiones de fase modifican los patrones de descarga, propagación y acumulación de vehículos, afectando tanto a intersecciones vecinas como a la evolución futura del tránsito en la propia red. Esta interdependencia espacial y temporal justifica el uso de enfoques cooperativos de aprendizaje por refuerzo multiagente, en los que múltiples controladores coordinan sus decisiones para mejorar el desempeño global y no solo el de una intersección individual [W⁺19, CWCL22].

Metodología

3.1 Integración de SUMO y el Agente de Aprendizaje por Refuerzo

Para implementar el entrenamiento y la evaluación de la política de control, el flujo de ejecución sigue un esquema de bucle cerrado en el que el script controlador se comunica con la instancia activa de SUMO a través de la interfaz TraCI. Este ciclo operativo se define por el envío secuencial de acciones (selección de fases) y la recepción de telemetría (longitud de colas, ocupación) que se procesan para construir la observación y la recompensa de cada paso de simulación. La Figura 3.1 ilustra la topología de esta interacción.




Figura 3.1: Bucle de control cerrado entre el simulador microscópico SUMO, la interfaz TraCI y el agente de Aprendizaje por Refuerzo en la metodología de entrenamiento.

3.2 Herramientas y Configuración

3.2.1 Edición de Redes y Tránsito

netedit

Código 3.1 ejemplo1.sh

```
1 #!/bin/bash
2 for i in {1..10}
3 do
4   echo $i
5 done
```

Otro formato de código, para utilizar como salida de ejecución.

Código 3.2 Salida del ejemplo1.sh

```
$ ./ejemplo1.sh
1
2
3
4
5
6
7
8
```

9
10

Análisis y discusión de resultados

En este capítulo se presentan y analizan los resultados obtenidos de las ejecuciones de entrenamiento de los algoritmos de estudio mencionados. Con el objetivo de distinguir con claridad las etapas metodológicas del entrenamiento de los agentes, la sección se organiza en tres partes.

En primer lugar, se reportan los resultados del proceso de ajuste de hiperparámetros. En segundo lugar, se evalúan los modelos finales seleccionados en los escenarios planteados, desde redes sintéticas hasta el escenario ubicado en Ciudad de Mendoza. Finalmente, se desarrolla una discusión integradora de los hallazgos, sus implicancias y las principales limitaciones del estudio.

4.1 Resultados del ajuste de hiperparámetros

En esta sección se resume el proceso de ajuste de hiperparámetros y se justifica la configuración utilizada en la evaluación posterior de los modelos.

4.1.1 Diseño del proceso de ajuste

4.1.2 Resultados del ajuste y análisis de sensibilidad

4.1.3 Configuración seleccionada para la evaluación final

4.2 Resultados de los modelos finales

Esta sección reúne los resultados obtenidos con los modelos finales una vez fijada la configuración experimental. La exposición se organiza según el tipo de escenario analizado.

4.2.1 Criterios de evaluación y métricas de comparación

4.2.2 Desempeño en escenarios sintéticos (3×1 , 3×3 , 4×4 heterogéneo)

4.2.3 Desempeño en la red de carreteras de la Ciudad de Mendoza

4.3 Discusión e interpretación de resultados

En esta sección se integran los resultados presentados y se discuten sus principales implicancias en relación con los objetivos del trabajo.

Conclusiones

Por último las conclusiones.

Bibliografía

- [Ach18] Achiam, Joshua: *Spinning Up in Deep Reinforcement Learning*, 2018. OpenAI. Disponible en: <https://spinningup.openai.com/>.
- [ACS24] Albrecht, Stefano V., Filippos Christianos y Lukas Schäfer: *Multi-Agent Reinforcement Learning: Foundations and Modern Approaches*. MIT Press, 2024. <https://www.marl-book.com/>, Consultado en 2025.
- [ALBBW⁺18] Alvarez Lopez, Pablo, Michael Behrisch, Laura Bieker-Walz, Jakob Erdmann, Yun Pang Flötteröd, Robert Hilbrich, Leonhard Lücken, Johannes Rummel, Peter Wagner y Evamarie Wießner: *Microscopic Traffic Simulation using SUMO*. En *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, páginas 2575–2582. IEEE, 2018.
- [Ale] Alegre, Lucas N.: *SUMO-RL 1.4.5 documentation*. Available at: <https://lucasalegre.github.io/sumo-rl/>.
- [AOS20] Amato, Christopher, Frans A. Oliehoek y Matthijs T.J. Spaan: *A Survey of Decentralized Partially Observable Markov Decision Processes and Applications*. Journal of Artificial Intelligence Research, 69:1–72, 2020.
- [APK03] Abdulhai, Baher, Rob Pringle y Grigoris J Karakoulas: *Reinforcement learning for true adaptive traffic signal control*. Journal of Transportation Engineering, 129(3):278–285, 2003.
- [AS22] Ault, James y Guni Sharon: *Cooperative Multi-agent Reinforcement Learning Applied to Multi-intersection Traffic Signal Control*. En *Proceedings of the 31st ACM International Conference on Information & Knowledge Management (CIKM '22)*, 2022. <https://people.engr.tamu.edu/guni/papers/CIKM22-MATCS.pdf>, Fuente: [7, 8] Destaca el "éxito limitado" de SARL y los enfoques independientes en redes.
- [CWCL19] Chu, Tianshu, Jie Wang, Lara Codecà y Zhaojian Li: *Multi-agent deep reinforcement learning for large-scale traffic signal control*. IEEE Transactions on Intelligent Transportation Systems, 21(3):1086–1095, 2019.
- [CWCL22] Chu, Tianshu, Jie Wang, Lara Codecà y Zhaojian Li: *Graph Neural Reinforcement Learning for Intelligent Traffic Signal Control*. IEEE Transactions on Intelligent Transportation Systems, 23(7):8878–8892, 2022.
- [CyMR18] Mayor R., Rafael Cal y: *Ingeniería de tránsito: Fundamentos y aplicaciones*. Alfaomega, 9na edición, 2018.
- [DLR25] DLR – Institute of Transportation Systems: *SUMO User Documentation*, 2025. <https://sumo.dlr.de/docs/>, Consultado en 2025.
- [dWGM⁺20] Witt, Christian Schroeder de, Tarun Gupta, Denys Makoviichuk, Viktor Maksimov, Edward Ivanov, Michael Schmid, Gregory Yakovlev, Philip Torr y cols.: *Is independent learning all you need in the starcraft multi-agent challenge?* arXiv preprint arXiv:2011.09533, 2020.
- [ETAA13] El-Tantawy, Samah, Baher Abdulhai y Hossam Abdulbaqi: *Multiagent reinforcement learning for integrated network of adaptive traffic signal controllers*

- (MARLIN-ATSC): methodology and large-scale application on downtown Toronto. *IEEE Transactions on Intelligent Transportation Systems*, 14(3):1140–1150, 2013.
- [FA11] Fernández A., Rodrigo: *Elementos de la teoría del tráfico vehicular*. Fondo Editorial de la Pontificia Universidad Católica del Perú, 2011.
- [FH21] Feriani, Amal y Ekram Hossain: *Multi-Agent Reinforcement Learning: Key Differences from Single-Agent RL*. arXiv preprint arXiv:2508.07001, 2021. Fuente: [9] Define la no estacionariedad como una diferencia clave de MARL vs SARL.
- [FNF⁺17] Foerster, Jakob, Nantas Nardelli, Gregory Farquhar, Philip H.S. Torr, Pushmeet Kohli y Shimon Whiteson: *Stabilising Experience Replay for Deep Multi-Agent Reinforcement Learning*. En *Proceedings of the 34th International Conference on Machine Learning (ICML)*, páginas 1146–1155. PMLR, 2017.
- [KCW⁺21] Kuba, Jakub Grudzien, Ruiqing Chen, Muning Wen, Ying Wen, Fuchun Sun, Jun Wang y Yaodong Yang: *Trust region policy optimisation in multi-agent reinforcement learning*. arXiv preprint arXiv:2109.11251, 2021.
- [LLW16] Li, Li, Yisheng Lv y Fei Yue Wang: *Traffic signal timing via deep reinforcement learning*. *IEEE/CAA Journal of Automatica Sinica*, 3(3):247–254, 2016.
- [LWT⁺17] Lowe, Ryan, Yi Wu, Aviv Tamar, Jean Harb, Pieter Abbeel y Igor Mordatch: *Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments*. En *Advances in Neural Information Processing Systems (NeurIPS)*, páginas 6379–6390, 2017.
- [MKS⁺15] Mnih, V., K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg y D. Hassabis: *Human-level control through deep reinforcement learning*. *Nature*, 518(7540):529–533, 2015. <https://doi.org/10.1038/nature14236>.
- [ne18] especificados, Autores no: *Traffic congestion cost Americans over \$160 billion in lost productivity*. Citado en arXiv:2406.13693 (Reporte original de UN 2018), 2018. Fuente: [1] Costos de congestión y emisiones de CO2.
- [PW16] Pande, Anurag y Brian Wolshon: *Traffic Engineering Handbook*. John Wiley & Sons, Inc., 7th edición, 2016.
- [RSS⁺18] Rashid, Tabish, Mikayel Samvelyan, Christian Schroeder, Gregory Farquhar, Jakob Foerster y Shimon Whiteson: *Qmix: Monotonic value function factorisation for deep multi-agent reinforcement learning*. En *International conference on machine learning*, páginas 4295–4304. PMLR, 2018.
- [SB18] Sutton, R.S. y A.G. Barto: *Reinforcement learning: An introduction*. The MIT Press, Cambridge, MA, 2nd edición, 2018.
- [SLG⁺17] Sunehag, Peter, Guy Lever, Audrunas Gruslys, Wojciech Marian Czarnecki, Vinicius Zambaldi, Max Jaderberg, Marc Lanctot, Nicolas Sonnerat, Joel Z Leibo, Karl Tuyls y cols.: *Value-decomposition networks for cooperative multi-agent learning*. arXiv preprint arXiv:1706.05296, 2017.
- [SWD⁺17] Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford y Oleg Klimov: *Proximal policy optimization algorithms*. arXiv preprint arXiv:1707.06347, 2017.

- [TMK⁺17] Tampuu, Ardi, Tambet Matiisen, Dorian Kodelja, Ilya Zauss, Kristjan Korjus, Juhan Aru, Jaan Birk y Raul Vicente: *Multiagent cooperation and competition with deep reinforcement learning*. PloS one, 12(4):e0172395, 2017.
- [W⁺19] Wei, H. y cols.: *A survey on traffic signal control methods*, 2019. Available at: <https://arxiv.org/abs/1904.08117>.
- [Wie00] Wiering, Marco A: *Multi-agent reinforcement learning for traffic light control*. Machine learning, 2000.
- [YVV⁺22] Yu, Chao, Akash Velu, Eugene Vinitsky, Jiaxuan Gao, Yu Wang, Alexandre Bayen y Yi Wu: *The surprising effectiveness of ppo in cooperative multi-agent games*. Advances in Neural Information Processing Systems, 35:24611–24624, 2022.
- [ZKF⁺24] Zhong, Yifan, Jakub Grudzien Kuba, Xidong Feng, Siyi Hu, Jiaming Ji y Yaodong Yang: *Heterogeneous-Agent Reinforcement Learning*. Journal of Machine Learning Research, 25:1–67, 2024.
- [ZLYZ23] Zhou, Mengdi, Xiaoteng Li, Yaodong Yang y Weinan Zhang: *A Survey on Centralized Training for Decentralized Execution in Multi-Agent Reinforcement Learning*. Artificial Intelligence Review, 2023.