

Semáforos Inteligentes: Un enfoque con Aprendizaje por Refuerzo Multi Agente

Tesina de Licenciatura en Ciencias de la Computación

Juan Martín Morales

Tutora: Dra Ana Carolina Olivera



UNCUYO
UNIVERSIDAD
NACIONAL DE CUYO



FACULTAD DE
INGENIERÍA

Facultad de Ingeniería
Universidad Nacional de Cuyo

Resumen

En este trabajo se aborda el problema de la congestión vehicular en áreas urbanas, proponiendo una solución basada en el Aprendizaje por Refuerzo Multi-Agente (MARL) Cooperativo para optimizar el control semafórico. Se analiza la evolución del parque automotor en Argentina, destacando el aumento significativo de vehículos y sus consecuencias en la movilidad urbana. Se presentan los desafíos asociados al control semafórico tradicional y se justifica la necesidad de enfoques adaptativos basados en inteligencia artificial. El objetivo principal es desarrollar y evaluar un sistema de control de tráfico que permita mejorar el flujo vehicular mediante políticas coordinadas entre múltiples intersecciones, utilizando simulaciones tanto en escenarios sintéticos como en la red vial real del Gran Mendoza. **Caro: falta completar**

Abstract

In this work, we address the problem of vehicular congestion in urban areas by proposing a solution based on Cooperative Multi-Agent Reinforcement Learning (MARL) to optimize traffic light control. We analyze the evolution of the automotive fleet in Argentina, highlighting the significant increase in vehicles and its consequences on urban mobility. We present the challenges associated with traditional traffic light control and justify the need for adaptive approaches based on artificial intelligence. The main objective is to develop and evaluate a traffic control system that improves vehicular flow through coordinated policies among multiple intersections, using simulations in both synthetic scenarios and the real road network of Greater Mendoza.

Caro: falta completar

Agradecimientos

Página de agradecimientos

Índice

1	Introducción	8
1.1	Motivación	9
2	Marco Teórico	11
2.1	Ingeniería de Tránsito	11
2.1.1	Terminología de Tránsito	12
2.1.2	Fundamentos de la Dinámica Vehicular	13
2.1.3	Sistemas de Control de Tránsito	18
2.1.4	Simulación de Tránsito	20
2.2	Aprendizaje por Refuerzo (RL)	22
2.2.1	El Proceso de Decisión de Markov (MDP)	23
2.2.2	Retorno	24
2.2.3	Función de Acción-Valor y Política	24
2.2.4	<i>Q-Learning</i>	24
2.2.5	<i>Deep Learning</i> y Redes Neuronales	25
2.2.6	<i>Deep Reinforcement Learning</i> (DRL)	25
2.3	Aprendizaje por Refuerzo Multi-Agente (MARL)	26
2.3.1	Procesos de Decisión de Markov Parcialmente Obser- vables Descentralizados (Dec-POMDP)	27
2.3.2	Paradigmas de Entrenamiento y Ejecución	27
2.3.3	Principales Familias de Algoritmos Cooperativos	28
2.3.4	Desafíos Prácticos en MARL	28
2.4	Control de Tráfico Urbano mediante MARL	30
2.4.1	Entorno de Simulación para Control Semafórico	30
2.4.2	Modelado del Problema del Control de Semáforos (Es- pacio de Estados, Acciones y Recompensas)	30
2.4.3	Coordinación entre Intersecciones y Mitigación de Con- gestión	31

Índice de códigos

Índice de figuras

1.1	Evolución de la flota vehicular circulante en Argentina (1990–2025). Datos: AFAC.	8
2.1	Representación esquemática de movimientos vehiculares y puntos de conflicto en una intersección semaforizada.	13
2.2	Relaciones temporales y espaciales entre vehículos consecutivos de una corriente de tránsito: intervalo (h) y espaciamiento (s).	15
2.3	Comparación esquemática de la distribución de intervalos temporales entre vehículos en flujo libre (exponencial negativa, consistente con el proceso de Poisson) y en flujo coordinado por semáforos (distribución desplazada con zona de exclusión física $t_{\min}$ y pico característico de pelotón).	18
2.4	Distribución temporal de la tasa de descarga y pérdidas asociadas durante un intervalo de verde en una aproximación semaforizada.	19
2.5	Representación en SUMO de carriles entrantes (en azul), carriles salientes (en negro) y enlaces (<i>links</i>) que definen las conexiones de giro y cruce.	22
2.6	Interacción agente-entorno en un proceso de decisión de Markov [SB20, p. 48].	23

Introducción

En las últimas décadas, en el mundo se ha producido un incremento sostenido del parque automotor a nivel mundial, acompañado por un proceso continuo de urbanización que ha convertido a la congestión vehicular en uno de los principales desafíos para la movilidad y eficiencia en áreas urbanas. Según los reportes de flota vehicular de Argentina, elaborados por la Asociación de Fábricas Argentinas de Componentes (AFAC), y utilizando el año 2012 como línea base, el volumen de vehículos registró un aumento del 21,7% en 2017. Dicha progresión se sostuvo a lo largo de la última década, alcanzando un incremento acumulado del 44,4% para el año 2025 (véase la Figura 1.1).




Figura 1.1: Evolución de la flota vehicular circulante en Argentina (1990–2025). Datos: AFAC.

Las congestiones vehiculares traen consigo múltiples consecuencias: desde importantes pérdidas de productividad por demoras en los tiempos de viaje, hasta un aumento en la cantidad de detenciones vehiculares y la consecuente emisión de gases nocivos para la salud y el medio ambiente, tales como CO, CO₂, NO_x, HC [ne18]. Este escenario impacta de manera notable en grandes ciudades con una alta densidad de vehículos. En este trabajo se utilizaron casos de estudio sintetizados y como caso de estudio real el Área Metropolitana del Gran Mendoza (GM), comprendida entre Avenida San Martín, Avenida Colón, Avenida Belgrano y Avenida Las Heras.

Frente a un escenario de congestión, una alternativa viable, sin recurrir a reestructuraciones costosas en la infraestructura, consiste en optimizar la gestión del tránsito mediante sistemas de control semafórico adaptativos. Los enfoques tradicionales de control semafórico han demostrado poca capacidad

de adaptación ante escenarios con mucha variabilidad de flujos de vehículos. Una alternativa prometedora resulta ser el Aprendizaje por Refuerzo (Reinforcement Learning, RL), un paradigma de inteligencia artificial dónde los semáforos pueden modelarse como agentes, capaces de aprender políticas de control a partir de la interacción con un entorno (la situación del tránsito) mediante la ejecución de acciones (cambios de fase) con el objetivo de maximizar una recompensa, como por ejemplo, el valor negativo de la suma de los tiempos de espera de los vehículos involucrados. **Caro: faltan citas acá**

Sin embargo, aplicar este enfoque de manera simultánea sobre múltiples intersecciones introduce desafíos adicionales. Un esquema de control centralizado resulta poco escalable debido al crecimiento exponencial del espacio de acciones conjunto. Una alternativa "ingenua" del Aprendizaje por Refuerzo Multi-Agente resulta ser el Aprendizaje Independiente (*Independent Learning* o IL), donde cada semáforo busca descongestionar de forma independiente y egoísta solo su propia intersección [AS22]. Este enfoque tiene dos desventajas críticas: primero, la optimización puramente local conduce a un óptimo global sub-óptimo; segundo, dado que todos los agentes aprenden y cambian sus políticas simultáneamente, el entorno se vuelve no estacionario para cada agente individual, lo cual viola los supuestos de convergencia del aprendizaje [FH21].

Por esta razón, en este trabajo final de carrera se aborda el problema desde el marco del Aprendizaje por Refuerzo Multi-Agente (MARL) Cooperativo. Bajo este paradigma, los controladores (agentes) actúan como un equipo. Aprenden políticas coordinadas, no para maximizar solo una recompensa individual, sino también una recompensa global compartida orientada a la minimización del tiempo de espera promedio de toda la red, evitando así los conflictos que surgen del aprendizaje independiente. La recompensa es un valor numérico que indica cuán efectiva fue la acción conjunta.

En este contexto, el objetivo general de este trabajo fue desarrollar y evaluar un sistema de control de tráfico basado en este enfoque cooperativo para optimizar el flujo vehicular urbano. Para lograrlo, se analizó la convergencia a políticas de control óptimas y la escalabilidad de distintos algoritmos MARL ante entornos no estacionarios mediante simulaciones en escenarios sintéticos y en la red vial real del Gran Mendoza. Esto permitió establecer una línea base de comparación para, posteriormente, validar empíricamente el desempeño de la arquitectura descentralizada y coordinada propuesta frente a los enfoques de control tradicionales y el estado del arte.

1.1 Motivación

La motivación principal de este trabajo radica en la marcada asimetría entre una demanda vehicular en constante crecimiento y una infraestructura vial que permanece estática. Dado que ensanchar avenidas o modificar fisi-

camente el trazado urbano en cascos densos como el del Gran Mendoza es económica y estructuralmente inviable, la alternativa más sostenible es la optimización lógica de los recursos existentes.

El desarrollo de soluciones basadas en software permite dotar de la adaptabilidad necesaria a la red semafórica actual. De este modo, es posible transformar un sistema rígido en uno inteligente capaz de mitigar las demoras y reducir la contaminación ambiental evitable, maximizando la eficiencia de la infraestructura vial sin requerir obras civiles de gran envergadura.

Caro: agregar acá la presentación de cada capítulo. El presente documento se encuentra organizado de la siguiente manera: en el Capítulo 1 se presenta la introducción y motivación del trabajo. En el Capítulo 2 se realiza una revisión bibliográfica de los enfoques de control semafórico basados en Aprendizaje por Refuerzo, destacando sus ventajas y limitaciones. En el Capítulo 3 se describe la metodología utilizada para el desarrollo del sistema de control propuesto, incluyendo la formulación del problema, la arquitectura del agente y los algoritmos implementados. En el Capítulo 4 se presentan los resultados obtenidos a través de simulaciones en escenarios sintéticos y en la red vial real del Gran Mendoza, comparando el desempeño del sistema propuesto con enfoques tradicionales. Finalmente, en el Capítulo 5 se discuten las conclusiones y se plantean posibles líneas futuras de investigación. (esto es un ejemplo, no es necesario que lo pongas tal cual, solo es para que te des una idea de cómo presentar cada capítulo)

Marco Teórico

2.1 Ingeniería de Tránsito

La ingeniería de tránsito se define como aquella fase de la ingeniería de transporte —disciplina que se enmarca tradicionalmente dentro de la ingeniería civil— que tiene que ver con la planeación segura y eficiente, el proyecto geométrico y la operación del tránsito por calles y carreteras, sus redes, terminales, tierras adyacentes y su relación con otros modos de transporte, tanto motorizados como no motorizados [CyMR18, p. 33]. Asimismo, el *Traffic Engineering Handbook* la describe formalmente como la subdisciplina enfocada en la planificación, el diseño geométrico y la operación de calles, carreteras y redes viales [PW16, p. 1]. En este trabajo, sus conceptos se abordan principalmente desde la perspectiva de la operación del tránsito urbano: permiten describir el funcionamiento físico de la red vial, caracterizar la oferta y demanda de circulación, e identificar las variables operacionales clave sobre las cuales puede intervenir de manera adaptativa un sistema de control.

Históricamente, la práctica de la ingeniería de tránsito puso un fuerte énfasis en proveer y ampliar la capacidad física vial mediante la construcción de nuevas obras o el ensanche de calzadas [PW16, Cap. 1]. Sin embargo, el crecimiento sostenido de la congestión evidenció que la ampliación de infraestructura no constituye una solución definitiva al problema. En áreas urbanas consolidadas, además, modificar el trazado vial resulta costoso y geométricamente inviable [CyMR18, Cap. 2]. Por ello, la práctica contemporánea complementa la provisión de infraestructura con estrategias de gestión de la demanda y control dinámico del tránsito, priorizando la optimización de los recursos existentes mediante dispositivos de control semafórico [PW16, CyMR18].

La operación de una red vial puede analizarse a partir de la relación entre la demanda vehicular y la capacidad disponible. La demanda vehicular corresponde a la cantidad de vehículos que requieren desplazarse por un determinado sistema vial, mientras que la oferta vial o capacidad representa la cantidad máxima de vehículos que pueden circular por dicho espacio físico bajo determinadas condiciones de operación [CyMR18, Cap. 2, Sec. 2.4]. Cuando la demanda se aproxima a la capacidad, el tránsito se vuelve inestable; cuando la supera, se presentan condiciones de sobresaturación o flujo forzado, caracterizadas por detenciones frecuentes y grandes demoras [CyMR18, Cap. 2, Sec. 2.4]. En este sentido, la congestión no se entiende solo como una percepción general de mal funcionamiento, sino como un fenómeno con manifestaciones físicas medibles: demoras, colas y detenciones [FA11, Cap. 1, Sec. 1.1].

2.1.1 Terminología de Tránsito

Antes de introducir los mecanismos de control y su formulación computacional, conviene precisar algunos términos operativos que se utilizarán de manera recurrente en este documento. Esta aclaración inicial también es habitual en estudios recientes sobre control semafórico basados en aprendizaje por refuerzo, donde los conceptos de movimientos, fases y señales se explicitan antes de formular el problema de control [W⁺19].

En este contexto, se emplearán las siguientes nociones:

- **Intersección, acceso y carril:** una intersección es el área física y operacional en la que confluyen dos o más corrientes de tránsito. Cada una de las calzadas de aproximación que ingresan a ella constituye un acceso, organizándose internamente en uno o más carriles destinados a canalizar los flujos vehiculares [PW16, CyMR18].
- **Movimiento vehicular y movimientos en conflicto:** un movimiento vehicular representa la trayectoria específica que describe un vehículo al cruzar la intersección hacia una salida determinada (e.g., giros o movimientos directos) [W⁺19]. Dos movimientos se consideran en conflicto o incompatibles cuando sus trayectorias se intersectan y generan puntos de conflicto en la intersección (véase la Figura 2.1), lo que impide su servicio simultáneo por razones de seguridad [FA11, Cap. 1].
- **Fase, ciclo e intervalo:** una fase representa el estado operativo del semáforo que otorga el derecho de paso a un grupo de movimientos compatibles de manera simultánea [PW16]. La secuencia completa de fases requerida para servir a todos los movimientos de la intersección constituye el ciclo semafórico, mientras que un intervalo es la fracción temporal del ciclo durante la cual las indicaciones del semáforo no varían [CyMR18].

En arterias urbanas, el tránsito se desarrolla bajo condiciones de flujo interrumpido: los vehículos no avanzan únicamente por su interacción con otros vehículos, sino también por la presencia de intersecciones, señales y dispositivos de control de tránsito [PW16, pp. 320–324]. Las intersecciones son puntos críticos de la red porque allí confluyen distintos accesos y movimientos vehiculares de cruce, convergencia y divergencia que pueden resultar incompatibles entre sí [PW16, pp. 321–323]. Por ello, su operación requiere ordenar estos movimientos y asignar la prioridad de paso de manera segura y eficiente.

El semáforo es uno de los dispositivos de control de tránsito utilizados para regular la circulación en intersecciones. Su función es asignar la prioridad de paso en forma alternada entre corrientes vehiculares incompatibles, evitando que distintos movimientos intenten ocupar simultáneamente el mismo




Figura 2.1: Representación esquemática de movimientos vehiculares y puntos de conflicto en una intersección semaforizada.

espacio de cruce [FA11, Cap. 1, Sec. 1.2]. Desde el punto de vista del modelado algorítmico, esta capacidad de modificar la prioridad de paso convierte al semáforo en el actuador mediante el cual un sistema de control puede intervenir sobre la operación de la intersección y afectar, directa o indirectamente, las demoras y colas observadas en la red.

2.1.2 Fundamentos de la Dinámica Vehicular

Para modelar y optimizar la operación de una red vial, es necesario caracterizar físicamente el movimiento de los vehículos. La ingeniería de tránsito estudia este fenómeno a partir de las características fundamentales de la corriente de tránsito, que permiten describir las condiciones de operación de una vía o intersección mediante magnitudes observables como el flujo, la velocidad y la densidad [PW16, pp. 203–204]. Cal y Mayor distingue estas magnitudes entre variables principales, que describen el comportamiento agregado del flujo vehicular, y variables asociadas, que expresan relaciones temporales y espaciales entre vehículos consecutivos [CyMR18, p. 302].

A nivel macroscópico, la corriente de tránsito se representa mediante variables agregadas como la tasa de flujo, la densidad y los promedios de velocidad. A nivel microscópico, se analizan magnitudes propias de vehículos individuales e interacciones entre pares consecutivos, como la velocidad puntual, el intervalo y el espaciamiento [CyMR18, p. 302]. Esta separación entre escalas es relevante para el modelado computacional: las variables macroscópicas resumen el estado operacional de los accesos de la red, mientras que las variables microscópicas describen el comportamiento de cada vehículo dentro del simulador [FA11]. La correspondencia y las relaciones de conversión

entre las variables de ambas escalas se resumen en la Tabla 2.1.

En el nivel macroscópico, las variables principales de la corriente de tránsito son:

- **Flujo o tasa de flujo (q):** representa la cantidad de vehículos que atraviesen una sección transversal de la vía por unidad de tiempo. Si el período de observación es menor a una hora, se proyecta como una tasa horaria equivalente en vehículos por hora (veh/h), $q = N/T$ [CyMR18, p. 303].
- **Densidad o concentración (k):** indica el número de vehículos que ocupan simultáneamente una longitud específica de vía, expresada en vehículos por kilómetro (veh/km), $k = N/d$ [CyMR18, p. 308]. En la práctica, se suele estimar indirectamente a través del porcentaje de ocupación temporal registrado por detectores inductivos [PW16, p. 204].
- **Velocidad media espacial (v_s):** es la velocidad media de los vehículos que ocupan un tramo de vía en un instante determinado. Corresponde al promedio armónico de las velocidades puntuales de los vehículos individuales y representa la magnitud de velocidad consistente con la dinámica del flujo espacial [CyMR18, p. 308].
- **Velocidad media temporal (v_t):** representa el promedio aritmético de las velocidades de los vehículos que cruzan una sección transversal fija de la vía durante un período de tiempo determinado [CyMR18, p. 308].

En el nivel microscópico, las variables asociadas describen el movimiento del vehículo individual y la separación entre vehículos consecutivos (véase la Figura 2.2):

- **Velocidad puntual (v_i):** es la velocidad a la que un vehículo individual (i) atraviesa una sección transversal específica de la vía.
- **Intervalo temporal (h):** es el tiempo transcurrido entre el paso de dos vehículos consecutivos por una sección fija de la calzada, medido respecto a puntos homólogos (e.g., parachoques delanteros) [CyMR18, p. 303]. El intervalo promedio en segundos se relaciona con la tasa de flujo como $h_{prom} = 3600/q$.
- **Espaciamiento simple (s):** es la distancia física entre puntos homólogos de dos vehículos consecutivos en un instante de tiempo [CyMR18, p. 308]. El espaciamiento promedio se relaciona de forma inversa con la densidad de la corriente de tránsito ($s_{prom} = 1/k$).

Cuadro 2.1: Comparación y correspondencia de variables de tránsito en escalas macroscópica y microscópica.

Escala	Variable Principal	Relación / Conversión
Macroscópica	Flujo (q , veh/h)	$q = 3600/h_{\text{prom}}$
	Densidad (k , veh/km)	$k = 1000/s_{\text{prom}}$
	Velocidad media espacial (v_s , km/h)	$q = k \cdot v_s$
	Velocidad media temporal (v_t , km/h)	$v_t = v_s + \frac{\sigma_s^2}{v_s}$ (Relación de Wardrop)
Microscópica	Velocidad puntual (v_i , km/h)	Variable individual de cada vehículo
	Intervalo temporal (h , s)	Tiempo entre pasos de vehículos sucesivos
	Espaciamiento simple (s , m)	Distancia espacial entre parachoques homólogos




Figura 2.2: Relaciones temporales y espaciales entre vehículos consecutivos de una corriente de tránsito: intervalo (h) y espaciamiento (s).

Estas variables macroscópicas y agregadas se relacionan de manera directa a través de la ecuación fundamental del flujo de tránsito:

$$q = k \cdot v_s \quad (2.1)$$

Cabe destacar que la velocidad media espacial (v_s) es la única físicamente consistente con esta ecuación fundamental. La velocidad media temporal (v_t) difiere de esta debido a que asigna mayor peso a los vehículos más rápidos que cruzan el punto de medición en un lapso dado. La vinculación analítica entre ambas variables se establece formalmente mediante la relación de Wardrop [FA11]:

$$v_t = v_s + \frac{\sigma_s^2}{v_s} \quad (2.2)$$

donde σ_s^2 es la varianza de la distribución de velocidades en el espacio. Dado que la varianza es siempre no negativa, se cumple que $v_t \geq v_s$, igualándose

únicamente en el caso hipotético en que todos los vehículos circulen exactamente a la misma velocidad. En intersecciones semaforizadas, esta relación dinámica permite modelar cómo las interrupciones del semáforo durante la luz roja detienen el flujo ($v_s \rightarrow 0$), provocando una acumulación de vehículos que eleva la densidad ($k \rightarrow k_{max}$) y genera colas y demoras asociadas a condiciones de flujo forzado [CyMR18, pp. 315–316].

Para un sistema de control de tránsito, estas variables son relevantes porque pueden medirse o estimarse a partir de sensores, detectores o registros del simulador. A partir de ellas es posible construir una representación del estado de la red y evaluar cómo evoluciona la operación ante distintas decisiones de control.

Métricas de Ineficiencia Operativa

La interrupción del flujo causada por semáforos o saturación genera efectos adversos que los sistemas de control buscan mitigar. Siguiendo la terminología de la ingeniería de tránsito, las principales manifestaciones medibles de esta ineficiencia son las demoras, las colas y las detenciones [FA11, Cap. 1, Sec. 1.1]:

- **Demoras:** Representan el tiempo adicional que un vehículo debe invertir para atravesar una intersección respecto del tiempo que le tomaría circular a velocidad de flujo libre. En intersecciones semaforizadas, una parte de esa demora aparece por la espera normal durante la luz roja. Otras demoras se producen cuando las llegadas de vehículos varían, cuando la demanda se acerca o supera la capacidad de la intersección, o cuando quedan colas sin disiparse al finalizar el verde, de modo que algunos vehículos deben esperar más de un ciclo para cruzar [FA11, Cap. 1, Sec. 1.1].
- **Colas:** Corresponden al número de vehículos acumulados detrás de una línea de detención a la espera de ser servidos. Esta medida espacial es especialmente relevante porque, cuando la cola supera la longitud del arco de aproximación, puede bloquear la intersección aguas arriba y propagar la congestión al resto de la red [FA11, Cap. 1, Sec. 1.1].
- **Detenciones:** Cuantifican la cantidad de veces que un vehículo debe reducir su velocidad hasta cero durante el recorrido. Una alta frecuencia de detenciones deteriora la continuidad operativa del flujo y suele asociarse con mayores procesos de aceleración y desaceleración [FA11, Cap. 1, Sec. 1.1].

Estas tres métricas constituyen indicadores directos del desempeño operativo de la red. En este trabajo, se adoptan como criterios de evaluación del controlador, ya que permiten cuantificar los efectos de la asignación dinámica de prioridad entre movimientos en conflicto en las intersecciones.

Descripción Probabilística del Flujo

En el modelado de tránsito, las llegadas vehiculares no siempre pueden representarse adecuadamente como una secuencia determinista y constante. Para flujos vehiculares bajos y medios, y cuando las llegadas no están fuertemente condicionadas por semáforos previos, es habitual aproximar el número de vehículos que llega a una sección durante un intervalo de tiempo mediante un proceso de Poisson [CyMR18, p. 342].

Esta aproximación supone independencia estadística entre llegadas y permite describir la variabilidad observada en la demanda de acceso a una intersección [CyMR18, p. 342]. La probabilidad discreta $P(X)$ de que lleguen exactamente X vehículos en un intervalo de tiempo se define como:

$$P(X) = \frac{m^X \cdot e^{-m}}{X!} \quad (2.3)$$

donde m representa el valor esperado o media de llegadas en dicho intervalo. Bajo el mismo supuesto, los intervalos de tiempo continuos (h) medidos entre vehículos sucesivos se describen mediante una distribución de probabilidad exponencial negativa [CyMR18, p. 343]:

$$P(h \geq t) = e^{-\frac{q}{3600} \cdot t} \quad (2.4)$$

Esta representación probabilística asume independencia entre arribos sucesivos, siendo una aproximación válida únicamente para flujos vehiculares bajos o moderados bajo condiciones de flujo libre, donde no exista la influencia de semáforos cercanos aguas arriba [CyMR18]. Sin embargo, este supuesto de independencia decae en condiciones de congestión o en redes viales urbanas semaforizadas. En estos casos, la operación de los semáforos interrumpe periódicamente el flujo y agrupa a los vehículos en pelotones (*platoons*), induciendo una fuerte dependencia espacio-temporal y correlación entre arribos consecutivos. La Figura 2.3 presenta una comparación conceptual de la distribución resultante de los intervalos temporales entre vehículos bajo estas dos condiciones operativas.

Esta limitación de los modelos analíticos tradicionales (como los de Poisson o teoría de colas clásica) justifica la necesidad de recurrir a la simulación microscópica de tránsito. En un simulador como SUMO, la formación, dispersión e interacción de pelotones vehiculares emergen de manera natural a partir de los modelos de seguimiento de vehículos y cambio de carril, permitiendo evaluar el control semaforico bajo flujos dinámicos realistas. Asimismo, incorporar arribos estocásticos no Poissonianos, perfiles de demanda variables y la inicialización de múltiples corridas con diferentes semillas aleatorias en el simulador es un procedimiento estándar para evaluar la robustez y capacidad de adaptación de cualquier esquema de control dinámico ante la incertidumbre operativa; esto permite asegurar que los algoritmos sean capaces de responder ante fluctuaciones dinámicas del tráfico en tiempo real,

en lugar de optimizarse para una secuencia de flujo determinista y artificial [CyMR18, PW16].




Figura 2.3: Comparación esquemática de la distribución de intervalos temporales entre vehículos en flujo libre (exponencial negativa, consistente con el proceso de Poisson) y en flujo coordinado por semáforos (distribución desplazada con zona de exclusión física $t_{\min}$ y pico característico de pelotón).

2.1.3 Sistemas de Control de Tránsito

Para mitigar los conflictos de tránsito e incrementar la seguridad en las intersecciones urbanas de flujo interrumpido, se emplean sistemas de control de tránsito [PW16, pp. 323–324]. El dispositivo de control por excelencia en estos nodos es el semáforo, definido como un dispositivo electrónico que regula la circulación de vehículos asignando el derecho de paso alternado mediante indicaciones luminosas rojas, amarillas y verdes [CyMR18, p. 169].

En el modelado algorítmico, los semáforos y sus parámetros de configuración constituyen los elementos actuadores de la red. La modificación de la duración del verde efectivo, la secuencia de fases y la sincronización entre nodos define el conjunto de intervenciones dinámicas mediante las cuales el sistema de control busca optimizar el paso vehicular.

Sobre esta base terminológica, la programación temporal de un semáforo se describe mediante la duración de las fases, la longitud de ciclo y la definición de los intervalos de transición y despeje. Estos parámetros determinan cuánto tiempo recibe prioridad cada conjunto de movimientos compatibles y condicionan directamente la capacidad de descarga, las demoras y la seguridad operacional de la intersección [PW16, pp. 341–343].

Para garantizar la seguridad vial, las transiciones entre fases no pueden ejecutarse de manera instantánea, sino que deben respetar intervalos de cambio y despeje [PW16, pp. 348–349]. En este trabajo, esos tiempos se consideran restricciones operativas de seguridad previamente definidas en la

configuración del simulador y del sistema semafórico. En consecuencia, su determinación no forma parte del proceso de decisión del agente, cuyo control se limita a la selección de fases dentro de un esquema temporal compatible con dichas restricciones.

Modelado de la Capacidad y el Verde Efectivo

Desde el punto de vista operativo, la capacidad de descarga de un acceso semaforizado depende del tiempo efectivo de servicio que recibe cada fase y de la tasa con la que la fila puede disiparse cuando el movimiento tiene prioridad [FA11, pp. 59–60]. En la práctica, la descarga observada no depende solo de la duración nominal del verde, sino también de pérdidas de arranque, transiciones y otras restricciones temporales del control, como se ilustra conceptualmente en la Figura 2.4. En este trabajo, estos efectos no se modelan mediante fórmulas analíticas de capacidad, sino mediante la dinámica microscópica del simulador y la configuración temporal del sistema semafórico, ya que esas interacciones determinan las colas, demoras y detenciones que el controlador busca mejorar.




Figura 2.4: Distribución temporal de la tasa de descarga y pérdidas asociadas durante un intervalo de verde en una aproximación semaforizada.

Clasificación de los Controladores de Semáforos

De acuerdo con su mecanismo operativo y su grado de respuesta a la demanda vehicular, los controladores de semáforos se clasifican clásicamente en control de tiempo fijo y control accionado por el tránsito [PW16, Sec. 4, pp. 339–340]. En el primero, los planes de señales se repiten de manera preprogramada a partir de datos históricos y no cambian en respuesta a la demanda instantánea. En el segundo, la intersección utiliza detectores en los

accesos para variar dinámicamente el inicio o la duración de las fases según la demanda observada en tiempo real.

Incluso en los esquemas accionados, la operación permanece sujeta a parámetros límite de seguridad y funcionamiento, como el verde mínimo y el verde máximo [PW16, pp. 346–348]. Estos parámetros restringen cuánto puede sostenerse o finalizarse una fase y, en este trabajo, forman parte de las condiciones operativas dentro de las cuales el controlador toma decisiones.

2.1.4 Simulación de Tránsito

Debido a la densidad y complejidad de la red urbana moderna, la sincronización y optimización de los tiempos de semáforos no pueden resolverse adecuadamente con modelos estáticos bajo condiciones dinámicas, por lo que se recurre a aproximaciones computacionales basadas en simulación de tránsito [PW16, p. 355]. De acuerdo con la taxonomía clásica [FA11, Cap. 4, Sec. 4.1, p. 147], estos modelos pueden organizarse en tres niveles de resolución. Los modelos macroscópicos describen el tránsito de manera agregada mediante variables como flujo, densidad y velocidad; los modelos mesoscópicos representan entidades intermedias, como grupos o pelotones de vehículos. Ambos niveles son útiles para estudiar fenómenos de red, pero no ofrecen el detalle necesario para observar cómo las decisiones semaforicas afectan, paso a paso, la formación de colas y la interacción local entre vehículos en una intersección.

Para este trabajo, el nivel de mayor interés es el microscópico, ya que representa explícitamente a cada vehículo, su ruta y su movimiento dentro de la red [FA11, Cap. 4, Sec. 4.1, p. 147]. SUMO (*Simulation of Urban MObility*) se ubica en esta categoría: es un simulador de tránsito microscópico, multimodal y de código abierto, diseñado para representar demandas vehiculares sobre redes viales y evaluar problemas de gestión del tránsito [ALBBW⁺18, DLR25]. En SUMO, la evolución vehicular es continua en el espacio y discreta en el tiempo; además, el entorno permite modelar calles con múltiples carriles, cambios de carril, distintos tipos de vehículos, rutas individuales, semáforos y salidas de simulación a nivel de vehículo, carril, arco o detector [DLR25].

Esta granularidad vuelve a la simulación microscópica especialmente adecuada para estudiar control semaforico mediante aprendizaje por refuerzo. Las decisiones sobre fases y tiempos de servicio no se evalúan mediante una fórmula cerrada de demora, sino observando sus consecuencias sobre la dinámica simulada: colas, tiempos de espera, detenciones, ocupación de carriles y propagación de congestión. Por ello, la simulación microscópica constituye el puente natural entre el problema de tránsito y su formulación computacional, al permitir que el controlador interactúe con un entorno dinámico y medible durante la ejecución.

Modelos Microscópicos de Comportamiento Vehicular

En la simulación microscópica, la evolución de cada vehículo se describe mediante mecanismos internos como el seguimiento vehicular [FA11, Cap. 1, Sec. 1.3.2] y el cambio de carril [PW16, pp. 352–353]. En SUMO, estos mecanismos se parametrizan a través de los tipos de vehículo y determinan cómo cada unidad ajusta su velocidad, mantiene separaciones de seguridad, cambia de carril y avanza sobre su ruta dentro de la red [DLR25].

Modelado de Intersecciones y Semáforos en SUMO

En este contexto, el simulador de tránsito constituye el entorno operativo sobre el cual se formaliza el problema de control semafórico. En SUMO, los programas semafóricos se definen mediante fases que especifican, para cada instante, el estado de las señales asociadas a los enlaces controlados de la intersección; por ello, una fase no se interpreta solo como un color general del semáforo, sino como una configuración de permisos para movimientos concretos entre carriles de entrada y salida, cuyos elementos geométricos asociados (carriles y conexiones de cruce) se representan en la Figura 2.5 [DLR25]. Esta representación es compatible con la formulación algorítmica del problema, donde una acción puede consistir en seleccionar una fase, mantener la fase actual o modificar la duración de servicio dentro de restricciones predefinidas.




Figura 2.5: Representación en SUMO de carriles entrantes (en azul), carriles salientes (en negro) y enlaces (*links*) que definen las conexiones de giro y cruce.

2.2 Aprendizaje por Refuerzo (RL)

El aprendizaje por refuerzo (*reinforcement learning*, en inglés) consiste en mapear situaciones (estados) a acciones, con el objetivo de maximizar una señal de recompensa numérica. En el marco del aprendizaje por refuerzo, existen dos elementos esenciales: uno o más agentes y un entorno.

El agente es el tomador de decisiones, al cual no se le indica explícitamente qué acciones tomar, sino que debe descubrir cuáles acciones generan más recompensas a través de la exploración y la experimentación. Generalmente, las acciones pueden afectar no solo la recompensa inmediata, sino también el estado siguiente y, a través de este, todas las recompensas futuras.

El otro elemento es el entorno, que representa el escenario con el que interactúa el agente. Este entorno debe modelarse mediante abstracción de tal manera que la interfaz de comunicación ofrezca al agente lo esencial para el proceso de aprendizaje. Para modelar este entorno se utilizan ideas de la teoría de sistemas dinámicos, específicamente de los procesos de decisión de Markov [SB20].

2.2.1 El Proceso de Decisión de Markov (MDP)

Los procesos de decisión de Markov (*Markov Decision Process*, MDP) son una formalización clásica de la toma de decisiones secuencial donde las acciones no sólo influyen en las recompensas inmediatas, sino también en situaciones posteriores o estados y, a través de ellas, en las recompensas futuras. Los MDP pretenden ser una forma matemáticamente idealizada del problema del aprendizaje por refuerzo para el que pueden hacerse afirmaciones teóricas aplicables en la práctica.

En un MDP, el agente y el entorno interactúan en cada uno de una secuencia de pasos temporales discretos, $t = 0, 1, 2, 3, \dots$. En cada paso de tiempo t , el agente recibe una representación del estado del entorno, $S_t \in \mathcal{S}$, y en esa base selecciona una acción, $A_t \in \mathcal{A}(s)$. Un paso de tiempo después, como consecuencia de esta acción, el agente recibe una recompensa numérica, $R_{t+1} \in \mathcal{R}$, y se encontrará en un nuevo estado S_{t+1} . Todo este proceso se puede observar esquemáticamente en la Figura 2.6.




Figura 2.6: Interacción agente-entorno en un proceso de decisión de Markov [SB20, p. 48].

En los MDP finitos, los conjuntos de estados, acciones y recompensas ($\mathcal{S}$, $\mathcal{A}$ y $\mathcal{R}$) contienen un número finito de elementos. Las variables aleatorias R_t y S_t siguen una distribución de probabilidad discreta p , la cual depende únicamente del estado y la acción precedentes. Esta dependencia exclusiva se conoce como la propiedad de Markov, y para las metodologías utilizadas en este trabajo se asume su cumplimiento [SB20]:

$$p(s', r | s, a) = \Pr\{S_t = s', R_t = r | S_{t-1} = s, A_{t-1} = a\} \quad (2.5)$$

Existen métodos que intentan desarrollar un modelo para comprender el entorno. Estos métodos buscan aprender la función de probabilidad p para poder planificar y se denominan métodos *basados en modelo*. Por otro lado, los algoritmos *libres de modelo* aprenden las consecuencias de las acciones a través de la experiencia pura sin estimar la función p , y constituyen la familia de algoritmos de mayor interés para el presente trabajo.

2.2.2 Retorno

Como se ha mencionado, el objetivo del agente es maximizar la recompensa acumulada recibida a lo largo del tiempo. En general, se busca maximizar el retorno esperado, donde el retorno, denotado G_t , se define como una función específica de una secuencia de recompensas.

En muchos casos resulta necesario priorizar las recompensas inmediatas frente a aquellas más lejanas en el tiempo, para lo cual se emplea un factor de descuento $\gamma \in [0, 1]$. Este parámetro se utiliza para obtener el retorno descontado:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \quad (2.6)$$

2.2.3 Función de Acción-Valor y Política

Todo algoritmo de aprendizaje por refuerzo requiere estimar una función de valor, la cual indica qué tan ventajoso es para el agente encontrarse en un determinado estado o elegir cierta acción desde el mismo. Esta noción se define en términos de recompensas futuras esperadas y se encuentra subordinada a formas particulares de actuar, denominadas políticas.

Una política es una función que mapea desde los estados hacia las probabilidades de seleccionar cada acción posible. Si un agente sigue una política π en el instante de tiempo t , entonces $\pi(a|s)$ es la probabilidad de que $A_t = a$ si $S_t = s$.

La función de valor de un estado s bajo una política π , denotada $V_\pi(s)$, es el retorno esperado al comenzar desde s y seguir la política π en adelante. Por otra parte, la función de acción-valor al elegir una acción a en el estado s bajo una política π , denotada $Q_\pi(s, a)$, se define formalmente como:

$$Q_\pi(s, a) = \mathbb{E}_\pi [G_t \mid S_t = s, A_t = a] = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s, A_t = a \right] \quad (2.7)$$

Tanto V_π como Q_π pueden estimarse empíricamente a partir de la experiencia. Estas funciones permiten establecer un orden parcial sobre las políticas, existiendo siempre al menos una política óptima, denotada por π_* , cuyo retorno esperado es mayor o igual que el de las demás para todos los estados. Las políticas óptimas comparten la misma función de acción-valor óptima $Q_*(s, a)$ [SB20].

2.2.4 *Q-Learning*

Una propiedad fundamental de Q_* es que debe satisfacer la ecuación de optimalidad de Bellman, la cual constituye la base teórica del algoritmo Q -

learning:

$$Q_*(s, a) = \mathbb{E} \left[R_{t+1} + \gamma \max_{a'} Q_*(S_{t+1}, a') \mid S_t = s, A_t = a \right] \quad (2.8)$$

A partir de esta relación iterativa, se deriva el siguiente método de actualización temporal para aproximar progresivamente Q_* :

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t) \right] \quad (2.9)$$

donde α es la tasa de aprendizaje, un parámetro que controla la velocidad de convergencia. En implementaciones tradicionales, los valores Q se almacenan en una estructura tabular. Sin embargo, cuando el espacio de estados adquiere magnitudes realistas, el enfoque tabular deja de ser escalable, requiriendo el uso de aproximadores de funciones.

2.2.5 *Deep Learning* y Redes Neuronales

El aprendizaje profundo (*deep learning*) es un subcampo del aprendizaje automático que se fundamenta en el entrenamiento de representaciones progresivas a partir de datos. En este paradigma, el procesamiento se estructura a través de modelos denominados redes neuronales, compuestas por múltiples capas de unidades básicas de cómputo conocidas como neuronas artificiales.

Una neurona artificial procesa señales mediante tres componentes principales:

1. **Entradas:** Recibe múltiples señales x_i , cada una ponderada por un coeficiente o peso w_i .
2. **Función de Agregación:** Computa la suma ponderada de las entradas junto con un término de sesgo (*bias*) b , representado como $z = \sum w_i x_i + b$.
3. **Función de Activación:** La variable z se transforma mediante una función matemática (como ReLU o tangente hiperbólica) para introducir no linealidad en el modelo, lo que permite a la red neuronal aproximar funciones complejas no lineales.

2.2.6 *Deep Reinforcement Learning* (DRL)

El *Deep Reinforcement Learning* (DRL) combina las técnicas de aprendizaje profundo con el aprendizaje por refuerzo clásico [MKS⁺15]. En este enfoque, las redes neuronales profundas actúan como aproximadores universales de las funciones de valor o de las políticas, posibilitando que los agentes de RL resuelvan tareas y tomen decisiones en entornos con espacios de estados continuos o de alta dimensionalidad.

Deep Q-Learning (DQN)

La integración de redes neuronales al algoritmo *Q-learning* da lugar a la arquitectura *Deep Q-Network* (DQN). En DQN, una red neuronal recibe una representación del estado y devuelve los valores Q estimados para todas las acciones disponibles [MKS⁺15]. Además de escalar a espacios mayores, DQN introduce dos mecanismos cruciales para estabilizar el proceso de entrenamiento:

- **Red objetivo (*target network*):** El algoritmo mantiene dos redes neuronales. La red principal parametrizada por θ se utiliza para seleccionar acciones y actualizarse en cada paso temporal. Simultáneamente, una red objetivo parametrizada por θ^- se emplea para calcular el valor objetivo en la ecuación de actualización. Los pesos de la red objetivo se mantienen congelados y se sincronizan periódicamente con los de la red principal, evitando oscilaciones inestables en las estimaciones.
- **Repetición de experiencias (*experience replay*):** A medida que el agente interactúa con el entorno, sus transiciones empíricas (s, a, r, s') se guardan en una memoria temporal o *replay buffer*. En lugar de entrenar con secuencias temporales altamente correlacionadas, la red neuronal se optimiza muestreando minilotes (*batches*) aleatorios de esta memoria.

Durante el entrenamiento, la función de pérdida a minimizar se formula en torno a la diferencia de los lados de la ecuación de Bellman:

$$\mathcal{L}(\theta) = \mathbb{E} \left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta) \right)^2 \right] \quad (2.10)$$

Exploración vs. Explotación

Para evitar que el agente converja prematuramente a políticas subóptimas, se debe establecer un balance entre explorar el entorno y explotar el conocimiento ya adquirido. En DQN suele utilizarse una política ϵ -greedy: con probabilidad $1 - \epsilon$ se selecciona la acción que maximiza el valor Q estimado por la red, y con probabilidad ϵ se ejecuta una acción aleatoria. Típicamente, ϵ inicializa en un valor alto y experimenta un decaimiento lineal a lo largo de los episodios formativos hasta alcanzar un valor mínimo residual.

2.3 Aprendizaje por Refuerzo Multi-Agente (MARL)

El aprendizaje por refuerzo multi-agente (*Multi-Agent Reinforcement Learning*, MARL) generaliza los principios del RL hacia sistemas donde múltiples

entidades aprenden e interactúan simultáneamente en un entorno compartido [LZPS24]. A diferencia del caso individual, las acciones de cada agente modifican el estado global del sistema, lo que induce una dinámica no estacionaria desde la perspectiva local de cualquier participante. En el contexto del control de tráfico urbano, las intersecciones vecinas comparten un objetivo común —maximizar la eficiencia vehicular—, configurando un escenario estrictamente cooperativo.

2.3.1 Procesos de Decisión de Markov Parcialmente Observables Descentralizados (Dec-POMDP)

Los entornos cooperativos multi-agente suelen formalizarse matemáticamente mediante el marco de los Procesos de Decisión de Markov Parcialmente Observables Descentralizados (Dec-POMDP). Este modelo para n agentes se define como una tupla $\langle \mathcal{S}, \{\mathcal{A}_i\}_{i=1}^n, T, R, \{\Omega_i\}_{i=1}^n, O, \gamma \rangle$, donde:

- $\mathcal{S}$ es el conjunto de estados globales del entorno.
- $\mathcal{A}_i$ corresponde al espacio de acciones disponibles para el agente i .
- $T(s' \mid s, a_{1:n})$ representa la función de transición conjunta.
- $R(s, a_{1:n})$ es la función de recompensa compartida.
- Ω_i denota el conjunto de observaciones individuales del agente i , regidas por la función de observación $O(o_{1:n} \mid s', a_{1:n})$.

En este esquema, cada agente basa sus decisiones en su historia local de observaciones τ_i , con el propósito de aprender una política descentralizada $\pi_i(a_i \mid \tau_i)$ que, al combinarse con las demás, maximice el retorno conjunto del sistema [AOS20].

2.3.2 Paradigmas de Entrenamiento y Ejecución

Para abordar la complejidad inherente a los Dec-POMDP, una estrategia ampliamente aceptada es el paradigma de **Entrenamiento Centralizado con Ejecución Descentralizada** (CTDE, por sus siglas en inglés) [ZLYZ23]. Durante la fase de entrenamiento (simulación), los algoritmos pueden aprovechar el estado global del sistema, las recompensas totales y las acciones conjuntas de todos los agentes para estabilizar la convergencia de las redes neuronales críticas. Sin embargo, para la fase de ejecución, se extraen actores o políticas puramente descentralizadas que requieren únicamente las variables observables locales de cada intersección para tomar decisiones de control.

2.3.3 Principales Familias de Algoritmos Cooperativos

El desarrollo de MARL ha consolidado distintas familias algorítmicas bajo el paradigma CTDE:

- **Descomposición de Valores:** Enfoques como *Value Decomposition Networks* (VDN) [SLG⁺18] y QMIX [RSDW⁺18] intentan factorizar la función de valor global en estimaciones locales por agente. QMIX, por ejemplo, utiliza una red neuronal adicional (red de mezcla) que asegura restricciones de monotonía, garantizando que el máximo conjunto coincida con la selección de los máximos individuales de cada agente.
- **Métodos Actor-Crítico Centralizados:** Esta vertiente extiende los enfoques de gradiente de política al escenario multi-agente, implementando un “crítico” que evalúa las acciones conjuntas a partir del estado global, y actores individuales independientes. Algoritmos como MADDPG (*Multi-Agent Deep Deterministic Policy Gradient*), introducido por Lowe et al. [LWT⁺17], se inscriben en esta categoría, facilitando el aprendizaje en espacios continuos y atenuando la varianza en la asignación de recompensas.
- **Asignación de Crédito y Modelado de Recompensas:** En sistemas descentralizados, resulta imperativo aislar la contribución específica de un agente respecto al desempeño colectivo. Para ello se emplean técnicas analíticas como las recompensas de diferencia (*difference rewards*) [DK11], que cuantifican la divergencia entre el retorno global actual y un escenario contrafactual hipotético en el que el agente evaluado adopta un comportamiento por defecto [FFA⁺18].

2.3.4 Desafíos Prácticos en MARL

La adopción de MARL enfrenta obstáculos sustanciales para su implementación práctica:

- **No Estacionariedad:** La evolución simultánea de las políticas de múltiples agentes ocasiona que las propiedades probabilísticas del entorno varíen constantemente, lo cual invalida las garantías teóricas de convergencia diseñadas para entornos de un solo agente.
- **Gestión de Memoria de Experiencias:** Las técnicas de *experience replay* pierden eficacia directa, ya que las transiciones recopiladas en etapas tempranas corresponden a dinámicas de interacción conjuntas que han quedado obsoletas, generando señales de gradiente ruidosas [FNF⁺17].
- **Escalabilidad:** La magnitud combinada de los espacios de estado y acción crece exponencialmente en función de la cantidad de agentes.

Para redes urbanas extensas, esta explosión combinatoria exige estrategias avanzadas de parametrización compartida y la adopción de redes neuronales convolucionales o basadas en grafos [CWCL22].

2.4 Control de Tráfico Urbano mediante MARL

2.4.1 Entorno de Simulación para Control Semafórico

La interfaz TraCI (*Traffic Control Interface*) permite consultar valores de una simulación en ejecución y modificar su estado de forma externa durante el avance paso a paso [DLR25]. A través de esta interfaz, un controlador puede obtener telemetría de vehículos, carriles, detectores, arcos o semáforos, y también aplicar cambios sobre el estado o la fase de los semáforos. Esta capacidad convierte a SUMO en un entorno experimental adecuado para evaluar decisiones secuenciales de control y para integrarlo con bibliotecas orientadas a aprendizaje por refuerzo, como SUMO-RL [ALBBW⁺18, Ale].

En este sentido, la integración entre el simulador y la política de control establece un bucle cerrado en el que el simulador actúa como el entorno (u *environment*) y la interfaz de programación expone la telemetría y los actuadores necesarios para guiar el proceso de aprendizaje, permitiendo que el controlador interactúe dinámicamente paso a paso.

2.4.2 Modelado del Problema del Control de Semáforos (Espacio de Estados, Acciones y Recompensas)

Desde la perspectiva del aprendizaje por refuerzo, la formulación del control semafórico establece una correspondencia directa entre los conceptos físicos del dominio del tránsito y los componentes de un problema de decisión secuencial. Las variables que definen el estado del tránsito en la intersección se traducen en observaciones para el agente, el control de las indicaciones luminosas define el espacio de acciones, y el desempeño operativo del sistema se utiliza para guiar el aprendizaje mediante la función de recompensa:

- **Espacio de observaciones (estados):** variables como la longitud de cola, el número de vehículos detenidos, el flujo de entrada o el tiempo de espera acumulado en los accesos de la intersección.
- **Espacio de acciones:** la selección o permanencia de fases semafóricas, respetando los tiempos mínimos y máximos de seguridad física de la intersección.
- **Función de recompensa:** métricas que cuantifican la calidad del flujo, tales como la reducción de la demora total, la disminución de detenciones consecutivas o la mitigación del crecimiento de colas en accesos críticos.

Esta formulación no implica que el algoritmo aprenda ni sustituya los modelos físicos del simulador: la dinámica vehicular permanece como parte del entorno, mientras el controlador aprende una política que asigna acciones a observaciones con el objetivo de mejorar el desempeño operativo de forma empírica [W⁺19, Ale, SB20].

2.4.3 Coordinación entre Intersecciones y Mitigación de Congestión

En una red urbana semaforizada, el comportamiento de cada intersección no puede analizarse de manera aislada. Las decisiones de fase modifican los patrones de descarga, propagación y acumulación de vehículos, afectando tanto a intersecciones vecinas como a la evolución futura del tránsito en la propia red. Esta interdependencia espacial y temporal justifica el uso de enfoques cooperativos de aprendizaje por refuerzo multiagente, en los que múltiples controladores coordinan sus decisiones para mejorar el desempeño global y no solo el de una intersección individual [W⁺19, CWCL22].

Bibliografía

- [ALBBW⁺18] Alvarez Lopez, Pablo, Michael Behrisch, Laura Bieker-Walz, Jakob Erdmann, Yun Pang Flötteröd, Robert Hilbrich, Leonhard Lücken, Johannes Rummel, Peter Wagner y Evamarie Wießner: *Microscopic Traffic Simulation using SUMO*. En *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, páginas 2575–2582. IEEE, 2018.
- [Ale] Alegre, Lucas N.: *SUMO-RL 1.4.5 documentation*. Available at: <https://lucasaalegre.github.io/sumo-rl/>.
- [AOS20] Amato, Christopher, Frans A. Oliehoek y Matthijs T.J. Spaan: *A Survey of Decentralized Partially Observable Markov Decision Processes and Applications*. Journal of Artificial Intelligence Research, 69:1–72, 2020.
- [AS22] Ault, James y Guni Sharon: *Cooperative Multi-agent Reinforcement Learning Applied to Multi-intersection Traffic Signal Control*. En *Proceedings of the 31st ACM International Conference on Information & Knowledge Management (CIKM '22)*, 2022. <https://people.engr.tamu.edu/guni/papers/CIKM22-MATCS.pdf>, Fuente: [7, 8] Destaca el "éxito limitado" de SARL y los enfoques independientes en redes.
- [CWCL22] Chu, Tianshu, Jie Wang, Lara Codecà y Zhaojian Li: *Graph Neural Reinforcement Learning for Intelligent Traffic Signal Control*. IEEE Transactions on Intelligent Transportation Systems, 23(7):8878–8892, 2022.
- [CyMR18] Mayor R., Rafael Cal y: *Ingeniería de tránsito: Fundamentos y aplicaciones*. Alfaomega, 9na edición, 2018.
- [DK11] Devlin, Sam y Daniel Kudenko: *Potential-Based Difference Rewards for Multiagent Reinforcement Learning*. Proceedings of the 10th International Conference on Autonomous Agents and Multiagent Systems (AAMAS), páginas 1037–1044, 2011.
- [DLR25] DLR – Institute of Transportation Systems: *SUMO User Documentation*, 2025. <https://sumo.dlr.de/docs/>, Consultado en 2025.
- [FA11] Fernández A., Rodrigo: *Elementos de la teoría del tráfico vehicular*. Fondo Editorial de la Pontificia Universidad Católica del Perú, 2011.

- [FFA⁺18] Foerster, Jakob, Gregory Farquhar, Triantafyllos Afouras, Nantas Nardelli y Shimon Whiteson: *Counterfactual Multi-Agent Policy Gradients*. En *Proceedings of the AAAI Conference on Artificial Intelligence*, volumen 32, 2018.
- [FH21] Feriani, Amal y Ekram Hossain: *Multi-Agent Reinforcement Learning: Key Differences from Single-Agent RL*. arXiv preprint arXiv:2508.07001, 2021. Fuente: [9] Define la no estacionariedad como una diferencia clave de MARL vs SARL.
- [FNF⁺17] Foerster, Jakob, Nantas Nardelli, Gregory Farquhar, Philip H.S. Torr, Pushmeet Kohli y Shimon Whiteson: *Stabilising Experience Replay for Deep Multi-Agent Reinforcement Learning*. En *Proceedings of the 34th International Conference on Machine Learning (ICML)*, páginas 1146–1155. PMLR, 2017.
- [LWT⁺17] Lowe, Ryan, Yi Wu, Aviv Tamar, Jean Harb, Pieter Abbeel y Igor Mordatch: *Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments*. En *Advances in Neural Information Processing Systems (NeurIPS)*, páginas 6379–6390, 2017.
- [LZPS24] Littman, Michael L., Chongjie Zhang, Liviu Panait y Yoav Shoham: *Multi-Agent Reinforcement Learning: Foundations and Modern Approaches*. MIT Press, 2024. <https://www.mar1-book.com/>, Consultado en 2025.
- [MKS⁺15] Mnih, V., K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg y D. Hassabis: *Human-level control through deep reinforcement learning*. *Nature*, 518(7540):529–533, 2015. <https://doi.org/10.1038/nature14236>.
- [ne18] especificados, Autores no: *Traffic congestion cost Americans over \$160 billion in lost productivity*. Citado en arXiv:2406.13693 (Reporte original de UN 2018), 2018. Fuente: [1] Costos de congestión y emisiones de CO2.
- [PW16] Pande, Anurag y Brian Wolshon: *Traffic Engineering Handbook*. John Wiley & Sons, Inc., 7th edición, 2016.
- [RSDW⁺18] Rashid, Tabish, Mikayel Samvelyan, Christian Schroeder De Witt, Gregory Farquhar, Jakob Foerster y Shimon Whiteson: *QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning*. En *Proceedings*

- of the 35th International Conference on Machine Learning (ICML), páginas 4295–4304. PMLR, 2018.
- [SB20] Sutton, R.S. y A.G. Barto: *Reinforcement learning: An introduction*. The MIT Press, Cambridge, MA, 2020.
- [SLG⁺18] Sunehag, Peter, Guy Lever, Audrunas Gruslys, Wojciech M. Czarnecki, Vinicius Zambaldi, Max Jaderberg, Marc Lanctot, Nicolas Sonnerat, Joel Z. Leibo, Karl Tuyls y Thore Graepel: *Value-Decomposition Networks For Cooperative Multi-Agent Learning*. En *Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems (AAMAS)*, páginas 2085–2087. International Foundation for Autonomous Agents and Multiagent Systems, 2018.
- [W⁺19] Wei, H. y cols.: *A survey on traffic signal control methods*, 2019. Available at: <https://arxiv.org/abs/1904.08117>.
- [ZLYZ23] Zhou, Mengdi, Xiaoteng Li, Yaodong Yang y Weinan Zhang: *A Survey on Centralized Training for Decentralized Execution in Multi-Agent Reinforcement Learning*. Artificial Intelligence Review, 2023.