

Semáforos Inteligentes: Un enfoque con Aprendizaje por Refuerzo Multi Agente

Tesina de Licenciatura en Ciencias de la Computación

Juan Martín Morales

Tutora: Dra Ana Carolina Olivera



UNCUYO
UNIVERSIDAD
NACIONAL DE CUYO



FACULTAD DE
INGENIERÍA

Facultad de Ingeniería
Universidad Nacional de Cuyo

Agradecimientos

Página de agradecimientos

Índice

1	Introducción	6
1.1	Motivación	7
2	Marco Teórico	9
2.1	Ingeniería de Tránsito y Tráfico	9
2.1.1	Fundamentos de la Dinámica Vehicular	10
2.1.2	Fundamentos de la Dinámica Vehicular	11
2.1.3	Sistemas de Control de Tráfico	15
2.1.4	Simulación de Tráfico	15
2.2	Aprendizaje por Refuerzo (RL)	15
2.2.1	El Proceso de Decisión de Markov (MDP)	15
2.2.2	Métodos Basados en Valor y Basados en Política	15
2.2.3	<i>Deep Reinforcement Learning</i> (DRL)	15
2.3	Aprendizaje por Refuerzo Multi-Agente (MARL)	15
2.3.1	Generalización de los MDP mediante Teoría de Juegos	15
2.3.2	Procesos de Decisión de Markov Parcialmente Observables Descentralizados (Dec-POMDP)	15
2.3.3	Paradigmas de Entrenamiento y Ejecución	15
2.3.4	Algoritmos de Aprendizaje Independiente	15
2.3.5	Algoritmos de Política Próxima en MARL	15
2.4	Control de Tráfico Urbano mediante MARL	16
2.4.1	Modelado del Problema del Control de Semáforos (Espacio de Estados, Acciones y Recompensas)	16
2.4.2	Coordinación entre Intersecciones y Mitigación de Congestión	16

Índice de códigos

Índice de figuras

1.1	Flota Circulante por provincia y región	6
2.1	Regímenes de estabilidad y de inestabilidad asintótica en el flujo vehicular [1].	13

Introducción

En las últimas décadas, en el mundo se ha producido un incremento sostenido del parque automotor a nivel mundial, acompañado por un proceso continuo de urbanización que ha a la congestión vehicular en uno de los principales desafíos para la movilidad y eficiencia en áreas urbanas. Según los reportes de flota vehicular de Argentina, elaborados por la Asociación de Fábricas Argentinas de Componentes (AFAC), y utilizando el año 2012 como línea base, el volumen de vehículos registró un aumento del 21,7% en 2017. Dicha progresión se sostuvo a lo largo de la última década, alcanzando un incremento acumulado del 44,4% para el año 2025.

El problema de las congestiones trae consigo múltiples consecuencias: desde importantes pérdidas de productividad por demoras en los tiempos de viaje, hasta un aumento en la cantidad de detenciones vehiculares y la consecuente emisión de gases nocivos para la salud y el medio ambiente, tales como CO , CO_2 , NO_x , HC . [2] Este escenario impacta de manera notable en grandes ciudades con gran densidad de vehículos. En este trabajo se tomó como caso de estudio el Área Metropolitana del Gran Mendoza (GM), comprendida entre Avenida San Martín, Avenida Colón, Avenida Belgrano y Avenida Las Heras. Gran parte de estas calles fueron planificadas para soportar flujos de tráfico significativamente menores a los actuales, y la dependencia de semáforos con ciclos fijos agrava la situación, ya que su inflexibilidad les impide adaptarse dinámicamente a los picos de demanda en tiempo real.

Frente a este escenario, una alternativa viable, sin recurrir a replanificaciones costosas en la infraestructura, consiste en optimizar la gestión del tránsito mediante sistemas de control semafórico adaptativos. Los en-




Figura 1.1: Flota Circulante por provincia y región

foques tradicionales de control semafórico han demostrado poca capacidad de adaptación ante escenarios con mucha variabilidad de flujos de vehículos. Una alternativa prometedora resulta ser el Aprendizaje por Refuerzo (Reinforcement Learning, RL), un paradigma de inteligencia artificial dónde los semáforos pueden modelarse como agentes, capaces de aprender políticas de control a partir de la interacción con un entorno (la situación del tránsito) mediante la ejecución de acciones (cambios de fase) con el objetivo de maximizar una recompensa, como por ejemplo, el valor negativo de la suma de los tiempos de espera de los vehículos involucrados

Sin embargo, aplicar este enfoque de manera simultánea sobre múltiples intersecciones introduce desafíos adicionales. Un esquema de control centralizado resulta poco escalable debido al crecimiento exponencial del espacio de acciones conjunto. Una alternativa "ingenua" del Aprendizaje por Refuerzo Multi-Agente resulta ser el Aprendizaje Independiente (*Independent Learning* o IL), donde cada semáforo busca descongestionar de forma independiente y egoísta solo su propia intersección.[3] Este enfoque tiene dos desventajas críticas: primero, la optimización puramente local conduce a un óptimo global sub-óptimo. Y segundo, dado que todos los agentes aprenden y cambian sus políticas simultáneamente, el entorno se vuelve no estacionario para cada agente individual, lo cual viola los supuestos de convergencia del aprendizaje.[4]

Por esta razón, este trabajo aborda el problema desde el marco del Aprendizaje por Refuerzo Multi-Agente (MARL) Cooperativo. Bajo este paradigma, los controladores (agentes) actúan como un equipo. Aprenden políticas coordinadas, no para maximizar solo una recompensa individual, sino también una recompensa global compartida orientada a la minimización del tiempo de espera promedio de toda la red, evitando así los conflictos que surgen del aprendizaje independiente. La recompensa es un valor numérico que indica cuán efectiva fue la acción conjunta.

En este contexto, el objetivo general de este trabajo fue desarrollar y evaluar un sistema de control de tráfico basado en este enfoque cooperativo para optimizar el flujo vehicular urbano. Para lograrlo, se analizó la convergencia a políticas de control óptimas y la escalabilidad de distintos algoritmos MARL ante entornos no estacionarios mediante simulaciones en escenarios sintéticos y en la red vial real del Gran Mendoza. Esto permitió establecer una línea base de comparación para, posteriormente, validar empíricamente el desempeño de la arquitectura descentralizada y coordinada propuesta frente a los enfoques de control tradicionales y el estado del arte.

1.1 Motivación

La motivación principal de este trabajo radica en la marcada asimetría entre una demanda vehicular en constante crecimiento y una infraestructura

vial que permanece estática. Dado que ensanchar avenidas o modificar físicamente el trazado urbano en cascos densos como el del Gran Mendoza es económica y estructuralmente inviable, la alternativa más sostenible es la optimización lógica de los recursos existentes.

El desarrollo de soluciones basadas en software permite dotar de la adaptabilidad necesaria a la red semafórica actual. De este modo, es posible transformar un sistema rígido en uno inteligente capaz de mitigar las demoras y reducir la contaminación ambiental evitable, maximizando la eficiencia de la infraestructura vial sin requerir obras civiles de gran envergadura.

Marco Teórico

2.1 Ingeniería de Tránsito y Tráfico

De acuerdo con las bases conceptuales establecidas por el *Traffic Engineering Handbook* del *Institute of Transportation Engineers* (ITE), la ingeniería de tránsito (o tráfico) se define formalmente como una subdisciplina de la ingeniería de transporte que aborda la planificación, el diseño y la operación de calles y carreteras, sus redes, las tierras adyacentes y su interacción con otros modos de transporte (como el aéreo, marítimo y ferroviario) así como con sus respectivas terminales. En el contexto del modelado de sistemas y las ciencias de la computación, comprender esta disciplina resulta crucial, ya que provee los modelos matemáticos, las variables de estado y los parámetros de control necesarios para simular y optimizar redes de transporte complejas.

Históricamente, desde la primera edición del manual en 1941, el enfoque de la profesión estuvo fuertemente centrado en proporcionar y expandir la capacidad vial mediante la construcción de nuevas infraestructuras y la ampliación de las arterias existentes. Sin embargo, la evidencia empírica a lo largo de las décadas demostró que el aumento de la congestión vehicular no podía mitigarse de forma sostenible únicamente añadiendo capacidad física. En consecuencia, la disciplina experimentó una evolución paradigmática hacia la gestión de la demanda de tráfico, buscando mitigar la congestión a través de la provisión de alternativas de viaje que integran múltiples modos de transporte.

En la actualidad, la práctica moderna se aleja de los enfoques tradicionales que priorizaban exclusivamente el flujo de automóviles. El nuevo paradigma exige que los ingenieros de tránsito conciban opciones de diseño y control que faciliten el movimiento seguro y eficiente de absolutamente todos los usuarios de la vía. Esto implica diseñar para un ecosistema heterogéneo que incluye peatones, ciclistas, usuarios de transporte público de todas las edades y niveles de habilidad, así como operadores de vehículos de emergencia y de carga comercial. Como ejemplo de esta visión integral, en el caso de las calles urbanas, los ingenieros deben considerar diseños de tráfico alternativos que induzcan velocidades de viaje más lentas; esta restricción de la dinámica vehicular no se ve como una penalización, sino como un mecanismo de control para crear entornos más seguros, fomentar la actividad económica en los centros de las ciudades y contribuir a la revitalización urbana.

Desde una perspectiva analítica y metodológica, la ingeniería de tránsito contemporánea integra soluciones sensibles al contexto, haciendo un profundo énfasis en la resiliencia, la sensibilidad ambiental, la confiabilidad del

sistema y la sostenibilidad. La disciplina ha migrado hacia un marco de diseño y análisis basado en el rendimiento (*performance-based design*). Bajo esta filosofía sistémica, las redes de transporte se diseñan para ser adaptables a demandas fluctuantes y preferencias cambiantes de los usuarios. Las decisiones de diseño y control óptimo ya no se basan únicamente en minimizar el costo de construcción, sino que los profesionales intentan cuantificar el rendimiento *ex-ante*, *in-itinere* y *ex-post* mediante múltiples métricas de costo-beneficio para la mejora de la movilidad y la creación de comunidades habitables.

Finalmente, el objetivo estructural de este enfoque moderno es lograr una armonización y una conexión fluida entre la vía pública y el entorno de uso de suelo circundante. Este nivel de análisis elimina la fragmentación tradicional del diseño en capas aisladas (donde primero se resolvía el tráfico vehicular y luego se adaptaba el espacio para peatones o personas con discapacidad), promoviendo en su lugar una interacción concurrente y multimodal en la planificación, operación y gestión sistémica de calles y carreteras.

2.1.1 Fundamentos de la Dinámica Vehicular

Para alimentar los procesos de toma de decisiones y calibrar los modelos computacionales subyacentes, la ingeniería de tránsito se nutre de rigurosos estudios empíricos que caracterizan la dinámica del sistema. Estos fundamentos estocásticos y deterministas son los que permiten la parametrización de simuladores de tráfico. Entre las variables macroscópicas y microscópicas fundamentales de la dinámica vehicular destacan:

- **Volumen de Tránsito:** Constituye una entrada clave para múltiples análisis de ingeniería, representando el recuento de vehículos, bicicletas o peatones que pasan por un punto o ingresan a una intersección durante un período determinado.
- **Velocidad:** Es una métrica fundamental del rendimiento del tráfico utilizada extensivamente en operaciones, diseño y auditorías de seguridad. Analíticamente, se modela a través de dos estadísticos principales: la velocidad media temporal (*Time-Mean Speed*), que representa la media aritmética de las velocidades recolectadas en un punto topológico específico; y la velocidad media espacial (*Space-Mean Speed*), definida como la distancia total recorrida sobre el tiempo total de viaje para todos los vehículos en un segmento, siendo esta última la métrica central empleada en las ecuaciones de conservación teóricas de velocidad-flujo-densidad.
- **Demora (*Delay*):** Parámetro crítico para medir la calidad del flujo vehicular, que se subdivide funcionalmente en: demora de control

(tiempo en cola sumado a pérdidas de tiempo por procesos de aceleración y desaceleración), demora geométrica (reducción de velocidad inducida por la fisonomía de la infraestructura) y demora total de tiempo de viaje.

- **Longitud de Cola (*Queue Length*):** Permite dimensionar carriles de almacenamiento y provee una medida útil de la eficiencia del control semafórico. Debido a que los modelos matemáticos macroscópicos suelen asumir colas infinitas, se emplean técnicas de simulación computacional para determinar longitudes reales y evitar escenarios de bloqueo (*spillback*) en intersecciones adyacentes o accesos.
- **Flujo de Saturación y Tiempo Perdido:** El flujo de saturación define la capacidad inherente de una vía, representando la tasa máxima de vehículos que pueden cruzar una intersección en una hora teórica de luz verde ininterrumpida. En conjunto con el tiempo perdido (la fracción no utilizable del ciclo semafórico, compuesta por el tiempo perdido de arranque al inicio del verde y el tiempo perdido de despeje o *clearance*), conforman las bases matemáticas ineludibles para programar fases y estimar la capacidad en controladores de tránsito.
- **Brechas y Aceptación de Brechas (*Gaps and Gap Acceptance*):** La dinámica de cruce en flujos de tráfico en conflicto depende de la distribución temporal entre vehículos sucesivos (brechas). El estudio de la "brecha crítica" —es decir, el intervalo de tiempo mínimo aceptable para que un conductor realice una maniobra de cruce— es fundamental para los cálculos de capacidad analítica en intersecciones no semaforizadas y rotondas, resultando vital para la parametrización de agentes en modelos de simulación microscópica.

““

2.1.2 Fundamentos de la Dinámica Vehicular

El estudio analítico del tráfico, bajo la premisa de que la circulación constituye un fenómeno físico y social medible [1], requiere caracterizar matemáticamente el movimiento de las unidades y sus interacciones en la red vial. Esta dinámica se aborda tradicionalmente a través de dos enfoques complementarios: el macroscópico, que trata la corriente vehicular como un medio continuo gobernado por variables agregadas, y el microscópico, que modela las propiedades y trayectorias de unidades discretas individuales [1, 5].

Dualidad y Correlación de Variables Micro-Macroscópicas

El estado físico de una corriente de tráfico continuo queda unívocamente determinado por tres variables macroscópicas principales: la tasa de flujo

(q), la velocidad media de espacio ($\bar{v}_e$) y la densidad o concentración (k) [5]. Estas variables se vinculan mediante la ecuación fundamental del flujo vehicular:

$$q = \bar{v}_e \cdot k \quad (2.1)$$

Para el desarrollo de modelos de simulación y la calibración de algoritmos de control, existe una correspondencia biunívoca entre estas propiedades agregadas y las mediciones microscópicas espaciales y temporales tomadas sobre los vehículos individuales [1, 5]:


1. **Tasa de Flujo e Intervalo:** El flujo (q) es el recíproco del intervalo temporal promedio ($\bar{t}$) medido entre el paso de dos vehículos consecutivos por una sección fija de la vía ($q = 3600/\bar{t}$) [1, 5].
2. **Densidad y Espaciamiento:** La concentración (k) es el recíproco del espaciamiento espacial promedio ($\bar{s}$) entre puntos homólogos de unidades consecutivas en un instante dado ($k = 1000/\bar{s}$) [1, 5].
3. **Velocidad Media de Espacio:** A diferencia de la media de tiempo ($\bar{v}_t$, obtenida mediante promedios aritméticos en un punto fijo), la velocidad media de espacio (*space mean speed*, $\bar{v}_e$) representa la media armónica de las velocidades instantáneas [1, 5]. Esta variable refleja matemáticamente el tiempo total empleado por la corriente para recorrer un tramo y es la que satisface de forma estricta la ecuación fundamental del flujo [5].

Estabilidad del Tráfico y Propagación de Perturbaciones


Cuando el espaciamiento entre vehículos consecutivos disminuye por debajo de un umbral crítico, los movimientos de las unidades se acoplan dinámicamente [1]. En este régimen, el vehículo sucesor se comporta analíticamente como un sistema de control realimentado que responde a los estímulos cinemáticos del líder tras un tiempo de reacción o desfase temporal (T) [1].

Desde la perspectiva de los sistemas dinámicos, un aspecto crítico para la gestión de intersecciones es determinar cómo se propagan las perturbaciones de velocidad (maniobras de frenado) a lo largo de una columna de vehículos. Este fenómeno se descompone en dos dominios esenciales [1]:

- **Estabilidad Local:** Evalúa si un vehículo individual es capaz de amortiguar y estabilizar su velocidad respecto al que lo antecede para evitar una colisión [1].
- **Estabilidad Asintótica:** Analiza el comportamiento sistémico a lo largo de la pista, determinando si la amplitud de una fluctuación cinemática se atenúa o se magnifica a medida que se desplaza hacia atrás en la fila de vehículos [1].



(a) Estabilidad



(b) Inestabilidad

Figura 2.1: Regímenes de estabilidad y de inestabilidad asintótica en el flujo vehicular [1].

Como se describe en la Figura 2.1, la evolución espacio-temporal del sistema difiere según su régimen: en un escenario asintóticamente estable la perturbación inicial se disipa, mientras que en uno inestable la fluctuación se magnifica de forma progresiva con cada vehículo seguidor.

Si el sistema opera en un régimen asintóticamente inestable, una deceleración menor provocará una onda de choque que crecerá en magnitud hasta culminar en una detención total del tráfico (*phantom traffic jam*) [1]. En términos de gestión de infraestructura, la evidencia empírica demuestra que cuando el flujo operativo se aproxima críticamente a la capacidad máxima de la pista ($q \geq 0.9Q$), cualquier perturbación exógena induce un estado de inestabilidad asintótica irreversible en el sistema dinámico [1], haciendo indispensable la intervención de mecanismos de control externos para regular la demanda en la red [6, 5].

Descripción Probabilística y Marcos Estocásticos

A pesar de las relaciones deterministas del flujo, el tráfico real exhibe una alta heterogeneidad debida al comportamiento estocástico de los conductores y a la dispersión en las tasas de llegada [5]. Para inyectar ruido estadístico y realismo en las herramientas de análisis, es imperativo estructurar un marco probabilístico bajo procesos aleatorios discretos y continuos [5].

Cuando los vehículos circulan bajo condiciones de flujo libre o dispersión moderada, se asume que las llegadas constituyen eventos mutuamente independientes [5]. Bajo las hipótesis de un proceso puntual de Poisson, la probabilidad de que se registren exactamente X arribos en una sección de control o línea de detención durante un intervalo de tiempo finito t se define como [5]:

$$P(X) = \frac{m^X \cdot e^{-m}}{X!} \quad (2.2)$$

Donde m representa el valor esperado de arribos en dicho intervalo, calculado a partir del volumen horario de diseño (V) como $m = (V \cdot t)/3600$ [5].

Consecuentemente, la contraparte continua de este proceso gobierna la distribución de los intervalos de tiempo individuales (t_i) entre unidades consecutivas. Si el flujo es aleatorio y poissoniano, los tiempos de paso se describen probabilísticamente mediante una distribución exponencial negativa [5]:

$$P(t_i \geq t) = e^{-\frac{q}{3600} \cdot t} \quad (2.3)$$

Este sustrato analítico estocástico constituye la herramienta matemática fundamental para modelar colas de espera, estimar las demoras en los accesos de las intersecciones y parametrizar los generadores aleatorios de tráfico dentro del entorno de simulación computacional [5].

2.1.3 Sistemas de Control de Tráfico

2.1.4 Simulación de Tráfico

2.2 Aprendizaje por Refuerzo (RL)

2.2.1 El Proceso de Decisión de Markov (MDP)

2.2.2 Métodos Basados en Valor y Basados en Política

2.2.3 *Deep Reinforcement Learning* (DRL)

Neurona artificial Red neuronal Deep Learning Deep Reinforcement Learning

2.3 Aprendizaje por Refuerzo Multi-Agente (MARL)

2.3.1 Generalización de los MDP mediante Teoría de Juegos

2.3.2 Procesos de Decisión de Markov Parcialmente Observables Descentralizados (Dec-POMDP)

2.3.3 Paradigmas de Entrenamiento y Ejecución

Entrenamiento y Ejecución Descentralizada (DTE)

Entrenamiento Centralizado con
Ejecución Descentralizada (CTDE)

2.3.4 Algoritmos de Aprendizaje Independiente

Independent Deep Q-Learning (IDQN)

Independent Proximal Policy Optimization (IPPO)

2.3.5 Algoritmos de Política Próxima en MARL

Multi-Agent Proximal Policy Optimization
(Optimización de Política Próxima Multi-Agente - MAPPO)

Heterogeneous-Agent Proximal Policy Optimization (Optimización
de Política Próxima para Agentes Heterogéneos - HAPPO)

2.4 Control de Tráfico Urbano mediante MARL

2.4.1 Modelado del Problema del Control de Semáforos (Espacio de Estados, Acciones y Recompensas)

2.4.2 Coordinación entre Intersecciones y Mitigación de Congestión

Bibliografía

- [1] Fernández A., Rodrigo: *Elementos de la teoría del tráfico vehicular*. Fondo Editorial de la Pontificia Universidad Católica del Perú, 2011.
- [2] especificados, Autores no: *Traffic congestion cost Americans over \$160 billion in lost productivity*. Citado en arXiv:2406.13693 (Reporte original de UN 2018), 2018. Fuente: [1] Costos de congestión y emisiones de CO2.
- [3] Ault, James y Guni Sharon: *Cooperative Multi-agent Reinforcement Learning Applied to Multi-intersection Traffic Signal Control*. En *Proceedings of the 31st ACM International Conference on Information & Knowledge Management (CIKM '22)*, 2022. <https://people.engr.tamu.edu/guni/papers/CIKM22-MATCS.pdf>, Fuente: [7, 8] Destaca el "éxito limitado" de SARL y los enfoques independientes en redes.
- [4] Feriani, Amal y Ekram Hossain: *Multi-Agent Reinforcement Learning: Key Differences from Single-Agent RL*. arXiv preprint arXiv:2508.07001, 2021. Fuente: [9] Define la no estacionariedad como una diferencia clave de MARL vs SARL.
- [5] Mayor R., Rafael Cal y: *Ingeniería de tránsito: Fundamentos y aplicaciones*. Alfaomega, 9na edición, 2018.
- [6] Pande, Anurag y Brian Wolshon: *Traffic Engineering Handbook*. John Wiley & Sons, Inc., 7th edición, 2016.