UNCUYO
UNIVERSIDAD NACIONAL DE CUYO

FACULTAD DE INGENIERÍA

Semáforos Inteligentes

Un Enfoque con Aprendizaje por Refuerzo Multiagente

Tesina

Licenciatura en Ciencias de la Computación

Autor

Juan Martín Morales

Directora

Dra. Ana Carolina Olivera

Ciudad de Mendoza, Argentina

2026

Resumen

Este trabajo aborda la congestión vehicular urbana mediante el control semafórico con aprendizaje por refuerzo multiagente. Cada intersección se representa por un agente que selecciona fases a partir de una observación local del tránsito. Se consideran la optimización de política proximal multiagente (*Multi-Agent Proximal Policy Optimization*, MAPPO) y con agentes heterogéneos (*Heterogeneous-Agent Proximal Policy Optimization*, HAPPO) con entrenamiento centralizado y ejecución descentralizada, y dos métodos independientes: optimización de política proximal (*Independent Proximal Policy Optimization*, IPPO) y red Q profunda (*Independent Deep Q-Network*, IDQN); además, se describe una adaptación de HAPPO con actualización secuencial de los actores. La espera acumulada por carril se codifica mediante una transformación logarítmico-lineal acotada y discretizada, con mayor resolución en valores bajos. La búsqueda de hiperparámetros se organiza en dos fases, una amplia y otra refinada, para los cuatro algoritmos en tres redes sintéticas; su extensión al microcentro de Mendoza requiere adaptar y verificar el protocolo urbano anterior. La comprobación operacional del centro de Mendoza usa una demanda sintética por pares origen-destino, de 220.000 viajes nominales diarios, y 74 programas semafóricos fijos con ciclo de 90 segundos. En doce horas, sus tasas representan 152.168,75 solicitudes esperadas. Una semilla de desarrollo y tres semillas confirmatorias completaron las ventanas independientes de dos y doce horas. En las tres semillas confirmatorias, la ventana larga terminó con entre 21.913 y 22.216 vehículos pendientes de ingreso. Esta comprobación caracteriza el escenario y no evalúa políticas aprendidas ni valida integralmente la demanda frente a datos de campo.

Abstract

This work addresses urban traffic congestion through multi-agent reinforcement learning for traffic-signal control. Each intersection is represented by an agent that selects phases from a local observation of traffic. The algorithms considered are Multi-Agent Proximal Policy Optimization (MAPPO) and Heterogeneous-Agent Proximal Policy Optimization (HAPPO) with centralized training and decentralized execution, and Independent Proximal Policy Optimization (IPPO) and Independent Deep Q-Network (IDQN) with independent learning; the method also describes an adaptation of HAPPO with sequential actor updates. Accumulated lane waiting is represented by a bounded, discretized log-linear transformation with finer resolution at lower values. Hyperparameter search is organized in two phases, a broad exploration and a refined search, for the four algorithms across three synthetic networks; extending it to downtown Mendoza requires adapting and verifying the previous urban protocol. The operational check of downtown Mendoza uses synthetic origin-destination demand, nominally 220,000 trips per day, and 74 fixed signal programs with a 90-second cycle. Its rates represent 152,168.75 expected requests over twelve hours. One development seed and three confirmatory seeds completed the separate two- and twelve-hour windows. Across the three confirmatory seeds, the longer window ended with between 21,913 and 22,216 vehicles waiting to enter. This check characterizes the scenario; it does not evaluate learned policies or establish comprehensive field validation of demand.

Agradecimientos

Página de agradecimientos

Índice general

1. Introducción **1**
1.1. Motivación . . . 3
1.2. Organización del documento . . . 3

2. Marco teórico **5**
2.1. Ingeniería de tránsito y simulación . . . 5
2.1.1. Terminología de tránsito . . . 6
2.1.2. Fundamentos de la dinámica vehicular . . . 8
2.1.3. Sistemas de control de tránsito . . . 14
2.1.4. Simulación de tránsito . . . 16
2.2. Aprendizaje por refuerzo (RL) . . . 21
2.2.1. Procesos de decisión de Markov (MDP) . . . 23
2.2.2. Métodos basados en valor y basados en política . . . 24
2.2.3. Aprendizaje profundo y redes neuronales . . . 28
2.2.4. Aprendizaje por refuerzo profundo (DRL) . . . 31
2.3. Aprendizaje por refuerzo multiagente (MARL) . . . 38
2.3.1. Fundamentos teóricos: juegos estocásticos, equilibrio de Nash y Dec-POMDP . . . 39
2.3.2. Desafíos del aprendizaje multiagente . . . 40
2.3.3. Paradigmas de entrenamiento y ejecución . . . 42
2.3.4. MADRL y líneas de base . . . 43
2.3.5. MAPPO . . . 43
2.3.6. HAPPO . . . 46
2.3.7. Antecedentes recientes del control semafórico multiagente . . . 52

3. Metodología **57**
3.1. Diseño experimental . . . 58
3.2. Escenarios de simulación . . . 59
3.2.1. Preparación de las redes de tráfico . . . 59
3.2.2. Redes de tráfico sintéticas . . . 59
3.2.3. Red de tráfico de la Ciudad de Mendoza . . . 62

3.3. Sistema de control multiagente 66
3.3.1. Entorno de simulación 68
3.3.2. Observación, acciones y recompensas 68
3.3.3. Agentes y algoritmos de aprendizaje 72
3.4. Entrenamiento y búsqueda de hiperparámetros 73
3.4.1. Condiciones de simulación y entrenamiento 74
3.4.2. Función objetivo de la búsqueda 75
3.4.3. Fase 1: búsqueda amplia 75
3.4.4. Fase 2: búsqueda refinada 76
3.4.5. Criterios de selección de configuraciones 76
3.5. Evaluación y análisis del desempeño 76
3.5.1. Entrenamiento y evaluación de los modelos finales 77
3.5.2. Métricas de desempeño y vehículos evaluados 77
3.5.3. Balance de vehículos en el escenario de Mendoza 79
3.6. Reproducibilidad y alcance 80
3.6.1. Entorno de cómputo y envío de trabajos 80
3.6.2. Alcance y limitaciones 80

4. Análisis y discusión de resultados **82**
4.1. Resultados del ajuste de hiperparámetros 82
4.1.1. Estado de la consolidación y de las búsquedas 83
4.1.2. Resultados del ajuste y análisis de sensibilidad 83
4.1.3. Selección de configuraciones de HPO 83
4.2. Evaluación de políticas y verificación de escenarios 83
4.2.1. Criterios de evaluación y métricas de comparación 83
4.2.2. Desempeño en escenarios sintéticos: 3×1, 3×3, 4×4 heterogéneo 83
4.2.3. Comprobación operacional del escenario de la Ciudad de Mendoza . 83
4.3. Discusión e interpretación de resultados 84

5. Conclusiones **85**

A. Arquitectura de software y especificaciones experimentales **86**
A.1. Diseño orientado a objetos del entorno de simulación 86
A.2. Jerarquía de funciones de recompensa y patrón Strategy 88
A.3. Patrones de diseño de la arquitectura 88
A.4. Parámetros de SUMO y programas semafóricos de referencia 89
A.4.1. Mendoza balance: red, demanda y evidencia operacional 89
A.5. Especificaciones para reproducir los experimentos 95
A.5.1. Infraestructura y almacenamiento de las ejecuciones 95
A.5.2. Comprobaciones preliminares 95

A.5.3. Detalles de las redes sintéticas 96
A.5.4. Espacio de búsqueda inicial de fase 1 96
A.5.5. Semillas de fase 1 en las redes sintéticas 99
A.5.6. Arquitecturas y semillas de la búsqueda refinada sintética 100
A.5.7. Dominios declarados y significado de los parámetros 101
A.5.8. Antecedente de calibración del codificador urbano 105
A.6. Pruebas exploratorias de observación y recompensa 105
A.6.1. Exploración preliminar de formulaciones 105
A.6.2. Comparación local y vecinal multiescenario 106
A.6.3. Configuración fija de la comparación multiescenario 108
A.6.4. Calibraciones y semillas 109
A.6.5. Evaluación de las formulaciones 109
A.6.6. Análisis por pares y criterio de decisión 109
A.6.7. Alcance y limitaciones de la comparación 111
A.7. Detalles del aprendizaje y de la codificación 111
A.7.1. Desarrollo algebraico del codificador 112
A.7.2. Aplicación de la máscara de acciones 113
A.7.3. Preparación de las figuras de escenarios 114
A.7.4. Vistas documentales de los escenarios 114

Índice de figuras

1.1. Evolución de la flota vehicular circulante estimada en Argentina entre 1990 y 2025, expresada en millones de vehículos. La línea y los marcadores representan los valores anuales disponibles; el área sombreada facilita la lectura de su magnitud. Elaboración propia a partir de reportes de AFAC. 1

2.1. Movimientos vehiculares, fases y cruces peatonales 7
2.2. Representación esquemática de movimientos vehiculares y puntos de conflicto en una intersección semaforizada. 8
2.3. Relaciones temporales y espaciales entre vehículos consecutivos de una corriente de tránsito: intervalo (h) y espaciamiento (s). 11
2.4. Comparación esquemática de distribuciones de intervalos temporales entre vehículos en flujo libre y en una corriente con formación de agrupamientos vehiculares. Las curvas representan situaciones conceptuales y no una distribución empírica particular. 13
2.5. Distribución temporal de la tasa de descarga y pérdidas asociadas durante un intervalo de verde en una aproximación semaforizada. 15
2.6. Correspondencia entre la circulación real y su representación en SUMO . . 17
2.7. Interfaz sumo-gui durante una simulación microscópica 18
2.8. Esquema conceptual de carriles, línea de detención y conexiones de una intersección semaforizada bajo circulación por la derecha. La fase representada habilita movimientos directos opuestos del eje horizontal y retiene los movimientos conflictivos. 19
2.9. Interacción agente-entorno en un proceso de decisión de Markov [SB18]. . . 23
2.10. Esquema de un método basado en valor 25
2.11. Esquema de un método basado en política 26
2.12. Arquitectura actor-crítico aplicada al control semafórico 28
2.13. Operaciones de una unidad neuronal artificial: suma ponderada de las entradas, incorporación del sesgo y aplicación de una función de activación. . 29
2.14. Arquitectura conceptual de una red neuronal *feedforward* con dos capas ocultas. 30

2.15. Flujo conceptual de DQN con repetición de experiencias y red objetivo. La red en línea selecciona acciones y recibe las actualizaciones; la red objetivo proporciona el término de *bootstrapping* del valor objetivo diferencia temporal (*Temporal-Difference*, TD). Elaboración propia a partir del algoritmo descrito por Mnih et al. [MKS+15]. 33
2.16. Red de política para un espacio discreto de acciones 35
2.17. Interacción agente-entorno en MARL cooperativo 40
2.18. Evolución de las políticas de dos agentes bajo WoLF-PHC en Piedra, Papel o Tijera 42
2.19. Paradigma de entrenamiento centralizado con ejecución descentralizada (CTDE). Durante el entrenamiento, el crítico utiliza información global privilegiada para estimar valores o ventajas que orientan la actualización de los actores locales; durante la ejecución, los actores solo requieren observaciones locales. 44
2.20. Esquema de actualización secuencial de HAPPO. A diferencia de PPO independiente, la actualización de cada agente está condicionada por el factor de ventaja reponderada M_{i_m}, que incorpora los cambios efectuados por los agentes que lo precedieron en la secuencia. 49

3.1. Etapas del procedimiento experimental en las redes sintéticas para comparar MAPPO, una adaptación de HAPPO, IPPO e IDQN. 58
3.2. Redes sintéticas: (a) corredor 3×1, (b) cuadrícula 3×3 y (c) red heterogénea $4 \times 4_H$. 60
3.3. Preparación de la red vial de Mendoza. 63
3.4. Dominio de Mendoza balance: controladores fijos (puntos rojos), avenidas de referencia y acceso asociado a la zona TAZ 28. 64
3.5. Solicitudes esperadas por hora y horizontes de evaluación en el escenario de Mendoza: corto (06:30–08:30, 2 h) y largo (06:00–18:00, 12 h). 65
3.6. Esquema ilustrativo de entradas, configuración y visualización del escenario urbano en SUMO; no representa los nombres de archivo efectivos de Mendoza balance. 66
3.7. Arquitectura general de Ray RLlib. 67
3.8. Curva de cuantización del codificador local de espera para $I = 22$ niveles y $M_{\text{lane}} = 1.136\,\text{veh·s}$. 70
3.9. Línea temporal de transición de fase y bloqueo por máscara de acciones con decisiones cada $\Delta t = 5\,\text{s}$. 71
3.10. Esquema de actualización de actores con tres agentes ilustrativos: (a) actualización paralela en MAPPO; (b) actualización secuencial con propagación del factor acumulado en HAPPO. 73

3.11. Criterio de inclusión en el conjunto de vehículos evaluados ($\mathcal{V}_{\text{ins}}$) según el instante efectivo de inserción. 78

4.1. Vehículos pendientes de ingreso durante las seis ejecuciones de doce horas. El rayado señala la hora en que se redistribuyeron las solicitudes. 84

A.1. Diagrama de clases del entorno de simulación y de sus relaciones principales. 87
A.2. Especificación UML del módulo de recompensas. 88
A.3. Estructura de la observación del actor y de la señal de recompensa en MAPPO: (a) formulación local A; (b) formulación vecinal C. 107
A.4. Ejemplo de codificación de observaciones. 113
A.5. Distribución de los intervalos de verde, amarillo y todo rojo en los ciclos de referencia de 90 segundos. 114
A.6. Zonas de análisis de tránsito de Mendoza balance, representadas mediante sus tramos asociados. Los identificadores van de 0 a 38, salvo 6 y 9; las marcas no representan límites territoriales. 115

Índice de tablas

2.1. Variables de tránsito macroscópicas y microscópicas 10
2.2. Archivos de entrada y configuración empleados en una simulación de SUMO. 21
2.3. Comparación sintética de familias algorítmicas PPO en entornos multiagente cooperativos. 51

3.1. Perfiles de vehículos de las redes de tráfico sintéticas. 59
3.2. Topología, control y demanda de las redes sintéticas. Se excluyen los tramos y carriles internos de los cruces. 61
3.3. Duraciones de los programas semafóricos de referencia en las redes de tráfico sintéticas (segundos). 62
3.4. Observaciones y recompensas en las fases de búsqueda con redes sintéticas. 71
3.5. Calentamiento y horizonte de simulación por procedimiento. 74

4.1. Comprobación del escenario urbano con programas fijos: síntesis por ventana. 83

A.1. Herramientas y responsabilidades en el sistema experimental. 87
A.2. Entradas del escenario Mendoza balance y SHA-256. 90
A.3. Programas semafóricos de Mendoza balance, controladores 1–25. 91
A.4. Programas semafóricos de Mendoza balance, controladores 26–50. 92
A.5. Programas semafóricos de Mendoza balance, controladores 51–74. 93
A.6. Opciones explícitas en las dos configuraciones de Mendoza balance. 94
A.7. Resultados por semilla en la ventana de 2 h. 94
A.8. Resultados por semilla en la ventana de 12 h. 94
A.9. Espacio inicial de fase 1 para MAPPO, IPPO y HAPPO. Las excepciones por algoritmo se indican en las filas. 97
A.10. Espacio inicial de fase 1 para IDQN. Los contadores se expresan en pasos según la interfaz del algoritmo. 98
A.11. Factores de estudio y valores fijos documentados para la fase 1 sintética. . 98
A.12. Correspondencia entre los parámetros de búsqueda y sus claves de configuración. 99
A.13. Semillas por escenario sintético en la fase 1. 99

A.14.Arquitecturas y semillas de la búsqueda refinada para las doce combinaciones sintéticas. La semilla de evaluación es común a los algoritmos del mismo escenario; las semillas de TPE no son réplicas de entrenamiento. . . 100
A.15.Dominios declarados para la búsqueda `phase2_refined` de HAPPO por escenario y arquitectura. 102
A.16.Dominios declarados para la búsqueda `phase2_refined` de IDQN por escenario y arquitectura. 103
A.17.Dominios declarados para la búsqueda refinada de IPPO por escenario y arquitectura. 103
A.18.Dominios declarados para la búsqueda refinada de MAPPO por escenario y arquitectura. 104
A.19.Variantes examinadas en la prueba preliminar sobre la red $4 \times 4_H$. . . . 106
A.20.Hiperparámetros fijos de aprendizaje de MAPPO. 108

Siglas

A2C Actor–crítico con ventaja (*Advantage Actor-Critic*).

AFAC Asociación de Fábricas Argentinas de Componentes.

API Interfaz de programación de aplicaciones (*Application Programming Interface*).

ASHA Algoritmo asíncrono de reducción sucesiva a la mitad (*Asynchronous Successive Halving Algorithm*).

BFS Búsqueda en anchura (*Breadth-First Search*).

CCAD Centro de Cómputo de Alto Desempeño.

CCAR Centro de Cómputo de Alto Rendimiento.

CI Tasa de completitud de vehículos insertados (*Completion of Inserted Vehicles*).

CLIP Objetivo sustituto recortado (*Clipped surrogate objective*).

CO Monóxido de carbono.

CO2 Dióxido de carbono.

CONICET Consejo Nacional de Investigaciones Científicas y Técnicas.

CPU Unidad central de procesamiento (*Central Processing Unit*).

CR Tasa de completitud (*Completion Rate*).

CTDE Entrenamiento centralizado con ejecución descentralizada (*Centralized Training with Decentralized Execution*).

CVaR Valor en riesgo condicional (*Conditional Value at Risk*).

DAG Grafo acíclico dirigido (*Directed Acyclic Graph*).

DDPG Gradiente de política determinista profundo (*Deep Deterministic Policy Gradient*).

Dec-POMDP Proceso de decisión de Markov parcialmente observable descentralizado (*Decentralized Partially Observable Markov Decision Process*).

DLR Centro Aeroespacial Alemán (*Deutsches Zentrum für Luft- und Raumfahrt*).

DQN Red Q profunda (*Deep Q-Network*).

DRL Aprendizaje por refuerzo profundo (*Deep Reinforcement Learning*).

E/S Entrada/salida (*Input/Output*).

FCEFN Facultad de Ciencias Exactas, Físicas y Naturales.

FHWA Administración Federal de Carreteras (*Federal Highway Administration*).

FLIR Infrarrojo de barrido frontal (*Forward Looking Infrared*).

GAE Estimación generalizada de ventaja (*Generalized Advantage Estimation*).

GPU Unidad de procesamiento gráfico (*Graphics Processing Unit*).

GUI Interfaz gráfica de usuario (*Graphical User Interface*).

HAML Aprendizaje espejo con agentes heterogéneos (*Heterogeneous-Agent Mirror Learning*).

HAPPO Optimización de política proximal con agentes heterogéneos (*Heterogeneous-Agent Proximal Policy Optimization*).

HARL Aprendizaje por refuerzo con agentes heterogéneos (*Heterogeneous-Agent Reinforcement Learning*).

HATRPO Optimización de política por región de confianza con agentes heterogéneos (*Heterogeneous-Agent Trust Region Policy Optimization*).

HBEFA Manual de factores de emisión para transporte por carretera (*Handbook Emission Factors for Road Transport*).

HC Hidrocarburos no combustionados.

HPC Computación de alto rendimiento (*High-Performance Computing*).

HPO Optimización de hiperparámetros (*Hyperparameter Optimization*).

IA Inteligencia artificial (*Artificial Intelligence*).

IDQN Red Q profunda independiente (*Independent Deep Q-Network*).

IL Aprendizaje independiente (*Independent Learning*).

IPPO Optimización de política proximal independiente (*Independent Proximal Policy Optimization*).

IQM Media intercuartílica (*Interquartile Mean*).

IR Tasa de inserción (*Insertion Rate*).

ITE Instituto de Ingenieros de Transporte (*Institute of Transportation Engineers*).

KL Divergencia de Kullback–Leibler.

MADDPG Gradiente de política determinista profundo multiagente (*Multi-Agent Deep Deterministic Policy Gradient*).

MADRL Aprendizaje por refuerzo profundo multiagente (*Multi-Agent Deep Reinforcement Learning*).

MAPPO Optimización de política proximal multiagente (*Multi-Agent Proximal Policy Optimization*).

MARL Aprendizaje por refuerzo multiagente (*Multi-Agent Reinforcement Learning*).

MDP Proceso de decisión de Markov (*Markov Decision Process*).

ML Aprendizaje automático (*Machine Learning*).

MLP Perceptrón multicapa (*Multi-Layer Perceptron*).

NFS Sistema de archivos de red (*Network File System*).

NOx Óxidos de nitrógeno.

OD Origen-destino (*Origin-Destination*).

OOD Fuera de distribución (*Out-of-Distribution*).

OSM OpenStreetMap.

PHEMlight Modelo de emisiones para vehículos livianos y pesados (*Passenger car and Heavy duty Emission Model light*).

POMDP Proceso de decisión de Markov parcialmente observable (*Partially Observable Markov Decision Process*).

POSIX Interfaz portable de sistemas operativos (*Portable Operating System Interface*).

PPO Optimización de política proximal (*Proximal Policy Optimization*).

QMIX Red de mezcla de valores Q (*Q-Mixing Network*).

ReLU Unidad lineal rectificada (*Rectified Linear Unit*).

RL Aprendizaje por refuerzo (*Reinforcement Learning*).

SGD Descenso de gradiente estocástico (*Stochastic Gradient Descent*).

SL Aprendizaje supervisado (*Supervised Learning*).

SLURM Herramienta simple de Linux para gestión de recursos (*Simple Linux Utility for Resource Management*).

SUMO Simulación de movilidad urbana (*Simulation of Urban MObility*).

TAZ Zona de análisis de tránsito (*Traffic Analysis Zone*).

TCP Protocolo de control de transmisión (*Transmission Control Protocol*).

TD Diferencia temporal (*Temporal-Difference*).

TPE Estimador de Parzen estructurado en árbol (*Tree-structured Parzen Estimator*).

TraCI Interfaz de control del tránsito (*Traffic Control Interface*).

TRPO Optimización de política por región de confianza (*Trust Region Policy Optimization*).

UL Aprendizaje no supervisado (*Unsupervised Learning*).

UML Lenguaje unificado de modelado (*Unified Modeling Language*).

UTM Sistema de coordenadas universal transversal de Mercator (*Universal Transverse Mercator*).

VDN Redes de descomposición de valor (*Value-Decomposition Networks*).

VF Función de valor (*Value Function*).

WGS84 Sistema Geodésico Mundial 1984 (*World Geodetic System 1984*).

WoLF-PHC Ascenso de colina en la política con ganar o aprender rápido (*Win or Learn Fast Policy Hill-Climbing*).

XML Lenguaje de marcado extensible (*Extensible Markup Language*).

Glosario

G_t **(retorno)** Suma acumulada, usualmente descontada, de las recompensas futuras a partir del instante t.

$G_{\mathbf{wait}}$ **(coeficiente de Gini de esperas)** Índice adimensional entre 0 y 1 que cuantifica la desigualdad entre las medias temporales de espera por controlador semafórico; no describe la distribución entre vehículos.

K_i **(número de acciones)** Número de fases semafóricas seleccionables por el agente i. Excluye las fases con amarillo y el estado final de todo rojo; las restricciones temporales pueden reducir el subconjunto de acciones habilitado en un instante.

$M_{i_{1:m}}$ **(factor de reponderación HAPPO)** Factor acumulativo de razones de probabilidad que repondera la ventaja conjunta en la actualización secuencial de HAPPO para reflejar los cambios de política de los agentes predecesores.

$Q(s, a)$ **(valor de acción)** Retorno esperado de ejecutar la acción a en el estado s y continuar posteriormente de acuerdo con una política determinada.

$R_t^{\mathbf{target}}$ **(retorno objetivo)** Estimación de retorno utilizada como referencia para ajustar la predicción de valor del crítico en el instante t.

$S[\pi_\theta]$ **(entropía de la política)** Medida de la dispersión de la distribución de acciones de la política; su inclusión en el objetivo favorece la exploración.

$V(s)$ **(valor de estado)** Retorno esperado al comenzar en el estado s y seguir una política determinada, promediando las acciones que dicha política selecciona.

$W_i^{(t)}$ **(espera atribuida a la intersección)** Suma de las esperas atribuidas a los carriles controlados por el agente i en el paso de decisión t, en veh·s. Se utiliza en la observación vecinal y en las diferencias de espera de la recompensa; depende de la memoria temporal finita de SUMO y no equivale a la espera total por viaje de TripInfo.

$W_{\mathbf{net}}$ **(demora acumulada global)** Métrica agregada que suma los segundos de espera de los vehículos detenidos en la red durante la ventana de evaluación.

α **(tasa de aprendizaje)** Paso de actualización que regula la magnitud del ajuste de los parámetros o valores en cada iteración de aprendizaje. En arquitecturas actor–crítico se especializa mediante subíndices, tales como α_θ para la red del actor y α_ϕ (o η) para el crítico.

δ_t **(error de diferencia temporal)** Diferencia entre la recompensa más el valor descontado del estado siguiente y la estimación de valor del estado actual.

ϵ_{clip} **(margen de recorte)** Hiperparámetro de PPO que delimita el intervalo utilizado para recortar la razón entre la probabilidad nueva y la anterior de una acción.

ϵ_{exp} **(exploración)** Probabilidad o coeficiente que controla la selección de acciones exploratorias frente a las acciones favorecidas por la política o la función de valor.

η **(tasa del optimizador)** Tamaño de paso empleado por el optimizador en la actualización de parámetros mediante descenso de gradiente.

γ **(factor de descuento)** Parámetro en el intervalo $[0, 1)$ que pondera la contribución de las recompensas futuras al retorno esperado.

$\hat{A}_t$ **(ventaja estimada)** Estimación del valor de la función de ventaja en el paso temporal t (habitualmente calculada mediante GAE), que cuantifica cuánto supera o desmejora el rendimiento de la acción ejecutada respecto del valor basal esperado del estado.

λ **(suavizado de la ventaja)** Hiperparámetro que pondera errores de diferencia temporal de distintos horizontes al estimar la ventaja y equilibra sesgo y varianza.

$\mathcal{L}(\theta)$ **(función de pérdida)** Función escalar que cuantifica el error del modelo y que se minimiza para ajustar los parámetros θ.

ϕ **(parámetros del crítico)** Vector de parámetros entrenables de la red que estima la función de valor del crítico.

π_θ **(política parametrizada)** Distribución de probabilidad sobre las acciones condicionada por el estado u observación y controlada por el vector de parámetros entrenables θ.

ρ_{coop} **(ponderación cooperativa)** Coeficiente en $[0, 1)$ que pondera la combinación entre la recompensa local de una intersección y la señal promedio de sus vecinos topológicos; los dominios de búsqueda pueden restringirlo a un intervalo menor.

θ **(parámetros de la política)** Vector de parámetros entrenables que determina la distribución de acciones de la política del actor.

a **(aceleración vehicular)** Parámetro de aumento de velocidad del tipo de vehículo en SUMO, expresado en metros por segundo cuadrado. En las ecuaciones de aprendizaje, la letra a puede representar una acción; son usos distintos que se distinguen por el contexto.

a_i, A_t **(acción)** Decisión ejecutada por un agente. En formulaciones temporales, A_t denota la variable aleatoria de acción en el paso t; en entornos multiagente, a_i representa la acción local del agente i y $\mathbf{a} = (a_1, \ldots, a_n)$ la acción conjunta. En el control semafórico corresponde a la fase asignada a la intersección.

c_1 **(coeficiente de valor)** Peso asignado al término de pérdida de la función de valor en el objetivo combinado de PPO.

c_2 **(coeficiente de entropía)** Peso asignado al término de entropía que incentiva la exploración en el objetivo combinado de PPO.

d **(desaceleración vehicular)** Parámetro de frenado del tipo de vehículo en SUMO, expresado como una magnitud positiva en metros por segundo cuadrado.

m_i **(carriles controlados)** Número de carriles entrantes controlados por el agente i. En el entorno utilizado, la observación local incorpora una medida de espera codificada por cada uno de estos carriles.

o_i **(observación local)** Información disponible para el agente i durante la ejecución descentralizada. Se obtiene a partir de los sensores o variables observables de la intersección que controla.

r_t **(recompensa)** Señal escalar recibida en el paso temporal t después de ejecutar una acción. Se utiliza para orientar la actualización de la política o de la función de valor.

s **(estado global)** Representación conjunta de las variables relevantes del entorno en un instante determinado. En el modelo multiagente puede incluir la información de todas las intersecciones y sus corrientes vehiculares.

$v_{\text{máx}}$ **(velocidad máxima vehicular)** Velocidad máxima configurada para un tipo de vehículo, expresada en metros por segundo; el límite de la vía también restringe la velocidad permitida.

Binding Mecanismo que conecta una biblioteca escrita en un lenguaje de programación con otro lenguaje para poder utilizar sus funciones.

Bootstrap Procedimiento de remuestreo con reemplazo utilizado para aproximar la incertidumbre de un estimador a partir de las observaciones disponibles.

Buffer Estructura que almacena temporalmente datos para su posterior procesamiento o remuestreo en algoritmos de aprendizaje.

***Epoch* (época)** Recorrido completo de optimización sobre el conjunto de datos recolectado para una iteración; puede reutilizarse durante varios *epochs*.

Logit Puntuación real sin normalizar que una red de política produce para una acción antes de convertirla en probabilidad.

***Minibatch* (minilote)** Subconjunto reducido de muestras extraído de un lote utilizado para estimar el gradiente y actualizar los parámetros de un modelo durante el entrenamiento.

Replay buffer Estructura que almacena experiencias previas para remuestrearlas durante el entrenamiento de un método basado en valor.

Rollout Secuencia ordenada de transiciones generada mientras una política interactúa con el entorno.

Softmax Función que transforma un conjunto de puntuaciones reales en probabilidades no negativas cuya suma es uno.

checkpoint Archivo que guarda los parámetros del modelo y, si está implementado, el estado del entrenamiento en una iteración intermedia o final. Puede utilizarse para reanudar o evaluar desde ese punto; su existencia no demuestra que el ensayo esté completo ni que sus resultados sean admisibles.

Actor (Aprendizaje por Refuerzo) Componente de la arquitectura del modelo de aprendizaje responsable de seleccionar y ejecutar la acción en el entorno basándose en el estado actual y la política que está aprendiendo.

Agente Entidad computacional que observa el estado de su entorno y ejecuta acciones según una política determinada con el objetivo de maximizar su recompensa a largo plazo.

Ciclo (Ingeniería de Tránsito) Secuencia completa y repetitiva de todas las fases semafóricas programadas en una intersección particular.

Cola vehicular Fila de vehículos que se detienen o avanzan muy lentamente debido a una restricción en la capacidad de la vía, tal como la luz roja de un semáforo.

Crítico (Aprendizaje por Refuerzo) Componente encargado de estimar la función de valor, prediciendo la recompensa futura esperada para evaluar la calidad de las acciones tomadas por el Actor y así guiar su actualización.

Densidad vehicular Número de vehículos presentes en un tramo o longitud específica de un carril en un instante dado.

desfase semafórico Relación temporal entre un punto de referencia de un programa semafórico local y el reloj común de coordinación.

Distribución loguniforme Distribución uniforme en el logaritmo de una variable positiva. Asigna la misma probabilidad a intervalos con igual razón entre sus extremos y permite explorar distintas escalas de magnitud.

Distribución uniforme continua Distribución que asigna la misma probabilidad a intervalos de igual longitud dentro de un rango. En la búsqueda de hiperparámetros, delimita propuestas para parámetros continuos.

Dominio de búsqueda Conjunto de rangos u opciones permitidos para los hiperparámetros en una búsqueda de configuraciones.

Ensayo de búsqueda de hiperparámetros Evaluación de una configuración concreta de hiperparámetros mediante entrenamiento y registro del objetivo y sus métricas. Puede terminar antes del presupuesto previsto y no equivale a un episodio ni a una iteración de entrenamiento.

Entorno El sistema dinámico con el que interactúa el agente. Responde a las acciones del agente produciendo transiciones de estado y emitiendo señales de recompensa.

Episodio Secuencia de interacción que comienza al reiniciar el entorno y termina cuando se alcanza una condición terminal o el horizonte máximo definido.

Estado Representación cuantitativa o cualitativa de la situación actual del entorno en un instante de tiempo específico. Sirve como base para que el agente seleccione su próxima acción.

Estudio de búsqueda de hiperparámetros Búsqueda que agrupa ensayos y su historial bajo una función objetivo y un espacio de búsqueda. En el protocolo de este proyecto, cada estudio se asocia con un algoritmo, un escenario y una arquitectura.

Fase (Ingeniería de Tránsito) Estado temporal de un controlador semafórico que habilita el derecho de paso a uno o más movimientos o corrientes vehiculares compatibles entre sí para que crucen una intersección de forma segura.

Flujo vehicular Cantidad de vehículos que pasan por una sección transversal específica de un carril o calzada durante un intervalo de tiempo determinado.

Función de Valor Estimación matemática de la cantidad total de recompensa que un agente puede esperar acumular en el futuro, comenzando desde un estado particular y siguiendo una política específica.

Grado de vecindad Cantidad de agentes vecinos directos de un agente. En el entorno utilizado, una conexión vial entre carriles controlados establece una relación de vecindad registrada para ambos agentes, incluso si la vía es de sentido único.

Hiperparámetro Valor de configuración que se fija antes de un entrenamiento, como la tasa de aprendizaje o el tamaño de las capas ocultas. Se distingue de los parámetros de la red, que se ajustan durante el aprendizaje.

Intervalo de confianza Rango que expresa la incertidumbre de una estimación. Su nivel nominal indica la proporción de estudios repetidos en la que el procedimiento cubriría el valor verdadero bajo sus supuestos; no asigna una probabilidad a ese valor una vez calculado el intervalo.

Iteración de entrenamiento Ciclo completo en el que se recolectan datos con una política y se realizan una o más actualizaciones de sus parámetros.

Lote (*batch*) Conjunto de muestras o transiciones procesadas conjuntamente durante una operación de entrenamiento..

Memoria temporal de espera Intervalo finito sobre el cual SUMO acumula la espera consultada mediante TraCI; se distingue de la espera total registrada por viaje en TripInfo.

Máscara de acciones Representación de las acciones habilitadas en una decisión; excluye del proceso de selección las acciones no admisibles. En el control semafórico, la admisibilidad depende de las fases, las transiciones y los tiempos definidos por el control; la máscara no constituye por sí sola una garantía de seguridad vial en campo.

Observación Subconjunto de información del estado completo del entorno que es efectivamente visible o medible por un agente individual, especialmente relevante en escenarios de observabilidad parcial.

Par de políticas Unidad experimental compuesta por dos políticas entrenadas con la misma semilla y evaluadas con el mismo conjunto de semillas de simulación.

Percentil Valor que deja una proporción determinada de las observaciones por debajo o a su altura. El percentil 99 corresponde aproximadamente al 99 % de las observaciones.

Política (Aprendizaje por Refuerzo) Estrategia que define el comportamiento del agente en un momento dado, mapeando los estados observados a probabilidades de selección de las acciones disponibles.

Proceso de Decisión de Markov Marco matemático utilizado para modelar la toma de decisiones en situaciones donde los resultados son en parte aleatorios y en parte bajo el control de un agente tomador de decisiones.

Recompensa Señal escalar devuelta por el entorno que evalúa cuán buena o mala fue la acción ejecutada por el agente en un estado particular. El objetivo del agente es maximizar la suma total de estas señales.

Semilla Número que inicializa un generador de números pseudoaleatorios. Permite repetir su secuencia cuando se conservan el procedimiento y la configuración; usar la misma semilla no garantiza resultados idénticos si se modifican las decisiones del agente o el entorno.

Serialización Conversión de un objeto o mensaje a una representación que puede almacenarse o transmitirse y luego reconstruirse.

Telemetría Conjunto de mediciones que el simulador registra durante la ejecución, como velocidades, posiciones, detenciones y tiempos de espera.

Teletransporte de SUMO Mecanismo de SUMO, denominado originalmente *teleport*, que retira temporalmente un vehículo bloqueado y lo reinserta para evitar que la simulación se detenga.

Transición (Aprendizaje por Refuerzo) Registro de un paso de interacción que contiene el estado u observación actual, la acción ejecutada, la recompensa recibida, el estado siguiente y, cuando corresponde, un indicador de terminación.

vehículos pendientes de ingreso Vehículos cuya salida programada ya corresponde, pero que todavía no han podido insertarse en la red vial; se distinguen de los vehículos retenidos dentro de ella.

Ventaja (Aprendizaje por Refuerzo) Métrica que cuantifica cuánto mejor o peor resulta tomar una acción particular en un estado dado, en comparación con el desempeño promedio esperado según la política actual.

1

Introducción

En las últimas décadas, el crecimiento del parque automotor y la urbanización sostenida han convertido a la congestión vehicular en uno de los principales desafíos para la movilidad urbana. Según los reportes de flota vehicular de Argentina elaborados por la Asociación de Fábricas Argentinas de Componentes (AFAC), y tomando 2012 como línea base, el volumen de vehículos aumentó un 21,7 % en 2017. Esta tendencia continuó durante la última década y alcanzó un incremento acumulado del 44,4 % en 2025 (véase la Figura 1.1) [Aso18, Aso26].

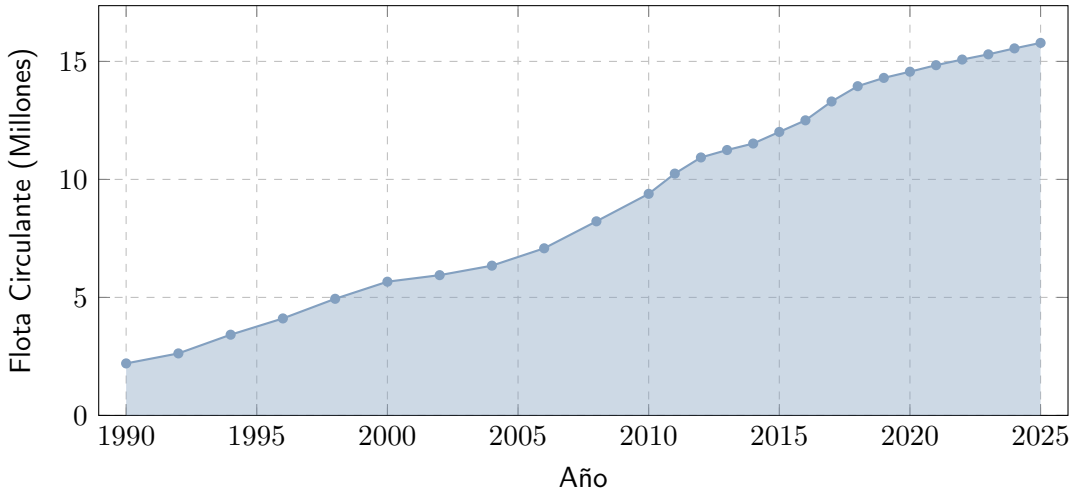


Figura 1.1: Evolución de la flota vehicular circulante estimada en Argentina entre 1990 y 2025, expresada en millones de vehículos. La línea y los marcadores representan los valores anuales disponibles; el área sombreada facilita la lectura de su magnitud. Elaboración propia a partir de reportes de AFAC.

Como refleja la Figura 1.1, la flota vehicular activa en Argentina experimentó una expansión sostenida entre 1990 y 2025, pasando de aproximadamente 2,2 millones a 15,78 millones de unidades operativas [Aso18, Aso26]. En los reportes de AFAC, la flota circulante comprende automóviles y vehículos comerciales livianos y pesados en condiciones de circular, excluyendo acoplados y remolques; representa una estimación del parque activo bajo esa definición, no el total histórico de unidades patentadas ni la cantidad de viajes realizados. Este incremento acumulado ejerce una presión creciente sobre redes viales consolidadas que poseen una capacidad física fija, agudizando la formación de colas y demoras en las intersecciones urbanas críticas.

La congestión deteriora las condiciones de operación de la red e incrementa las demoras y las detenciones de los vehículos [CyMR18]. Una alternativa para mejorar esa operación sin grandes modificaciones de infraestructura consiste en ajustar los semáforos a las condiciones del tránsito. Los enfoques tradicionales pueden presentar limitaciones para responder a variaciones en el flujo vehicular [PW16].

En este contexto, los avances en inteligencia artificial (*Artificial Intelligence*, IA) y en particular el aprendizaje por refuerzo (*Reinforcement Learning*, RL) permiten modelar los semáforos como agentes que aprenden políticas de control a partir de la interacción con el entorno. Las acciones corresponden a cambios de fase y la recompensa puede definirse, por ejemplo, como el negativo del tiempo de espera acumulado. Diversos estudios han mostrado la viabilidad de este enfoque, desde algoritmos tabulares aplicados a una sola intersección [Wie00] hasta modelos de redes coordinadas basados en redes neuronales profundas y control multiagente [W$^+$19].

Sin embargo, la aplicación simultánea de este enfoque en múltiples intersecciones introduce desafíos adicionales. Un esquema centralizado puede resultar poco escalable, pues el espacio de acciones conjunto crece multiplicativamente con el número de intersecciones [ACS24]. En una formulación de aprendizaje por refuerzo multiagente (*Multi-Agent Reinforcement Learning*, MARL) con aprendizaje independiente (*Independent Learning*, IL), cada semáforo optimiza su propia intersección sin considerar explícitamente el efecto de sus decisiones sobre el resto de la red [AS22]. Además, como todos los agentes aprenden y modifican sus políticas al mismo tiempo, cada uno observa un entorno no estacionario. Esto dificulta la convergencia de los algoritmos de agente único [FNF$^+$17].

Por esta razón, este trabajo estudia el control multiagente con un objetivo de coordinación vial. Cada agente recibe una recompensa individual. La búsqueda amplia explora combinaciones de señales locales y vecinales, mientras que el protocolo refinado fija una recompensa local. En MAPPO y HAPPO, un crítico centralizado incorpora información conjunta durante el entrenamiento. La observación vecinal, la recompensa mixta y la centralización del crítico son mecanismos distintos cuyo uso depende del protocolo.

El objetivo general es desarrollar y evaluar procedimientos de control semafórico mediante aprendizaje por refuerzo multiagente. El diseño compara MAPPO y HAPPO, con

entrenamiento centralizado y ejecución descentralizada, frente a IPPO e IDQN, con aprendizaje independiente. Para ello, organiza una búsqueda amplia y otra refinada en tres redes sintéticas.

Para extender la investigación a un dominio urbano, se construye un escenario del microcentro de Mendoza y se verifica su funcionamiento con programas semafóricos fijos. Esta verificación no evalúa políticas aprendidas; el aprendizaje urbano requiere adaptar y verificar el procedimiento para ese escenario.

La propuesta incorpora una codificación de la espera acumulada por carril mediante una transformación logarítmico-lineal en I niveles. La resolución no uniforme distingue con mayor detalle valores bajos de esa medida y acota los valores representados a partir de un umbral. La elección de cómo representar el tránsito influye en el problema de aprendizaje y cuenta con antecedentes en control semafórico [GR18]. En este trabajo, la codificación se utiliza en todos los agentes.

También se estudia una adaptación de HAPPO para intersecciones con distintas geometrías, fases disponibles y demandas. A diferencia de la actualización de actores utilizada en MAPPO, esta adaptación los actualiza secuencialmente y repondera las ventajas individuales según los cambios de política precedentes [KCW+22]. El crítico centralizado incorpora información conjunta durante el entrenamiento. La comparación con MAPPO, IPPO y IDQN examina el desempeño de procedimientos completos en esos escenarios, sin atribuir de antemano una ventaja a HAPPO ni aislar el efecto de su actualización secuencial.

1.1. Motivación

La motivación de este trabajo se centra en estudiar cómo coordinar agentes que aprenden en una misma red vial. El control adaptativo basado en aprendizaje por refuerzo permite ajustar decisiones a las condiciones observadas [MMLK25]. En una red de múltiples intersecciones, interesa examinar cómo esa adaptación puede incorporar los efectos de las decisiones locales sobre los cruces vecinos.

Las diferencias de demanda, geometría y fases disponibles entre intersecciones motivan, además, el estudio de políticas que puedan adaptarse a esas condiciones. La comparación de MAPPO y HAPPO con los esquemas independientes IPPO e IDQN permite examinar distintas formas de aprendizaje y coordinación bajo una misma formulación del problema.

1.2. Organización del documento

Para dar respuesta a los objetivos planteados y estructurar el desarrollo de la investigación, el presente documento se organiza en cinco capítulos y un apéndice técnico.

Este capítulo contextualiza la congestión vehicular urbana y presenta el alcance y los objetivos del trabajo. El capítulo 2 desarrolla los fundamentos de ingeniería de tránsito, procesos de decisión de Markov, aprendizaje profundo y aprendizaje por refuerzo

multiagente necesarios para seguir el diseño experimental.

El capítulo 3 describe los escenarios de simulación, la interfaz de control de los agentes y los protocolos de búsqueda y evaluación. El capítulo 4 presenta la evidencia de búsqueda y los resultados de la verificación del escenario de Mendoza.

Finalmente, el capítulo 5 sintetiza las conclusiones principales a la luz de los objetivos propuestos, delimita el alcance y las limitaciones del estudio, y proyecta líneas de trabajo futuro. Como complemento técnico, el apéndice A describe el diseño de software del paquete `marlTLC` mediante diagramas de clases en lenguaje unificado de modelado (*Unified Modeling Language*, UML) y reúne los dominios de búsqueda y los parámetros de ejecución de los experimentos.

2

Marco teórico

Este capítulo presenta los fundamentos teóricos del trabajo y vincula la ingeniería de tránsito con el aprendizaje por refuerzo para la toma de decisiones secuenciales en redes viales. Estos conceptos permiten modelar una red semafórica como un entorno estocástico y formular políticas de control adaptativo con agentes homogéneos y heterogéneos.

Primero se introducen los conceptos de ingeniería de tránsito y simulación (sección 2.1). Luego se desarrollan los fundamentos del aprendizaje por refuerzo y su integración con redes neuronales (sección 2.2), seguidos de su extensión al caso multiagente y de los algoritmos MAPPO y HAPPO (sección 2.3). Finalmente, se revisan los antecedentes recientes de control semafórico multiagente según sus esquemas de coordinación, representación del estado y tratamiento de la heterogeneidad (sección 2.3.7).

2.1. Ingeniería de tránsito y simulación

La ingeniería de tránsito es una rama de la ingeniería de transporte, tradicionalmente vinculada con la ingeniería civil. Se ocupa de la planificación, el diseño geométrico y la operación segura y eficiente del tránsito en calles, carreteras y redes viales, de acuerdo con manuales especializados como el *Traffic Engineering Handbook* [PW16] y con la literatura clásica del área [CyMR18]. En este trabajo, sus conceptos se abordan desde la perspectiva del modelado computacional y la gestión adaptativa. Permiten describir el funcionamiento físico de la red, caracterizar la oferta y la demanda de circulación e identificar las variables sobre las que puede intervenir el sistema de control.

Históricamente, la práctica de la ingeniería de tránsito puso un fuerte énfasis en aumentar la capacidad física vial mediante la construcción de nuevas obras o el ensanche de

calzadas [PW16]. Sin embargo, el crecimiento sostenido del parque automotor evidenció que la ampliación de la infraestructura no constituye una solución definitiva al problema de la congestión. En áreas urbanas consolidadas, además, modificar el trazado vial resulta costoso y, en algunos casos, difícil de realizar [CyMR18]. Por ello, la práctica contemporánea complementa la infraestructura física con estrategias de control dinámico del tránsito, priorizando la optimización de los recursos existentes mediante dispositivos de control semafórico.

La operación de una red vial puede analizarse a partir de la relación entre la demanda vehicular y la capacidad disponible. La demanda vehicular (D) corresponde a la cantidad de vehículos que requieren desplazarse por un determinado sistema vial en un lapso dado, mientras que la oferta vial o capacidad (c) representa la cantidad máxima de vehículos que pueden circular por dicho espacio físico bajo determinadas condiciones de operación [CyMR18]. Cuando la demanda se aproxima a la capacidad, el tránsito se vuelve inestable; cuando la supera ($D > c$), se presentan condiciones de sobresaturación o flujo forzado, caracterizadas por detenciones frecuentes y grandes demoras. En este sentido, la congestión no se entiende solo como una percepción general de mal funcionamiento, sino como un fenómeno con manifestaciones físicas medibles: demoras, colas y detenciones [FA11].

Estas magnitudes cumplen una función doble en el modelo computacional: pueden formar parte de las observaciones y de la señal de recompensa de los agentes, y también se utilizan para evaluar el desempeño del agente. Su definición permite vincular la descripción física del tránsito con la formulación posterior del problema de aprendizaje.

2.1.1. Terminología de tránsito

Antes de formular el problema de control, es necesario distinguir algunos términos que se utilizarán a lo largo del capítulo. En particular, se diferencian los movimientos que realizan los vehículos, las fases que habilitan esos movimientos y los intervalos durante los cuales se mantienen las indicaciones semafóricas [Fed08].

En este contexto, se emplearán las siguientes nociones:

- **Intersección (*intersection*), acceso (*approach*) y carril (*lane*):** una intersección es el área física y operacional en la que confluyen dos o más corrientes de tránsito. Cada una de las calzadas de aproximación que ingresan a ella constituye un acceso [PW16], organizándose internamente en uno o más carriles destinados a canalizar los flujos vehiculares [CyMR18].

- **Movimiento vehicular y movimientos en conflicto:** un movimiento vehicular representa la trayectoria específica que describe un vehículo al cruzar la intersección hacia una salida determinada, por ejemplo, un giro o un movimiento directo [W$^+$19]. Dos movimientos pueden generar puntos de conflicto cuando sus trayectorias se intersectan (véase la Figura 2.2). Cuando la geometría y la señalización no permiten

proteger su operación simultánea, esos movimientos deben programarse en intervalos distintos por razones de seguridad [FA11].

- **Fase (*phase*), ciclo (*cycle*) e intervalo (*interval*):** una fase es una configuración de señales que habilita simultáneamente un conjunto de movimientos compatibles [PW16]. El ciclo corresponde a la secuencia completa de fases necesaria para atender los movimientos de la intersección. Un intervalo es el período durante el cual las indicaciones semafóricas permanecen constantes [CyMR18].

La Figura 2.1 ilustra estos conceptos en una intersección de cuatro accesos. Los números del 1 al 8 identifican movimientos vehiculares individuales y las etiquetas $P2$, $P4$, $P6$ y $P8$ identifican cruces peatonales del esquema. Esta numeración sigue de manera esquemática una convención habitual de los manuales de temporización semafórica; no representa una configuración experimental ni una asignación obligatoria de fases para el caso de estudio. Las flechas, los accesos y las etiquetas de calles permiten distinguir trayectorias y sentidos, mientras que los cruces peatonales muestran otros usuarios que también deben considerarse al ordenar los movimientos. En este trabajo, la Figura se utiliza para separar la noción geométrica de movimiento de la regla semafórica que habilita un conjunto de movimientos compatibles [Fed08]. Por ejemplo, dos movimientos que no comparten un punto de conflicto pueden incluirse en una misma fase, mientras que los que sí lo comparten deben atenderse en fases compatibles o sucesivas.

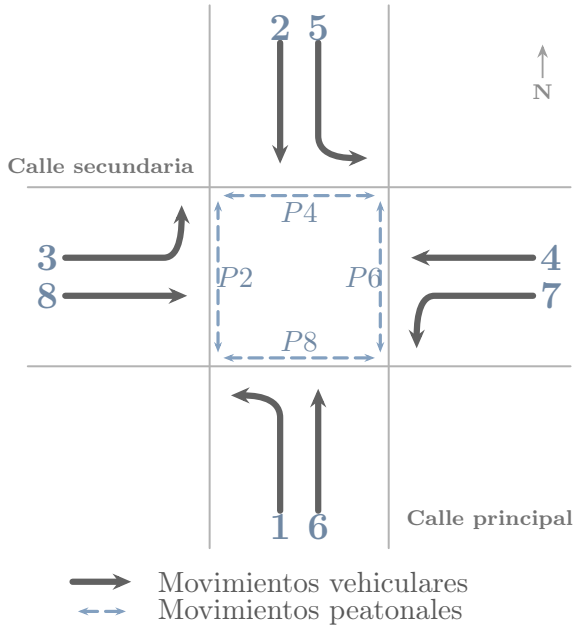


Figura 2.1: Convención esquemática de movimientos vehiculares, fases y cruces peatonales concurrentes en una intersección de cuatro accesos, adaptada conceptualmente del manual de temporización semafórica de Administración Federal de Carreteras (*Federal Highway Administration*, FHWA) [Fed08].

La Figura 2.2 presenta tres formas esquemáticas de relación entre trayectorias. Hay

cruce cuando dos trayectorias se intersectan en un punto; *convergencia* cuando trayectorias distintas se unen en una misma corriente; y *divergencia* cuando una corriente se separa en trayectorias diferentes. Los puntos coloreados marcan el lugar de interacción que se analiza en cada caso. Cada relación puede originar un punto de conflicto según la geometría y la simultaneidad de los movimientos: por eso, la incompatibilidad no depende solo de que las líneas se relacionen, sino de que su operación conjunta comprometa la seguridad. En el modelo semafórico, estos casos se utilizan para determinar qué movimientos pueden habilitarse en una misma fase y cuáles deben retenerse; la Figura muestra relaciones geométricas, no una programación temporal concreta.

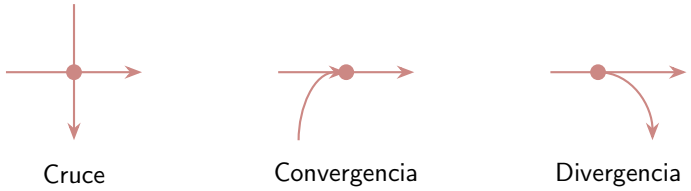


Figura 2.2: Representación esquemática de movimientos vehiculares y puntos de conflicto en una intersección semaforizada.

En arterias urbanas, el tránsito se desarrolla bajo condiciones de flujo interrumpido: los vehículos no avanzan únicamente por su interacción con otros vehículos, sino también por la presencia de intersecciones, señales y dispositivos de control de tránsito [PW16]. Las intersecciones son puntos críticos de la red porque allí confluyen distintos accesos y movimientos vehiculares de cruce, convergencia y divergencia que pueden resultar incompatibles entre sí, como resume la Figura 2.2. Por ello, su operación requiere ordenar estos movimientos y asignar la prioridad de paso de manera segura y eficiente.

El semáforo es uno de los dispositivos de control de tránsito utilizados para regular la circulación en intersecciones. Su función es asignar la prioridad de paso en forma alternada entre corrientes vehiculares incompatibles, evitando que distintos movimientos intenten ocupar simultáneamente el mismo espacio de cruce [FA11]. Desde el punto de vista del modelado algorítmico, esta capacidad de modificar la prioridad de paso convierte al semáforo en el actuador mediante el cual un sistema de control puede intervenir sobre la operación de la intersección y afectar, directa o indirectamente, las demoras y colas observadas en la red.

2.1.2. Fundamentos de la dinámica vehicular

Para modelar y optimizar la operación de una red vial, es necesario caracterizar físicamente el movimiento de los vehículos. La ingeniería de tránsito estudia este fenómeno a partir de las características fundamentales de la corriente de tránsito, que permiten describir las condiciones de operación de una vía o intersección mediante magnitudes observables como el flujo, la velocidad y la densidad [PW16]. Cal y Mayor distingue estas magnitudes entre variables principales, que describen el comportamiento agregado del flu-

jo vehicular, y variables asociadas, que expresan relaciones temporales y espaciales entre vehículos consecutivos [CyMR18].

A nivel macroscópico, la corriente de tránsito se representa mediante variables agregadas como la tasa de flujo, la densidad y los promedios de velocidad. A nivel microscópico, se analizan magnitudes propias de vehículos individuales e interacciones entre pares consecutivos, como la velocidad puntual, el intervalo y el espaciamiento [CyMR18]. Esta separación entre escalas es fundamental para el modelado computacional: las variables macroscópicas resumen el estado operacional de los accesos de la red, mientras que las variables microscópicas describen el comportamiento de cada vehículo dentro del simulador [FA11]. La correspondencia y las relaciones de conversión entre las variables de ambas escalas se resumen en la Tabla 2.1.

En el nivel macroscópico, las variables principales de la corriente de tránsito son [CyMR18]:

- **Flujo o tasa de flujo (q):** representa la cantidad de vehículos que atraviesan una sección transversal de la vía por unidad de tiempo. Si el período de observación es menor a una hora, se proyecta como una tasa horaria equivalente en vehículos por hora, calculada como $q = N/T$, donde N es el número de vehículos observados y T es la duración del intervalo de medición expresado en horas.

- **Densidad o concentración (k):** indica el número de vehículos que ocupan simultáneamente una longitud específica de vía, expresada en vehículos por kilómetro, calculada como $k = N/d$, donde d representa la longitud del tramo de vía analizado. En la práctica, se suele estimar indirectamente a través del porcentaje de ocupación temporal registrado por detectores inductivos [PW16].

- **Velocidad media espacial (v_s):** es la velocidad media de los vehículos que ocupan un tramo de vía en un instante determinado. Corresponde al promedio armónico de las velocidades puntuales de los vehículos individuales y representa la magnitud de velocidad consistente con la dinámica del flujo espacial.

- **Velocidad media temporal (v_t):** representa el promedio aritmético de las velocidades de los vehículos que cruzan una sección transversal fija de la vía durante un período de tiempo determinado.

En el nivel microscópico, las variables asociadas son [CyMR18]:

- **Velocidad puntual (v_i):** es la velocidad instantánea a la que un vehículo individual (i) atraviesa una sección transversal específica de la vía.

- **Intervalo temporal (h):** es el tiempo transcurrido entre el paso de dos vehículos consecutivos por una sección fija de la calzada, medido respecto a puntos homólogos,

por ejemplo, los paragolpes delanteros. El intervalo promedio en segundos (h_{prom}) se relaciona con la tasa de flujo como $h_{\text{prom}} = 3600/q$.

- **Espaciamiento simple (s):** es la distancia física entre puntos homólogos de dos vehículos consecutivos en un instante de tiempo. El espaciamiento promedio en metros (s_{prom}) se relaciona de forma inversa con la densidad de la corriente de tránsito como $s_{\text{prom}} = 1000/k$.

La Figura 2.3 complementa estas definiciones con las magnitudes que se miden en el espacio y en el tiempo. El largo del vehículo l y la separación libre e son distancias, expresadas en metros; el espaciamiento s es la distancia entre puntos homólogos de vehículos consecutivos, también en metros. El avance temporal β es el tiempo asociado al recorrido del largo del vehículo a la velocidad v, la brecha temporal g es el tiempo entre el paso del vehículo precedente y el siguiente respecto de puntos de referencia distintos, y el intervalo temporal h es el tiempo entre pasos de puntos homólogos; β, g y h se expresan en segundos. Las cotas inferiores representan relaciones espaciales y las superiores relaciones temporales; no son dos vehículos distintos ni dos mediciones independientes. En este trabajo, estas magnitudes sirven para vincular la descripción individual de los vehículos con las variables agregadas del flujo.

Tabla 2.1: Comparación y correspondencia de variables de tránsito en escalas macroscópica y microscópica.

Escala	**Variable Principal**	**Relación / Conversión**
Macroscópica	Flujo (q, vehículos por hora)	$q = 3600/h_{\text{prom}}$
	Densidad (k, vehículos por kilómetro)	$k = 1000/s_{\text{prom}}$
	Velocidad media espacial (v_s, kilómetros por hora)	$q = k \cdot v_s$
	Velocidad media temporal (v_t, kilómetros por hora)	$v_t = v_s + \frac{\sigma_s^2}{v_s}$ (Relación de Wardrop)
Microscópica	Velocidad puntual (v_i, kilómetros por hora)	Variable individual de cada vehículo
	Intervalo temporal (h, segundos)	Tiempo entre pasos de vehículos sucesivos
	Espaciamiento simple (s, metros)	Distancia espacial entre paragolpes homólogos

La Figura 2.3 presenta de manera conjunta estas distancias y tiempos entre vehículos, y permite interpretar cómo las magnitudes microscópicas describen la separación y el avance de una corriente.

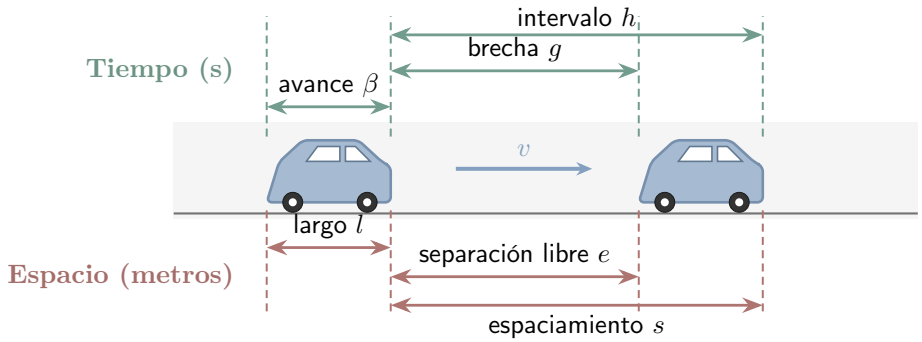


Figura 2.3: Relaciones temporales y espaciales entre vehículos consecutivos de una corriente de tránsito: intervalo (h) y espaciamiento (s).

Estas variables macroscópicas se relacionan de manera directa a través de la ecuación fundamental del flujo de tránsito:

$$q = k \cdot v_s \tag{2.1}$$

donde q es la tasa de flujo, k es la densidad y v_s es la velocidad media espacial. La ecuación (2.1) utiliza la velocidad media espacial, ya que relaciona el flujo y la cantidad de vehículos presentes en un tramo. La velocidad media temporal (v_t) es la media aritmética de las velocidades observadas en un punto durante un intervalo, mientras que v_s, asociada al promedio de las velocidades de una muestra espacial tomada sobre un tramo, se estima en la práctica como media armónica de las velocidades puntuales medidas en una sección durante un intervalo. Cuando existe variabilidad entre las velocidades, ambas magnitudes pueden diferir. La relación entre ellas se expresa mediante la relación de Wardrop [FA11]:

$$v_t = v_s + \frac{\sigma_s^2}{v_s} \tag{2.2}$$

donde σ_s^2 representa la varianza de la distribución de las velocidades de los vehículos en el espacio. La ecuación (2.2) muestra que, dado que la varianza es no negativa ($\sigma_s^2 \geq 0$), se cumple $v_t \geq v_s$, con igualdad únicamente cuando todos los vehículos circulan a la misma velocidad. En una intersección semaforizada, una indicación roja puede reducir localmente la velocidad media y aumentar la acumulación de vehículos en los accesos. Estos efectos se manifiestan en la formación de colas y en el incremento de las demoras [CyMR18].

Métricas de ineficiencia operativa

La interrupción del flujo causada por semáforos o saturación genera efectos adversos que los sistemas de control buscan mitigar. Siguiendo la terminología de la ingeniería de tránsito, las principales manifestaciones medibles de esta ineficiencia son las demoras, las colas y las detenciones [FA11]:

- **Demoras:** representan el tiempo adicional que un vehículo debe invertir para atravesar una intersección respecto del tiempo que le tomaría circular a velocidad de flujo libre. En intersecciones semaforizadas, una parte de esa demora aparece por la espera normal durante la luz roja. Otras demoras se producen cuando las llegadas de vehículos varían, cuando la demanda se acerca o supera la capacidad de la intersección, o cuando quedan colas sin disiparse al finalizar el verde, de modo que algunos vehículos deben esperar más de un ciclo para cruzar.

- **Colas:** corresponden al número de vehículos acumulados detrás de una línea de detención a la espera de traspasarla. Esta medida espacial es especialmente relevante porque, cuando la cola supera la longitud del arco de aproximación, puede bloquear la intersección precedente y propagar la congestión al resto de la red.

- **Detenciones:** cuantifican la cantidad de veces que un vehículo debe reducir su velocidad hasta cero durante el recorrido. Una alta frecuencia de detenciones deteriora la continuidad operativa del flujo y suele asociarse con mayores procesos de aceleración y desaceleración.

Estas magnitudes permiten describir el desempeño operacional de una intersección y de la red. En la formulación computacional, también pueden utilizarse para construir observaciones, señales de recompensa o criterios de evaluación del agente.

Descripción probabilística del flujo y agrupamientos vehiculares

En el modelado de tránsito, las llegadas vehiculares no siempre pueden representarse adecuadamente como una secuencia determinista y constante. Para flujos vehiculares bajos y medios, y cuando las llegadas no están fuertemente condicionadas por semáforos previos, es habitual aproximar el número de vehículos que llega a una sección durante un intervalo de tiempo mediante un proceso de Poisson [CyMR18].

Esta aproximación supone independencia estadística entre llegadas y permite describir la variabilidad observada en la demanda de acceso a una intersección [CyMR18]. La probabilidad discreta $P(X)$ de que lleguen exactamente X vehículos en un intervalo de tiempo se define como:

$$P(X) = \frac{m^X \cdot e^{-m}}{X!} \tag{2.3}$$

donde $X \in \mathbb{N}_0$ es la variable aleatoria discreta que representa el número de arribos vehiculares, $m > 0$ representa el valor esperado o media de llegadas en dicho intervalo, y e es la base del logaritmo natural. La ecuación (2.3) formaliza esta probabilidad discreta. Bajo el mismo supuesto, los intervalos de tiempo continuos (h) medidos entre vehículos sucesivos se describen mediante una distribución de probabilidad exponencial negativa [CyMR18]:

$$P(h \geq t) = e^{-\frac{q}{3600} \cdot t} \tag{2.4}$$

donde h es el intervalo temporal en segundos, q es el flujo en vehículos por hora, y t es el umbral de tiempo analizado. La ecuación (2.4) expresa la probabilidad de que el intervalo supere dicho umbral.

Esta representación probabilística supone independencia entre arribos sucesivos y resulta adecuada para flujos bajos o moderados en condiciones de flujo libre, sin influencia de semáforos cercanos en intersecciones precedentes [CyMR18]. El supuesto pierde validez en condiciones de congestión o en redes urbanas semaforizadas. En estos casos, los semáforos interrumpen el flujo agrupando los vehículos, lo que introduce dependencia espacio-temporal entre arribos consecutivos. La Figura 2.4 compara conceptualmente los intervalos temporales resultantes bajo ambas condiciones. En ella, $h_{\text{mín}}$ representa un umbral mínimo conceptual para el intervalo mostrado en la curva con agrupamientos vehiculares; no es una estimación obtenida de datos de este trabajo. Las curvas y ese umbral tienen, por lo tanto, función ilustrativa y no constituyen una distribución empírica particular.

En este trabajo, la limitación de esos modelos analíticos motiva el uso de simulación microscópica para analizar la operación semafórica bajo condiciones variables. En el simulador *Simulation of Urban Mobility* (SUMO), la formación, dispersión e interacción de los agrupamientos vehiculares emergen de la dinámica simulada de los vehículos y de sus cambios de carril. Los procesos aleatorios del simulador se inicializan con una semilla (*seed*), un número que permite repetir su secuencia pseudoaleatoria bajo la misma configuración y versión. Cambiar la semilla permite estudiar variaciones de la simulación. Repetirla no hace iguales los resultados si también cambia el agente o sus decisiones.

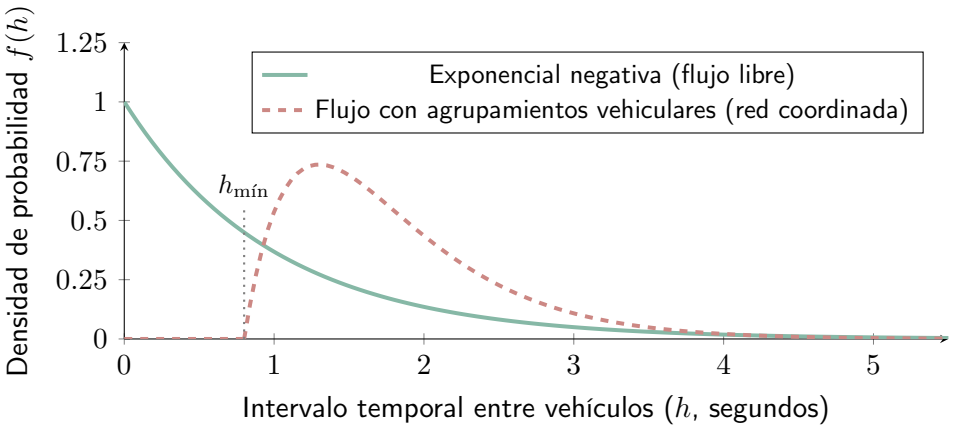


Figura 2.4: Comparación esquemática de distribuciones de intervalos temporales entre vehículos en flujo libre y en una corriente con formación de agrupamientos vehiculares. Las curvas representan situaciones conceptuales y no una distribución empírica particular.

La Figura 2.4 se interpreta comparando la forma de ambas curvas. El eje horizontal representa el intervalo h entre vehículos y el eje vertical la densidad de probabilidad $f(h)$, es decir, la concentración relativa de intervalos alrededor de cada valor. En el modelo exponencial, la densidad disminuye desde el origen y asigna mayor frecuencia relativa

a los intervalos breves. En la representación con agrupamientos vehiculares, la densidad comienza después de $h_{\text{mín}}$ y alcanza un máximo alejado del origen, lo que ilustra que el arribo de un vehículo queda condicionado por la separación y la coordinación con los que lo preceden. La comparación permite reconocer por qué el supuesto de arribos independientes puede resultar insuficiente en una red semaforizada.

2.1.3. Sistemas de control de tránsito

Para ordenar los movimientos en conflicto y regular el paso en las intersecciones urbanas se utilizan sistemas de control de tránsito [PW16]. El semáforo asigna el derecho de paso de manera alternada mediante indicaciones luminosas rojas, amarillas y verdes [CyMR18].

En el modelo computacional, el semáforo actúa como el mecanismo mediante el cual el controlador interviene sobre la red. La selección de fases, la duración del verde efectivo y la coordinación entre intersecciones modifican la prioridad de paso y afectan la evolución de las colas y las demoras.

Sobre esta base terminológica, la programación temporal de un semáforo se describe mediante la duración de las fases, la longitud de ciclo y la definición de los intervalos de transición y despeje. Estos parámetros determinan cuánto tiempo recibe prioridad cada conjunto de movimientos compatibles y condicionan directamente la capacidad de descarga, las demoras y la seguridad operacional de la intersección [PW16].

En relación con los giros izquierdos, los manuales de temporización distinguen entre operación permisiva, protegida y protegida-permisiva. En una fase permisiva, el giro se ejecuta aprovechando brechas en la corriente opuesta; en una fase protegida, el giro recibe una indicación exclusiva y los movimientos conflictivos permanecen detenidos; en una fase protegida-permisiva, ambas condiciones se combinan durante distintos intervalos del ciclo [Fed08]. En este análisis, la distinción resulta útil porque muestra que una fase no es solo un color del semáforo, sino una regla operacional que habilita ciertos movimientos, impone cesión de paso en otros y restringe los movimientos en conflicto.

Para garantizar la seguridad vial, las transiciones entre fases no pueden ejecutarse de manera instantánea, sino que deben respetar intervalos de cambio y despeje ($t_{\text{amarillo}} + t_{\text{rojo_todo}}$) [PW16]. En esta investigación, esos tiempos se consideran restricciones operativas de seguridad previamente definidas en la configuración del simulador y del sistema semafórico. En consecuencia, su determinación no forma parte del proceso de decisión del agente, cuyo control se limita a la selección o extensión de fases dentro de un esquema temporal compatible con dichas restricciones.

Modelado de la capacidad y el verde efectivo

Desde el punto de vista operativo, la capacidad de descarga de un acceso semaforizado depende del tiempo efectivo de servicio que recibe cada fase y de la tasa con la que la fila puede disiparse cuando el movimiento tiene prioridad [FA11]. En la Figura 2.5, $q_{\text{máx}}$

representa la tasa de descarga de saturación, g el intervalo de verde efectivo, y l_1 y l_2 las pérdidas inicial y final de servicio, respectivamente; el tiempo se expresa en segundos y la tasa de flujo en vehículos por hora. La barra inferior distingue los intervalos de rojo, verde y amarillo, mientras que la curva superior muestra cómo la descarga alcanza y abandona el régimen de saturación. La descarga observada no depende solo de la duración nominal del verde, sino también de pérdidas de arranque, transiciones y otras restricciones temporales del control. La Figura es conceptual: estos parámetros no se estiman en este trabajo. En su lugar, los efectos se representan mediante la dinámica microscópica del simulador y la configuración temporal del sistema semafórico, ya que esas interacciones determinan las colas, demoras y detenciones que el controlador busca mejorar.

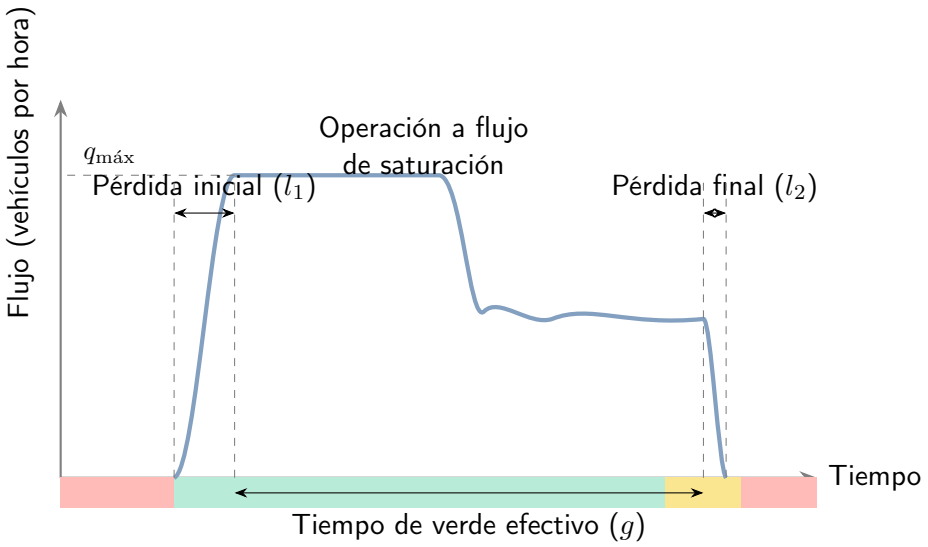


Figura 2.5: Distribución temporal de la tasa de descarga y pérdidas asociadas durante un intervalo de verde en una aproximación semaforizada.

La Figura 2.5 debe leerse como una relación temporal: las pérdidas l_1 y l_2 reducen el intervalo en que la fase puede descargar vehículos a la tasa $q_{\text{máx}}$. Por tanto, el verde efectivo g no equivale necesariamente al verde nominal programado en el controlador.

Clasificación de los controladores de semáforos

De acuerdo con su mecanismo operativo y su grado de respuesta a la demanda vehicular, los controladores de semáforos se clasifican clásicamente en control de tiempo fijo y control accionado por el tránsito [PW16]. En el primero, los planes de señales se repiten de manera preprogramada a partir de datos históricos y no cambian en respuesta a la demanda instantánea. En el segundo, la intersección utiliza detectores en los accesos para variar dinámicamente el inicio o la duración de las fases según la demanda observada en tiempo real.

Incluso en los esquemas accionados, la operación permanece sujeta a parámetros límite de seguridad y funcionamiento, como el verde mínimo ($g_{\text{mín}}$) y el verde máximo ($g_{\text{máx}}$)

[PW16]. Estos parámetros restringen cuánto puede sostenerse o finalizarse una fase y, en este trabajo, forman parte de las condiciones operativas dentro de las cuales el controlador toma decisiones.

2.1.4. Simulación de tránsito

Debido a la densidad y complejidad de las redes urbanas, la sincronización y optimización de los tiempos semafóricos requiere representar la evolución del tránsito bajo condiciones variables. Los modelos analíticos y agregados resultan útiles bajo determinados supuestos, pero pueden ser limitados para describir la formación de colas y las interacciones locales durante la operación dinámica de una red [PW16]. De acuerdo con la taxonomía clásica [FA11], los modelos de tránsito pueden organizarse en tres niveles de resolución. Los modelos macroscópicos describen el tránsito de manera agregada mediante variables como flujo, densidad y velocidad; los mesoscópicos representan entidades intermedias, como agrupamientos vehiculares; y los microscópicos modelan individualmente los vehículos, sus rutas y su evolución dentro de la red. Para esta investigación resulta especialmente relevante este último nivel, pues permite examinar cómo las decisiones semafóricas inciden en la formación de colas, las detenciones y las interacciones locales entre vehículos.

La simulación de tránsito constituye una representación abstracta del fenómeno real. Su objetivo no es reproducir visualmente una escena particular, sino modelar los procesos que determinan la evolución de la circulación mediante reglas de comportamiento y variables observables. La calidad de los resultados depende de la representación de la red, la demanda, la flota, los modelos de comportamiento y las reglas de control. Por ello, la simulación debe entenderse como un entorno experimental sujeto a supuestos y parámetros, cuyos resultados requieren una evaluación operacional acorde con el objetivo del estudio. La correspondencia entre el fenómeno y su representación se resume en la Figura 2.6: el tránsito real constituye la referencia y el simulador representa sus vehículos, red y reglas dinámicas para permitir experimentos controlados.

La Figura 2.6 muestra, de forma sintética, la correspondencia entre una escena vial y su representación microscópica en SUMO. Su función es ilustrar cómo los vehículos y la infraestructura se transforman en entidades computacionales; no constituye una validación del simulador ni una representación del escenario utilizado en este trabajo.

SUMO pertenece a la categoría microscópica descrita por Fernández [FA11]. Es una *suite* libre y de código abierto iniciada en el Instituto de Sistemas de Transporte del Centro Aeroespacial Alemán (*Deutsches Zentrum für Luft- und Raumfahrt*, DLR), que permite modelar sistemas de tránsito intermodales, incluidos vehículos, transporte público y peatones. También ofrece herramientas para importar redes, calcular rutas, visualizar y evaluar simulaciones, además de interfaces para controlar su ejecución [DLR26].

En SUMO, la evolución vehicular se actualiza en pasos temporales discretos sobre una



Figura 2.6: Correspondencia entre la circulación real y su representación microscópica en SUMO. Fuente: DLR – Institute of Transportation Systems, *SUMO User Documentation* [DLR26].

representación espacial continua. El entorno permite modelar calles con múltiples carriles, cambios de carril, distintos tipos de vehículos, rutas individuales, semáforos y salidas de simulación a nivel de vehículo, carril, arco o detector [DLR26].

La interfaz gráfica del programa `sumo-gui` permite inspeccionar visualmente la red, los vehículos y algunos valores de la simulación durante la ejecución. Esta visualización cumple una función de apoyo para la inspección del escenario y la depuración del modelo; las métricas utilizadas para la evaluación se obtienen de las salidas de simulación y de las interfaces de control [DLR26]. La interfaz y su función de inspección se muestran en la Figura 2.7; la interfaz gráfica de usuario (*Graphical User Interface*, GUI) no constituye la fuente de las métricas ni reemplaza su cálculo operacional.

La Figura 2.7 reúne cuatro zonas de inspección. A la izquierda se observa la red completa, útil para localizar la parte del escenario que se está examinando. A la derecha se muestra una vista ampliada de la calzada y de un vehículo seleccionado, mientras que el gráfico superpuesto en la parte inferior representa la evolución temporal de su velocidad, expresada en metros por segundo. La franja inferior contiene el registro de mensajes y advertencias producidos durante la ejecución, y la barra superior agrupa los controles de avance, pausa, tiempo y escala de visualización. En conjunto, estos elementos permiten verificar visualmente la presencia de vehículos, su movimiento y posibles inconsistencias de configuración. En este trabajo la interfaz se usa con fines de inspección y depuración; la evaluación cuantitativa se realiza con las salidas de simulación y las interfaces de control [DLR26].

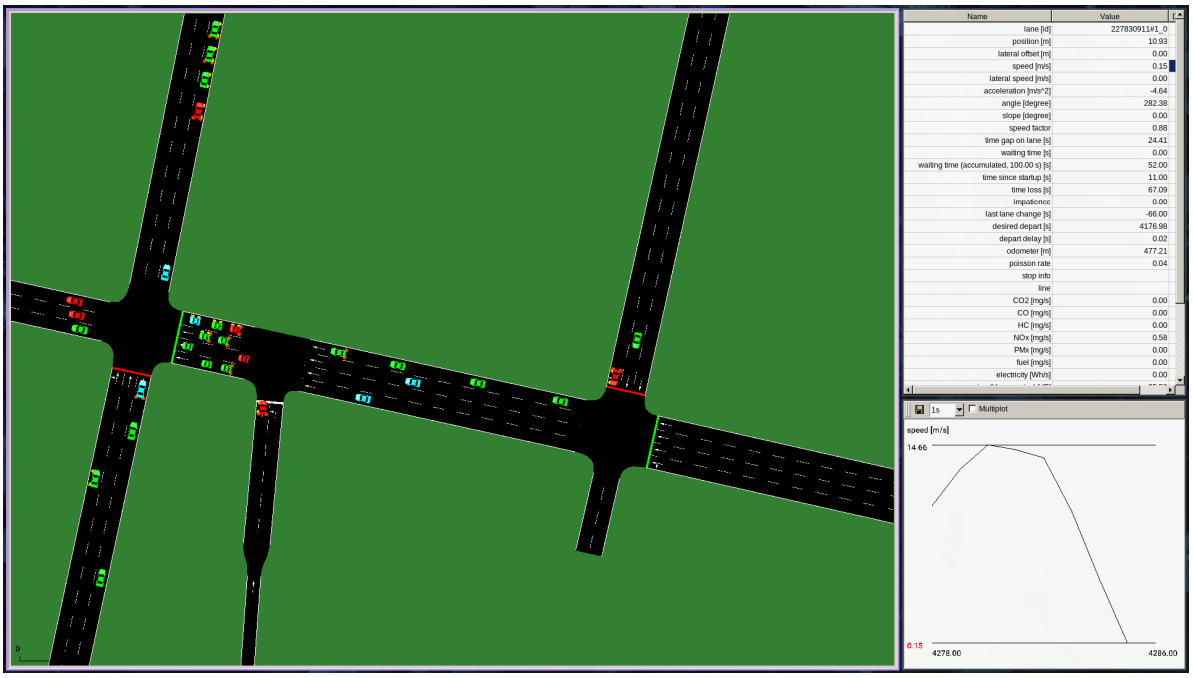


Figura 2.7: Interfaz del programa `sumo-gui` durante una simulación microscópica. El panel izquierdo presenta una vista general de la red; el derecho muestra información sobre un vehículo particular; el recuadro inferior grafica su velocidad y el superior muestra los valores de sus variables relacionadas. Fuente: DLR – Institute of Transportation Systems, *SUMO User Documentation* [DLR26].

Esta granularidad vuelve a la simulación microscópica especialmente adecuada para estudiar control semafórico mediante aprendizaje por refuerzo. Las decisiones sobre fases y tiempos de servicio pueden evaluarse mediante sus consecuencias sobre la dinámica simulada: colas, tiempos de espera, detenciones, ocupación de carriles, completitud de viajes y propagación de congestión. En la formulación computacional, las variables de tránsito constituyen observaciones, las fases admisibles constituyen acciones y la evolución simulada constituye la transición del entorno. La definición operacional de estas variables y su procedimiento de cálculo se presentan en la metodología.

Representación microscópica de intersecciones en SUMO

La naturaleza microscópica de la simulación no se reduce a representar visualmente vehículos. Cada unidad modifica su velocidad y posición de acuerdo con modelos de seguimiento vehicular y cambio de carril, los parámetros de su tipo de vehículo y las restricciones de la red. De este modo, variables como la aceleración, la separación entre vehículos, la velocidad deseada y la disponibilidad de carriles intervienen en la formación y dispersión de colas. Los valores concretos utilizados para la flota y para estos parámetros pertenecen a la configuración experimental y se detallan en la metodología [DLR26].

En este contexto, el simulador de tránsito constituye el entorno operativo sobre el cual se formaliza el problema de control semafórico. La Figura 2.8 esquematiza la representación microscópica de una intersección con circulación por la derecha [DLR26], en la que

se distinguen carriles, líneas de detención y conexiones:

- **Carriles entrantes (L_{in}) y salientes (L_{out}):** los carriles entrantes conducen el flujo vehicular hacia la intersección y los salientes reciben la descarga tras cruzar el nodo, indicados mediante flechas que señalan el sentido de circulación.
- **Línea de detención (*stop line*):** líneas blancas continuas próximas al final de cada carril entrante, delante de las cuales se detienen los vehículos cuando la fase no habilita su movimiento.
- **Conexiones (*links*):** relaciones que conectan un carril entrante con uno saliente a través del área de cruce. En SUMO, cada enlace controlado se asocia con un índice y con un estado de señal (G para verde prioritario, g para verde con cesión de paso, y para amarillo y r para rojo). En la fase conceptual ilustrada, las flechas verdes corresponden a los movimientos directos opuestos habilitados del eje horizontal, mientras que las flechas rojas señalan las conexiones retenidas.

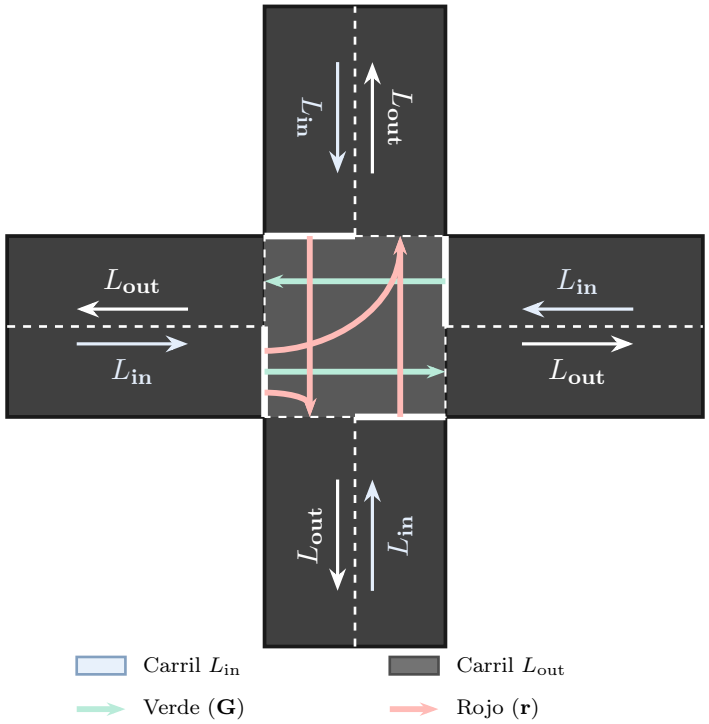


Figura 2.8: Esquema conceptual de carriles, línea de detención y conexiones de una intersección semaforizada bajo circulación por la derecha. La fase representada habilita movimientos directos opuestos del eje horizontal y retiene los movimientos conflictivos.

Por consiguiente, una fase no modifica la geometría ni el sentido de los carriles, sino que determina qué conexiones pueden utilizarse durante cada intervalo de control. Esta representación resulta directamente compatible con la formulación algorítmica del problema, donde una acción válida debe seleccionar una fase compatible con la geometría

de la intersección y respetar las transiciones y restricciones de seguridad definidas por el entorno.

Componentes y configuración de SUMO

La *suite* SUMO reúne aplicaciones para construir redes, generar demandas, ejecutar simulaciones, visualizar sus resultados y controlar la ejecución mediante interfaces externas [DLR26]:

- **netconvert:** aplicación que importa redes desde distintas fuentes y compila su representación en el formato nativo de SUMO. También permite reconstruir o ajustar elementos de la red, como las conexiones y los programas semafóricos.
- **netedit:** editor gráfico para crear y modificar de forma interactiva nodos, calles, carriles, conexiones, restricciones de giro y elementos de control semafórico.
- **osmWebWizard:** herramienta que automatiza la generación de un escenario a partir de un área seleccionada de OpenStreetMap (OSM). Se considera una alternativa de importación y no reemplaza el procesamiento específico realizado con `netconvert`.
- **interfaz de control del tránsito (*Traffic Control Interface*, TraCI):** interfaz que permite consultar el estado de una simulación en ejecución y modificarlo durante el avance paso a paso, incluyendo variables de vehículos, carriles, detectores y semáforos [DLR26].
- **libsumo:** implementación embebida que ofrece la interfaz de programación de SUMO sin la comunicación mediante conexiones de red (*sockets*) de la modalidad TraCI estándar. Esta alternativa resulta útil para integrar el simulador con controladores externos y reducir la sobrecarga de comunicación.

Desde la perspectiva del modelado computacional, una simulación de SUMO se construye a partir de archivos lenguaje de marcado extensible (*Extensible Markup Language*, XML) de red, demanda, elementos adicionales y configuración [DLR26]. Los archivos de zonas de análisis de tránsito (*Traffic Analysis Zone*, TAZ) pueden utilizarse durante la estructuración espacial y la generación de demanda, mientras que las salidas de la simulación se solicitan mediante opciones de configuración específicas. Sus funciones generales se resumen en la Tabla 2.2:

Métricas de evaluación operacional

La simulación produce medidas para evaluar el control semafórico. En este trabajo se consideran las siguientes categorías de indicadores:

- **Demora y tiempo de espera:** cuantifican el tiempo adicional o el tiempo detenido que experimentan los vehículos durante su recorrido. Pueden analizarse de forma

Tabla 2.2: Archivos de entrada y configuración empleados en una simulación de SUMO.

Archivo	**Extensión**	**Función en el Modelo Computacional**
Red Vial	`.net.xml`	Topología física, carriles, conexiones y lógicas semafóricas.
Rutas y Demanda	`.rou.xml`	Tipos de vehículos, viajes, flujos e itinerarios.
Zonas TAZ	`.taz.xml`	Zonas para estructurar espacialmente la demanda.
Elementos Adicionales	`.add.xml`	Detectores, tipos de vehículo y programas auxiliares.
Configuración	`.sumocfg`	Archivos de entrada, opciones de ejecución y salidas.

agregada en la red y desagregarse por intersección, acceso o agente, siempre que se mantenga una definición operacional consistente [CyMR18, DLR26].

- **Completitud y flujo servido:** la cantidad de vehículos que completa su itinerario y su relación con la demanda generada permiten distinguir una reducción genuina de la demora de una disminución del flujo atendido.
- **Equidad espacial:** la distribución de las demoras entre intersecciones permite identificar si una política mejora el desempeño global a costa de concentrar la espera en accesos o agentes particulares.
- **Indicadores de validez de la simulación:** el mecanismo de teletransporte de SUMO, denominado originalmente *teleport*, retira temporalmente vehículos bloqueados y los reinserta para evitar que la simulación se detenga. Sus activaciones, los vehículos pendientes y otras incidencias permiten detectar bloqueos o condiciones que comprometen la comparabilidad de una ejecución.

Las definiciones operacionales, fórmulas, unidades, ventanas de evaluación y procedimientos de agregación empleados en este trabajo se presentan en la metodología. Las recompensas y las pérdidas de optimización corresponden al entrenamiento de los algoritmos de aprendizaje y se desarrollan en las secciones dedicadas a RL y MARL.

En este marco, SUMO permite observar el estado de la red y modificar las fases semafóricas durante la ejecución mediante interfaces de control. Esta capacidad convierte el control semafórico en un problema de decisión secuencial, lo que motiva la introducción del aprendizaje por refuerzo en la siguiente sección [DLR26].

2.2. Aprendizaje por refuerzo (RL)

El aprendizaje automático (*Machine Learning*, ML) suele dividirse en tres paradigmas. En el aprendizaje supervisado (*Supervised Learning*, SL), el modelo se entrena con ejemplos etiquetados que indican la salida esperada. En el aprendizaje no supervisado (*Unsupervised Learning*, UL), se busca descubrir estructura en datos no etiquetados, por

ejemplo mediante agrupamiento o reducción de dimensionalidad. El aprendizaje por refuerzo (RL) aborda un problema distinto: una entidad aprende mediante interacción con un entorno qué acciones elegir para maximizar una recompensa acumulada [SB18].

Esta diferencia es central. En RL no existe, en general, un supervisor que indique cuál era la acción correcta en cada situación. El agente aprende por experiencia, ensayando acciones, observando sus consecuencias y ajustando su comportamiento a partir de las recompensas obtenidas. Además, las consecuencias relevantes de una acción no siempre se manifiestan de forma inmediata: una decisión puede producir una recompensa baja en el corto plazo, pero conducir a estados favorables en el futuro. Por este motivo, el aprendizaje por refuerzo se ocupa explícitamente del problema de la recompensa diferida y de la asignación de crédito a decisiones pasadas [SB18].

La formulación básica distingue entre el agente (*agent*), que aprende y toma decisiones, y el entorno (*environment*), que representa todo aquello externo al agente con lo cual este interactúa. En cada paso, el agente observa una situación, selecciona una acción y recibe una nueva observación junto con una recompensa: este ciclo constituye la interacción agente–entorno. El comportamiento está determinado por una política (*policy*), denotada por π, que especifica cómo elegir acciones a partir de los estados u observaciones disponibles. La señal de recompensa (*reward signal*) define el objetivo inmediato, mientras que la función de valor estima la conveniencia de estados o acciones en términos de recompensa futura. Sutton y Barto también distinguen el modelo del entorno, entendido como una descripción de sus transiciones y recompensas; cuando no se conoce o no se utiliza explícitamente, se habla de métodos libres de modelo (*model-free*).

En este trabajo, se utiliza controlador para el sistema general que regula las señales y agente para la entidad que aprende y selecciona acciones. Cada agente regula una intersección y la red vial simulada en SUMO constituye su entorno. La selección de una fase constituye la acción, mientras que la evolución posterior del tránsito produce nuevas observaciones y una señal de recompensa que orienta el aprendizaje [DLR26].

Para fijar ideas, considérese un par de intersecciones vecinas. El agente observa localmente las colas y demoras de su intersección, selecciona una fase y modifica la corriente de vehículos que llegará a la siguiente. Esa consecuencia aguas abajo puede cambiar sus arribos y colas, y se refleja en una recompensa asociada al desempeño de la red. El retorno permite acumular esos efectos a lo largo de varias decisiones, en lugar de evaluar una fase solo por su consecuencia inmediata.

Un aspecto característico de RL es el dilema entre exploración y explotación. El agente debe explotar acciones que, según su experiencia, producen buenos resultados, pero también debe explorar alternativas menos conocidas que podrían conducir a políticas superiores. Si explora demasiado, desperdicia oportunidades de obtener recompensa; si explota demasiado pronto, puede converger a comportamientos subóptimos. Este equilibrio es especialmente relevante en problemas de control, donde las acciones modifican la

experiencia futura disponible para el aprendizaje [SB18].

2.2.1. Procesos de decisión de Markov (MDP)

El marco matemático estándar para estudiar problemas de aprendizaje por refuerzo de un solo agente es el proceso de decisión de Markov (*Markov Decision Process*, MDP). En un MDP finito, el agente y el entorno interactúan en pasos temporales discretos $t = 0, 1, 2, \ldots$: en cada instante, el agente recibe $S_t \in \mathcal{S}$, selecciona $A_t \in \mathcal{A}(S_t)$ y el entorno emite $R_{t+1} \in \mathcal{R}$ y transita a S_{t+1} [LML+25]. La notación se ilustra en la Figura 2.9.

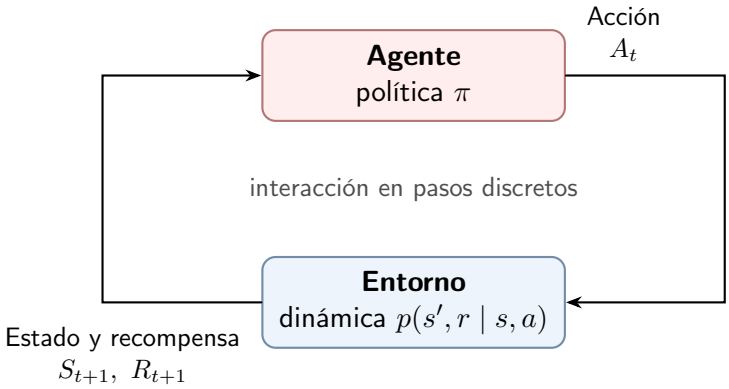


Figura 2.9: Interacción agente-entorno en un proceso de decisión de Markov [SB18].

De forma compacta, un MDP finito queda caracterizado por la tupla $\langle \mathcal{S}, \mathcal{A}, P, R, \gamma \rangle$, donde $\mathcal{S}$ es el espacio de estados, $\mathcal{A}$ el espacio de acciones, P la dinámica de transición probabilística, R la función de recompensa y $\gamma \in [0, 1)$ el factor de descuento.

La dinámica del entorno queda definida por la función $p(s', r \mid s, a)$, que especifica la probabilidad condicional conjunta de observar el próximo estado s' y la recompensa r al ejecutar la acción a en el estado s:

$$p(s', r \mid s, a) \doteq \Pr\{S_{t+1} = s', R_{t+1} = r \mid S_t = s, A_t = a\} \tag{2.5}$$

En esta formulación, $S_t \in \mathcal{S}$ y $A_t \in \mathcal{A}$ denotan el estado y la acción en el instante t, mientras que $S_{t+1} \in \mathcal{S}$ y $R_{t+1} \in \mathbb{R}$ representan el estado sucesor y la recompensa escalar devueltos por el entorno. Si bien conceptualmente el estado comprende toda la información necesaria para determinar la dinámica, en el control semafórico el agente suele disponer de observaciones locales de tránsito que constituyen una representación parcial de dicho estado.

El proceso satisface la propiedad de Markov si la distribución condicional del próximo estado y recompensa depende exclusivamente del estado y la acción presentes, resultando condicionalmente independiente del historial de transiciones previas [SB18].

Una suposición habitual del MDP es que el agente observa un estado suficientemente informativo del entorno. Sin embargo, en muchas aplicaciones reales el agente solo recibe observaciones parciales o ruidosas. En estos casos, el marco se generaliza a un proceso

de decisión de Markov parcialmente observable (*Partially Observable Markov Decision Process*, POMDP), donde el historial de observaciones puede ser necesario para inferir el estado subyacente [ACS24].

Para formalizar la meta de maximizar la recompensa a largo plazo se define el retorno descontado G_t, que incorpora un factor $\gamma \in [0, 1)$ para ponderar la importancia de las recompensas futuras [SB18]:

$$G_t \doteq R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \tag{2.6}$$

En esta formulación, el retorno G_t acumula las recompensas futuras ponderadas por el factor de descuento $\gamma \in [0, 1)$. Un valor de γ cercano a cero privilegia la optimización a muy corto plazo, mientras que valores próximos a uno confieren mayor peso a las consecuencias remotas [ACS24]. En el control semafórico, esta acumulación temporal resulta indispensable para que el agente aprenda a prevenir condiciones de bloqueo o saturación en ciclos futuros, en lugar de limitarse a disipar la cola inmediata a expensas de la red.

2.2.2. Métodos basados en valor y basados en política

Los algoritmos de RL pueden agruparse, a grandes rasgos, en métodos basados en valor y métodos basados en política. Esta distinción no agota la taxonomía del campo, pero permite introducir las familias de algoritmos más relevantes para este trabajo.

Esta clasificación distingue dos formas de obtener una regla de decisión. Los métodos basados en política aprenden directamente una función que relaciona cada estado con una acción o con una distribución de probabilidad sobre las acciones. En cambio, los métodos basados en valor aprenden indirectamente la regla de decisión: estiman la conveniencia de los estados o de los pares estado–acción y, a partir de esas estimaciones, determinan qué alternativa conviene ejecutar [SB18]. En el control semafórico, las alternativas corresponden a las distintas fases admisibles de una intersección.

La Figura 2.10 representa esta segunda alternativa. A partir del estado observado, la función de valor estima la conveniencia esperada de las acciones disponibles y la decisión se obtiene comparando esas estimaciones. El esquema corresponde directamente al caso de una función de valor de acción $Q(s, a)$; si se utiliza una función de valor de estado $V(s)$, la elección de la acción requiere valorar los estados sucesores que produciría cada alternativa. Por ello, $V(s)$ y $Q(s, a)$ cumplen funciones relacionadas, pero no intercambiables en la evaluación de los estados y en la selección de acciones.

En los métodos basados en valor, el objetivo es determinar la conveniencia de encontrarse en un estado o de ejecutar una acción concreta. Formalmente, esto se expresa mediante la función de valor de estado $v_\pi(s) \doteq \mathbb{E}_\pi[G_t \mid S_t = s]$ y la función de valor de acción $q_\pi(s, a) \doteq \mathbb{E}_\pi[G_t \mid S_t = s, A_t = a]$, las cuales satisfacen las relaciones recursivas de las ecuaciones de Bellman [SB18]. En la notación empleada en la Figura 2.10, estas

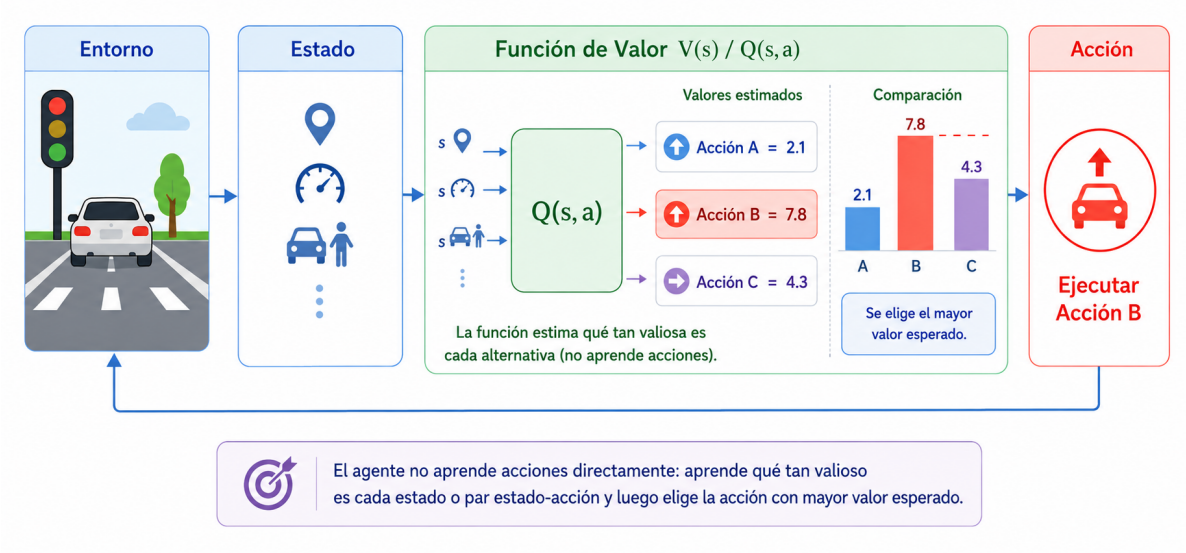


Figura 2.10: Esquema de un método basado en valor. A partir del estado observado s, la función de valor estima el retorno esperado de los pares estado–acción $Q(s, a)$. Las estimaciones para las acciones disponibles se comparan y se selecciona la alternativa con mayor valor esperado para ejecutarla en el entorno. La exploración puede incorporarse mediante estrategias como la selección ε-greedy [SB18].

funciones se escriben habitualmente como $V(s)$ y $Q(s, a)$ cuando no es necesario hacer explícita la política respecto de la cual se calcula el valor.

Cuando el propósito es identificar la política óptima en lugar de evaluar una fija, se emplean las ecuaciones de optimalidad de Bellman:

$$q_*(s, a) = \mathbb{E}\left[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a\right]. \tag{2.7}$$

En la ecuación (2.7), la esperanza $\mathbb{E}$ promedia las transiciones estocásticas del entorno y la maximización sobre las fases admisibles a' formaliza el principio de optimalidad. En el ámbito semafórico, esta relación expresa el compromiso entre la recompensa inmediata obtenida por la fase activa y la calidad del estado vehicular resultante para las decisiones subsiguientes [SB18].

En ausencia de un modelo analítico de transición, los métodos de TD aproximan estas funciones a partir de la experiencia mediante *bootstrapping*: utilizan una estimación del valor del estado siguiente para actualizar el valor actual. Un ejemplo es Q-learning, cuya regla de actualización converge hacia la función óptima $q_*(s, a)$ en el caso tabular, bajo el supuesto de que todos los pares estado–acción continúen explorándose y que la tasa de aprendizaje decrezca adecuadamente a lo largo del tiempo [SB18]:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha\left[R_{t+1} + \gamma \max_{a} Q(S_{t+1}, a) - Q(S_t, A_t)\right] \tag{2.8}$$

donde $\alpha \in (0, 1]$ es la tasa de aprendizaje (*learning rate*) que pondera la magnitud del

ajuste, R_{t+1} es la recompensa inmediata observada, y el término $\max_a Q(S_{t+1}, a)$ aproxima el retorno óptimo alcanzable desde el estado sucesor S_{t+1}.

Q-learning es un algoritmo *off-policy*: la política que genera los datos de interacción puede diferir de la política objetivo cuya función de valor se optimiza. Por el contrario, los métodos de gradiente de política operan generalmente de forma *on-policy*, utilizando transiciones producidas por la política en curso de optimización. Esta diferencia resulta decisiva al extender los algoritmos al entorno multiagente, donde las políticas de las intersecciones vecinas evolucionan simultáneamente.

En los métodos basados en política, la regla de decisión se parametriza directamente como $\pi_\theta(a \mid s) = \Pr\{A_t = a \mid S_t = s, \theta\}$, donde $\theta \in \mathbb{R}^d$ representa el vector de parámetros ajustables de la política. La política puede ser determinista, si asigna siempre la misma acción a un estado, o estocástica, si produce una distribución de probabilidad sobre las acciones posibles [SB18]. La Figura 2.11 ilustra este último caso: para el estado observado, la política asigna probabilidades a cada fase admisible y la selección se efectúa mediante muestreo o según la alternativa más probable, de acuerdo con la regla de ejecución adoptada.

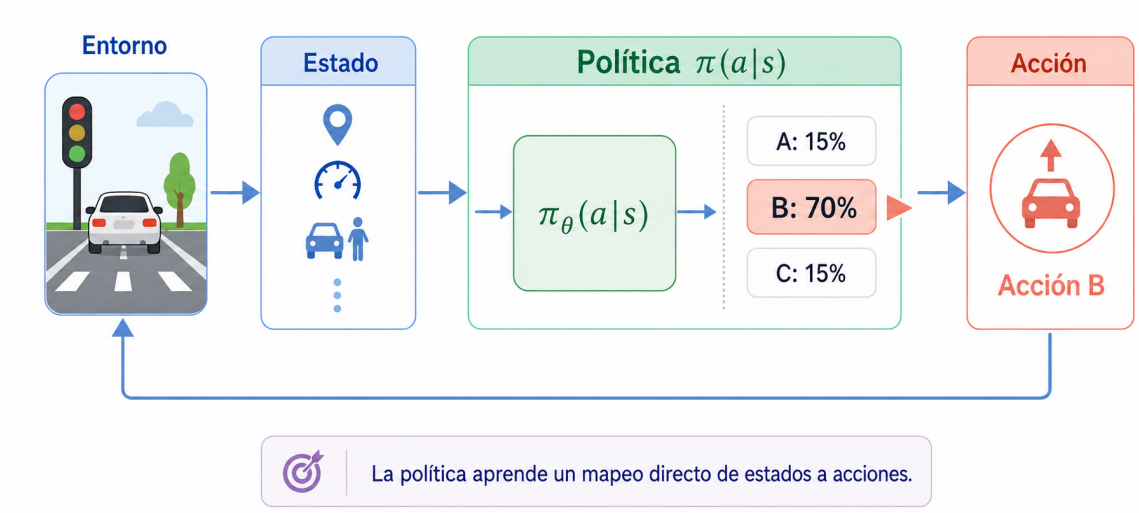


Figura 2.11: Esquema de un método basado en política. A partir del estado observado s, la política parametrizada $\pi_\theta(a \mid s)$ genera directamente una distribución de probabilidad sobre las acciones disponibles. La regla de ejecución puede seleccionar la alternativa de mayor probabilidad o muestrear una acción a partir de dicha distribución [SB18].

La optimización persigue maximizar el rendimiento esperado $J(\theta)$ mediante ascenso de gradiente:

$$\theta_{t+1} = \theta_t + \alpha \nabla J(\theta_t) \tag{2.9}$$

donde $\nabla J(\theta_t)$ es el gradiente del rendimiento respecto de los parámetros y $\alpha > 0$ determina la magnitud del paso de actualización. El Teorema del Gradiente de Política (*Policy Gradient Theorem*) proporciona el sustento teórico para estimar analíticamente $\nabla J(\theta_t)$

a partir de trayectorias muestreadas, ajustando la política para elevar la probabilidad de aquellas fases que conducen a menores demoras en la red [SB18].

Los métodos actor-crítico combinan una política parametrizada con una estimación de valor y actualizan ambos componentes de manera concurrente [KT03, SB18]. El actor representa la política $\pi_\theta(a \mid s)$ y determina la distribución utilizada para seleccionar la acción. El crítico no controla el entorno: estima, por ejemplo, el valor de estado $V_\phi(s)$ y produce una señal que indica si el resultado observado fue mejor o peor que lo esperado bajo la política vigente. Los parámetros θ y ϕ pueden optimizarse de forma independiente o compartir una representación común de las observaciones de tránsito.

En una formulación actor-crítico de un paso, después de ejecutar A_t en S_t, el entorno devuelve la recompensa R_{t+1}, el estado S_{t+1} y el indicador terminal d_{t+1}. El crítico calcula el error de diferencia temporal mediante:

$$\delta_t = R_{t+1} + \gamma(1 - d_{t+1})V_\phi(S_{t+1}) - V_\phi(S_t), \tag{2.10}$$

En la ecuación (2.10), el factor $(1 - d_{t+1})$ anula la contribución del estado siguiente ante transiciones terminales. Cuando V_ϕ aproxima adecuadamente el valor real V^π, δ_t actúa como un estimador de un paso de la ventaja: un valor positivo refleja que la fase ejecutada reportó un desempeño superior al esperado en ese estado de tránsito, mientras que un valor negativo indica lo contrario. El crítico ajusta sus parámetros ϕ minimizando el error temporal, mientras que el actor utiliza esta misma señal δ_t para modular la actualización de la política:

$$\theta \leftarrow \theta + \alpha_\theta \, \delta_t \, \nabla_\theta \log \pi_\theta(A_t \mid S_t). \tag{2.11}$$

En la regla (2.11), $\alpha_\theta > 0$ es la tasa de aprendizaje del actor y $\nabla_\theta \log \pi_\theta(A_t \mid S_t)$ indica cómo cambiar sus parámetros para aumentar la probabilidad de la acción elegida. Un error δ_t positivo favorece esa acción, mientras que uno negativo reduce su probabilidad. Los métodos posteriores emplean estimadores de ventaja de varios pasos, como estimación generalizada de ventaja (*Generalized Advantage Estimation*, GAE), y procesan conjuntos de transiciones llamados lote (*batch*). Esta regla permite comprender cómo el crítico orienta la actualización del actor.

La Figura 2.12 sintetiza el flujo operativo entre actor y entorno, así como el circuito de evaluación mediante el cual el crítico genera la señal de retroalimentación compartida.

En síntesis, el estado resume las condiciones de tránsito disponibles para el agente, la acción corresponde a la selección de una fase, la recompensa refleja la consecuencia operativa inmediata y el valor estima su impacto a largo plazo. Cuando el espacio de estados es continuo o de gran escala, como ocurre en las redes viales urbanas, las funciones de valor y las políticas requieren aproximadores de alta capacidad representacional. A continuación se introducen las redes neuronales artificiales como el modelo adoptado para este fin, preservando intactos los fundamentos de RL expuestos hasta aquí.

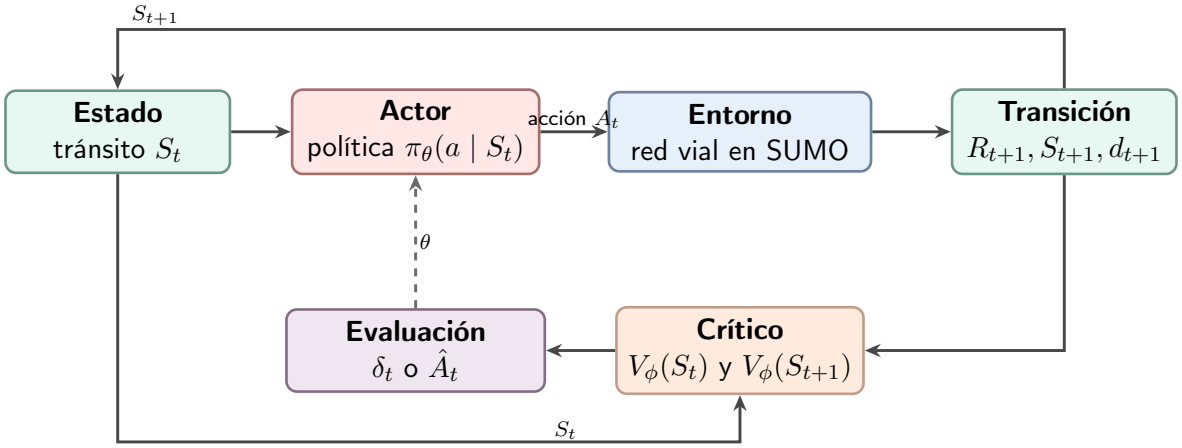


Figura 2.12: Arquitectura actor-crítico aplicada al control semafórico en la formulación de un MDP. El actor selecciona una acción y el crítico evalúa la transición para construir la señal que actualiza ambos componentes. Elaboración propia a partir de [KT03, SB18].

2.2.3. Aprendizaje profundo y redes neuronales

Para estructurar este desarrollo, se expone en primer término la unidad neuronal básica y su composición en redes multicapa; luego se aborda su optimización mediante retropropagación y descenso de gradiente; finalmente, se analiza su integración en RL a través de DQN y PPO. Cabe destacar que la red neuronal actúa como un aproximador de funciones de alta capacidad, mientras que la dirección del aprendizaje proviene exclusivamente de las señales de recompensa generadas por la interacción con el entorno [SB18].

El aprendizaje profundo (*Deep Learning*) se enfoca en el entrenamiento de arquitecturas con múltiples capas de parámetros ajustables capaces de extraer representaciones jerárquicas y relaciones no lineales directamente de los datos [BB24, GBC16]. En este trabajo, esta capacidad se aprovecha para aproximar funciones de valor y políticas de control semafórico donde una formulación tabular resulta impracticable debido a la continuidad y dimensionalidad del estado del tránsito.

Aunque la denominación "neuronal" proviene de una analogía simplificada con modelos biológicos iniciales, una red artificial constituye un modelo matemático determinista cuyos parámetros se optimizan a partir de datos y gradientes de pérdida [GBC16].

La unidad neuronal y redes *feedforward*

En problemas de control con espacios de estados continuos o de gran escala, los métodos tabulares resultan impracticables [SB18]. La aproximación de funciones resuelve esta limitación mediante representaciones parametrizadas, lo que permite generalizar lo aprendido a situaciones similares no observadas. Para este fin se emplean redes neuronales artificiales [BB24].

La unidad neuronal artificial constituye el bloque computacional básico de estas arquitecturas [BB24, GBC16]. Esta procesa un vector de entradas ponderándolo mediante un vector de pesos, añade un término de sesgo y aplica una función de activación no lineal

para producir una respuesta escalar. En el ámbito semafórico, las entradas corresponden típicamente a variables observables del tránsito (como tiempos de espera acumulados o longitudes de cola por carril), mientras que los pesos modulan la contribución relativa de cada acceso hacia la decisión final.

La Figura 2.13 ilustra este procesamiento: la transformación afín $z = \mathbf{w}^\top \mathbf{x} + b$ integra las entradas $\mathbf{x} = (x_1, \ldots, x_n)$ con los pesos $\mathbf{w}$ y el sesgo b, antes de que la activación $y = g(z)$ genere la salida. Sin la introducción de estas no linealidades $g(\cdot)$, una red multicapa se reduciría a una transformación afín simple, imposibilitando la captura de patrones de congestión complejos.

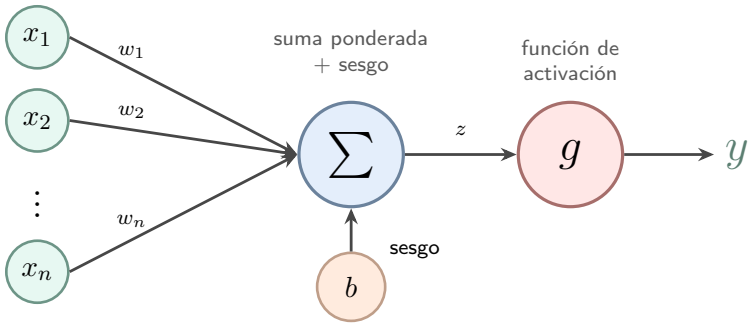


Figura 2.13: Operaciones de una unidad neuronal artificial: suma ponderada de las entradas, incorporación del sesgo y aplicación de una función de activación.

Como ejemplo conceptual, la red puede recibir las métricas de demora de una intersección y emitir estimaciones de calidad o probabilidades sobre las fases admisibles, orientando la asignación del verde hacia las aproximaciones más críticas.

En una red multicapa, la operación para una unidad u dentro de la capa k se formaliza mediante la ecuación (2.12) [BB24, GBC16]:

$$a_{k,u} = \mathbf{w}_{k,u}^\top \mathbf{x}_{k-1} + b_{k,u}, \qquad y_{k,u} = g_k(a_{k,u}) \tag{2.12}$$

donde $\mathbf{x}_{k-1}$ es el vector de activaciones proveniente de la capa anterior, $\mathbf{w}_{k,u}$ es el vector de pesos, $b_{k,u}$ es el sesgo y g_k es la función de activación. Entre las funciones más empleadas en capas intermedias destacan:

- **unidad lineal rectificada (*Rectified Linear Unit*, ReLU):** $g(z) = \max\{0, z\}$, que propaga linealmente las activaciones positivas y bloquea las negativas, con pendiente uno para valores positivos durante la optimización.
- **Leaky ReLU:** $g(z) = \max\{0, z\} + \alpha \min\{0, z\}$, con $\alpha \ll 1$, que conserva una pendiente pequeña en el semieje negativo para mitigar la inactivación de unidades.
- **Tanh:** $g(z) = \tanh(z)$, que ofrece una respuesta no lineal diferenciable acotada en $(-1, 1)$.

Las redes *feedforward* encadenan estas transformaciones en capas sucesivas sin conexiones recurrentes sin retroalimentación temporal. Para una arquitectura con L capas parametrizadas, la propagación completa se describe como:

$$\mathbf{h}_k = g_k\left(\mathbf{W}_k^\top \mathbf{h}_{k-1} + \mathbf{b}_k\right), \qquad k = 1, \ldots, L, \qquad \mathbf{h}_0 = \mathbf{x}, \qquad \mathbf{y} = \mathbf{h}_L \tag{2.13}$$

donde $\mathbf{W}_k$ y $\mathbf{b}_k$ denotan la matriz de pesos y el vector de sesgos de la capa k, respectivamente, y g_k se aplica componente a componente. En el agente semafórico, el vector de entrada $\mathbf{h}_0 = \mathbf{x}$ contiene las esperas acumuladas por carril y la salida $\mathbf{y} = \mathbf{h}_L$ produce las valoraciones Q o probabilidades de selección de fase.

La Figura 2.14 esquematiza esta composición con dos capas ocultas conectadas en cascada hacia la salida.

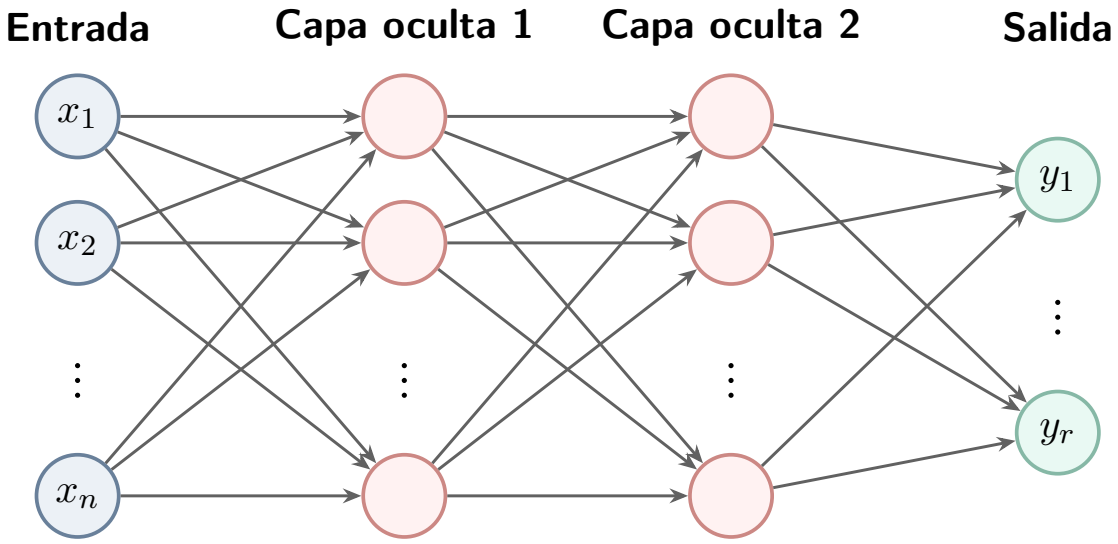


Figura 2.14: Arquitectura conceptual de una red neuronal *feedforward* con dos capas ocultas.

El Teorema de Aproximación Universal es un resultado de existencia: bajo condiciones apropiadas, una red de dos capas parametrizadas, con una capa oculta suficientemente ancha, puede aproximar una función continua sobre un dominio compacto con una precisión arbitraria. El teorema no proporciona por sí mismo un procedimiento para encontrar los parámetros, no garantiza un entrenamiento eficiente, una buena generalización ni un buen desempeño práctico sobre datos no observados. La profundidad puede ofrecer representaciones jerárquicas y una mayor eficiencia expresiva para ciertas familias de funciones, pero agregar capas o neuronas no garantiza por sí solo un menor error de prueba [BB24].

El proceso de optimización

Durante el entrenamiento, la red procesa las observaciones mediante propagación hacia adelante y contrasta su respuesta frente a un objetivo mediante una función de pérdida escalar diferenciable $\mathcal{L}(\theta)$. El algoritmo de retropropagación (*backpropagation*) calcula

analíticamente las derivadas parciales de dicha pérdida respecto de cada peso y sesgo aplicando de forma sistemática la regla de la cadena [BB24].

Los pesos y sesgos son parámetros que se ajustan durante el aprendizaje; los hiperparámetros, como la tasa de aprendizaje y el tamaño de las capas ocultas, son valores de configuración que se fijan antes de entrenar y pueden seleccionarse mediante una búsqueda.

Con estos gradientes, los parámetros se actualizan iterativamente en sentido opuesto a la pendiente del error:

$$\theta_{t+1} = \theta_t - \eta \nabla_\theta \mathcal{L}(\theta_t), \tag{2.14}$$

donde θ reúne los parámetros entrenables de la red, $\nabla_\theta \mathcal{L}(\theta_t)$ es el gradiente de la función de pérdida y $\eta > 0$ es la tasa de aprendizaje. Calcular el gradiente con todos los datos puede resultar costoso. Por ello, se utilizan subconjuntos de muestras, denominados *minibatches*, para realizar cada actualización. Adam adapta el tamaño del paso para cada parámetro a partir de promedios móviles del gradiente y de su cuadrado [BB24].

A diferencia del aprendizaje supervisado convencional —donde la pérdida compara la salida con una etiqueta externa fija—, en RL el objetivo se deriva de las recompensas y transiciones producidas por la interacción con el simulador, y cambia a medida que la política mejora su comportamiento.

2.2.4. Aprendizaje por refuerzo profundo (DRL)

El DRL combina algoritmos de RL con aproximadores neuronales. En el control semafórico, las observaciones del tránsito, como colas, ocupación o velocidades, pueden alimentar la red; sus salidas pueden representar valores de acción o parámetros de una política; y las recompensas asociadas con demoras, detenciones y colas orientan la función de pérdida del algoritmo de aprendizaje. Esta integración resulta útil cuando el espacio de estados es continuo o de alta dimensionalidad, aunque exige mecanismos de estabilización y una evaluación cuidadosa de la eficiencia de las muestras [ACS24].

Factores de inestabilidad del aprendizaje

La integración de aproximadores no lineales con aprendizaje por refuerzo puede inducir inestabilidad numérica o divergencia en las estimaciones si no se controlan las condiciones de actualización. Sutton y Barto [SB18] describen este fenómeno mediante la denominada tríada mortal (*deadly triad*), originada por la concurrencia de tres elementos:

- **Aproximación de funciones:** el uso de un modelo parametrizado, como una red neuronal, para estimar valores en lugar de almacenarlos individualmente en una tabla.
- ***Bootstrapping*:** la actualización de estimaciones de valor apoyándose en otras estimaciones aprendidas previamente (métodos TD), sin esperar a disponer del retorno

completo.

- **Entrenamiento *off-policy*:** el aprendizaje sustentado en una distribución de datos generada por una política de comportamiento distinta de la política objetivo.

Aunque prescindir del *bootstrapping* o de la aproximación de funciones comprometería la eficiencia muestral o la escalabilidad ante redes viales complejas, los algoritmos profundos modernos introducen mecanismos arquitectónicos específicos para amortiguar esta inestabilidad [SB18].

Deep Q-Network (DQN): aproximación neuronal de valores de acción

En los métodos basados en valor, DQN sustituye la tabla de estados y acciones por una red neuronal $Q(s, a; \theta)$ parametrizada por θ [MKS+15]. Ante una observación de tránsito, la red genera una estimación del valor Q para cada fase admisible. La función de acción-valor óptima $q_*(s, a)$ representa el máximo retorno esperado al seleccionar la mejor secuencia de decisiones futuras, objetivo que DQN persigue aproximar a partir de las recompensas del entorno.

Para mitigar la inestabilidad de la tríada mortal —en particular el problema del valor objetivo cambiante, donde actualizar el valor de un estado altera impredeciblemente las estimaciones de estados adyacentes—, DQN incorpora dos componentes estructurales [MKS+15]:

- **Redes objetivo (*Target Networks*):** una red secundaria idéntica cuyos parámetros θ^- se congelan temporalmente. Esta red se utiliza exclusivamente para calcular el término de *bootstrapping* del valor objetivo TD, desacoplando la estimación en curso del objetivo de aprendizaje y amortiguando oscilaciones.

- **Memoria de repetición de experiencias (*replay buffer*):** almacena transiciones históricas $(s_t, a_t, r_{t+1}, s_{t+1}, d_{t+1})$ en un *buffer* $\mathcal{D}$. La optimización extrae *minibatches* aleatorios de esta memoria, lo cual mitiga la correlación temporal propia del flujo continuo de vehículos en el simulador y aproxima los datos a la hipótesis de muestras independientes.

En la repetición de experiencias priorizada, las transiciones con mayor magnitud de error de diferencia temporal tienen mayor probabilidad de ser muestreadas. Las actualizaciones se ponderan para atenuar el sesgo de este muestreo no uniforme [SQAS16].

Durante la interacción con SUMO, la red en línea evalúa la observación de tránsito y una regla ϵ_{exp}-greedy selecciona la fase a ejecutar; la transición resultante se almacena en $\mathcal{D}$. Durante el entrenamiento, la red en línea actualiza sus pesos θ a partir de los *minibatches* muestreados del *buffer* contra el valor objetivo fijado por la red objetivo, cuyos parámetros θ^- se sincronizan solo de forma periódica (Figura 2.15).

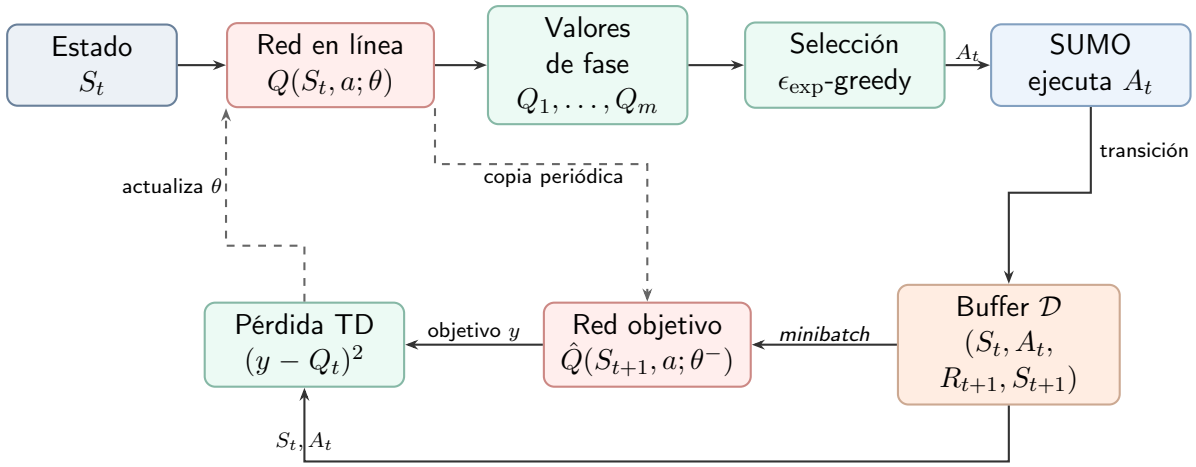


Figura 2.15: Flujo conceptual de DQN con repetición de experiencias y red objetivo. La red en línea selecciona acciones y recibe las actualizaciones; la red objetivo proporciona el término de *bootstrapping* del valor objetivo TD. Elaboración propia a partir del algoritmo descrito por Mnih et al. [MKS+15].

La función de pérdida minimizada por DQN, representada en el bloque inferior de la Figura 2.15, es la de la ecuación (2.15):

$$\mathcal{L}(\theta) = \mathbb{E}_{(s_j, a_j, r_{j+1}, s_{j+1}, d_{j+1}) \sim \mathcal{D}} \left[\left(\underbrace{r_{j+1} + \gamma(1 - d_{j+1}) \max_{a'} \hat{Q}(s_{j+1}, a'; \theta^-)}_{\text{Valor objetivo de TD}} - \underbrace{Q(s_j, a_j; \theta)}_{\text{Predicción actual}} \right)^2 \right] \tag{2.15}$$

En la ecuación (2.15), la esperanza se evalúa empíricamente promediando sobre un *mini-batch* de transiciones $(s_j, a_j, r_{j+1}, s_{j+1}, d_{j+1})$ extraídas de $\mathcal{D}$. La función de pérdida minimiza la discrepancia cuadrática entre la estimación actual $Q(s_j, a_j; \theta)$ y el valor objetivo temporal compuesto por la recompensa inmediata observada y la mayor estimación del valor futuro sobre las fases admisibles, calculada por la red objetivo $\hat{Q}(s_{j+1}, a'; \theta^-)$. El factor $(1 - d_{j+1})$ anula la contribución del estado siguiente cuando la transición es terminal $(d_{j+1} = 1)$, mientras que a' recorre las fases semafóricas admisibles.

Los cuatro bloques numerados como algoritmos en este capítulo son pseudocódigos: descripciones ordenadas e independientes de un lenguaje de programación, no fragmentos ejecutables. En ellos, una transición registra lo ocurrido en un paso; un episodio agrupa pasos desde el reinicio hasta la terminación; y un *rollout* es la secuencia de transiciones recolectada con una política. Una iteración de entrenamiento comprende la recolección de datos y su optimización, mientras que una *epoch* es una reutilización completa de esos datos dentro de la misma iteración. Cada actualización puede calcularse sobre un *mini-batch*, es decir, un subconjunto de las muestras. Las líneas "Entrada" y "Salida" indican, respectivamente, qué información necesita el procedimiento y qué componentes entrenados produce; las líneas indentadas pertenecen al ciclo inmediatamente superior. En lo

sucesivo se utiliza lote para *batch* y se conservan los términos *minibatch*, *buffer* y *epoch*, definidos aquí y en el glosario.

El procedimiento de DQN combina la recolección de experiencias, la selección de fases con política ϵ_{exp}-greedy y la optimización de la red neuronal a partir de *minibatches* muestreados del *replay buffer*. El algoritmo 1 especifica este procedimiento:

Algoritmo 1 Deep Q-Network con repetición de experiencias

Entrada: entorno, fases admisibles, capacidad N, horizonte T en pasos de decisión, γ y ϵ_{exp}

Salida: parámetros entrenados θ de la red de acción-valor

Inicializar el *buffer* de experiencias $\mathcal{D}$ con capacidad N
Inicializar la red de acción-valor $Q(s, a; \theta)$ con parámetros aleatorios
Inicializar la red objetivo $\hat{Q}(s, a; \theta^-)$ con $\theta^- \leftarrow \theta$
para episodio $= 1, 2, \ldots$ **hacer**
    Inicializar el estado s_t
    para $t = 1, 2, \ldots, T$ **hacer**
        Seleccionar a_t mediante una política ϵ_{exp}-greedy basada en $Q(s_t, a; \theta)$
        Ejecutar a_t y observar la recompensa r_{t+1}, el estado s_{t+1} y si el episodio terminó
        Almacenar $(s_t, a_t, r_{t+1}, s_{t+1}, d_{t+1})$ en $\mathcal{D}$
        si $\mathcal{D}$ contiene al menos un *minibatch* completo **entonces**
            Extraer un *minibatch* de transiciones de $\mathcal{D}$
            Calcular $y_j = r_{j+1} + \gamma(1 - d_{j+1}) \max_{a'} \hat{Q}(s_{j+1}, a'; \theta^-)$
            Actualizar θ minimizando $(y_j - Q(s_j, a_j; \theta))^2$
        fin si
        Actualizar periódicamente la red objetivo: $\theta^- \leftarrow \theta$
        $s_t \leftarrow s_{t+1}$
        si $d_{t+1} = 1$ **entonces**
            Terminar el ciclo interno y comenzar un nuevo episodio
        fin si
    fin para
fin para

En esta formulación, el agente desacopla la recolección de experiencias en el simulador de la optimización paramétrica de la red. La memoria $\mathcal{D}$ reduce la correlación temporal de las observaciones de tráfico, mientras que la red objetivo estabiliza el valor objetivo de Bellman mediante la sincronización periódica de θ^-. La especificación detallada de los hiperparámetros operacionales (capacidad N, horizonte T, tasa de aprendizaje y cronograma de exploración) se desarrolla en el capítulo 3.

Aproximación de políticas, función de ventaja y *Policy Gradient*

Como alternativa a derivar la política de forma indirecta a partir de una función de valor (como en DQN), DRL permite parametrizar directamente la política del agente mediante una red neuronal $\pi(a|s;\theta)$ [ACS24]. Bajo la formulación MDP, en un problema de acciones discretas la red recibe el estado s, calcula un vector de puntajes continuos $z \in \mathbb{R}^m$ y los proyecta a una distribución de probabilidad mediante la función *softmax* [SB18, BB24]:

$$\pi_\theta(a_i \mid s) = \frac{e^{z_i}}{\sum_{j=1}^{m} e^{z_j}} \tag{2.16}$$

la cual garantiza valores estrictamente positivos que suman la unidad. En este ejemplo, las acciones corresponden a las fases semafóricas admisibles: las variables del estado de tránsito ingresan a la red y sus salidas representan probabilidades sobre dicho conjunto de acciones. Las políticas basadas en observaciones locales se formalizan posteriormente mediante Dec-POMDP. La acción puede muestrearse de esa distribución durante el entrenamiento, preservando la exploración estocástica.

La Figura 2.16 muestra este recorrido para un agente semafórico. A diferencia de DQN, las salidas no son estimaciones de valor: son probabilidades que suman uno. La señal de ventaja no entra a la red para seleccionar la acción; se utiliza durante el entrenamiento para modificar los parámetros en la dirección indicada por el gradiente de la log-probabilidad de la acción observada.

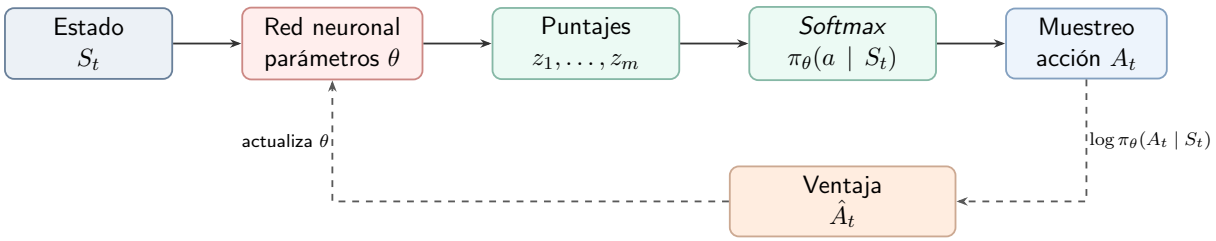


Figura 2.16: Red de política para un espacio discreto de acciones en la formulación de un MDP. El estado determina una distribución sobre las acciones disponibles; durante el aprendizaje, la ventaja pondera el gradiente de la log-probabilidad de la acción seleccionada [SB18, KT03].

La optimización de políticas se fundamenta en aislar la contribución específica de una acción respecto del rendimiento promedio del estado. Formalmente, la función de ventaja (*Advantage Function*) se define como la diferencia entre el valor de la acción y el valor medio del estado [SB18]:

$$A^\pi(s,a) \doteq Q^\pi(s,a) - V^\pi(s) \tag{2.17}$$

donde $Q^\pi(s,a)$ es el retorno esperado al seleccionar la acción a en el estado s bajo la política π, y $V^\pi(s) = \mathbb{E}_{a\sim\pi}[Q^\pi(s,a)]$ representa el valor esperado medio en dicho estado. Un valor $A^\pi(s,a) > 0$ señala que la fase semafórica ejecutada supera el desempeño promedio

de la intersección ante esas condiciones de cola, mientras que $A^\pi(s,a) < 0$ indica una decisión comparativamente deficiente.

Para estimar la ventaja combinando errores temporales de distintos horizontes, Schulman et al. [SML+16] desarrollaron el estimador GAE:

$$\hat{A}_t^{\mathrm{GAE}(\gamma,\lambda)} \doteq \sum_{l=0}^{\infty} (\gamma\lambda)^l \delta_{t+l}^V \tag{2.18}$$

donde $\delta_t^V = R_{t+1} + \gamma(1 - d_{t+1})V_\phi(S_{t+1}) - V_\phi(S_t)$ es el error temporal del crítico parametrizado por ϕ, d_{t+1} es el indicador terminal, $\gamma \in [0, 1)$ es el factor de descuento y $\lambda \in [0, 1]$ es el parámetro de suavizado exponencial. El hiperparámetro λ interpola estimaciones de ventaja de distintos horizontes. Para $\lambda = 0$, se obtiene el residuo TD de un paso δ_t^V, que suele reducir la varianza a costa de depender de la precisión del crítico y, por tanto, puede introducir sesgo. Para $\lambda = 1$, con el retorno completo, se recupera el estimador Monte Carlo descontado menos el valor del estado; este suele presentar mayor varianza. En trayectorias truncadas, el *bootstrapping* y la aproximación del crítico pueden modificar este compromiso.

El Teorema del Gradiente de Política (*Policy Gradient Theorem*) [SB18] fundamenta analíticamente la optimización directa de los parámetros de la política maximizando el retorno esperado $J(\theta)$. Empleando la función de ventaja como línea de base para mitigar la varianza, el gradiente se aproxima mediante la esperanza muestral sobre un lote de transiciones recolectadas:

$$\nabla_\theta J(\theta) \approx \hat{\mathbb{E}}_t \left[\nabla_\theta \log \pi_\theta(A_t \mid S_t) \hat{A}_t \right] \tag{2.19}$$

donde $\pi_\theta(A_t \mid S_t)$ denota la probabilidad asignada a la fase A_t bajo los parámetros θ, y $\hat{A}_t$ es la ventaja estimada mediante GAE. Como esquematiza la Figura 2.16, la dirección del vector gradiente escala proporcionalmente a $\hat{A}_t$, incrementando la probabilidad de ocurrencia de aquellas fases que superan el desempeño esperado y desincentivando aquellas que provocan demoras excesivas.

Proximal Policy Optimization (PPO) y control de las actualizaciones

Una actualización demasiado grande de los parámetros puede reducir el rendimiento de la política. Los métodos que se describen a continuación buscan limitar ese cambio para conservar un aprendizaje estable.

Para acotar el tamaño de paso en el espacio de distribuciones de probabilidad, Kakade y Langford [KL02] y Schulman et al. formularon el algoritmo de optimización de política por región de confianza (*Trust Region Policy Optimization*, TRPO) [SLA+15] mediante métodos de región de confianza. En el análisis teórico de TRPO, bajo los supuestos del modelo y una actualización que respete la región de confianza basada en la divergencia de

Kullback–Leibler (KL, una medida probabilística que cuantifica la discrepancia estadística entre la nueva política y la previa [GBC16, SLA+15]), la maximización exacta de la cota sustituta produce una política con retorno esperado no decreciente:

$$J(\pi_{k+1}) \geq J(\pi_k) \tag{2.20}$$

El algoritmo práctico de TRPO aproxima este procedimiento mediante ventajas estimadas, una divergencia KL promedio y optimización numérica. Sin embargo, resolver la optimización cuadrática con restricciones de TRPO en redes neuronales profundas resulta costoso en términos de cómputo. Como alternativa de primer orden, PPO [SWD+17] reemplaza la restricción formal por un objetivo sustituto recortado (CLIP) que busca limitar actualizaciones excesivas, sin transferir automáticamente la garantía teórica de TRPO.

Definiendo la razón de probabilidad entre la política actual y la previa:

$$r_t(\theta) \doteq \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\theta_{\text{old}}}(a_t \mid s_t)} \tag{2.21}$$

donde $\pi_{\theta_{\text{old}}}$ representa la política que recolectó el lote de transiciones, PPO maximiza el objetivo recortado:

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\text{mín} \left(r_t(\theta)\hat{A}_t,\ \text{clip}(r_t(\theta), 1-\epsilon_{\text{clip}}, 1+\epsilon_{\text{clip}})\hat{A}_t \right) \right] \tag{2.22}$$

En la ecuación (2.22), $\epsilon_{\text{clip}} > 0$ fija el margen de recorte. La función $\text{clip}(x, l, u)$ conserva x si está entre l y u, devuelve l si queda por debajo y u si lo supera. El operador mín elige el menor de los dos términos. Así, una ventaja positiva deja de incentivar aumentos de la razón por encima de $1+\epsilon_{\text{clip}}$, y una ventaja negativa deja de incentivar reducciones por debajo de $1-\epsilon_{\text{clip}}$. Este mecanismo limita el incentivo del objetivo; no impone una restricción estricta al cambio de la política.

En la arquitectura actor-crítico práctica, este objetivo de política se integra de forma conjunta con la regresión del crítico y un término de regularización entrópica:

$$J^{\text{PPO}}(\theta, \phi) = L^{\text{CLIP}}(\theta) - c_1\hat{\mathbb{E}}_t \left[\left(V_\phi(s_t) - R_t^{\text{target}} \right)^2 \right] + c_2\hat{\mathbb{E}}_t \left[S[\pi_\theta](s_t) \right] \tag{2.23}$$

donde ϕ son los parámetros del crítico, R_t^{target} es el retorno objetivo estimado (calculado como $\hat{A}_t + V_\phi(s_t)$), $S[\pi_\theta](s_t) \doteq -\sum_a \pi_\theta(a \mid s_t) \log \pi_\theta(a \mid s_t)$ es la entropía de Shannon de la política en s_t, y $c_1, c_2 > 0$ son coeficientes de ponderación [SWD+17]. La inclusión del término entrópico favorece la exploración activa al penalizar distribuciones excesivamente concentradas, favoreciendo que se consideren distintas fases durante el aprendizaje.

PPO opera de forma predominantemente *on-policy*: recolecta un lote de trayectorias con la política vigente $\pi_{\theta_{\text{old}}}$, ejecuta un número acotado de *epochs* de optimización sobre *minibatches*, y luego descarta el lote. De esta forma, las siguientes actualizaciones utilizan

experiencia obtenida con una política más reciente. El algoritmo 2 describe este ciclo de entrenamiento:

Algoritmo 2 Proximal Policy Optimization (PPO)

Entrada: entorno, horizonte de recolección, *epochs* K, γ, λ_{GAE} y ϵ_{clip}
Salida: parámetros entrenados θ del actor y ϕ del crítico

Inicializar los parámetros del actor θ y del crítico ϕ
Inicializar la política de recolección con $\theta_{\text{old}} \leftarrow \theta$
para iteración $= 1, 2, \ldots$ **hacer**
    Recolectar trayectorias con la política $\pi_{\theta_{\text{old}}}$
    Calcular los retornos objetivo y las ventajas estimadas $\hat{A}_t$
    para *epoch* $= 1$ hasta K **hacer**
        Muestrear *minibatches* del conjunto de trayectorias recolectado
        Calcular $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{\text{old}}}(a_t|s_t)}$
        Actualizar θ maximizando $L^{\text{CLIP}}(\theta)$
        Actualizar ϕ minimizando el error cuadrático del valor
        Incorporar, si corresponde, un término de entropía para favorecer la exploración
    fin para
    $\theta_{\text{old}} \leftarrow \theta$
fin para

En PPO, θ_{old} representa la política recolectora y permanece fijo al calcular las razones de probabilidad. El lote se reutiliza durante un número acotado de *epochs*; el recorte reduce el incentivo para que las razones superen el intervalo $[1 - \epsilon_{\text{clip}}, 1 + \epsilon_{\text{clip}}]$, pero no impone una restricción estricta ni garantiza una mejora monótona [SWD+17]. Después de la optimización, θ_{old} se actualiza con θ y se recolectan nuevas experiencias. Durante la ejecución en la red semafórica, el crítico se desacopla y el agente utiliza únicamente su actor local π_θ.

2.3. Aprendizaje por refuerzo multiagente (MARL)

El MARL generaliza el marco de RL hacia sistemas donde múltiples agentes autónomos interactúan y aprenden en un entorno compartido [ACS24]. En el control de redes semafóricas, la hipótesis de agente aislado deja de sostenerse: la fase habilitada en un cruce regula el flujo vehicular emitido hacia los accesos de las intersecciones adyacentes, acoplando espacialmente las dinámicas de congestión de toda la red. Cada agente influye directamente en las tasas de arribo y longitudes de cola de sus vecinos, lo que demanda esquemas de coordinación capaces de optimizar el flujo global.

Liang et al. [LML+25] categorizan los problemas multiagente según la estructura de sus

recompensas en completamente competitivos, mixtos o completamente cooperativos. Este trabajo persigue un objetivo de coordinación vial, pero sus implementaciones entregan recompensas individuales. En la búsqueda refinada, MAPPO y HAPPO emplean recompensa local; la fase amplia también explora señales vecinales (Sección 3.3.2). La finalidad cooperativa no hace idénticos los retornos individuales ni convierte automáticamente la implementación en un juego de recompensa escalar compartida.

2.3.1. Fundamentos teóricos: juegos estocásticos, equilibrio de Nash y Dec-POMDP

La extensión matemática del MDP ante múltiples actores decisores se formaliza mediante los Juegos Estocásticos o Juegos Markovianos (*Stochastic Games*), introducidos originalmente por Shapley [Sha53] y adaptados al aprendizaje por refuerzo contemporáneo por Albrecht et al. [ACS24].

Un Juego Estocástico de n agentes se define mediante la tupla:

$$\langle \mathcal{N}, \mathcal{S}, \{\mathcal{A}_i\}_{i=1}^{n}, P, \{R_i\}_{i=1}^{n}, \gamma \rangle \tag{2.24}$$

donde $\mathcal{N} = \{1, \ldots, n\}$ es el conjunto de agentes (intersecciones), $\mathcal{S}$ representa el espacio de estados globales de la red vial, $\mathcal{A}_i$ es el conjunto discreto de fases semafóricas disponibles para el agente i, y $\mathbf{a} = (a_1, \ldots, a_n) \in \boldsymbol{\mathcal{A}} \equiv \mathcal{A}_1 \times \cdots \times \mathcal{A}_n$ denota la acción conjunta. La función de transición $P(s' \mid s, \mathbf{a})$ modela la probabilidad de evolucionar hacia el estado global s' dada la acción conjunta ejecutada en el simulador SUMO, y $R_i(s, \mathbf{a})$ es la función de recompensa asignada al agente i.

En el análisis de estabilidad de estos sistemas, el equilibrio de Nash describe una configuración donde ningún agente puede incrementar unilateralmente su retorno esperado desviándose de su política actual [ACS24]. Formalmente, una política conjunta $\boldsymbol{\pi}^* = (\pi_1^*, \ldots, \pi_n^*)$ constituye un equilibrio de Nash si:

$$J(\pi_i, \boldsymbol{\pi}_{-i}^*) \leq J(\pi_i^*, \boldsymbol{\pi}_{-i}^*), \quad \forall \pi_i \in \Pi_i, \quad \forall i \in \mathcal{N} \tag{2.25}$$

donde $J(\cdot)$ denota el retorno esperado del agente i bajo el perfil de políticas indicado, $\boldsymbol{\pi}_{-i}^*$ representa el perfil de políticas conjuntas de todos los agentes excepto el agente i, y Π_i es el espacio de políticas admisibles. Aunque en sistemas estrictamente cooperativos este equilibrio caracteriza puntos de estabilidad mutua, no garantiza por sí mismo la optimalidad global de Pareto.

En redes urbanas reales, los agentes carecen de información instantánea y global sobre todo el trazado vial. Cada intersección opera sujeta a observabilidad parcial, percibiendo únicamente el estado de sus detectores locales. Una formulación teórica para observabilidad parcial y retorno compartido es el proceso de decisión de Markov parcialmente observable descentralizado (*Decentralized Partially Observable Markov Decision Process*,

Dec-POMDP) [AOS20], definido por la tupla:

$$\langle \mathcal{N}, \mathcal{S}, \{\mathcal{A}_i\}_{i=1}^{n}, P, R, \{\Omega_i\}_{i=1}^{n}, O, \gamma \rangle \tag{2.26}$$

donde Ω_i es el conjunto de observaciones locales accesibles al agente i, y $O(o_1, \ldots, o_n \mid s', \mathbf{a}) = \Pr\{\mathbf{o} = (o_1, \ldots, o_n) \mid s', \mathbf{a}\}$ es la función de emisión estocástica de observaciones [AOS20]. El estado global s es una variable del modelo que no tiene por qué ser accesible a cada agente; en general, una política descentralizada puede depender del historial local de observaciones y acciones τ_i y expresarse como $\pi_i(a_i \mid \tau_i)$. En la tupla, R es una recompensa escalar compartida. La implementación experimental entrega señales individuales R_i y se describe como un juego parcialmente observable, sin identificarla automáticamente con ese caso cooperativo de recompensa compartida (sección 3.3.2). Cada agente adopta una política reactiva basada en la observación actual $\pi_i(a_i \mid o_i)$, sin identificar o_i con s (Figura 2.17).

La Figura 2.17 esquematiza este acoplamiento: cada agente procesa su observación local o_i y emite una fase a_i. La concurrencia de estas decisiones conforma la acción conjunta $\mathbf{a}$, la cual perturba el estado global del simulador de tráfico y devuelve a cada agente su nueva observación y su retroalimentación individual r_i.

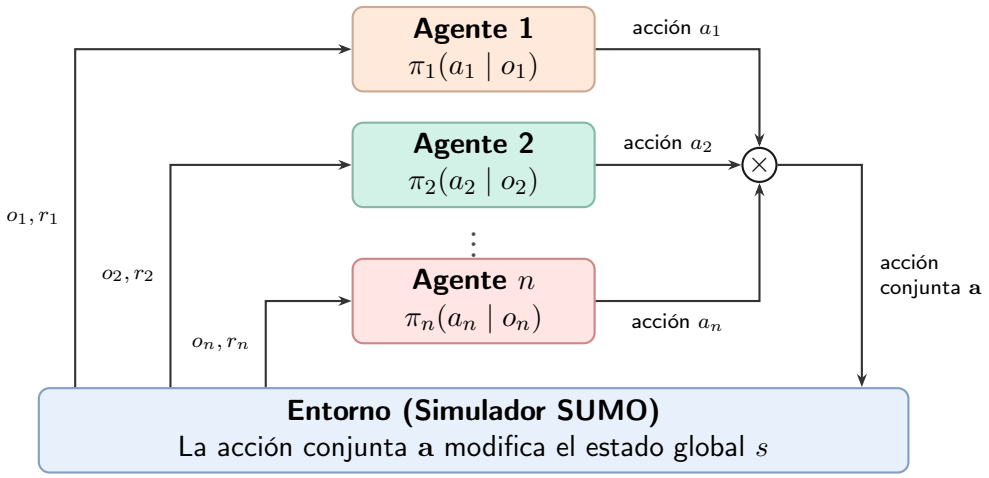


Figura 2.17: Interacción agente-entorno en un esquema MARL cooperativo. Cada semáforo emite una acción local (a_i) formando una acción conjunta ($\mathbf{a}$) que modifica el estado global del entorno de tráfico.

2.3.2. Desafíos del aprendizaje multiagente

La transición desde el aprendizaje individual hacia el dominio multiagente introduce desafíos teóricos y computacionales específicos [ACS24]:

- **Explosión combinatoria del espacio de acciones conjuntas:** si cada agente i dispone de un conjunto de acciones locales $\mathcal{A}_i$, la cardinalidad del espacio de acciones

conjuntas es:

$$|\boldsymbol{\mathcal{A}}| = \prod_{i=1}^{n} |\mathcal{A}_i| \,. \tag{2.27}$$

Cuando todos los agentes poseen A acciones, esta cardinalidad es A^n y, por tanto, crece exponencialmente con el número de agentes. Para una red de escala urbana, evaluar o enumerar exhaustivamente $\boldsymbol{\mathcal{A}}$ deja de ser una alternativa viable, lo que motiva el diseño de enfoques escalables, como políticas de decisión localmente descentralizadas.

- **No estacionariedad y el problema del valor objetivo cambiante:** desde la perspectiva local del agente i, la función de transición ambiental percibida:

$$\mathcal{P}_i(s' \mid s, a_i) = \sum_{\mathbf{a}_{-i}} P(s' \mid s, a_i, \mathbf{a}_{-i}) \boldsymbol{\pi}_{-i}(\mathbf{a}_{-i} \mid s) \tag{2.28}$$

varía de forma continua a medida que los restantes agentes adaptan sus respectivas políticas $\boldsymbol{\pi}_{-i}$. Como formalizaron Bowling y Veloso [BV02], este cambio produce el problema del valor objetivo cambiante (*moving target*): una política óptima frente al comportamiento vigente de los vecinos puede dejar de ser adecuada en cuanto estos ajustan sus parámetros. Aunque el sistema global puede seguir describiéndose mediante un juego markoviano, la dinámica observada por un agente local se vuelve no estacionaria cuando las políticas de los demás agentes cambian y no forman parte de su información. En consecuencia, las condiciones de convergencia de los métodos de agente único basados en MDPs estacionarios dejan de ser suficientes [FNF+17, LML+25].

  En juegos competitivos o de suma cero como Piedra, Papel o Tijera, el aprendizaje independiente con tasas fijas genera trayectorias oscilatorias alrededor del equilibrio. Algoritmos especializados como ascenso de colina en la política con ganar o aprender rápido (*Win or Learn Fast Policy Hill-Climbing*, WoLF-PHC) modulan adaptativamente su tasa de aprendizaje, amortiguando las espirales hacia el equilibrio de Nash ($\pi^*(a) = 1/3$), como ilustra la Figura 2.18. En el control semafórico, la no estacionariedad se manifiesta cuando un cruce extiende su verde para permitir el paso de un grupo de vehículos y modifica las llegadas a los cruces siguientes; si los agentes aprenden sin coordinación, corren el riesgo de generar variaciones de las colas que dificulten el servicio en otros cruces.

- **Observabilidad parcial:** bajo el formalismo Dec-POMDP, cada semáforo basa su inferencia exclusivamente en detectores locales, desconociendo el estado global de la red vial y las decisiones simultáneas de cruces lejanos, lo cual dificulta la estimación del valor de sus decisiones.

- **Asignación de crédito multiagente (*Credit Assignment*):** cuando múltiples agentes actúan en paralelo, determinar la contribución marginal de cada decisión local sobre el desempeño del sistema resulta complejo [ACS24]. Una acción local desfavorable puede quedar enmascarada si el resto de los semáforos operó de forma eficiente, o viceversa. La fase amplia explora recompensas que combinan señales de cada intersección y sus vecinos (Sección 3.3.2), pero esa combinación no identifica la contribución causal de cada acción.

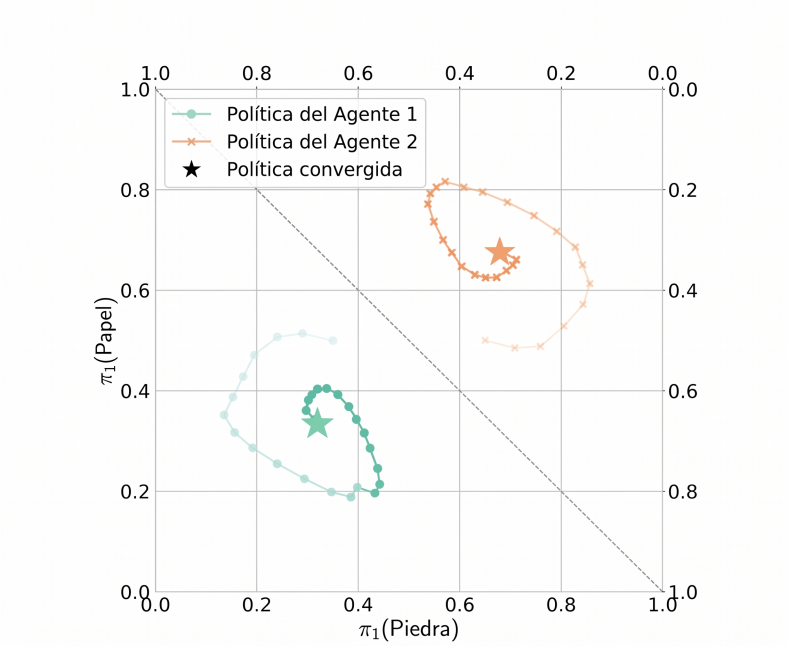


Figura 2.18: Evolución de las políticas de dos agentes con el algoritmo WoLF-PHC en el juego de Piedra, Papel o Tijera. La diagonal discontinua divide el gráfico en dos símplex de probabilidad, uno para cada agente. Cada punto en el símplex representa una distribución sobre las tres acciones disponibles; las trayectorias muestran el avance de las políticas durante el entrenamiento y los marcadores centrales destacan la política convergida en el equilibrio de Nash ($\pi^*(a) = 1/3$ para cada acción). Adaptado de [BV02, ACS24].

2.3.3. Paradigmas de entrenamiento y ejecución

Para mitigar la no estacionariedad respetando la observabilidad parcial de los agentes durante la ejecución, la literatura distingue dos paradigmas fundamentales según la información disponible durante la optimización [ZLYZ23]:

- **Aprendizaje independiente (Independent Learning, IL):** cada agente aprende de forma totalmente descentralizada tratando a los demás agentes como componentes estocásticos del entorno. Aunque computacionalmente simple y altamente escalable, es susceptible a la inestabilidad por no estacionariedad.

- **Entrenamiento centralizado con ejecución descentralizada (Centralized Training with Decentralized Execution, CTDE):** durante la etapa de entrenamiento en el simulador, se aprovecha información global privilegiada (estados conjuntos o concatenaciones de observaciones) para estimar valores y orientar el aprendizaje de las políticas locales; durante la etapa de ejecución, el componente centralizado se desacopla y cada agente opera con su política local. La Figura 2.19 ilustra esta separación entre etapas.

2.3.4. aprendizaje por refuerzo profundo multiagente (*Multi-Agent Deep Reinforcement Learning*, MADRL) y líneas de base

El uso de redes neuronales para aproximar políticas y funciones de valor de varios agentes forma parte del MADRL [LWT+17]. Para evaluar empíricamente el valor agregado del entrenamiento centralizado (MAPPO y HAPPO), esta investigación establece dos líneas de base de aprendizaje independiente (IL):

- **IDQN (Línea de base basada en valor):** extensión de DQN donde cada intersección mantiene su propia red $Q_i(o_i, a_i)$ [TMK+17]. Al operar *off-policy* con un *replay buffer*, almacena transiciones generadas bajo políticas anteriores, por lo que las experiencias pueden reflejar comportamientos distintos de los actuales [FNF+17].

- **IPPO (Línea de base basada en política):** instancia un optimizador PPO independiente por agente [dWGM+20]. Dado su régimen *on-policy*, descarta el lote tras cada iteración, mitigando la acumulación de datos obsoletos. Aunque no elimina el acoplamiento no estacionario, su mecanismo de recorte permite utilizarlo como referencia frente a los métodos coordinados.

La Figura 2.19 resume esta partición operativa entre ambas etapas.

2.3.5. Multi-Agent Proximal Policy Optimization (MAPPO)

Para extender las ventajas de estabilidad de PPO al contexto multiagente bajo el paradigma CTDE, Yu et al. [YVV+22] estudiaron una configuración de Multi-Agent Proximal Policy Optimization (MAPPO) basada en PPO y un crítico centralizado. En lugar de rediseñar el estimador base, MAPPO preserva la simplicidad computacional de PPO mediante la factorización explícita entre políticas descentralizadas y evaluación centralizada:

- **Actores descentralizados ($\pi_{\theta_i}(a_i \mid o_i)$):** cada agente i procesa exclusivamente su vector de observación local o_i para seleccionar su fase semafórica a_i. En intersecciones con geometrías idénticas puede compartirse parámetros entre actores, aunque esto no constituye una restricción conceptual.

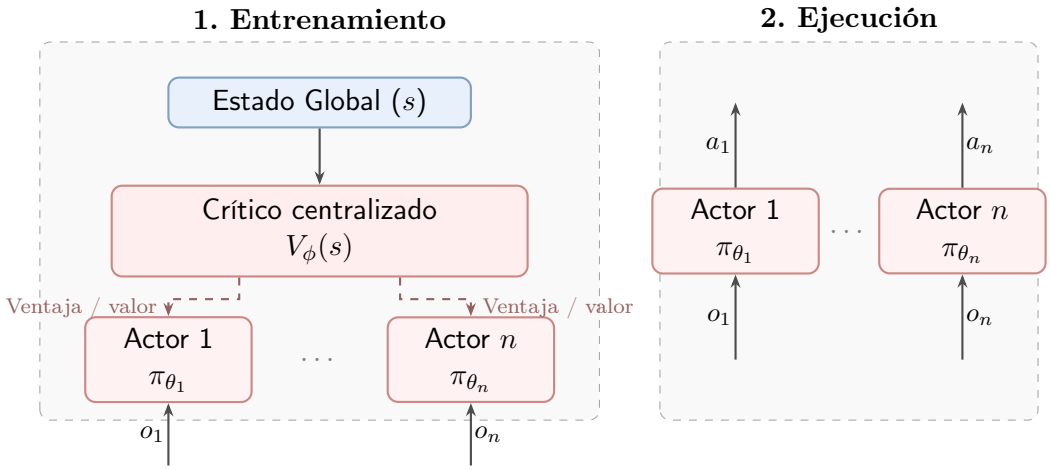


Figura 2.19: Paradigma de entrenamiento centralizado con ejecución descentralizada (CTDE). Durante el entrenamiento, el crítico utiliza información global privilegiada para estimar valores o ventajas que orientan la actualización de los actores locales; durante la ejecución, los actores solo requieren observaciones locales.

- **Crítico centralizado ($V_\phi(s)$):** durante el entrenamiento, el crítico puede utilizar información global que no está disponible para los actores. Una representación global adecuada puede facilitar la estimación del valor. Una estimación más precisa también puede reducir la variabilidad de las actualizaciones, aunque esto depende de la configuración [YVV+22].

El objetivo de optimización de los actores promedia los términos individuales de recorte PPO sobre los n agentes:

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\frac{1}{n} \sum_{i=1}^{n} \min \left(r_t^i(\theta) \hat{A}_t(s_t, \mathbf{a}_t),\ \text{clip}(r_t^i(\theta), 1-\epsilon_{\text{clip}}, 1+\epsilon_{\text{clip}}) \hat{A}_t(s_t, \mathbf{a}_t) \right) \right] \tag{2.29}$$

donde $r_t^i(\theta) = \frac{\pi_{\theta_i}(a_t^i|o_t^i)}{\pi_{\theta_{i,\text{old}}}(a_t^i|o_t^i)}$ denota la razón de probabilidad local de cada agente y ϵ_{clip} es el margen de recorte. Paralelamente, el crítico centralizado se actualiza minimizando el error cuadrático frente al retorno objetivo R_t^{target}, estimado empíricamente sobre el lote de transiciones mediante la suma de la ventaja GAE y el valor de estado previo $\hat{A}_t(s_t, \mathbf{a}_t) + V_\phi(s_t)$ [YVV+22, SML+16]:

$$\mathcal{L}^{\text{VF}}(\phi) = \hat{\mathbb{E}}_t \left[\left(V_\phi(s_t) - R_t^{\text{target}} \right)^2 \right]. \tag{2.30}$$

Factores críticos de diseño y optimización en MAPPO

Yu et al. [YVV+22] analizaron empíricamente diversos factores de implementación e hiperparámetros que afectan el rendimiento de MAPPO:

1. **Normalización de retornos:** en los experimentos de Yu et al., normalizar los objetivos de valor puede favorecer el ajuste del crítico cuando cambia la escala de

las recompensas.

2. **Estructuración del estado global del crítico:** en ese estudio, la entrada s se evaluó con distintas representaciones: concatenación directa de observaciones (CL : $s = (o_1, \ldots, o_n)$), estado global extraído directamente del simulador (EP), o estados aumentados específicos por agente ($AS_i = EP \cup o_i$), combinados opcionalmente con filtrado de redundancias (FP).

3. **Reutilización de datos:** la cantidad de *epochs* (K) y la división en *minibatches* regulan la reutilización del lote. Yu et al. observaron que una reutilización excesiva puede deteriorar el rendimiento, especialmente en tareas difíciles.

El algoritmo 3 especifica el ciclo computacional de MAPPO bajo el paradigma CTDE.

Algoritmo 3 Algoritmo Multi-Agent Proximal Policy Optimization (MAPPO)

Entrada: entorno multiagente, n agentes, horizonte de recolección, *epochs* K, γ, λ_{GAE} y ϵ_{clip}
Salida: parámetros entrenados de los actores θ y del crítico centralizado ϕ

Inicializar los parámetros de la política (actor) θ y del valor (crítico) ϕ
Inicializar el *buffer* de datos $\mathcal{D} \leftarrow \emptyset$
para iteración $= 1, 2, \ldots$ **hacer**
    Recolectar trayectorias *on-policy* para todos los agentes utilizando la política conjunta $\boldsymbol{\pi}_\theta$
    Calcular las ventajas conjuntas $\hat{A}_t(s_t, \mathbf{a}_t)$ mediante GAE a partir del crítico centralizado $V_\phi(s_t)$
    Calcular los retornos objetivos R_t^{target} normalizados para el crítico
    Almacenar las transiciones $(s_t, \mathbf{o}_t, \mathbf{a}_t, \hat{A}_t, R_t^{\text{target}})$ en $\mathcal{D}$
    para *epoch* $= 1$ hasta K **hacer**
        Muestrear *minibatches* de datos desde $\mathcal{D}$
        Actualizar la política maximizando el objetivo de recorte PPO por agente: $L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\frac{1}{n} \sum_{i=1}^{n} \text{mín} \left(r_t^i(\theta)\hat{A}_t,\ \text{clip}(r_t^i(\theta), 1 - \epsilon_{\text{clip}}, 1 + \epsilon_{\text{clip}})\hat{A}_t \right) \right]$
        Actualizar el crítico ϕ minimizando el error cuadrático medio del valor: $\mathcal{L}^{\text{VF}}(\phi) = \hat{\mathbb{E}}_t \left[\left(V_\phi(s_t) - R_t^{\text{target}} \right)^2 \right]$
    fin para
    Vaciar el *buffer* de datos $\mathcal{D} \leftarrow \emptyset$
fin para

Durante el entrenamiento, el crítico centralizado $V_\phi(s)$ procesa el estado global de la red vial para calcular ventajas conjuntas mediante GAE, guiando la optimización paralela de los actores locales π_{θ_i} con el objetivo recortado. Al finalizar cada iteración, el *buffer* $\mathcal{D}$ se descarta por completo para preservar el régimen *on-policy* del método. En la etapa de ejecución, el crítico se desacopla y cada agente actúa con autonomía computacional a partir de su vector local o_t^i. Los hiperparámetros de entrenamiento y la arquitectura de las redes se detallan en el capítulo 3.

La formulación anterior presenta la variante teórica con una ventaja conjunta. En la implementación de este trabajo, el crítico centralizado produce una salida por agente y los objetivos de GAE se calculan por agente a partir de la recompensa individual descrita en la sección 3.3.2; por tanto, la ecuación resume el paradigma CTDE y no debe leerse como una identidad exacta del código ejecutado.

2.3.6. Heterogeneous-Agent Proximal Policy Optimization (HAPPO)

En sistemas de control complejos, los agentes pueden presentar asimetrías físicas y operacionales: diferencias en la configuración de actuadores, distintos espacios de acciones o demandas regionales contrapuestas. En entornos homogéneos, compartir parámetros puede mejorar la eficiencia de aprendizaje; en entornos heterogéneos, esa práctica puede limitar la especialización. Además, las actualizaciones independientes no poseen una garantía general de convergencia debido al aprendizaje simultáneo no coordinado [KCW+22].

Kuba et al. y Zhong et al. propusieron algoritmos de aprendizaje por refuerzo multiagente para políticas heterogéneas, sin exigir que todos los agentes compartan parámetros. Esta línea se denomina aprendizaje por refuerzo con agentes heterogéneos (Heterogeneous-Agent Reinforcement Learning, HARL). Cada agente i puede mantener su propia arquitectura y parámetros θ^i, adaptados a su espacio de acciones local $\mathcal{A}_i$. En esta línea, optimización de política por región de confianza con agentes heterogéneos (*Heterogeneous-Agent Trust Region Policy Optimization*, HATRPO) y HAPPO emplean una actualización secuencial de los agentes. HAPPO sustituye la restricción KL de la formulación de región de confianza por un objetivo recortado. Zhong et al. lo encuadran en el marco de aprendizaje espejo con agentes heterogéneos (*Heterogeneous-Agent Mirror Learning*, HAML), que establece resultados de mejora monótona y convergencia bajo sus condiciones, entre ellas una recompensa compartida [KCW+22, ZKF+24].

Compartición de parámetros y políticas heterogéneas

Una distinción central entre MAPPO y HAPPO radica en la homogeneidad de las políticas y en el orden de actualización:

- **Compartición de parámetros:** en MAPPO se utiliza habitualmente cuando los agentes poseen espacios de observación y acción compatibles. Todos los agentes pueden compartir los mismos pesos $\theta_1 = \cdots = \theta_n = \theta$, aunque la formulación de MAPPO también puede implementarse sin esta restricción.
- **Políticas heterogéneas y actualización secuencial:** HAPPO permite que cada agente mantenga una política independiente $\pi_{\theta^i}(a_i \mid o_i)$ y actualiza los actores siguiendo una permutación. El lote de trayectorias de la iteración actual se reutiliza de forma limitada; esto no equivale a un *buffer* histórico de *experience sharing* como el empleado por algoritmos específicos de compartición de experiencia.

Lema de descomposición de la ventaja multiagente

La actualización simultánea de todos los agentes puede generar inestabilidad porque el cambio concurrente de las políticas altera tanto las distribuciones de acción como la distribución conjunta de las trayectorias. HAPPO aborda este problema mediante una actualización secuencial: en cada iteración se optimiza un agente por vez, condicionando cada paso a los cambios ya efectuados por los precedentes. Para sustentar este esquema, la ventaja conjunta de la red debe poder descomponerse en contribuciones marginales ordenadas [KCW+22].

Esta descomposición se formaliza en el lema de descomposición de la ventaja multiagente propuesto por Kuba et al. [KCW+22]. En cualquier juego markoviano cooperativo, para una política conjunta $\boldsymbol{\pi}$ y un orden arbitrario de los agentes $i_{1:n} = (i_1, \ldots, i_n)$, la ventaja conjunta de la red se descompone exactamente como la suma de las ventajas marginales de cada agente, condicionadas por las decisiones de los que lo preceden en la secuencia:

$$A^{\boldsymbol{\pi}}(s, \mathbf{a}) = \sum_{m=1}^{n} A^{\boldsymbol{\pi}}_{i_m}(s, \mathbf{a}_{i_{1:m-1}}, a_{i_m}) \tag{2.31}$$

donde la ventaja marginal del agente i_m se define como:

$$A^{\boldsymbol{\pi}}_{i_m}(s, \mathbf{a}_{i_{1:m-1}}, a_{i_m}) \doteq Q^{\boldsymbol{\pi}}_{i_{1:m}}(s, \mathbf{a}_{i_{1:m-1}}, a_{i_m}) - Q^{\boldsymbol{\pi}}_{i_{1:m-1}}(s, \mathbf{a}_{i_{1:m-1}}). \tag{2.32}$$

En la ecuación (2.32), $Q^{\boldsymbol{\pi}}_{i_{1:m}}(s, \mathbf{a}_{i_{1:m-1}}, a_{i_m})$ evalúa el retorno esperado fijando las acciones de los primeros m agentes de la secuencia, mientras que las decisiones de los agentes posteriores ($\mathbf{a}_{i_{m+1:n}}$) se promedian según sus probabilidades bajo la política vigente.

La deducción matemática original de este lema asume un juego markoviano estrictamente cooperativo con un retorno escalar compartido $R(s, \mathbf{a})$ para toda la red. En sistemas espaciales distribuidos de gran escala, como el control semafórico urbano, asignar una recompensa global idéntica a todas las intersecciones dificulta la asignación de crédito, extremo que Chu et al. respaldan con evidencia empírica en redes extensas [CWCL19], y encarece la estimación de las ventajas [ACS24]. En este trabajo se emplean señales locales y, en protocolos específicos, de vecindario inmediato. Esta decisión de implementación no conserva por sí sola los supuestos del lema original.

Bajo retornos desacoplados, la identidad aditiva de la ecuación (2.31) no se traduce en una equivalencia algebraica directa entre un único valor global y los retornos individuales; no obstante, el principio de optimización secuencial por bloques (tipo Gauss-Seidel) conserva su utilidad práctica para desacoplar el aprendizaje concurrente [ACS24, WZK+23].

La relevancia teórica de este lema radica en que es una identidad analítica exacta para cualquier juego cooperativo sin imponer restricciones de aditividad o de monotonía sobre la función de valor en la red de mezclado (a diferencia de las condiciones de factorización IGM de arquitecturas como redes de descomposición de valor (*Value-Decomposition Networks*,

VDN) [SLG+18] o red de mezcla de valores Q (*Q-Mixing Network*, QMIX) [RSDW+18]).

Esquema de actualización secuencial y factor de razón compuesto M

Para explotar analíticamente esta descomposición teniendo en cuenta los cambios de los agentes ya actualizados, HAPPO actualiza las políticas de los agentes de manera secuencial dentro de cada iteración k. En cada ciclo se sortea una permutación de los agentes $i_{1:n} \in \mathrm{Sym}(n)$ (donde $\mathrm{Sym}(n)$ representa el conjunto de todas las permutaciones posibles de los n agentes) para que ningún agente ocupe siempre la misma posición en la secuencia [KCW+22, WZK+23].

Cuando corresponde el turno del agente i_m, los agentes previos en la secuencia ($i_{1:m-1}$) ya han actualizado sus parámetros a $\theta_{k+1}^{i_j}$, mientras que los agentes posteriores ($i_{m+1:n}$) conservan aún sus parámetros previos $\theta_k^{i_j}$. Para guiar al agente i_m teniendo en cuenta la alteración de la distribución conjunta producida por los agentes ya actualizados, Kuba et al. [KCW+22] demostraron que no se requiere entrenar un crítico separado por cada subgrupo; la ventaja marginal puede computarse reponderando la ventaja conjunta $A^{\boldsymbol{\pi}_k}(s, \mathbf{a})$ mediante la productoria acumulada de las razones de probabilidad de los agentes ya actualizados:

$$M_{i_{1:m}}(s_t, \mathbf{a}_t) \doteq \left(\prod_{j=1}^{m-1} \frac{\pi_{\theta_{k+1}^{i_j}}^{i_j}(a_t^{i_j} \mid o_t^{i_j})}{\pi_{\theta_k^{i_j}}^{i_j}(a_t^{i_j} \mid o_t^{i_j})} \right) A^{\boldsymbol{\pi}_k}(s_t, \mathbf{a}_t) \tag{2.33}$$

donde $\pi_{\theta_{k+1}^{i_j}}^{i_j}$ es la política recién optimizada del agente i_j y $\pi_{\theta_k^{i_j}}^{i_j}$ es su versión previa. Para el primer agente ($m = 1$), la productoria es vacía y $M_{i_1}(s_t, \mathbf{a}_t) \equiv A^{\boldsymbol{\pi}_k}(s_t, \mathbf{a}_t)$. En la formulación algorítmica práctica, el término acumulado $M_{i_{1:m}}$ se mantiene en una variable de memoria M_{i_m} por cada agente, la cual se actualiza recursivamente conforme avanzan las optimizaciones precedentes. El factor $M_{i_{1:m}}$ actúa como un estimador de importancia que ajusta la ventaja conjunta al nuevo perfil de comportamiento sin requerir simulaciones adicionales en el entorno [KCW+22].

Así, la política del agente i_m se optimiza maximizando el objetivo sustituto recortado ponderado por $M_{i_{1:m}}$:

$$\begin{aligned} L^{\mathrm{HAPPO}}(\theta^{i_m}) = \hat{\mathbb{E}}_t \Big[\min \Big(& r_t^{i_m}(\theta^{i_m}) M_{i_{1:m}}(s_t, \mathbf{a}_t), \\ & \mathrm{clip}\big(r_t^{i_m}(\theta^{i_m}), 1 - \epsilon_{\mathrm{clip}}, 1 + \epsilon_{\mathrm{clip}}\big) M_{i_{1:m}}(s_t, \mathbf{a}_t) \Big) \Big] \end{aligned} \tag{2.34}$$

donde $r_t^{i_m}(\theta^{i_m}) = \frac{\pi_{\theta^{i_m}}^{i_m}(a_t^{i_m} | o_t^{i_m})}{\pi_{\theta_k^{i_m}}^{i_m}(a_t^{i_m} | o_t^{i_m})}$ representa la razón de probabilidad individual del agente.

Concluida la optimización de θ^{i_m}, se computa la razón post-optimización:

$$\rho_{\text{post}}^{i_m} \doteq \frac{\pi_{\theta_{k+1}^{i_m}}^{i_m}(a_t^{i_m} \mid o_t^{i_m})}{\pi_{\theta_k^{i_m}}^{i_m}(a_t^{i_m} \mid o_t^{i_m})} \tag{2.35}$$

y se propaga recursivamente hacia los agentes pendientes mediante:

$$M_{i_{1:m+1}}(s_t, \mathbf{a}_t) \leftarrow \rho_{\text{post}}^{i_m} \cdot M_{i_{1:m}}(s_t, \mathbf{a}_t). \tag{2.36}$$

Garantía de mejora monótona

El principio de mejora monótona en aprendizaje por refuerzo formaliza que la secuencia de retornos esperados de la política conjunta no disminuye entre ciclos sucesivos de entrenamiento, comportándose como una función monótonamente no decreciente respecto de la iteración k:

$$J(\boldsymbol{\pi}_{k+1}) \geq J(\boldsymbol{\pi}_k). \tag{2.37}$$

Para políticas heterogéneas, Kuba et al. [KCW+22] demostraron analíticamente esta propiedad para el algoritmo HATRPO bajo los supuestos del juego markoviano cooperativo con recompensa compartida y una actualización restringida por la divergencia KL. Resolver las restricciones de HATRPO en redes neuronales profundas requiere un costo de cómputo elevado. Por ello, HAPPO sustituye la cota formal de divergencia KL por el objetivo sustituto recortado CLIP de primer orden de la ecuación (2.34).

La garantía de HATRPO no se transfiere automáticamente al sustituir su restricción por un recorte. El análisis de HAPPO dentro de HAML establece garantías bajo las condiciones de ese marco [KCW+22, ZKF+24]. Su aplicación a un controlador semafórico requiere comprobar esas condiciones: las recompensas específicas de cada agente no definen por sí solas el retorno compartido del planteo cooperativo. La metodología delimita por ello el alcance de las garantías para la adaptación utilizada y evalúa empíricamente su desempeño. La Figura 2.20 resume este esquema de propagación secuencial.

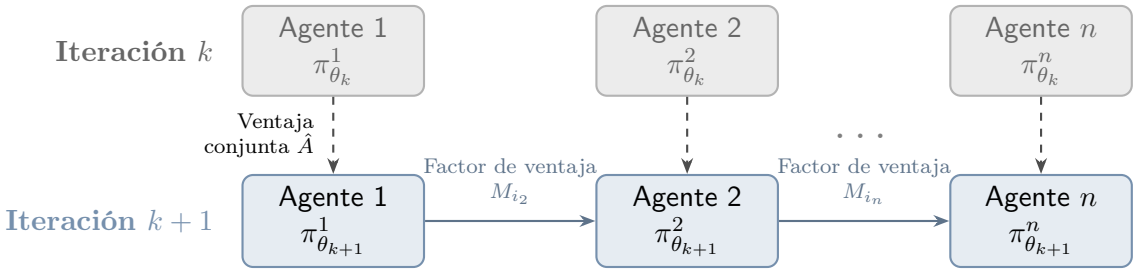


Figura 2.20: Esquema de actualización secuencial de HAPPO. A diferencia de PPO independiente, la actualización de cada agente está condicionada por el factor de ventaja reponderada M_{i_m}, que incorpora los cambios efectuados por los agentes que lo precedieron en la secuencia.

El algoritmo 4 presenta la secuencia completa de optimización de HAPPO.

Algoritmo 4 Algoritmo Heterogeneous-Agent Proximal Policy Optimization (HAPPO)

Entrada: entorno multiagente, conjunto $\mathcal{N}$ de n agentes, horizonte de recolección, γ, λ_{GAE} y ϵ_{clip}

Salida: políticas heterogéneas entrenadas $\{\theta^i\}_{i=1}^n$ y crítico centralizado ϕ

Inicializar los parámetros de las políticas individuales $\{\theta^i, \forall i \in \mathcal{N}\}$ y del crítico centralizado $V_\phi(s)$
para iteración $= 1, 2, \ldots$ **hacer**
    Recolectar un conjunto de trayectorias $\mathcal{D}$ utilizando la política conjunta $\boldsymbol{\pi}_\theta$
    Calcular el estimador de ventaja conjunta $\hat{A}(s, \mathbf{a})$ con GAE a partir del crítico $V_\phi(s)$
    Calcular los retornos objetivo R_t^{target} utilizados para ajustar el crítico
    Sortear una permutación de los agentes $i_{1:n} \in \text{Sym}(n)$
    Inicializar los factores $M_{i_m}(s, \mathbf{a}) \leftarrow \hat{A}(s, \mathbf{a})$ para todo $m \in \{1, \ldots, n\}$
    para $m = 1 \ldots n$ **hacer**
        Obtener el agente actual i_m y su factor modificador $M_{i_m}(s, \mathbf{a})$
        Actualizar θ^{i_m} a $\theta_{k+1}^{i_m}$ maximizando el objetivo recortado de la ecuación (2.34)
        Recalcular la razón post-optimización: $\rho_{\text{post}}^{i_m} \leftarrow \frac{\pi_{\theta_{k+1}^{i_m}}^{i_m}(a_t^{i_m}|o_t^{i_m})}{\pi_{\theta_k^{i_m}}^{i_m}(a_t^{i_m}|o_t^{i_m})}$
        para $j = m + 1 \ldots n$ **hacer**
            Actualizar el factor modificador para agentes posteriores: $M_{i_j}(s_t, \mathbf{a}_t) \leftarrow \rho_{\text{post}}^{i_m} \cdot M_{i_j}(s_t, \mathbf{a}_t)$
        fin para
    fin para
    Actualizar el crítico centralizado ϕ mediante descenso de gradiente: $\mathcal{L}^{\text{VF}}(\phi) = \hat{\mathbb{E}}_t \left[\left(V_\phi(s_t) - R_t^{\text{target}} \right)^2 \right]$
fin para

El procedimiento de HAPPO organiza secuencialmente la actualización de los actores locales mediante la permutación aleatoria $i_{1:n}$ y la propagación recursiva de los factores modificadores M_{i_m}. Tras optimizar sucesivamente a los n agentes sobre el lote de transiciones $\mathcal{D}$, el crítico centralizado V_ϕ ajusta sus parámetros mediante descenso de gradiente sobre los retornos acumulados. Durante la etapa de ejecución descentralizada, cada política local selecciona a_i a partir de o_i, sin requerir evaluar el crítico centralizado ni comunicación entre agentes para seleccionar su acción [KCW+22].

La adaptación para control semafórico de este trabajo conserva la actualización sucesiva de los actores, pero inicializa los factores M_{i_m} con las ventajas individuales $\hat{A}_i(s, \mathbf{a})$ calculadas mediante el crítico centralizado multi-salida a partir de las señales de recompensa individuales (Sección 3.3.2), propagándolos mediante la razón $\rho_{\text{post}}^{i_m}$ tras optimizar a

cada actor. A diferencia del Algoritmo 4, la implementación actualiza el crítico al comienzo de cada época, antes de los actores (Sección 3.3.3).

Esta adaptación utiliza ventajas individuales, mientras que la demostración teórica parte de una recompensa global compartida. Su efecto sobre el aprendizaje debe comprobarse mediante los experimentos; esta adaptación no hereda por sí sola la garantía teórica de mejora.

Para finalizar el estudio comparativo de los algoritmos derivados de PPO en escenarios MARL, la Tabla 2.3 sintetiza sus principales propiedades operativas, arquitectónicas y teóricas.

Tabla 2.3: Comparación sintética de familias algorítmicas PPO en entornos multiagente cooperativos.

Eje de análisis	**PPO de agente único**	**IPPO independiente**	**MAPPO / CTDE**	**HAPPO / HARL**
Paradigma	agente único	IL (descentralizado)	CTDE (centralizado/desc.)	CTDE; familia HARL
Actores	único $\pi_\theta(a \mid s)$	n políticas locales	actores locales; puede compartir parámetros	n políticas heterogéneas
Arquitectura del crítico	único $V_\phi(s)$	n críticos locales $V_{\phi_i}(o_i)$	un crítico centralizado $V_\phi(s)$	un crítico centralizado $V_\phi(s)$
Optimización	PPO estándar	PPO local simultáneo	PPO local con crítico global	actualización secuencial $i_{1:n}$
Señal de ventaja	ventaja local $\hat{A}(s, a)$	ventaja local $\hat{A}_i(o_i, a_i)$	ventaja conjunta $\hat{A}(s, \mathbf{a})$	factor compuesto $M_{i_{1:m}}(s, \mathbf{a})$
Mejora monótona	No estricta para PPO	Sin garantía general	Sin garantía estricta	Bajo las condiciones de HAML
Tipo de agente	No aplica	Depende de la implementación	Pensado para agentes homogéneos; la compartición de parámetros es opcional	Pensado para agentes heterogéneos

2.3.7. Antecedentes recientes del control semafórico multiagente

Para orientar la comparación, los antecedentes seleccionados se organizan según tres ejes: coordinación y entrenamiento, representación de las observaciones, y tratamiento de la heterogeneidad o la equidad entre intersecciones. Se priorizan investigaciones directamente relacionadas con la formulación de este trabajo.

El control coordinado de múltiples intersecciones mediante aprendizaje por refuerzo constituye un área de investigación activa. Entre los enfoques iniciales se encuentran aquellos que asignaban un agente a cada semáforo y utilizaban información local sobre colas, fases o vehículos detenidos. Sin embargo, la optimización aislada de cada intersección no contempla que una acción modifica el flujo recibido por los cruces vecinos. Por este motivo, la literatura evolucionó hacia formulaciones cooperativas que incorporan mecanismos de coordinación espacial, representaciones estructuradas del estado y esquemas de entrenamiento centralizado [ACS24, LML+25].

Coordinación y entrenamiento

En la consolidación del control semafórico coordinado mediante aprendizaje profundo, varios trabajos abordaron de manera temprana la asignación de crédito y la no estacionariedad en redes viales:

- **Control actor-crítico con descuento espacial (MA2C):** Chu et al. [CWCL19] propusieron una arquitectura de ventaja actor-crítico multiagente donde cada intersección incorpora a su función de valor y recompensa la información de sus vecinos inmediatos atenuada por un factor de descuento espacial. Este trabajo fundamentó conceptualmente y evidenció de manera empírica que una recompensa de equipo global en redes extensas induce severos problemas de asignación de crédito, mientras que las recompensas regionalmente estructuradas permiten coordinar corredores sin requerir estados globales inmanejables.

- **Coordinación basada en presión vehicular (PressLight):** Wei et al. [WCZ+19] fundamentaron su función de recompensa en el principio de *Max-Pressure* de la ingeniería de transporte, que en la teoría de control de redes garantiza estabilidad de cola bajo supuestos específicos de un esquema de servicio discreto. PressLight incorpora ese principio mediante una recompensa igual al negativo de la presión de la intersección, calculada a partir de las densidades vehiculares de entrada y salida. Esa incorporación no hereda la garantía formal de estabilidad y coordina de manera implícita las intersecciones adyacentes sin necesidad de comunicación explícita.

- **Atención en grafos para cooperación a nivel de red (CoLight):** Wei et al. [WXZ+19] introdujeron redes de atención en grafos para permitir que los agentes

semafóricos intercambien dinámicamente representaciones de sus estados con cruces vecinos, adaptando la influencia de cada intersección adyacente según las condiciones variables de congestión.

- **Límites del aprendizaje independiente en redes viales:** Ault y Sharon [AS22] analizaron las limitaciones de los enfoques independientes frente a formulaciones cooperativas en redes de múltiples intersecciones, evidenciando un deterioro progresivo en el desempeño y en la fluidez del tránsito a medida que la demanda se incrementa debido a la falta de coordinación y a la no estacionariedad del entorno.

A partir de estas bases fundacionales, diversas investigaciones recientes han explorado mecanismos alternativos de optimización y distribución de cómputo. Wu et al. [WWS+22] estudian el control de redes de gran escala mediante agentes distribuidos de aprendizaje por refuerzo profundo y una arquitectura de cómputo distribuido. Proponen dos variantes, Nash-A2C y Nash-A3C, que incorporan un equilibrio de Nash en el aprendizaje por refuerzo y se despliegan en una arquitectura distribuida para simulación y control. En sus experimentos reportan reducciones del tiempo de congestión y de la demora total de red frente a controladores de referencia. Este antecedente es pertinente como referencia de escalabilidad, pero no es equivalente a la formulación de este trabajo: aquí la ejecución también es local por intersección y los métodos centralizados incorporan información conjunta durante el entrenamiento, sin introducir una capa de cómputo fog ni un equilibrio de Nash.

En una formulación cooperativa basada en DQN, Haddad et al. [HHA22] incorporan a la función de aprendizaje de cada intersección información sobre los estados, acciones y recompensas de sus vecinos. El estudio informa mejoras en tiempo de espera, longitud de cola y emisiones de dióxido de carbono frente a controladores de referencia. Esta evidencia respalda la necesidad de considerar el efecto de las decisiones vecinas, pero su mecanismo de coordinación es una transferencia explícita de información hacia la pérdida de DQN. En el protocolo de búsqueda con dominios reducidos de este estudio, IPPO e IDQN implementan el paradigma de aprendizaje independiente y reciben una señal de recompensa estrictamente local ($R_i = L_i$, $\rho_{\text{coop}} = 0$); MAPPO y HAPPO usan también recompensa local en la búsqueda refinada, con crítico centralizado durante el entrenamiento. Estas alternativas no son equivalentes al mecanismo propuesto por Haddad et al., sino procedimientos de coordinación distintos que se comparan bajo una misma representación y escenario.

Fang et al. [FYX+23] proponen un método de coordinación de red que formula el control semafórico como un problema multiobjetivo: combina eficiencia, seguridad y coordinación espacial entre intersecciones mediante un esquema de entrenamiento centralizado con ejecución descentralizada. Además de reportar resultados en redes sintéticas y arterias reales, el trabajo destaca que las dependencias espacio-temporales entre agentes deben

representarse explícitamente. Su propuesta ofrece un contraste con las recompensas individuales y la representación interpretable utilizadas en este trabajo, que no incorporan una optimización multiobjetivo ni una representación latente basada en atención.

Representación del estado

En cuanto a la representación agregada y el aprendizaje basado en valor, Kolat et al. [KKBA23] proponen un enfoque DQN multiagente con parámetros compartidos. Los agentes observan cantidades escaladas de vehículos detenidos y reciben una recompensa que penaliza el desequilibrio entre los accesos. Los resultados muestran mejoras en el tiempo de viaje y el consumo de combustible respecto de un controlador de ciclo fijo. Sirve como referencia para contrastar una representación agregada del estado y una coordinación inducida por la recompensa con la evaluación de IDQN y de métodos basados en políticas realizada en esta investigación.

Dentro de la línea centrada en la representación del estado, Yang [Yan23] propone HG-M2I, una arquitectura que combina información espacial y temporal mediante un grafo jerárquico. El modelo integra estados de los agentes y de sus vecinos en representaciones latentes utilizadas por las políticas. Posteriormente, Chen et al. [CYL+24] presentan CoevoMARL, que utiliza atención en grafos y una unidad recurrente para aprender cómo varía en el tiempo la dependencia entre intersecciones. Mientras HG-M2I organiza la información según una jerarquía espacial, CoevoMARL adapta las relaciones entre agentes a la evolución del tránsito. Ambos trabajos muestran la importancia de construir observaciones informativas, aunque recurren a representaciones latentes aprendidas, a diferencia de la transformación explícita e interpretable que se evalúa aquí.

En el caso de una representación basada en celdas, Deng et al. [DLSZ26] introducen una partición de longitud variable. Los accesos se dividen mediante una función que combina componentes logarítmicos y lineales, y cada celda almacena la cantidad de vehículos, la velocidad media y la ocupación espacial. Esta partición asigna mayor detalle a las zonas próximas a la intersección y comprime las regiones más alejadas. Entre los trabajos seleccionados, es el antecedente más cercano al uso de una transformación logarítmica en la representación semafórica; sin embargo, el logaritmo determina la longitud espacial de las celdas y no codifica el tiempo de espera acumulado por carril.

Heterogeneidad y equidad

Ren et al. [RDZ+24] abordan la coordinación bajo demandas heterogéneas mediante un esquema de dos capas. Cada agente combina su ventaja local con la de las intersecciones vecinas a través de un factor de cooperación adaptable, que luego se ajusta según el rendimiento global de la red. El método considera la demora y las emisiones vehiculares, y coordina los objetivos locales y globales mediante ese factor adaptable. Este antecedente permite contrastar la coordinación adaptativa de las señales de aprendizaje con la heterogeneidad de políticas considerada por HAPPO, aunque no emplea su procedimiento de

actualización secuencial.

En la coordinación mediante entrenamiento centralizado, Liu et al. [LZF+25] formulan el control semafórico como un juego parcialmente observable con restricciones y proponen VF-MAPPO. En este método, la equidad se expresa mediante una cota sobre el tiempo máximo de espera de los vehículos, mientras que un crítico centralizado con atención espaciotemporal estima tanto la eficiencia de la red como el cumplimiento de la restricción. Esta formulación resulta especialmente pertinente para esta investigación porque vincula con una variable temporal de operación el paradigma de entrenamiento centralizado con ejecución descentralizada. No obstante, el tiempo de espera se incorpora como restricción de optimización y no mediante una codificación no lineal de la observación.

En el tratamiento de agentes heterogéneos, otro enfoque es HAPS-PPO, presentado por Lu et al. [LFYZ25]. El método completa con relleno las observaciones de distinta dimensión y agrupa a los agentes según sus espacios de acción, asignando cabezales de política específicos a cada grupo. Esto permite coordinar intersecciones con geometrías y conjuntos de fases diferentes.

Posicionamiento del proyecto

La selección analizada sugiere que el desempeño del control semafórico multiagente depende de tres decisiones relacionadas: el algoritmo utilizado para aprender y coordinar las políticas, la representación de las condiciones de operación y el tratamiento de intersecciones con demandas, geometrías o espacios de acción diferentes. Los enfoques basados en DQN proporcionan una referencia para el aprendizaje por valor. Los modelos de grafos construyen representaciones latentes de las relaciones espaciales, mientras que las variantes de MAPPO incorporan información global durante el entrenamiento. Los esquemas de cooperación adaptable o con múltiples cabezales atienden distintas formas de heterogeneidad. La codificación por carril y la discretización de variables de tránsito también cuentan con antecedentes en control semafórico [GR18]; aquí se emplean para representar la espera acumulada por carril mediante la transformación especificada en la metodología.

Entre los antecedentes considerados, HeteroLight aborda la heterogeneidad mediante una arquitectura de parámetros compartidos con módulos que extraen características generales y específicas de cada intersección [ZLFS24], mientras que MATLight se apoya en un marco de aprendizaje especular para agentes heterogéneos (*heterogeneous-agent mirror learning*) y emplea un Transformer para procesar secuencias de estados [ZWL24]. Son mecanismos distintos de la adaptación HAPPO implementada aquí: no se los presenta como equivalentes ni como evidencia de que HAPPO sea superior. Entre las fuentes consultadas no se localizó una evaluación conjunta de IDQN, IPPO, MAPPO y HAPPO bajo una misma formulación, ni una aplicación directa del HAPPO original al control de fases semafóricas urbanas. Esta observación delimita la búsqueda realizada y no permite

concluir que tales estudios no existan.

En particular, este trabajo explora una codificación híbrida logarítmica-lineal del tiempo de espera acumulado por carril. Al asignar valores continuos a un conjunto finito de intervalos, la cuantización agrupa esperas dentro de una misma categoría y limita los valores representables; la saturación también reúne los valores que alcanzan la cota. En aprendizaje por refuerzo, una abstracción de estados puede simplificar el problema y conservar comportamiento cercano al óptimo cuando los estados agrupados son suficientemente similares, bajo las condiciones teóricas correspondientes [AHL16]. Ese resultado no constituye una garantía para esta codificación: aquí se transforman observaciones locales en un problema parcialmente observable y no se demuestra que los valores agrupados sean equivalentes para la política óptima. La resolución no uniforme del codificador asigna más niveles a esperas bajas, lo que permite distinguirlas con mayor detalle; es una hipótesis de diseño, pues la cuantización también puede descartar distinciones relevantes, en particular cerca de los umbrales entre intervalos.

Su efecto se examina como parte del sistema completo, sin un experimento que compare el mismo sistema con y sin esa transformación. Esta propuesta se diferencia de las observaciones agregadas utilizadas por los enfoques DQN, de las proyecciones latentes basadas en grafos y de la partición espacial de Deng et al. [DLSZ26], que divide los accesos y no codifica la espera acumulada por carril.

A su vez, el diseño experimental contempla la búsqueda de configuraciones de IDQN, IPPO, MAPPO y HAPPO sobre una misma representación local de observación. En MAPPO se utiliza un crítico centralizado compartido de múltiples salidas, condicionado por la concatenación de observaciones locales, con valores y ventajas calculados por agente. En HAPPO, las ventajas individuales estimadas mediante GAE se reponderan en las actualizaciones secuenciales de los actores; esta adaptación no aplica directamente el lema original de descomposición de ventajas. Los críticos estiman valores durante el entrenamiento en ambos procedimientos, pero no se atribuye al crítico la diferencia entre ellos ni se postula una actualización secuencial del crítico.

Dado que la comparación se basa en procedimientos completos, no es posible aislar el efecto directo de un solo elemento, como la actualización secuencial o el crítico centralizado. Determinar dicho impacto requeriría una retirada de componentes, evaluando el sistema sin esa pieza específica mientras los demás factores permanecen constantes. De este modo, la solución puede contrastarse con los antecedentes recientes en términos de representación, paradigma de entrenamiento y capacidad para tratar agentes heterogéneos. El Capítulo 3 describe cómo se concreta esta propuesta en el diseño experimental.

3

Metodología

Este capítulo describe cómo se entrenan y evalúan en simulación microscópica las políticas de control semafórico. La comparación abarca cuatro algoritmos y tres redes viales sintéticas de complejidad creciente. MAPPO y una adaptación de HAPPO usan entrenamiento centralizado y ejecución descentralizada; IPPO e IDQN aprenden de forma independiente. Los cuatro comparten la interfaz desarrollada para esta tesina, que codifica la espera acumulada por carril mediante una transformación logarítmico-lineal y calcula la recompensa según su variación entre pasos de decisión. Para el centro de Mendoza se construyen una red y una demanda sintética, y se verifica la operación con programas fijos coordinados; no se evalúan allí políticas aprendidas.

La Figura 3.1 resume las seis etapas de la comparación sintética: preparar la geometría y la demanda en SUMO; buscar hiperparámetros en dominios amplios; refinarlos en una segunda fase; seleccionar configuraciones con filtros operacionales en un panel común de semillas; entrenar desde cero un modelo por algoritmo y red; y evaluar la espera, la atención a la demanda y la distribución espacial de las demoras.

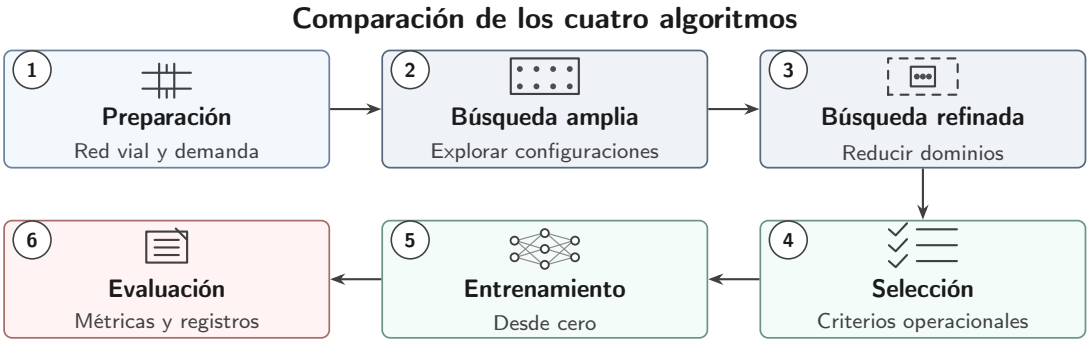


Figura 3.1: Etapas del procedimiento experimental en las redes sintéticas para comparar MAPPO, una adaptación de HAPPO, IPPO e IDQN.

Las secciones 3.1, 3.2 y 3.3 presentan el diseño experimental, los escenarios y la interfaz de control. La búsqueda de hiperparámetros se desarrolla en la Sección 3.4; la evaluación, en la Sección 3.5; y la reproducibilidad y las limitaciones, en la Sección 3.6.

3.1. Diseño experimental

Como el aprendizaje por refuerzo requiere probar repetidamente acciones semafóricas, el diseño experimental utiliza simulación microscópica. Las tres redes sintéticas permiten comparar algoritmos en escenarios de complejidad creciente: un corredor de tres cruces (3×1), una cuadrícula homogénea de nueve cruces (3×3) y una cuadrícula heterogénea de dieciséis ($4 \times 4_H$), con diferencias en carriles, sentidos y fases disponibles. Además, se verifica la operación del modelo del centro de Mendoza, cuya red tiene 74 controladores con programas fijos.

En las tres redes sintéticas, el ajuste de hiperparámetros de MAPPO, la adaptación de HAPPO, IPPO e IDQN se estructura en dos fases sucesivas. La fase 1 explora dominios amplios y la fase 2 refina los intervalos a partir de las configuraciones de mejor desempeño en cada escenario. Una etapa posterior selecciona las configuraciones que cumplen criterios de admisibilidad operacional antes del entrenamiento desde cero de las políticas definitivas.

Como exploración preliminar, se probaron distintas formulaciones de observación y recompensa con MAPPO y se comparó una formulación local con otra vecinal. Esta comparación modificó conjuntamente la observación y la recompensa, por lo que no permite aislar sus efectos individuales. El protocolo refinado de comparación de algoritmos utiliza la formulación local. Las configuraciones y el procedimiento de las pruebas exploratorias se documentan en la Sección A.6 del Apéndice A.

En la selección de configuraciones y en la evaluación final, la espera media se analiza junto con los vehículos insertados y la tasa de viajes completados. Así se comprueba si una menor espera coincide con una menor inserción en los bordes de la red; esta relación no permite atribuir por sí sola la diferencia a una circulación más fluida [JLW+24].

3.2. Escenarios de simulación

Cada escenario reúne una red vial, una demanda y un programa semafórico. La red define las calzadas, los carriles y su conexión; el programa especifica las fases y su secuencia, y la demanda determina los viajes. Los tres escenarios sintéticos y el urbano se simulan en SUMO [ALBBW+18, DLR26]. Primero se describen las redes y sus condiciones comunes; después, la construcción del escenario del centro de Mendoza.

3.2.1. Preparación de las redes de tráfico

La preparación incluyó definir calzadas, carriles por aproximación y longitudes de almacenamiento. Para las redes sintéticas se usó `netedit`; la red de Mendoza se construyó a partir de cartografía de OSM. Los programas semafóricos se definieron por separado: en las redes sintéticas se conservaron los programas fijos de referencia (Tabla 3.3), mientras que en Mendoza se construyó un plan coordinado, descrito en la Sección 3.2.3 y detallado en la Sección A.4 del Apéndice A.

3.2.2. Redes de tráfico sintéticas

Las redes sintéticas comparten las mismas reglas de circulación. La velocidad máxima se limita a 13,89 metros por segundo (50 kilómetros por hora), aunque el tipo de vehículo admita una velocidad mayor. La Tabla 3.1 resume los tres perfiles del archivo `urban_vehicle_mix.add.xml`. Allí, a_{veh} y d_{veh} son la aceleración y la desaceleración, en metros por segundo cuadrado; $v_{\text{máx}}$ es la velocidad máxima, en metros por segundo [DLR26].

Tabla 3.1: Perfiles de vehículos de las redes de tráfico sintéticas.

Perfil (tipo SUMO)	**Proporción**	a_{veh} **(m/s²)**	d_{veh} **(m/s²)**	$v_{\text{máx}}$ **(m/s)**
Lento (`SLOWVEHTYPE`)	25 %	1,9	4,0	8,33
Estándar (`MEDVEHTYPE`)	60 %	2,6	4,5	13,89
Rápido (`FASTVEHTYPE`)	15 %	3,1	5,0	19,44

Los vehículos miden 4,5 metros y mantienen una separación mínima de 2,5 metros (`minGap`). Se utiliza el modelo de seguimiento de Krauss, que determina cómo un vehículo ajusta su velocidad respecto del que circula delante. Su parámetro adimensional $\sigma = 0{,}5$ regula la variabilidad aleatoria de la conducción [Kra98, DLR26].

Las rutas se generaron con `random_routes_taz.py` a partir de matrices origen-destino (*Origin-Destination*, OD), que distribuyen el flujo entre las zonas TAZ perimetrales de cada red. Los archivos expresan la demanda solicitada en vehículos por hora mediante el atributo `vehsPerHour` de SUMO. La construcción de las matrices y las asignaciones principales se detallan en la Sección A.5.3 del Apéndice A.

La Figura 3.2 muestra las tres redes a partir de sus archivos XML. Los puntos señalan intersecciones controladas y las flechas, el sentido de circulación. Las franjas representan

carriles; cuando hay sentidos opuestos, se dibujan a ambos lados del eje vial. Las escalas y los anchos son convencionales y varían entre paneles. Las zonas TAZ se definen mediante los tramos de entrada y salida del perímetro. Para cada intersección i, m_i indica el número de carriles entrantes controlados y K_i, las fases verdes seleccionables. Las redes 3×1 y 3×3 tienen cuatro accesos por cruce y dos carriles por sentido. En cambio, la red $4 \times 4_H$ combina tramos de uno a cuatro carriles por sentido e incluye arterias de mano única.

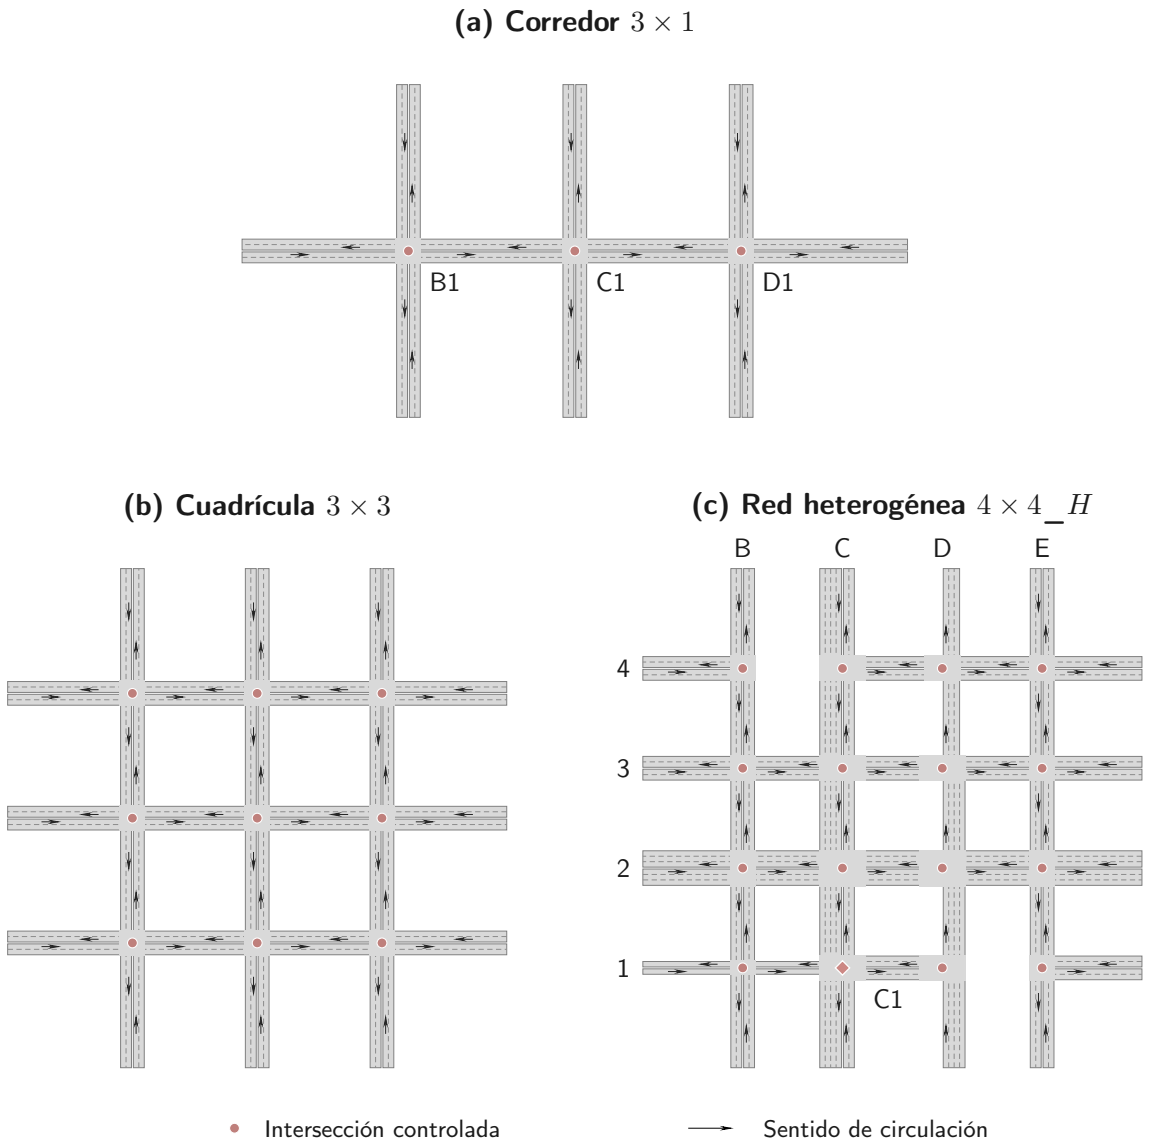


Figura 3.2: Redes sintéticas: (a) corredor 3×1, (b) cuadrícula 3×3 y (c) red heterogénea $4 \times 4_H$.

Los paneles permiten comparar las siguientes características:

- **Panel (a) — Corredor** 3×1**:** consta de tres cruces alineados (B1, C1 y D1). El 75 % del flujo solicitado se concentra en ambos sentidos de la arteria horizontal y el 25 % restante se reparte entre los pares transversales válidos, lo que permite

analizar la propagación longitudinal de colas y la coordinación sobre una corriente dominante.

- **Panel (b) — Cuadrícula 3×3:** dispone de nueve cruces en una grilla regular con dimensiones locales uniformes de observación y acción ($m_i = 8$, $K_i = 2$), orientada a evaluar el acoplamiento bidimensional entre intersecciones interiores y perimetrales.
- **Panel (c) — Cuadrícula heterogénea $4 \times 4_H$:** abarca dieciséis cruces organizados en las columnas B a E (oeste a este) y las filas 1 a 4 (sur a norte), con ausencia deliberada de los tramos horizontales B4–C4 y D1–E1. La fila 2 conforma una arteria de tres carriles por sentido, mientras que el acceso oeste hacia B1 y el tramo B1–C1 poseen un solo carril por sentido; la columna C cuenta con cuatro carriles hacia el sur y dos hacia el norte, y la columna D opera en sentido único hacia el norte. Asimismo, la intersección C1 (destacada con un rombo) admite tres acciones ($K_{\mathrm{C1}} = 3$ por incluir fase de giro protegido), frente a las dos acciones de los quince cruces restantes.

Las redes sintéticas tienen una separación nominal de 100 metros entre centros de cruces consecutivos. En 3×3 y $4 \times 4_H$, la longitud efectiva de almacenamiento de cada tramo es ligeramente menor porque los carriles de aproximación finalizan en el borde de la caja interna de la intersección. Para caracterizar las redes de manera uniforme se contabilizan únicamente los tramos de circulación y sus carriles de aproximación y salida, excluyendo los conectores internos con los que SUMO modela las trayectorias dentro del cruce.

El grado de vecindad cuenta los vecinos directos de cada agente; el criterio para establecer esa relación se explica en la Sección 3.3.1. La Tabla 3.2 reúne la topología, la demanda y las dimensiones del control. Los intervalos muestran la variación entre agentes de una misma red.

Tabla 3.2: Topología, control y demanda de las redes sintéticas. Se excluyen los tramos y carriles internos de los cruces.

Característica	**3×1**	**3×3**	**$4 \times 4_H$**
Agentes	3	9	16
Tramos de circulación	20	48	71
Carriles	40	96	166
Carriles por tramo y sentido	2	2	1–4
Carriles entrantes controlados (m_i)	8	8	5–12
Acciones por agente (K_i)	2	2	2 o 3
Grado de vecindad	1–2	2–4	1–4
Zonas de análisis de tránsito	8	12	16
Flujo solicitado (vehículos por hora)	3.260	7.087	7.202

La Tabla 3.3 resume las secuencias de los programas semafóricos de referencia. Cada ciclo dura 90 segundos; la Figura A.5 del Apéndice A muestra su distribución temporal. En la tabla, V_i es el verde de la fase i, A_i el intervalo amarillo (3 s) y R el intervalo de todo rojo o despeje (1 s).

En la red $4 \times 4_H$, la tabla identifica la fase de giro protegido de C1 y el intervalo de todo rojo de C4 y D1. Las restricciones temporales del control aprendido se describen en la Sección 3.3.2.

Tabla 3.3: Duraciones de los programas semafóricos de referencia en las redes de tráfico sintéticas (segundos).

Red de tráfico e intersecciones	**Secuencia cronológica de fases e intervalos**	**Ciclo**
3×1: todas (3)	$V_1 = 42,\ A_1 = 3,\ V_2 = 42,\ A_2 = 3$	90 s
3×3: todas (9)	$V_1 = 42,\ A_1 = 3,\ V_2 = 42,\ A_2 = 3$	90 s
$4 \times 4_H$: 13 intersecciones con secuencia común	$V_1 = 42,\ A_1 = 3,\ V_2 = 42,\ A_2 = 3$	90 s
$4 \times 4_H$: C1	$V_1 = 38,\ A_1 = 3,\ V_2 = 37,\ A_2 = 3,$ $V_3 = 6$ (giro protegido), $A_3 = 3$	90 s
$4 \times 4_H$: C4 y D1	$V_1 = 42,\ A_1 = 3,\ V_2 = 41,\ A_2 = 3,$ $R = 1$ (todo rojo)	90 s

3.2.3. Red de tráfico de la Ciudad de Mendoza

El escenario del centro de Mendoza representa una red vial urbana de geometría irregular. La configuración actual, `mendoza_220k_balance`, usa demanda sintética nominal de 220.000 viajes diarios, distribuida entre 37 zonas TAZ, y 74 controladores semafóricos fijos. Esta configuración actualiza la variante previa O2/P2 con otra red y demanda.

Dominio y datos disponibles

La red vial se obtuvo de cartografía de OSM mediante `netconvert` y se proyectó en sistema de coordenadas universal transversal de Mercator (*Universal Transverse Mercator*, UTM) zona 19S, con referencia Sistema Geodésico Mundial 1984 (*World Geodetic System 1984*, WGS84). Las imágenes satelitales y los relevamientos de vista de calle sirvieron para corregir sentidos, carriles por aproximación, conectores de giro e ingresos laterales en Catamarca, Buenos Aires y Leandro N. Alem. El área abarca José Vicente Zapata y Colón al sur, Manuel Belgrano al oeste, Las Heras al norte y la avenida General San Martín como eje norte–sur.

La Figura 3.3 resume la preparación de la red, desde la cartografía hasta su conversión y depuración en SUMO. El esquema ilustra esas etapas, pero no reproduce la geometría final de Mendoza balance.

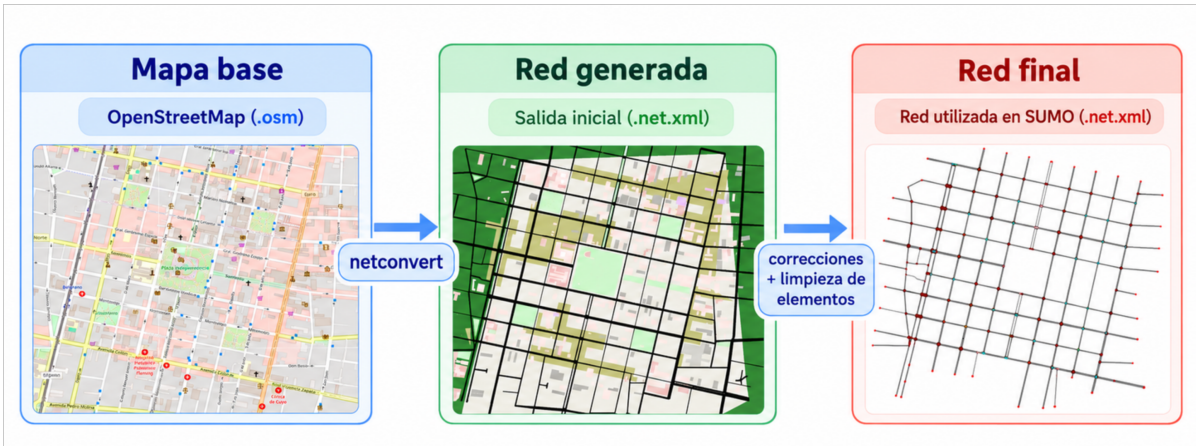


Figura 3.3: Esquema ilustrativo de la preparación de la red vial: cartografía, conversión mediante `netconvert` y depuración. No representa la topología final del escenario balance. Cartografía: © colaboradores de OpenStreetMap (`https://www.openstreetmap.org/copyright`).

La red tiene 255 tramos, 554 carriles y 744 conexiones. El archivo de zonas contiene 37 TAZ, asociadas con 517 pares OD activos y 6.204 flujos horarios.

El perfil horario heredado se calculó a partir de 32 días hábiles de registros de la cámara 169, asociada al acceso oriental de la zona TAZ 28. El promedio informado fue de 25.175,84 vehículos diarios. La cámara está fuera del área modelada; sus conteos parciales no bastan para determinar una matriz urbana origen–destino.

La cámara aporta el perfil horario. Para distribuir espacialmente los flujos se resolvió un problema lineal por hora sobre rutas explícitas. La asignación cambia las marginales OD frente a la referencia anterior y evita el giro Benegas→Civit. Los conteos disponibles no permiten calibrar las tasas de cada movimiento ni la demanda completa [vZW80].

La Figura 3.4 ubica los controladores, las avenidas de referencia y el acceso asociado a la zona TAZ 28. La Figura A.6 representa las zonas mediante sus tramos de acceso, no como polígonos o límites territoriales.

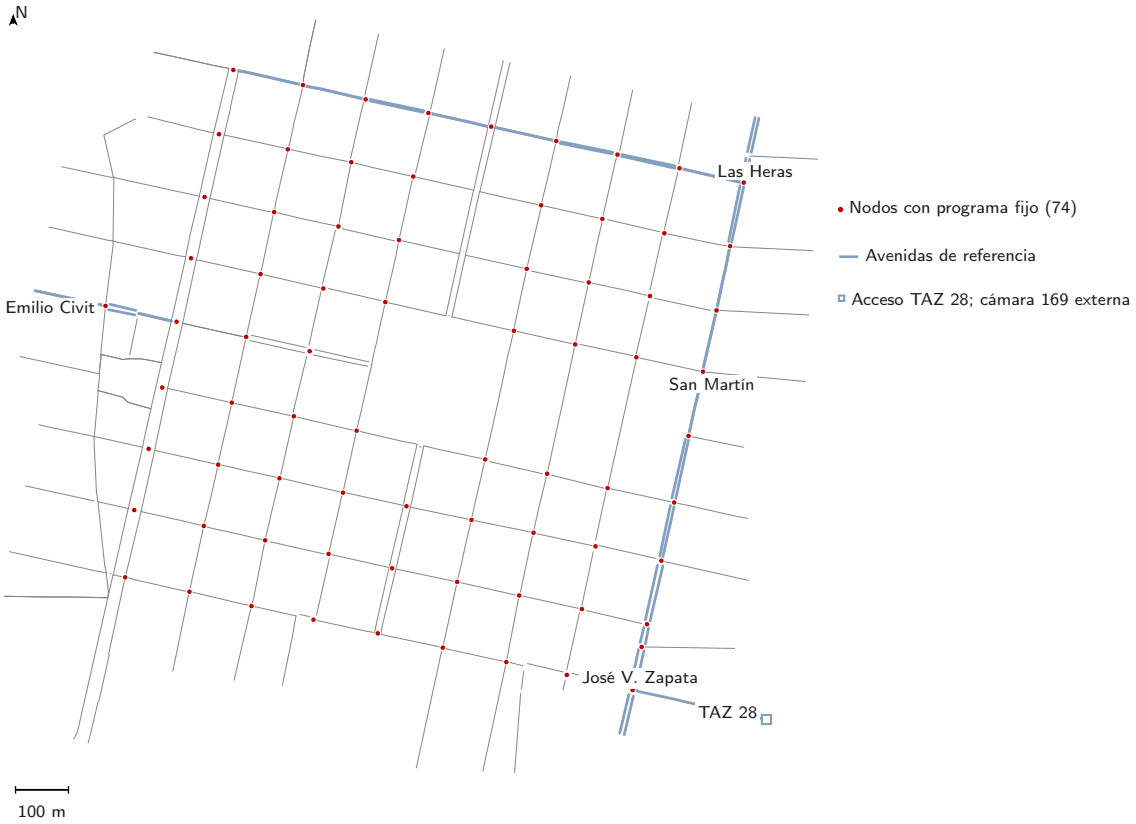


Figura 3.4: Dominio de Mendoza balance: controladores fijos (puntos rojos), avenidas de referencia y acceso asociado a la zona TAZ 28.

Construcción del plan fijo

Los 74 controladores operan con programas fijos incluidos en la red. El ciclo de 90 segundos y los desfases, que determinan el inicio de cada programa respecto del ciclo, son conceptos de coordinación semafórica [Fed08, cap. 6]. El ciclo es una decisión del escenario, no un óptimo estimado. La configuración actual incorpora un controlador respecto del plan previo, redistribuye el tiempo de verde a partir de las duraciones anteriores y fija en cinco segundos el intervalo amarillo.

La configuración de cada programa está registrada en el archivo de red y en su manifiesto.

Construcción de la demanda y selección del volumen nominal

La demanda se distribuye en flujos horarios con rutas explícitas. Un programa lineal ajustó la asignación espacial por hora: la solución evita el giro Benegas→Civit y modifica las marginales OD frente a la especificación previa. La redistribución afecta entre 11,6 % y 23,6 % de la demanda de cada hora. Esta distribución responde a decisiones de construcción y análisis sintético; no es una matriz calibrada con conteos completos.

El nominal de 220.000 viajes diarios describe la escala de la demanda, no el volumen servido durante una ventana. La integral de las tasas de 06:00 a 18:00 corresponde a 152.168,75 solicitudes esperadas. Esta cifra no equivale a los vehículos cargados, insertados

o llegados ni estima la capacidad vial.

La Figura 3.5 muestra las solicitudes esperadas por hora según la convención temporal del escenario. Las dos ventanas comienzan por separado con la red vacía: la de 12 h cubre $[0, 43.200)$ s y la de 2 h, $[1.800, 9.000)$ s. Por eso, la ventana corta no reproduce el estado de la simulación larga a las 06:30.

La generación de solicitudes es estocástica [Ecl26a], de modo que los conteos varían entre semillas. Si no encuentran una brecha suficiente en el carril de entrada, los vehículos permanecen pendientes de ingreso.

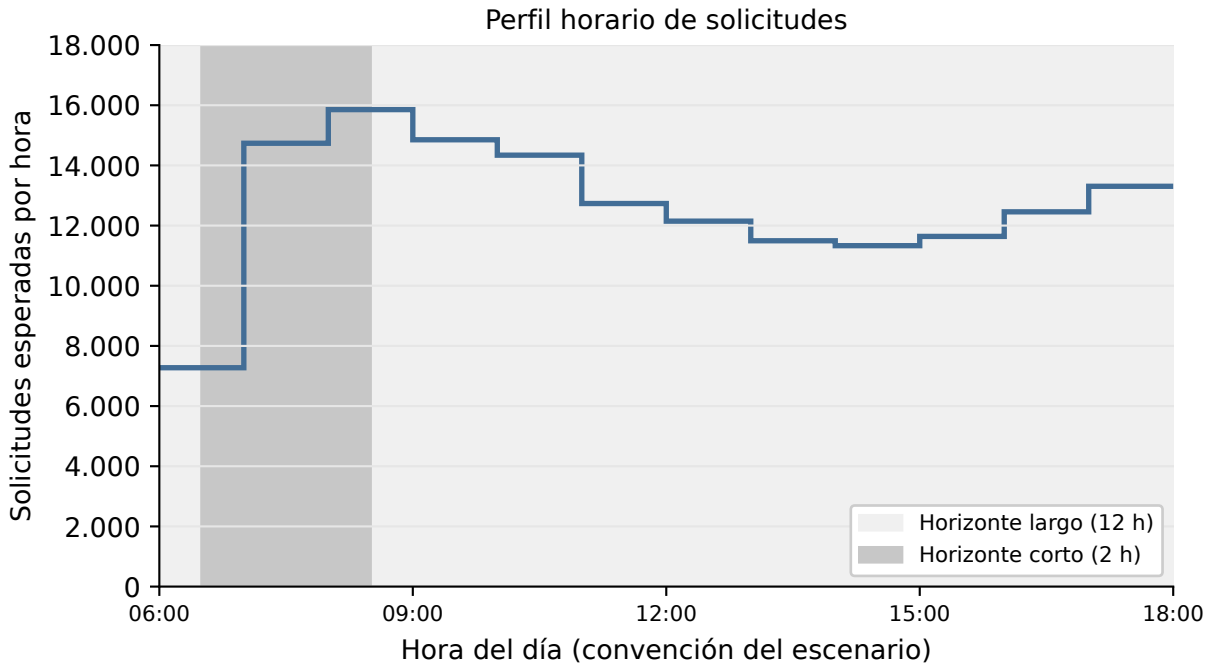


Figura 3.5: Solicitudes esperadas por hora y horizontes de evaluación en el escenario de Mendoza: corto (06:30–08:30, 2 h) y largo (06:00–18:00, 12 h).

La Figura 3.6 resume cómo se relacionan la red, la demanda, las zonas y la configuración de SUMO. La red reúne la geometría, las conexiones y los programas semafóricos; las rutas contienen los viajes, y los archivos adicionales vinculan las zonas con otros elementos. Las configuraciones balance comparten estas entradas y usan un paso de un segundo, pero corresponden a ventanas independientes: 12 h (0–43.200 s) y 2 h (1.800–9.000 s).

La configuración establece un umbral de teletransporte de 300 segundos y `max-num-teleports=0`; también registra las colisiones como advertencias y asocia las zonas con intersecciones. No especifica destinos de salida. La Sección A.4.1 del Apéndice A documenta las opciones y los hashes empleados para identificar el escenario.

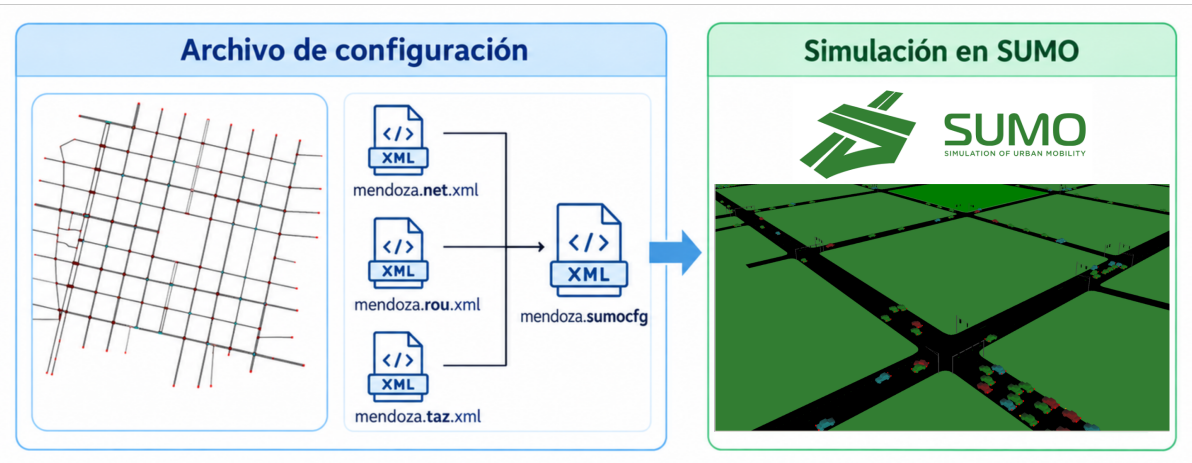


Figura 3.6: Esquema ilustrativo de entradas, configuración y visualización del escenario urbano en SUMO; no representa los nombres de archivo efectivos de Mendoza balance.

Verificación del escenario, aceptación y alcance

La evidencia actual comprende una semilla de desarrollo (104729) y tres semillas confirmatorias nuevas (2026102001, 2026102002 y 2026102003), cada una evaluada en las dos ventanas. Las ventanas comienzan por separado con la red vacía; sus dos resultados de una misma semilla no son réplicas independientes adicionales. Las tres semillas nuevas completaron ambos horizontes. Este presupuesto no es un cálculo de precisión estadística y la condición inicial debe considerarse al interpretar los resultados [Law15].

El criterio de aceptación exige cero teletransportes, cero colisiones registradas, cero descartes y una tasa CR de al menos 0,75. Los registros de las tres semillas confirmatorias y de la semilla de desarrollo se distinguen en la Sección A.4.1 del Apéndice A. La ausencia de colisiones registradas depende de las opciones de SUMO y no certifica seguridad física.

La simulación conserva vehículos pendientes de ingreso, especialmente desde los orígenes de Las Heras, y congestión en otros sectores. Tres semillas no demuestran robustez ante cualquier semilla o versión del simulador.

Esta comprobación describe el escenario urbano con demanda sintética y programas fijos; no evalúa políticas aprendidas. Contrastar el modelo con el tránsito real requeriría conteos independientes por movimiento y mediciones de tiempos de viaje en corredores interiores [Sar13, WVW19].

3.3. Sistema de control multiagente

En las redes sintéticas, el sistema de aprendizaje transforma las mediciones microscópicas del tránsito en observaciones locales y traduce las decisiones de los agentes en estados semafóricos dentro del simulador. Los cuatro algoritmos comparten esta interfaz, que sigue el ciclo agente–entorno presentado en el Capítulo 2.

Cada agente i gobierna las señales de una intersección (o de un conjunto de nodos asociados a un mismo controlador semafórico), caracterizada por m_i carriles entrantes

controlados y K_i fases verdes seleccionables. Los intervalos de cambio amarillo y el estado inicial de despeje en todo rojo son gestionados automáticamente por el entorno durante las transiciones y la inicialización, por lo que no forman parte del espacio de decisiones discretas del agente.

Ray proporciona una infraestructura de cómputo distribuido. Sobre ella, RLlib organiza el aprendizaje por refuerzo y Ray Tune coordina los ensayos de búsqueda de hiperparámetros [LLN+18a, LLN+18b]. El paquete desarrollado, `marlTLC`, integra SUMO con RLlib y utiliza PyTorch para implementar y optimizar las redes neuronales [PGM+19].

RLlib separa la obtención de experiencia de la actualización de los modelos. El grupo de muestreo (`EnvRunnerGroup`) reúne trabajadores que interactúan con el entorno y generan episodios. El grupo de aprendizaje (`LearnerGroup`) utiliza esos datos para calcular las pérdidas y actualizar los pesos, que luego se sincronizan con los trabajadores de muestreo [Ray26].

La Figura 3.7 resume este ciclo y muestra los módulos de redes neuronales (`RLModule`), agrupados para el caso multiagente. El fragmento de configuración y la estructura de actor y crítico son ilustrativos; no representan una configuración común a los cuatro algoritmos de esta tesina. La procedencia específica de los recursos gráficos queda pendiente de confirmación documental.

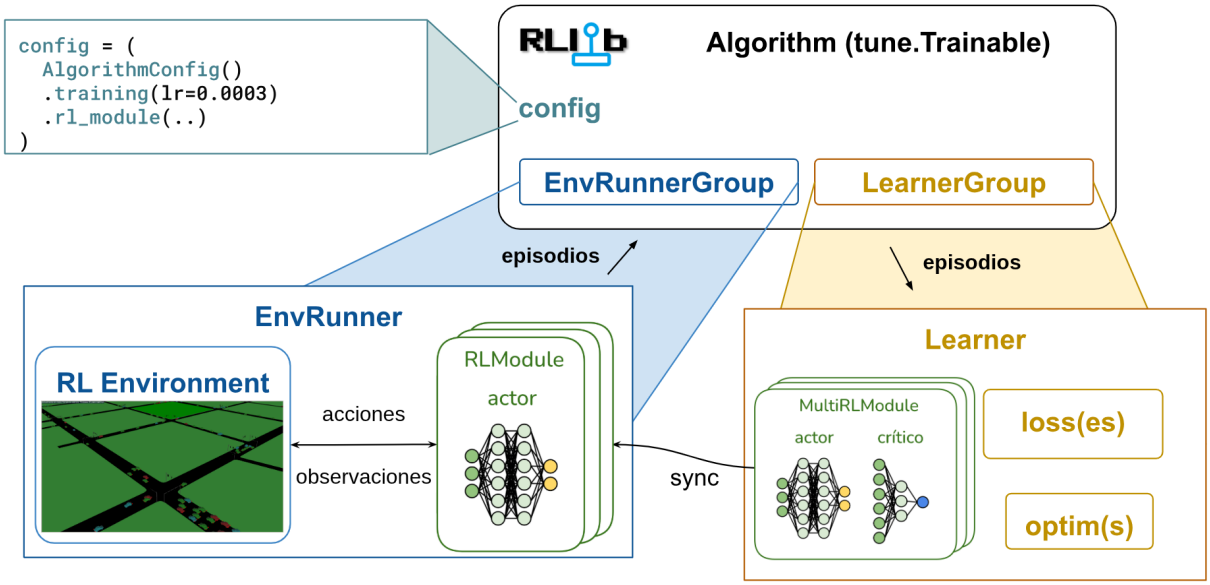


Figura 3.7: Esquema conceptual del muestreo y el aprendizaje en Ray RLlib, según su documentación oficial [Ray26].

En la implementación de `marlTLC`, `BaseSumoEnvironment` controla la simulación mediante `libsumo` y su subclase `SumoRllibEnv` adapta esas operaciones a la interfaz multiagente de RLlib. Durante el muestreo, los trabajadores de RLlib envían las acciones semafóricas al entorno y reciben observaciones, recompensas e indicadores de cierre. El

entorno también registra los viajes en `TripInfo` para su evaluación. La relación entre las clases de esta interfaz se detalla en la Sección A.1 del Apéndice A.

3.3.1. Entorno de simulación

Al inicio de cada experimento, el entorno ejecuta el período de calentamiento configurado y guarda una instantánea del estado de SUMO al comienzo de la ventana de control. Cada llamada a `reset` restaura esa instantánea, reinicia los contadores y la contabilidad de espera por carril, y coloca los semáforos en todo rojo. En cada llamada a `step`, el entorno aplica las acciones de los agentes y ejecuta las transiciones amarillas necesarias. Luego avanza la simulación hasta el siguiente instante de decisión y devuelve las nuevas observaciones, recompensas e indicadores del episodio.

El episodio concluye al agotarse el horizonte temporal estipulado o, cuando se activa la opción `terminate_on_empty`, al vaciarse por completo la red y la cola de inserción (verificado mediante `getMinExpectedNumber`). La interfaz sigue el estándar de Gymnasium/RLlib y distingue los indicadores de terminación (`terminated`) y truncamiento por límite de tiempo (`truncated`). En los experimentos sobre las redes sintéticas se utilizó la configuración `time_limit_as_truncation=False`, bajo la cual el cierre por horizonte activa ambos indicadores e inhibe el *bootstrapping* del valor del estado final en la estimación de ventaja generalizada (véase la Ecuación (2.18) del Capítulo 2).

Finalmente, la topología de acoplamiento entre intersecciones se construye de forma automática a partir del grafo vial: el entorno define como vecinos directos a dos agentes siempre que al menos un conector saliente de un carril controlado por el primero desemboque en un carril entrante controlado por el segundo, registrando una relación de adyacencia simétrica para ambos.

3.3.2. Observación, acciones y recompensas

La formulación del problema representa el estado operativo de cada intersección a partir de la fase activa y de la espera vehicular por carril, restringe las acciones mediante una máscara dependiente del tiempo transcurrido y define la recompensa a partir de la variación de la espera entre pasos de decisión consecutivos.

Observaciones y codificación de la espera

En cada paso de decisión t, el agente i recibe una observación local $o_i^{(t)}$ conformada por el índice de su fase activa $p_i^{(t)}$ (que incluye un código específico para el estado inicial de todo rojo) y las esperas codificadas de sus m_i carriles entrantes controlados:

$$o_i^{(t)} = \big(p_i^{(t)}, e(w_{i,1}^{(t)}), \ldots, e(w_{i,m_i}^{(t)})\big), \tag{3.1}$$

donde $w_{i,l}^{(t)}$ denota la espera acumulada atribuida al carril l del agente i (en veh·s) y $e(\cdot)$ es una función de discretización en I niveles enteros dentro del conjunto $\{0, 1, \ldots, I-1\}$.

Las políticas operan de manera reactiva sobre $o_i^{(t)}$, sin almacenar un historial recurrente de observaciones pasadas.

Para calcular $w_{i,l}^{(t)}$, el entorno consulta la espera acumulada de cada vehículo presente en el carril mediante `getAccumulatedWaitingTime` de SUMO. Esta lectura abarca una ventana móvil de 1.000 s, fijada por `waiting_time_memory` [Ecl26c]. Para evitar el doble cómputo al cambiar de carril, el entorno descuenta las esperas previamente atribuidas a ese vehículo en otros carriles y sustituye por cero los resultados negativos. La suma de los carriles controlados da la espera de la intersección: $W_i^{(t)} = \sum_{l=1}^{m_i} w_{i,l}^{(t)}$.

La salida de vehículos, sus cambios de carril y el vencimiento de la ventana de memoria pueden reducir la señal local sin que disminuya la espera acumulada por viaje. Esta última se evalúa con `TripInfo.waitingTime`, que acumula la espera durante todo el viaje sin esa ventana de olvido [Ecl26d].

La función codificadora $e(x)$ proyecta la espera acumulada por carril sobre I niveles. Cuando $x \geq M_{\text{lane}}$, asigna el nivel máximo; los valores que superan la cota se limitan a M_{lane}. Para valores inferiores, combina una transformación logarítmica —que otorga mayor poder discriminativo a las esperas bajas y moderadas— con una componente lineal, seguida de un redondeo hacia arriba (ceil). Su formulación algebraica exacta se desarrolla en la Sección A.7.1 del Apéndice A.

El número de niveles I forma parte de los hiperparámetros explorados en las búsquedas. La cota de escala M_{lane} (`max_lane_value`) se fijó en una calibración previa con 300 s de calentamiento, a partir del percentil 99 del máximo por paso de $w_{i,l}^{(t)}$. Se obtuvieron 1.184, 1.136 y 712 veh·s para las redes 3×1, 3×3 y $4 \times 4_H$, respectivamente.

La Figura 3.8 ilustra la curva escalonada producida por $e(x)$ para $I = 22$ niveles y $M_{\text{lane}} = 1.136$ veh·s (red 3×3). Se aprecia cómo los intervalos de cuantización se estrechan cerca del origen —por ejemplo, $e(0) = 0$, $e(120) = 10$ y $e(600) = 18$— y se ensanchan progresivamente hacia el extremo superior de la escala.

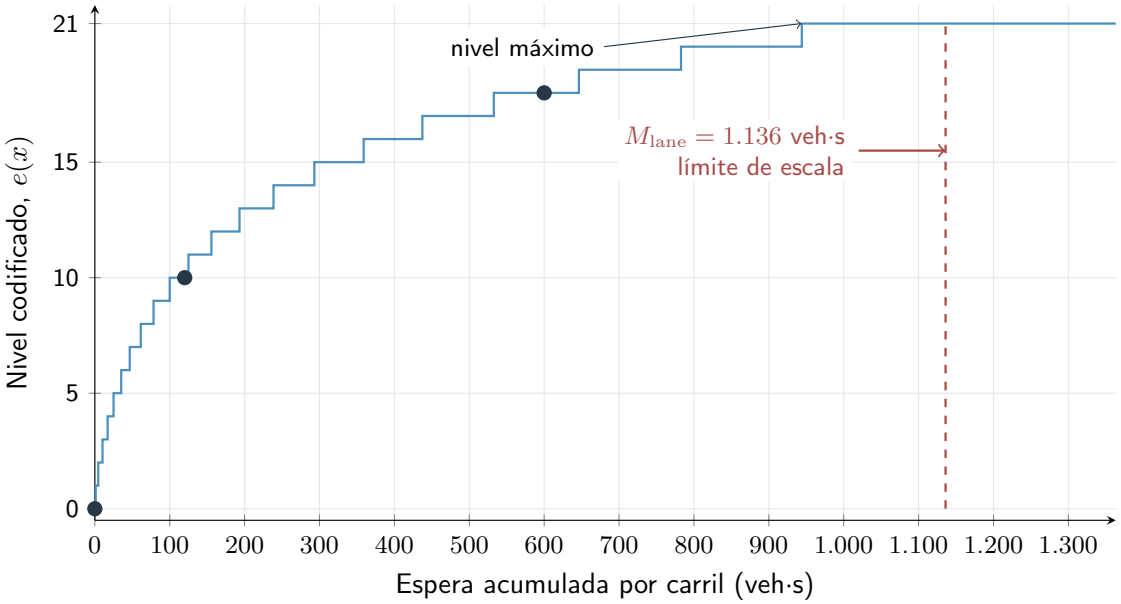


Figura 3.8: Curva de cuantización del codificador local de espera para $I = 22$ niveles y $M_{\text{lane}} = 1.136$ veh·s.

Acciones permitidas y cambios de fase

A partir de la observación recibida, el agente i selecciona una fase verde dentro del conjunto discreto $\{0, 1, \ldots, K_i - 1\}$. Una máscara de acciones restringe la elección a las fases compatibles con el tiempo mínimo de verde y las transiciones amarillas.

Los agentes toman decisiones cada $\Delta t = 5\,\text{s}$. Al mantener la fase activa, ese intervalo transcurre íntegramente en verde. Si solicitan un cambio permitido, el entorno ejecuta 4 s de amarillo y 1 s de verde de la nueva fase dentro del mismo paso de decisión. La nueva fase debe permanecer al menos 5 s en verde antes de admitir otro cambio. Al comenzar el episodio, el paso del estado inicial de todo rojo al verde se realiza directamente, sin amarillo.

La Figura 3.9 muestra cómo estas restricciones afectan las decisiones. Si se acepta un cambio en $t = 0\,\text{s}$, el verde comienza en $t = 4\,\text{s}$. En la decisión de $t = 5\,\text{s}$ solo ha transcurrido un segundo de verde y la máscara obliga a mantener la fase. El mínimo se cumple en $t = 9\,\text{s}$, pero la siguiente oportunidad de decidir llega en $t = 10\,\text{s}$, tras seis segundos efectivos de verde.

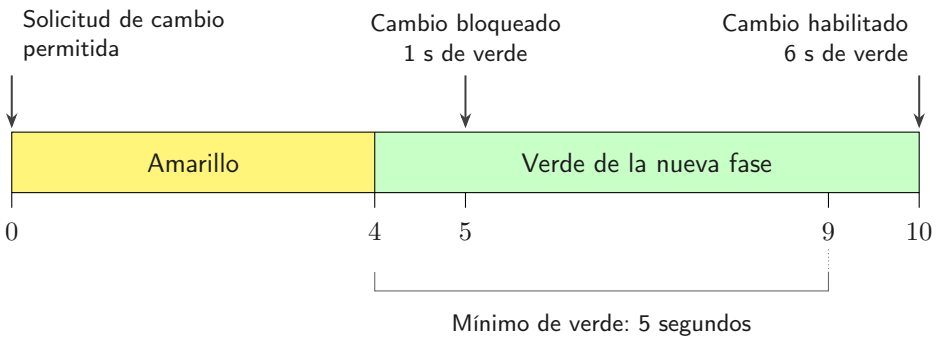


Figura 3.9: Línea temporal de transición de fase y bloqueo por máscara de acciones con decisiones cada $\Delta t = 5\,\mathrm{s}$.

En IPPO, MAPPO y HAPPO, la máscara anula las acciones inválidas desplazando sus *logits* antes de la normalización *softmax*. En IDQN, las excluye del cálculo del máximo valor de acción. La formulación se detalla en la Sección A.7.2 del Apéndice A.

Señal de recompensa

La recompensa local $L_i^{(t)}$ es la diferencia entre las esperas acumuladas atribuidas a la intersección i en dos pasos de decisión consecutivos (en veh·s); toma valores positivos cuando la espera atribuida disminuye:

$$L_i^{(t)} = W_i^{(t-1)} - W_i^{(t)}. \tag{3.2}$$

En la fase 1, la recompensa combina la señal local $L_i^{(t)}$ con un promedio de señales vecinales sin dividir por el número de carriles; el peso vecinal ρ_{coop} se explora en el intervalo $[0;\, 0{,}95)$. En la fase 2 (búsqueda refinada), la recompensa es estrictamente local ($R_i^{(t)} = L_i^{(t)}$) y se fija $\rho_{\text{coop}} = 0$. La Tabla 3.4 resume las observaciones y recompensas utilizadas en las redes sintéticas.

Tabla 3.4: Observaciones y recompensas en las fases de búsqueda con redes sintéticas.

Procedimiento	**Observación**	**Recompensa**	**Peso vecinal**
Fase 1: búsqueda amplia	Local	Local y vecinal, sin normalización por carriles	$[0;\, 0{,}95)$
Fase 2: búsqueda refinada	Local	Local	0

3.3.3. Agentes y algoritmos de aprendizaje

La implementación de los cuatro algoritmos en `marlTLC` adapta a una interfaz común de Ray RLlib las formulaciones generales presentadas en la Sección 2.3 y en las secciones 2.3.5 y 2.3.6 del Capítulo 2. Sus decisiones de arquitectura y aprendizaje son las siguientes:

- **Parámetros independientes por intersección:** en los cuatro algoritmos, cada agente cuenta con su propia red neuronal sin compartir pesos (*parameter sharing*), lo que permite acomodar de manera directa las dimensiones heterogéneas de entrada (m_i) y de salida (K_i) presentes en $4 \times 4_H$.

- **Aprendizaje independiente en IDQN e IPPO:** ambos métodos estiman valores y actualizan sus parámetros empleando únicamente las observaciones locales $o_i^{(t)}$ y las recompensas $R_i^{(t)}$ de cada intersección. En IDQN, cada agente entrena su red de valores de acción con una red objetivo actualizada periódicamente y una memoria de experiencias multiagente (*replay buffer*) con muestreo priorizado según la magnitud del error de diferencia temporal. En IPPO, cada intersección entrena un actor y un crítico locales sobre lotes de episodios *on-policy*, y estandariza por agente las ventajas estimadas mediante GAE.

- **Crítico centralizado con salidas por agente en MAPPO y HAPPO:** siguiendo el esquema CTDE (Figura 2.19), el crítico centralizado recibe la concatenación de las observaciones de todos los agentes. Si hay N agentes, produce N salidas escalares de valor asociadas a sus respectivas recompensas individuales.

  Antes de actualizar las políticas, las ventajas se estandarizan por agente restando su media y dividiendo por su desviación estándar. Para acotar el impacto de valores atípicos, la pérdida del crítico satura en el umbral c_v (`vf_clip_param`) el error cuadrático medio entre agentes de cada transición (Ecuación (A.4) del Apéndice A).

- **Orden de actualización en HAPPO:** en cada época, se actualiza primero el crítico y luego los actores, de forma secuencial y con el lote completo de transiciones por agente. El orden $i_1, \ldots, i_N$ se fija antes de actualizar los actores. En cada posición, `greedy_selection_prob` determina la probabilidad de elegir al agente pendiente con mayor media de ventaja absoluta estandarizada $|\hat{A}_i|$; en caso contrario, se elige al azar entre los restantes.

  La adaptación conserva el factor acumulado $M_{i_{1:m}}$ de la actualización secuencial. Como cada agente recibe una recompensa individual, la garantía de mejora monótona de HAML no se aplica bajo su supuesto de recompensa compartida (Sección 2.3.6). La secuencia implementada se detalla en la Sección A.7 del Apéndice A.

La Figura 3.10 contrasta el flujo de actualización de actores entre ambos métodos centralizados para un caso ilustrativo de tres agentes (i_1, i_2, i_3). En el panel (a), correspondiente a MAPPO, los actores se actualizan en paralelo empleando únicamente sus ventajas por agente $\hat{A}_i$. En el panel (b), correspondiente a HAPPO, los actores se actualizan de manera secuencial y cada agente transfiere al siguiente el factor acumulado de razones de verosimilitud, actualizado después de optimizar cada actor (representado mediante las flechas horizontales discontinuas).

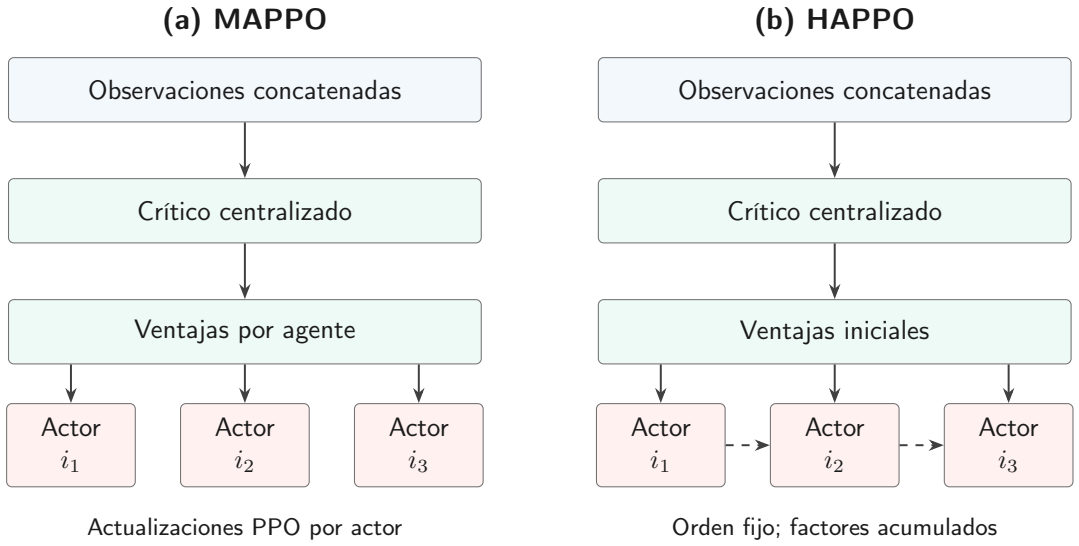


Figura 3.10: Esquema de actualización de actores con tres agentes ilustrativos: (a) actualización paralela en MAPPO; (b) actualización secuencial con propagación del factor acumulado en HAPPO.

3.4. Entrenamiento y búsqueda de hiperparámetros

La optimización de hiperparámetros (*Hyperparameter Optimization*, HPO) busca configuraciones de aprendizaje y aplica el mismo máximo de iteraciones por ensayo a los cuatro algoritmos. Se organiza en dos fases: la primera explora dominios amplios, dos tamaños de perceptrón multicapa y el peso vecinal; la segunda refina los dominios y usa recompensa local. Cada ensayo entrena una configuración candidata durante un número limitado de iteraciones de entrenamiento. En la familia PPO, el tamaño objetivo del lote se expresa en episodios; en IDQN, en transiciones extraídas del *replay buffer* descrito en la Sección 3.3.3. La Sección A.5.4 del Apéndice A detalla el espacio de búsqueda.

Los diagnósticos permiten seguir el aprendizaje durante la búsqueda. Luego, un panel común de simulaciones sirve para seleccionar las configuraciones candidatas. La evaluación final se realiza con modelos entrenados desde cero y semillas independientes.

Optuna registra las configuraciones evaluadas y los valores de la función objetivo. Integrado con Ray Tune, propone nuevas configuraciones a partir de los resultados disponibles, mientras Ray Tune organiza la ejecución de los ensayos [ASY+19, LLN+18b].

El estimador de Parzen estructurado en árbol (*Tree-structured Parzen Estimator*, TPE) genera las propuestas separando los ensayos previos en dos grupos: los que obtuvieron mejores valores de la función objetivo y los restantes. Luego compara las distribuciones de sus hiperparámetros y favorece configuraciones más características del grupo de mejores resultados [BBBK11].

La búsqueda usa algoritmo asíncrono de reducción sucesiva a la mitad (*Asynchronous Successive Halving Algorithm*, ASHA) para detener ensayos de forma temprana. El período de gracia establece cuántas iteraciones deben completarse antes de considerar una detención. Después, ASHA compara resultados intermedios de ensayos con niveles de entrenamiento similares y continúa los más prometedores. El factor de reducción determina qué fracción prosigue; cuanto mayor es, más selectiva resulta la continuación [LJR+20].

3.4.1. Condiciones de simulación y entrenamiento

La Tabla 3.5 resume el calentamiento y la duración de cada procedimiento.

Tabla 3.5: Calentamiento y horizonte de simulación por procedimiento.

Procedimiento	**Calentamiento**	**Horizonte**
Redes sintéticas, búsqueda de fase 1	600 s	3.600 s
Redes sintéticas, búsqueda de fase 2	600 s	3.600 s
Redes sintéticas, entrenamiento y evaluación final	600 s	3.600 s
Mendoza, aceptación con programas fijos (12 h)	No se añade	43.200 s
Mendoza, aceptación con programas fijos (2 h)	No se añade	7.200 s

En la fase 1, una semilla inicializa el aprendizaje y la simulación de SUMO durante el entrenamiento; otra controla las simulaciones de diagnóstico, y una tercera, independiente de la primera, inicializa el muestreador TPE. La Tabla A.13 reúne estas semillas y las asociadas a los perfiles canónicos de generación de rutas; la Tabla A.14 presenta las de la búsqueda refinada.

Durante el entrenamiento se intercalan episodios de diagnóstico, en los que las acciones se eligen de forma determinista: los métodos basados en PPO seleccionan la acción permitida con mayor probabilidad y IDQN, la de mayor valor estimado. Sus registros se almacenan por separado y no forman parte del objetivo de optimización.

3.4.2. Función objetivo de la búsqueda

La búsqueda minimiza el objetivo compuesto J_r, expresado en segundos por vehículo, que combina la espera media con una penalización por inestabilidad reciente. En cada iteración válida de entrenamiento r, la espera media por vehículo insertado w_r se calcula como la suma de los tiempos de espera (`TripInfo.waitingTime`) de los episodios completados dividida por el total de vehículos insertados en ellos.

Para medir la inestabilidad reciente se excluyen las primeras cinco mediciones válidas del ensayo y se conserva una ventana con hasta las diez más recientes. Cada par consecutivo de esa ventana aporta un incremento no negativo de espera $\Delta w_s = \max(0, w_s - w_{s-1})$, con $s = 1, \ldots, n$ y un máximo de nueve diferencias.

La penalización T_r captura los aumentos más severos de espera: es el promedio del 20 % de los incrementos mayores, inspirado en el concepto de valor en riesgo condicional (*Conditional Value at Risk*, CVaR) sobre una muestra finita. Para calcularla se ordenan los incrementos de mayor a menor, $\Delta w_{(1)} \geq \cdots \geq \Delta w_{(n)}$, y se toman los primeros $k = \lceil 0{,}2n \rceil$. El objetivo combina la espera de la iteración actual con esta penalización:

$$J_r = w_r + T_r, \qquad \text{con} \quad T_r = \begin{cases} \dfrac{1}{k} \displaystyle\sum_{j=1}^{k} \Delta w_{(j)}, & \text{si } n > 0 \;\; \big(k = \lceil 0{,}2n \rceil\big), \\ 0, & \text{si } n = 0. \end{cases} \tag{3.3}$$

3.4.3. Fase 1: búsqueda amplia

La fase 1 combina los cuatro algoritmos y las tres redes sintéticas con dos arquitecturas de perceptrón multicapa: `h128`, con dos capas ocultas de 128 unidades cada una, y `h256`, con dos de 256. Se obtienen así $4 \times 3 \times 2 = 24$ estudios independientes.

Cada estudio dispone de 100 ensayos iniciales, ampliables a 150, con un máximo de 40 iteraciones de entrenamiento por ensayo. ASHA utiliza un período de gracia de 10 iteraciones y un factor de reducción de 4. El seguimiento diagnóstico se realiza cada 10 iteraciones.

La familia PPO explora la tasa de aprendizaje, el umbral de recorte del actor, los coeficientes de entropía y divergencia KL, el parámetro λ de GAE, la cota de pérdida del crítico y el tamaño de lote.

IDQN explora el horizonte de retorno de múltiples pasos, la frecuencia de actualización de la red objetivo y la agenda de exploración ε-voraz.

En los cuatro algoritmos se fija el factor de descuento en $\gamma = 0{,}99$ y se exploran conjuntamente la cantidad de niveles I del codificador y el peso vecinal ρ_{coop} mediante una distribución uniforme continua, una distribución loguniforme o muestreos discretos. Los dominios completos se presentan en las Tablas A.9, A.10 y A.11 del Apéndice A [SWD+17, YVV+22, ELR23].

3.4.4. Fase 2: búsqueda refinada

La fase 2 busca refinar la búsqueda de hiperparámetros a partir de la información obtenida en la fase 1 e identificar configuraciones prometedoras para la selección posterior.

3.4.5. Criterios de selección de configuraciones

Para la selección posterior a la fase 2 en cada combinación de algoritmo y red sintética, el protocolo contempla una preselección técnica y una evaluación operacional antes del entrenamiento final desde cero. Los criterios combinan la espera media con el volumen de vehículos insertados, la tasa de completitud y los teletransportes:

1. **Admisibilidad técnica y preselección:** para ser admisible, el ensayo debe alcanzar 60 iteraciones; sus métricas deben ser numéricas y finitas, con al menos 15 registros finitos de métricas de tránsito; y tanto la configuración efectiva como el archivo del modelo final deben estar completos y ser legibles.

   Entre los candidatos admisibles con espera diagnóstica disponible, se priorizan los que registran cero inicios de teletransporte y una CI diagnóstica de al menos 0,95. Luego se ordenan por menor espera y por identificador de política. Estos criterios priorizan candidatos, pero no son filtros obligatorios en esta etapa.

   Para cubrir las arquitecturas disponibles, se toma primero un candidato de cada una y se completa la lista, hasta tres, con los restantes en ese orden (véase la Sección A.5.6 del Apéndice A).

2. **Evaluación en panel común y filtros operacionales:** los candidatos preseleccionados para los cuatro algoritmos de una misma red se evalúan sobre un panel común de tres semillas de SUMO. Tomando como referencia empírica de flujo el máximo de vehículos insertados en ese panel para cada red y semilla, se exige que cada episodio registre: (i) cero inicios de teletransporte, (ii) una tasa de completitud de vehículos insertados (*Completion of Inserted Vehicles*, CI) de al menos 0,95 (Ecuación (3.5)), y (iii) un volumen de inserciones no inferior al 95 % de la referencia empírica del panel.

3. **Elección final:** entre los candidatos que superan los tres filtros operacionales se selecciona aquel de menor espera media por vehículo insertado. Las semillas de este panel, especificadas en la Sección A.5.6 del Apéndice A, quedan reservadas para esta etapa y no intervienen en la evaluación final, que emplea un conjunto propio de semillas (Sección 3.5.1).

3.5. Evaluación y análisis del desempeño

En la evaluación, los pesos de las políticas permanecen fijos y las acciones se seleccionan de forma determinista. Se presenta primero el protocolo de los modelos finales y se definen

las métricas globales y locales; luego se describe el balance de vehículos usado para verificar el escenario de Mendoza con programas fijos.

3.5.1. Entrenamiento y evaluación de los modelos finales

Para la comparación final entre IDQN, IPPO, MAPPO y HAPPO, el procedimiento entrena desde cero un modelo definitivo por cada combinación de algoritmo y red sintética que disponga de una configuración seleccionada en la Sección 3.4.5, utilizando una semilla de aprendizaje inédita y el presupuesto completo de 60 iteraciones de la fase 2.

La evaluación final utiliza el punto de control (*checkpoint*) de la última iteración y comprende 20 simulaciones con semillas de SUMO nuevas, reservadas para esta etapa y distintas de las utilizadas en búsqueda y selección. Esto abarca hasta 240 episodios para las doce combinaciones de algoritmo y red sintética, con 600 s de calentamiento y 3.600 s de control (Tabla 3.5). El listado de veinte semillas se fija y registra por combinación antes de iniciar la evaluación. Cada ejecución se identifica mediante la semilla de simulación, la configuración efectiva y el punto de control evaluado.

Para cada combinación y métrica se informa la media muestral y la desviación estándar muestral con divisor $20 - 1 = 19$, sin descartes retroactivos. El resumen requiere veinte observaciones válidas; si falta alguna, no se calcula para esa combinación y métrica. Los cierres anticipados se conservan en el registro y no cuentan como horizontes completos. Las repeticiones por fallos técnicos mantienen el intento original y la semilla asignada.

3.5.2. Métricas de desempeño y vehículos evaluados

Las métricas de las políticas se organizan en dos niveles: indicadores globales de la red vial, calculados a partir de los viajes registrados en `TripInfo`, e indicadores locales a escala de intersección, construidos sobre las mediciones por carril de cada agente.

Métricas globales de viaje y atención a la demanda

En los experimentos de aprendizaje sobre las redes sintéticas, la población evaluada $\mathcal{V}_{\text{ins}}$ reúne los vehículos cuyo instante efectivo de inserción en la red (`depart`) pertenece a la ventana de control $[t_{\text{inicio}}, t_{\text{fin}})$. Los viajes inconclusos al cierre quedan censurados a la derecha: se observa su espera hasta t_{fin}, sin conocer la espera total que acumularían al llegar a destino. Para conservar estos registros junto con los viajes finalizados, las simulaciones activan `-tripinfo-output.write-unfinished` de SUMO [Ecl26d].

La Figura 3.11 ilustra el criterio de pertenencia a $\mathcal{V}_{\text{ins}}$ mediante cuatro trayectorias tipo a través de la ventana $[t_{\text{inicio}}, t_{\text{fin}})$ (franja sombreada), donde el círculo vacío indica el instante de salida programado, el círculo lleno la inserción efectiva y el cuadrado la llegada a destino:

- **Caso 1:** el vehículo ingresa durante el calentamiento ($t < t_{\text{inicio}}$), por lo que queda excluido de $\mathcal{V}_{\text{ins}}$ aunque concluya su recorrido dentro de la ventana.

- **Caso 2:** el vehículo ingresa y arriba a destino dentro de $[t_{\text{inicio}}, t_{\text{fin}})$; integra $\mathcal{V}_{\text{ins}}$, aporta su espera completa y se contabiliza como viaje finalizado.
- **Caso 3:** el vehículo ingresa dentro de la ventana pero continúa en tránsito en t_{fin}; integra $\mathcal{V}_{\text{ins}}$ aportando su espera acumulada hasta el cierre e interviene en el denominador de la tasa de completitud, pero no en su numerador.
- **Caso 4:** el vehículo tiene salida programada pero permanece retenido en la cola externa de inserción hasta t_{fin}, por lo que no ingresa a $\mathcal{V}_{\text{ins}}$ y se refleja en el volumen de inserciones y en el retraso de ingreso (`departDelay`), que no computa en la espera de viaje.

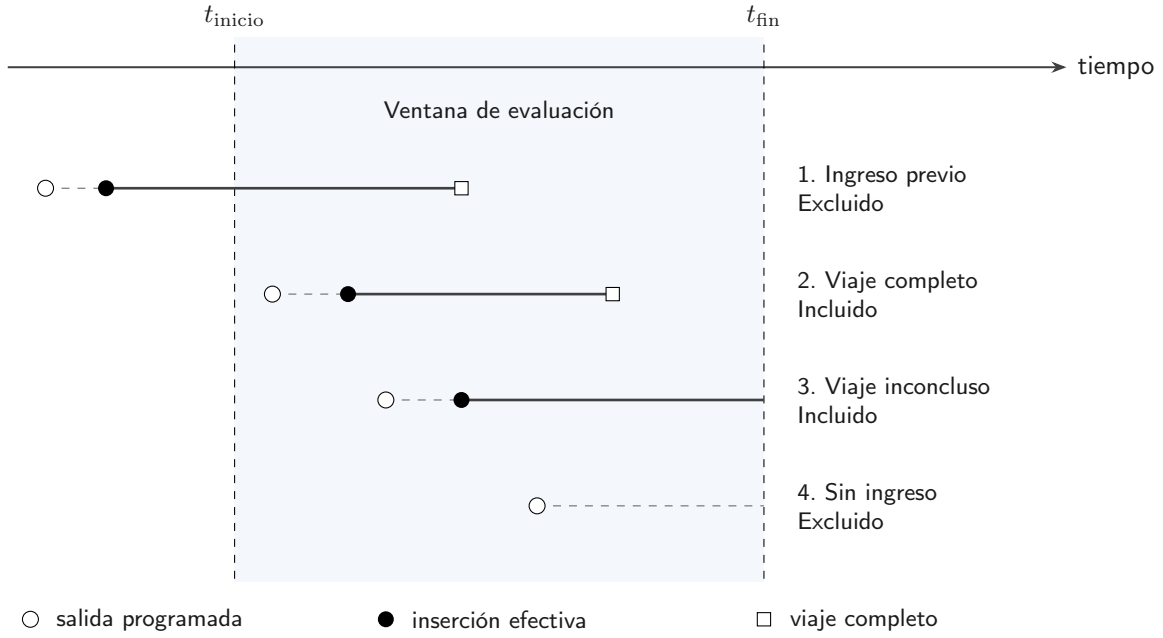


Figura 3.11: Criterio de inclusión en el conjunto de vehículos evaluados ($\mathcal{V}_{\text{ins}}$) según el instante efectivo de inserción.

Sobre este conjunto de vehículos insertados $\mathcal{V}_{\text{ins}}$ (con $|\mathcal{V}_{\text{ins}}| > 0$) se definen tres métricas globales:

- **Espera media por vehículo insertado ($\bar{w}_{\text{ins}}$):** promedio de `waitingTime` (w_v, segundos acumulados a velocidad $\leq 0{,}1\,\text{m/s}$ sin paradas programadas) en segundos por vehículo:

$$\bar{w}_{\text{ins}} = \frac{1}{|\mathcal{V}_{\text{ins}}|} \sum_{v \in \mathcal{V}_{\text{ins}}} w_v, \qquad w_v = \texttt{waitingTime}_v. \tag{3.4}$$

- **Tasa de completitud sobre vehículos insertados (CI):** proporción de vehículos de $\mathcal{V}_{\text{ins}}$ que alcanzan su destino antes de t_{fin}:

$$CI = \frac{|\{v \in \mathcal{V}_{\text{ins}} : \text{completó su viaje antes de } t_{\text{fin}}\}|}{|\mathcal{V}_{\text{ins}}|}. \tag{3.5}$$

- **Pérdida temporal media ($\bar{\ell}$):** promedio del atributo `timeLoss` sobre $\mathcal{V}_{\text{ins}}$ (en segundos por vehículo), que cuantifica el exceso de tiempo de viaje respecto de la circulación en flujo libre [Ecl26d].

Si no se inserta ningún vehículo en la ventana, las tres métricas quedan indefinidas.

Métricas locales por agente y equidad espacial

A escala de las intersecciones controladas se calculan dos indicadores complementarios a partir de la espera de cada intersección $W_i^{(t)}$, obtenida al sumar las esperas atribuidas a sus carriles:

- **Promedio de espera acumulada por agente:** cociente entre la suma temporal de $W_i^{(t)}$ a lo largo de la ventana de control y la suma de los conteos de vehículos presentes $n_i^{(t)}$ en los carriles del agente i en cada paso de decisión (en segundos). Este cociente pondera los pasos según la cantidad de vehículos presentes. Si el denominador es nulo, se informa cero junto con el conteo nulo.

- **Desigualdad espacial de espera (coeficiente de Gini, G_{wait}):** para cada agente $i \in \{1, \ldots, N\}$, se calcula primero la media temporal $\bar{w}_i$ de los cocientes por paso $W_i^{(t)}/n_i^{(t)}$, asignando cero en los pasos con $n_i^{(t)} = 0$. Esta media da el mismo peso a cada paso, a diferencia del cociente de sumas del indicador anterior. Ordenando dichas medias de menor a mayor como $\bar{w}_{(1)} \leq \bar{w}_{(2)} \leq \cdots \leq \bar{w}_{(N)}$, la equidad en el reparto de esperas entre intersecciones se cuantifica mediante el coeficiente adimensional de Gini:

$$G_{\text{wait}} = \frac{2\sum_{i=1}^{N} i \cdot \bar{w}_{(i)} - (N+1)\sum_{i=1}^{N} \bar{w}_{(i)}}{N\sum_{i=1}^{N} \bar{w}_{(i)}}. \tag{3.6}$$

  Si todas las medias son cero, la implementación informa $G_{\text{wait}} = 0$ por convención. Con suma de medias positiva, un valor nulo indica igualdad entre las medias de espera de los agentes, y los valores elevados indican mayor desigualdad entre ellas; no miden por sí solos la magnitud de las colas.

Incidencias de la simulación

Durante las ventanas de evaluación se contabilizan los inicios de teletransporte mediante `getStartingTeleportIDList` de TraCI; un vehículo puede contribuir con más de un evento. La selección de configuraciones en las redes sintéticas exige cero inicios. El contador nativo `teleports` de Summary solo puede sustituir esta medición si se comprueba su equivalencia para el procedimiento correspondiente.

3.5.3. Balance de vehículos en el escenario de Mendoza

La verificación del escenario de Mendoza parte de la red vacía, sin calentamiento previo. El balance al cierre de cada horizonte utiliza cinco contadores del archivo `Summary`

de SUMO [Ecl26b]. Se denotan por L los vehículos cargados (`loaded`), por I los insertados (`inserted`) y por A los viajes completados (`arrived`). Los vehículos que siguen circulando son R (`running`) y los vehículos pendientes de ingreso, W (`waiting`).

Estos conteos cumplen las identidades de conservación $L = I + W$ e $I = A + R$. A partir de ellos se definen la tasa de completitud (*Completion Rate*, CR), la tasa de inserción (*Insertion Rate*, IR) y el cociente de llegadas sobre inserciones del horizonte:

$$CR = \frac{A}{L}, \qquad IR = \frac{I}{L}, \qquad \frac{A}{I} = \frac{CR}{IR}. \tag{3.7}$$

Cada cociente se informa como indefinido si su denominador es cero. El contador `loaded` puede incluir solicitudes cuya salida está programada para más adelante; por ello, no equivale automáticamente a la demanda que ya debía ingresar.

3.6. Reproducibilidad y alcance

La trazabilidad experimental del estudio se sustenta en la preservación de los archivos de red y demanda, las configuraciones de SUMO, las semillas de cada etapa, los dominios e hiperparámetros efectivos y los puntos de control de los modelos entrenados, cuyo inventario se documenta en la Sección A.5 del Apéndice A.

3.6.1. Entorno de cómputo y envío de trabajos

Las campañas documentadas se ejecutaron en el clúster de alto desempeño Toko (UNCuyo), mediante trabajos por lotes gestionados con Slurm, que conservaron por separado los registros y artefactos de cada combinación experimental. Los scripts configuraron un recurso de unidad de procesamiento gráfico (*Graphics Processing Unit*, GPU) para Ray, pero los registros disponibles no permiten confirmar la asignación de una tarjeta física a cada trabajo. La organización de las colas y el resguardo de resultados se detallan en la Sección A.5.1 del Apéndice A.

3.6.2. Alcance y limitaciones

En la comparación de los cuatro algoritmos, el protocolo define un modelo final por combinación de algoritmo y escenario, evaluado mediante veinte simulaciones con semillas distintas. La dispersión entre sus episodios representa variabilidad de la simulación, no de entrenamientos independientes [ASC+21].

Igualar el máximo de iteraciones de búsqueda ofrece un marco práctico de comparación con recursos finitos, aunque los algoritmos muestrean de manera distinta: la familia PPO trabaja *on-policy*, mientras que IDQN reutiliza experiencias del *replay buffer* y opera *off-policy*. Por ello, los resultados deben interpretarse dentro de los dominios explorados, las poblaciones vehiculares definidas y las condiciones operacionales verificadas en este capítulo.

El objetivo J_r ordena las configuraciones según la espera y sus aumentos recientes dentro de cada ensayo. La variabilidad entre entrenamientos y la estabilidad futura requieren evaluaciones específicas y no quedan caracterizadas por esta medida.

La demanda de Mendoza balance se construyó mediante una redistribución sintética por hora, con rutas explícitas y cambios sustanciales de marginales y distancias respecto de referencias previas. La evaluación confirmatoria comprende tres semillas nuevas en dos ventanas; la semilla 104729 corresponde a desarrollo, no a una cuarta confirmación.

En Mendoza, completar el horizonte sin teletransportes y superar el umbral de completitud no garantiza que haya ingresado toda la demanda. Por eso, los vehículos que aún esperan ingresar deben informarse junto con los viajes completados. La estabilidad de las colas y el desempeño en períodos más extensos quedan fuera de estos horizontes.

La comprobación urbana presentada aquí corresponde a programas fijos. No se informa una campaña de aprendizaje de políticas para Mendoza; cualquier extensión requeriría adaptar y verificar el procedimiento y sus datos por separado.

4

Análisis y discusión de resultados

Este capítulo organiza los resultados por procedimiento: búsqueda de hiperparámetros, evaluación de los modelos finales y verificación del escenario de Mendoza. Sus métricas y criterios se interpretan según las unidades experimentales definidas en la metodología.

El escenario de Mendoza se verificó con una demanda nominal de 220.000 viajes diarios y programas semafóricos fijos. Sus conteos describen la operación simulada; no evalúan políticas aprendidas.

4.1. Resultados del ajuste de hiperparámetros

La presentación de HPO sigue las dos fases de búsqueda en las tres redes sintéticas. Extender el aprendizaje a Mendoza requiere adaptar y verificar el procedimiento para la demanda y los programas fijos descritos en la metodología. Los dominios y criterios se interpretan según el escenario al que corresponden.

4.1.1. Estado de la consolidación y de las búsquedas

4.1.2. Resultados del ajuste y análisis de sensibilidad

4.1.3. Selección de configuraciones de HPO

4.2. Evaluación de políticas y verificación de escenarios

4.2.1. Criterios de evaluación y métricas de comparación

4.2.2. Desempeño en escenarios sintéticos: 3×1, 3×3, 4×4 heterogéneo

4.2.3. Comprobación operacional del escenario de la Ciudad de Mendoza

Las seis ejecuciones de cada ventana completaron el horizonte y cumplieron los criterios de aceptación definidos en la metodología. La Tabla 4.1 resume los doce casos: no hubo teletransportes, colisiones detectadas ni descartes, y al menos el 75 % de los vehículos cargados llegó a destino. La media de viajes completados asigna igual peso a las seis ejecuciones; los rangos muestran sus extremos. Los casos individuales y sus registros se conservan en el apéndice.

Tabla 4.1: Comprobación del escenario urbano con programas fijos: síntesis por ventana.

Ventana	Aceptados	Completados (media)	Pendientes (rango)	Llegaron/ cargados (%)
2 h	6/6	19.896,5	4.813–5.020	76,32–77,17 %
12 h	6/6	125.080,5	25.984–26.529	82,11–82,31 %

En doce horas se completaron, en promedio, 125.080,5 viajes, frente a 152.168,75 solicitudes esperadas por las tasas. Las solicitudes realizadas fluctúan: los cargados estuvieron entre 151.529 y 153.148. Al cierre permanecían entre 778 y 951 vehículos circulando y entre 25.984 y 26.529 pendientes de ingreso. Por tanto, el cumplimiento del criterio de aceptación no equivale a atender toda la demanda ni a servir 220.000 viajes en doce horas. El nominal diario y los conteos del horizonte describen magnitudes diferentes.

La Figura 4.1 muestra la evolución de los vehículos pendientes de ingreso en las seis ejecuciones largas. Cada trazo corresponde a una ejecución; el rayado identifica la hora en que se redistribuyeron las solicitudes. Las trayectorias muestran acumulación de vehículos fuera de la red durante el horizonte, pero no permiten establecer la estabilidad de las colas para tiempos indefinidos.

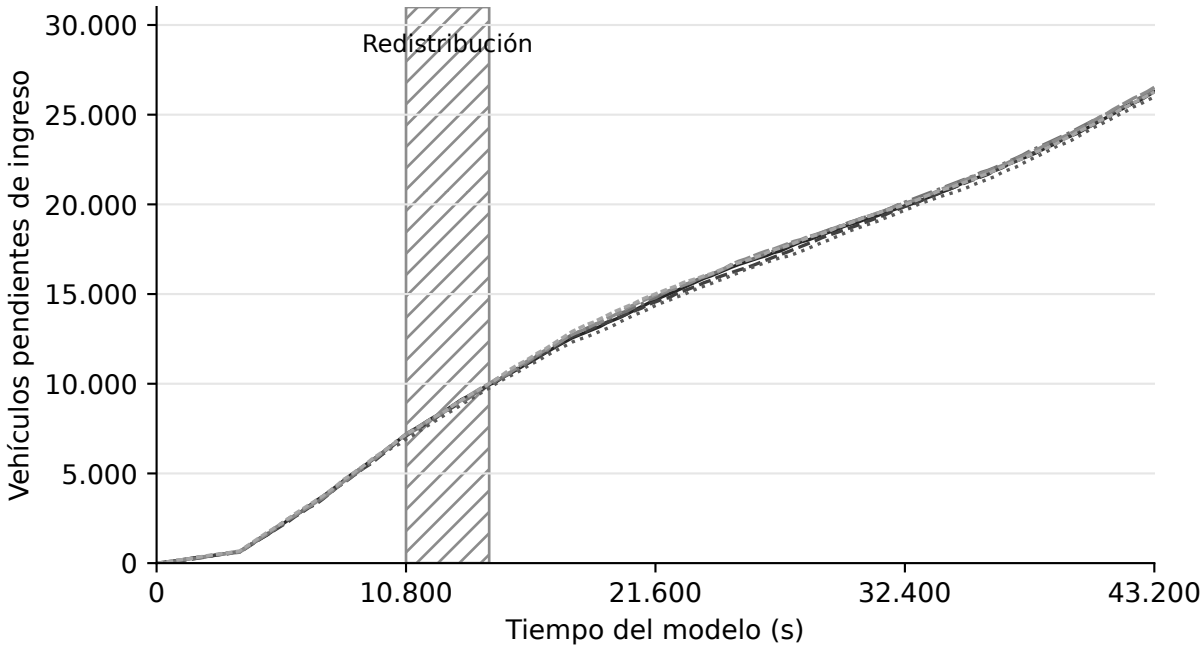


Figura 4.1: Vehículos pendientes de ingreso durante las seis ejecuciones de doce horas. El rayado señala la hora en que se redistribuyeron las solicitudes.

En las ejecuciones de aceptación con programas fijos y horizonte de dos horas llegó a destino entre el 76,32 % y el 77,17 % de los vehículos cargados. Este horizonte termina antes de la redistribución de solicitudes, por lo que no evalúa su efecto. Las ejecuciones no corresponden al ajuste de hiperparámetros previsto para el aprendizaje urbano; los detalles se conservan en el apéndice.

Una ejecución larga con la demanda redistribuida completó el horizonte en condiciones en que la referencia uniforme había fallado. Esta diferencia describe los casos observados, pero no identifica una causa única: los cambios pueden alterar las solicitudes, su orden y la secuencia aleatoria. La selección adaptativa y la reutilización de semillas limitan la generalización.

4.3. Discusión e interpretación de resultados

En esta sección se integran los resultados presentados y se discuten sus principales implicancias en relación con los objetivos del trabajo. La lectura de la desigualdad espacial de espera requiere considerar que el coeficiente G_{wait} pondera por igual las intersecciones con demandas desiguales, de modo que un valor bajo puede reflejar una distribución uniforme de la demora media y, al mismo tiempo, disparidades de carga estructural entre cruces.

5

Conclusiones

Este capítulo sintetiza los hallazgos del estudio, relaciona la evidencia experimental con los objetivos planteados y delimita el alcance de las conclusiones. También identifica las limitaciones del modelo y propone líneas de trabajo futuro. Las afirmaciones finales deben interpretarse dentro de los escenarios, métricas y protocolos descritos en la metodología.

A

Arquitectura de software y especificaciones experimentales

Este apéndice complementa el Capítulo 3 documentando el diseño orientado a objetos del paquete `marlTLC`, las especificaciones detalladas del escenario urbano de Mendoza, los dominios y semillas de las campañas de búsqueda y evaluación, y las formulaciones algebraicas del codificador de observaciones y de la pérdida del crítico. La documentación distingue el escenario histórico O2/P2 del canónico posterior `mendoza_220k_balance`; sus redes, programas y demandas no son intercambiables.

A.1. Diseño orientado a objetos del entorno de simulación

El diseño del entorno separa la gestión del simulador microscópico de la interfaz de aprendizaje multiagente. La clase abstracta `BaseSumoEnvironment` encapsula la inicialización de SUMO, el avance temporal y las consultas de bajo nivel a través de la interfaz de programación de aplicaciones (*Application Programming Interface*, API) de `libsumo` y TraCI. A partir de ella, la subclase `SumoRllibEnv` adapta el ciclo de simulación al contrato `MultiAgentEnv` de Ray RLlib. La Tabla A.1 sintetiza el rol de cada biblioteca principal dentro de la arquitectura.

Tabla A.1: Herramientas y responsabilidades en el sistema experimental.

Herramienta	Función
SUMO y `libsumo`	Simulación microscópica del tránsito e interfaz de control en memoria.
`SumoRllibEnv`	Adaptación del simulador a la interfaz multiagente de entrenamiento.
Ray RLlib	Orquestación distribuida de los procesos de muestreo y optimización.
PyTorch	Cómputo de redes neuronales y actualización de parámetros por gradiente.

La Figura A.1 organiza las responsabilidades del entorno: `BaseSumoEnvironment` administra la simulación y sus estados guardados; `SumoRllibEnv` adapta su interfaz a RLlib; `TrafficLight` gestiona fases, carriles, vecinos y recompensas; y `Lane`, las medidas de espera. Las flechas de herencia apuntan a la clase general y la multiplicidad 1..∗ indica uno o más objetos relacionados. Los diagramas representan la especificación de diseño, sin describir una correspondencia exhaustiva entre clases y archivos ejecutables.

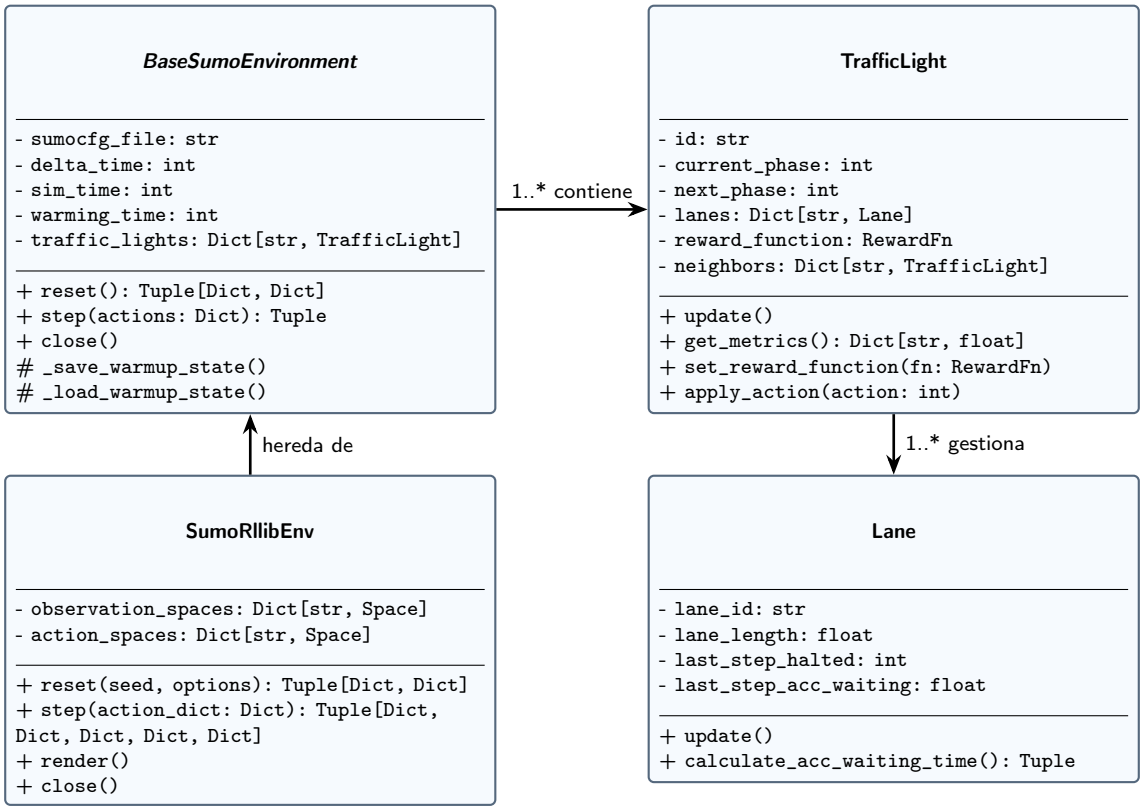


Figura A.1: Diagrama de clases UML del entorno de simulación y sus relaciones principales.

A.2. Jerarquía de funciones de recompensa y patrón *Strategy*

El cálculo de la señal de recompensa se desacopla del bucle principal del entorno mediante los patrones de diseño ***Strategy*** y ***Composite***, lo que permite intercambiar formulaciones locales y vecinales mediante parámetros de configuración. La clase abstracta `RewardFn` define la operación polimórfica `compute_reward(tl_id)`, implementada por estrategias locales como `DiffAccWaitingTimeNormalized` y por agregadores espaciales como `NeighborAvgReward` y `NeighborhoodRelevanceReward` (Figura A.2).

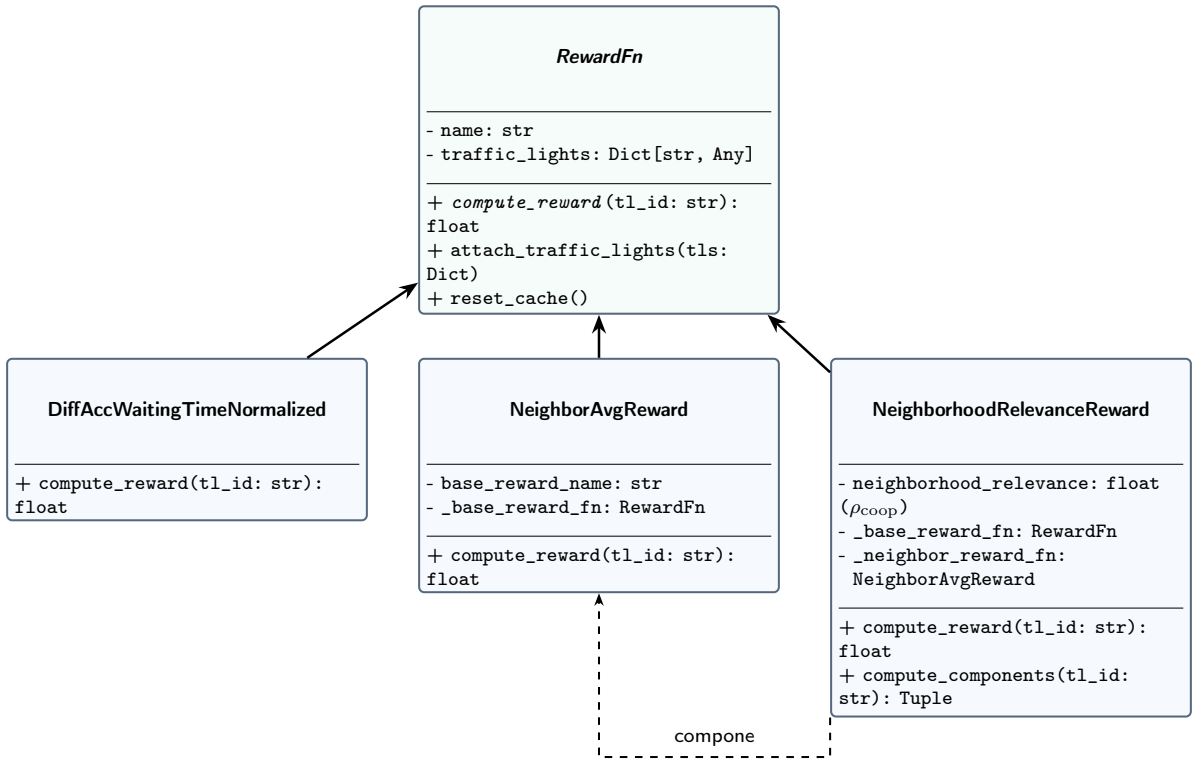


Figura A.2: Diagrama de clases UML del módulo de recompensas. Las subclases implementan la interfaz `RewardFn`; `NeighborhoodRelevanceReward` combina la señal local con el promedio vecinal ponderado por ρ_{coop}.

A.3. Patrones de diseño de la arquitectura

La especificación de `marlTLC` utiliza los siguientes mecanismos de diseño:

1. **Estrategia (*Strategy*):** encapsula las formulaciones de recompensa tras la interfaz común `RewardFn`, permitiendo alternar entre señales locales, vecinales y basadas en presión sin modificar `TrafficLight`.

2. **Método de fábrica y registro (*Factory Method* / *Registry*):** instancia funciones de recompensa y módulos neuronales a partir de diccionarios de configuración

(`RewardFactory` y el decorador `@register_reward`), respetando el principio abierto/cerrado.

3. **Objeto compuesto (*Composite*):** combina señales locales y promedios de intersecciones adyacentes (`NeighborhoodRelevanceReward`) bajo la misma interfaz `RewardFn`.

4. **Subtipado estructural (*Protocol*):** desacopla la consulta de métricas vecinales (`NeighborInfoProvider`) de la implementación concreta de `TrafficLight`, facilitando las pruebas unitarias mediante objetos simulados (*mocks*).

5. **Adaptador (*Adapter*):** traduce la API procedural de TraCI y `libsumo` al contrato orientado a objetos `MultiAgentEnv` de Ray RLlib a través de `SumoRllibEnv`.

6. **Decorador (*Decorator*):** extiende declarativamente el registro de componentes y la aplicación de la máscara de acciones sobre los módulos en PyTorch.

A.4. Parámetros de SUMO y programas semafóricos de referencia

En todos los experimentos de aprendizaje sintéticos, el parámetro `waiting_time_memory` de SUMO —que fija la ventana temporal de la métrica `getAccumulatedWaitingTime` [Ecl26c]— se establece en 1.000 s. Las duraciones de los programas semafóricos de referencia de las tres redes sintéticas se presentaron en la Tabla 3.3 del Capítulo 3; a continuación se detallan los programas fijos y la evidencia operacional de Mendoza.

A.4.1. Mendoza balance: red, demanda y evidencia operacional

El escenario `mendoza_220k_balance` utiliza SUMO 1.27.1, una red con 255 tramos de circulación, 554 carriles externos, ningún tramo interno, 744 conexiones y 74 controladores semafóricos fijos. El archivo de zonas contiene 37 TAZ, con identificadores de 0 a 38 salvo 6 y 9. Se conserva el ciclo común de 90 s; los programas actuales derivan de un plan previo, incorporan un controlador y normalizan las fases preservando sus verdes relativos, con amarillo de 5 s.

La matriz sintética distribuye 6.204 flujos horarios entre 517 pares OD activos, mediante rutas explícitas. Su construcción usa una optimización lineal por hora; evita el giro Benegas→Civit y cambia entre 11,6 % y 23,6 % de la masa respecto de las referencias documentadas. Las marginales actuales no se conservan como una matriz validada con datos de campo. El perfil horario heredado procede de 32 días hábiles de la cámara 169, con un promedio de 25.175,84 vehículos diarios; la documentación disponible no identifica al custodio de ese registro. La cámara está fuera del dominio modelado y no equivale a una medición completa de los flujos por movimiento. El nominal es 220.000 viajes diarios, mientras que la integral de demanda esperada de 12 h es 152.168,75 solicitudes.

La Tabla A.2 identifica las entradas congeladas y sus hashes SHA-256. Los manifiestos y registros compactos de cada caso se conservan bajo `datos/mendoza220k_balance/`; no se duplican las salidas nativas extensas.

Tabla A.2: Entradas del escenario Mendoza balance y SHA-256.

Entrada	SHA-256
`nets/Mendoza/mendoza_220`	`06222972799a5583f9d9846f69909e6a33cb01c0`
`k_balance.net.xml`	`6cc5e2f602c1511cf7671115`
`nets/Mendoza/mendoza_220`	`b80859cb6f162601dd4b7dc8599144e0bf2608dd`
`k_balance.taz.xml`	`38a5bc1ca5cd2e1236702e0a`
`nets/Mendoza/mendoza_220`	`917e1904329d6b84fece04766a4196eebae0fb23`
`k_balance.rou.xml`	`04a729944f5f52df2c00e0ca`
`nets/Mendoza/mendoza_220`	`eba9d238efdfc98d732d00d0c60183f30340b886`
`k_balance_12h.sumocfg`	`9f03583b14f0da02ff2d3ddc`
`nets/Mendoza/mendoza_220`	`6d0922b1c9374b60b214e30d85efeb50dcb90d0f`
`k_balance_2h.sumocfg`	`311af9620d22d3ac470b03cd`
`nets/Mendoza/gran_mendoz`	`fe96f276987b8f9ccd71736a76a8524eb948b192`
`a2.add.xml`	`b2326221b92f4959749b8a38`

Programas semafóricos

Los programas fijos efectivos están definidos en el archivo de red. Las Tablas A.3–A.5 resumen los desfases y las duraciones de fase de sus 74 controladores. Los estados XML completos se conservan en `datos/mendoza220k_balance/fuentes/programas.json`.

Tabla A.3: Programas semafóricos de Mendoza balance, controladores 1–25.

N.º	ID	Desfase (s)	Duraciones de fase (s)
1	10815785964	0	80, 5, 5
2	10936722266	0	18, 5, 1, 60, 5, 1
3	10936722273	0	41, 5, 39, 5
4	10936722274	0	44, 5, 36, 5
5	12990936866	1	34, 5, 46, 5
6	12990936872	21	37, 5, 43, 5
7	1840278959	0	31, 5, 49, 5
8	1840278966	0	40, 5, 40, 5
9	1840279037	0	46, 5, 34, 5
10	1840279039	0	30, 5, 50, 5
11	1840279043	0	34, 5, 46, 5
12	1866455049	0	40, 5, 40, 5
13	286045064	0	61, 5, 19, 5
14	286045221	0	80, 5, 5
15	287040660	0	42, 5, 38, 5
16	287040669	0	42, 5, 38, 5
17	287040677	0	56, 5, 24, 5
18	287040684	0	31, 5, 49, 5
19	287040690	0	47, 5, 33, 5
20	287040708	0	35, 5, 45, 5
21	287040724	0	42, 5, 38, 5
22	287040734	0	53, 5, 27, 5
23	287040821	0	36, 5, 44, 5
24	287042850	0	28, 5, 52, 5
25	287042851	24	27, 5, 53, 5

Tabla A.4: Programas semafóricos de Mendoza balance, controladores 26–50.

N.º	ID	Desfase (s)	Duraciones de fase (s)
26	287042852	18	33, 5, 47, 5
27	287042859	82	35, 5, 45, 5
28	287042860	73	38, 5, 42, 5
29	287044657	0	43, 5, 37, 5
30	287044661	0	63, 5, 17, 5
31	287044665	0	22, 5, 22, 5, 5, 5, 21, 5
32	287048117	0	21, 5, 32, 5, 22, 5
33	287048125	0	28, 5, 52, 5
34	287048129	75	42, 5, 38, 5
35	287055420	0	42, 5, 38, 5
36	287055424	0	43, 5, 37, 5
37	287055428	0	37, 5, 43, 5
38	287055431	0	56, 5, 24, 5
39	287055445	13	49, 5, 31, 5
40	287055449	0	33, 5, 47, 5
41	287055452	0	80, 5, 5
42	287055464	0	40, 5, 40, 5
43	287055465	0	41, 5, 39, 5
44	5364445246	0	39, 5, 41, 5
45	5364445248	0	43, 5, 37, 5
46	5364445249	0	37, 5, 43, 5
47	5364451013	0	48, 5, 32, 5
48	676748101	0	40, 5, 40, 5
49	676748105	0	30, 5, 50, 5
50	676748107	0	43, 5, 37, 5

Tabla A.5: Programas semafóricos de Mendoza balance, controladores 51–74.

N.º	ID	Desfase (s)	Duraciones de fase (s)
51	676748143	0	30, 5, 50, 5
52	676748153	15	44, 5, 36, 5
53	676748154	52	47, 5, 33, 5
54	676748155	0	37, 5, 43, 5
55	676748156	0	38, 5, 42, 5
56	676748161	0	40, 5, 40, 5
57	676748167	0	40, 5, 40, 5
58	676748171	75	30, 5, 50, 5
59	676748182	0	35, 5, 45, 5
60	676748185	0	52, 5, 28, 5
61	676748186	0	56, 5, 24, 5
62	676748187	0	37, 5, 43, 5
63	cluster_1086062886_286045446	0	46, 5, 34, 5
64	cluster_1086062891_676748165	0	40, 5, 40, 5
65	cluster_1086062935_287048132	0	40, 5, 40, 5
66	cluster_1086062975_287055453	0	22, 5, 58, 5
67	cluster_1086742602_437558121	0	40, 5, 40, 5
68	cluster_1086742611_437558117	0	40, 5, 40, 5
69	cluster_1086742616_437558119	0	80, 5, 5
70	cluster_1086742636_2624642126	13	40, 5, 40, 5
71	cluster_1086742680_2606023806_437558123	0	40, 5, 40, 5
72	cluster_1086742689_437558120	0	40, 5, 40, 5
73	cluster_1086742734_437558124	0	40, 5, 40, 5
74	cluster_2606030890_437558126_623948419	0	40, 5, 40, 5

Construcción de la demanda

La distribución espacial de demanda se generó a partir de flujos horarios y rutas explícitas, resolviendo por separado un problema lineal por hora. La tasa de cada flujo se representa mediante `period=exp(`λ`)`, donde $\lambda = q/3600$ es la tasa de llegadas en vehículos por segundo, obtenida del flujo horario q. El intervalo exponencial se interpreta según la Ecuación 2.4 del Capítulo 2. La construcción evita Benegas→Civit y no conserva las marginales de la especificación previa; el cambio de itinerario modifica también las distancias. No acredita calibración de campo.

Configuración y resultados conservados

Las configuraciones de 2 h y 12 h parten de una red vacía y usan paso de 1 s, `time-to-teleport`=300 s, `max-num-teleports`=0, `max-depart-delay`=−1 y `collision.action=warn`. La Tabla A.6 resume las opciones explícitas; no se completan opciones ausentes con valores predeterminados supuestos.

Tabla A.6: Opciones explícitas en las dos configuraciones de Mendoza balance.

Opción	2 h	12 h
Inicio t (s)	1800	0
Fin t (s)	9000	43200
Paso (s)	1	1
Umbral de teleport (s)	300	300
Máximo de teleports	0	0
Acción ante colisión	`warn`	`warn`
Semilla de desarrollo	104729	104729
Asignación de zonas	`true`	`true`

Se observó una ejecución de desarrollo con semilla 104729 y tres semillas confirmatorias nuevas (2026102001–2026102003); cada semilla tiene un caso en ambas ventanas. Las configuraciones canónicas declaran 104729; los seis archivos por caso registran las semillas confirmatorias correspondientes. La unidad confirmatoria es la semilla, no cada combinación de semilla y horizonte. Según el balance definido en la Sección 3.5.3 del Capítulo 3, L es el total de vehículos cargados, I el de insertados, A el de viajes llegados, R los que siguen circulando y W los pendientes de ingreso. Las Tablas A.7 y A.8 muestran esos contadores al cierre; la tasa de completitud es CR. Cero colisiones registradas describe el control configurado en SUMO y no certifica seguridad física.

Tabla A.7: Resultados por semilla en la ventana de 2 h.

Semilla	L	I	A	R	W	CR	TP/Col./Desc.
104729	25.924	21.749	20.941	808	4.175	80,78 %	0/0/0
2026102001	25.821	21.723	20.878	845	4.098	80,86 %	0/0/0
2026102002	25.956	21.865	21.024	841	4.091	81,00 %	0/0/0
2026102003	25.969	21.764	20.934	830	4.205	80,61 %	0/0/0

Tabla A.8: Resultados por semilla en la ventana de 12 h.

Semilla	L	I	A	R	W	CR	TP/Col./Desc.
104729	152.492	130.249	129.526	723	22.243	84,94 %	0/0/0
2026102001	152.869	130.956	130.156	800	21.913	85,14 %	0/0/0
2026102002	152.044	130.105	129.378	727	21.939	85,09 %	0/0/0
2026102003	152.492	130.276	129.526	750	22.216	84,94 %	0/0/0

Las tres semillas confirmatorias completaron ambos horizontes con cero teletransportes, colisiones y descartes, y con una tasa de completitud de al menos 0,75. La tabla de síntesis resume solo esas tres semillas; el caso de desarrollo se muestra por separado en las tablas precedentes. Quedaron vehículos pendientes de ingreso, en especial desde las zonas

de acceso de Las Heras 37 y 38, y se observó congestión en otros sectores. La evidencia fortalece la repetibilidad de este escenario bajo SUMO 1.27.1, pero no establece riesgo bajo de fallo, capacidad vial, calibración de campo ni desempeño de políticas aprendidas.

A.5. Especificaciones para reproducir los experimentos

Este apéndice distingue los valores observados en configuraciones y archivos de ejecución de los parámetros, dominios y semillas que aparecen en los diseños de búsqueda. En este contexto, fase 1 y fase 2 designan etapas de búsqueda de hiperparámetros.

A.5.1. Infraestructura y almacenamiento de las ejecuciones

Los programas de envío de trabajos, o *scripts*, especifican recursos solicitados; se distinguen de los registros de asignación efectiva. La metodología resume las plataformas utilizadas en la Sección 3.6.1.

Los trabajos se envían con `sbatch`, comando del gestor de trabajos herramienta simple de Linux para gestión de recursos (*Simple Linux Utility for Resource Management*, SLURM). En las búsquedas sintéticas, fase 1 utiliza `submit_phase1.sh` y fase 2 especifica `submit_phase2_refined.sh`.

Las configuraciones de los scripts corresponden a una combinación de algoritmo, red de tráfico y arquitectura, y solicitan un nodo de cómputo, una tarea de ejecución, diez núcleos de unidad central de procesamiento (*Central Processing Unit*, CPU) y una partición con aceleración por GPU. El manual institucional describe una partición de Toko con hasta ocho núcleos; por ello no permite confirmar los recursos físicos asignados a cada trabajo [Tok24].

El script refinado también especifica el uso exclusivo del nodo y un límite de tiempo. La configuración de Ray limita a un ensayo simultáneo por trabajo; ASHA define las detenciones anticipadas según los parámetros de cada búsqueda.

Los registros de las ejecuciones documentadas se guardaron en almacenamiento persistente y se copiaron al espacio temporal del nodo durante la ejecución. Aunque los scripts configuraron un recurso de GPU para Ray, no solicitaron una tarjeta física mediante un identificador de recurso de SLURM; por ello, los archivos del proyecto no permiten asociar cada trabajo con un modelo específico de GPU.

A.5.2. Comprobaciones preliminares

En una comprobación de 3×3, cerca del 70 % de los vehículos cargados —incluidos en la demanda de SUMO— completó el viaje; este dato no se extrapola a las otras redes. Esa comprobación incluyó 600 segundos de calentamiento y 3600 segundos de control.

A.5.3. Detalles de las redes sintéticas

La Tabla 3.2 reúne las dimensiones comparables de las redes. Este apartado conserva las excepciones topológicas y las asignaciones de demanda por par OD que explican la función de cada escenario.

En el corredor 3×1, los cruces B1, C1 y D1 se disponen en línea. El 75 % del flujo solicitado se asigna a los pares de zonas $3 \rightarrow 4$ (40 %) y $4 \rightarrow 3$ (35 %); el 25 % restante se distribuye de manera reproducible entre los pares válidos.

La red 3×3 forma una cuadrícula regular. Sus asignaciones principales son 20 % para $5 \rightarrow 6$, 17,5 % para $6 \rightarrow 5$, 17,5 % para $10 \rightarrow 1$ y 20 % para $1 \rightarrow 10$; el 25 % restante se reparte entre los pares válidos.

En $4 \times 4_H$, la fila 2 tiene tres carriles por sentido, mientras que el sector A1–B1–C1 de la fila 1 tiene uno por sentido. La columna C es asimétrica, con cuatro carriles hacia el sur y dos hacia el norte. La columna D solo permite circular hacia el norte: tiene cuatro carriles hasta D3 y tres desde D3 hasta el borde norte. Las demás vías tienen dos carriles por sentido donde existe circulación. Faltan los enlaces horizontales B4–C4 y D1–E1, por lo que la red no es una malla completa.

C1 tiene tres acciones seleccionables. C4 y D1 tienen dos, aunque sus programas de referencia contienen cinco fases, porque las fases amarillas y el estado final de todo rojo no son acciones de los agentes. B4 y E1 tienen un vecino; los demás agentes tienen entre dos y cuatro. La demanda asigna 20 % a $5 \rightarrow 9$, 17,5 % a $6 \rightarrow 5$, 17,5 % a $13 \rightarrow 1$ y 20 % a $1 \rightarrow 13$; el 25 % restante se distribuye entre pares válidos. Estas diferencias de capacidad, conectividad y demanda se presentan como características del escenario, no como una variación controlada de un único factor.

A.5.4. Espacio de búsqueda inicial de fase 1

Esta sección especifica los dominios iniciales por algoritmo y los factores que se mantienen fijos. Los rangos se contrastaron con el código de `experiments/marl_experiments/tuning/shared/search_space.py` y con la revisión documental del 10 de octubre de 2026 conservada en `docs/initial_search_space_criteria.md`, dentro de `marl-tlc`.

Las Tablas A.9 y A.10 reúnen los dominios por familia algorítmica. Cada fila identifica el parámetro por su función; la Tabla A.12 conserva su correspondencia con las claves del código. El muestreo uniforme continuo asigna la misma probabilidad a intervalos de igual longitud; el loguniforme lo hace a intervalos de igual longitud en escala logarítmica. Uniforme entera permite cualquiera de los enteros del rango, incluidos ambos extremos, y categórico restringe la búsqueda a las alternativas enumeradas. Los intervalos continuos conservan la notación de las distribuciones declaradas; la inclusión de cero como extremo no garantiza una propuesta exactamente nula. En las llamadas enteras del código, el límite superior es exclusivo: por ejemplo, `randint(4,65)` permite los enteros de 4 a 64. Otros factores, como el límite de escala del codificador de espera acumulada por carril,

se fijan por escenario. La Tabla A.11 especifica esos factores para los estudios sintéticos documentados.

Las funciones generales de estos parámetros se desarrollan en el marco teórico. En esta implementación, la cota de valor limita la pérdida cuadrática del crítico, no la espera física (Sección A.7). El programa consultado de fase 1 no normaliza la señal vecinal por carriles; su configuración no verifica por sí sola cada ensayo histórico.

Tabla A.9: Espacio inicial de fase 1 para MAPPO, IPPO y HAPPO. Las excepciones por algoritmo se indican en las filas.

Parámetro	Dominio	Muestreo
Peso de recompensa vecinal	[0; 0,95)	Uniforme continua
Tasa de aprendizaje	$[3 \times 10^{-5}; 10^{-3}]$	Loguniforme
Recorte del actor	[0,10; 0,22)	Uniforme continua
Parámetro de GAE	[0,88; 0,99)	Uniforme continua
Peso de entropía	[0; 0,01)	Uniforme continua
Límite del gradiente	[0,25; 5]	Loguniforme
Coeficiente de penalización KL	[0,05; 0,5]	Loguniforme
Objetivo de divergencia KL	[0,005; 0,03]	Loguniforme
Cota de pérdida de valor	[5; 20]	Loguniforme
Recorridos de optimización	5–15; HAPPO: 5–18	Uniforme entera
Episodios por lote	2–12	Uniforme entera
Niveles del codificador	4–64	Uniforme entera
Tamaño del minilote*	{128; 256; 512}	Categórico
Probabilidad de ordenación (HAPPO)	[0,20; 0,90)	Uniforme continua

El asterisco indica que HAPPO procesa el lote completo por actor: el tamaño de minilote registrado no determina una subdivisión efectiva. La probabilidad de ordenación se aplica según la Sección 3.3.3; su dominio excluye tanto el orden completamente aleatorio como la selección siempre guiada por la ventaja.

En las redes sintéticas, para PPO, entre 2 y 12 episodios nominales por lote equivalen a un objetivo de 1440 a 8640 pasos de decisión, al multiplicar por $3600/5 = 720$ pasos por episodio controlado. La recolección de episodios completos puede producir un tamaño efectivo distinto. Los niveles del codificador modifican la representación de las observaciones; el peso vecinal modifica la recompensa. No son parámetros del optimizador y se distinguen de la inclusión de información vecinal en la observación, que permanece desactivada durante esta búsqueda.

En IDQN, la probabilidad de exploración desciende desde uno hasta el valor final propuesto, durante el número de pasos configurado. La red objetivo se actualiza con la frecuencia indicada, y el horizonte de varios pasos fija cuántas transiciones intervienen en el retorno utilizado para aprender. Sus frecuencias y contadores corresponden a pasos de entrenamiento o muestreo según la interfaz de RLlib, no a segundos de SUMO. El lote

de IDQN contiene transiciones y no equivale al número de episodios utilizado para los métodos PPO.

Tabla A.10: Espacio inicial de fase 1 para IDQN. Los contadores se expresan en pasos según la interfaz del algoritmo.

Parámetro	Dominio	Muestreo
Peso de recompensa vecinal	[0; 0,95)	Uniforme continua
Tasa de aprendizaje	$[10^{-5}; 10^{-3}]$	Loguniforme
Transiciones por lote	{64; 128; 256; 512}	Categórico
Límite del gradiente	{0,5; 1; 2; 5; 10}	Categórico
Actualización de red objetivo	{500; 1.000; 2.000; 5.000}	Categórico
Pasos para reducir exploración	{5.000; 10.000; 20.000}	Categórico
Exploración final	[0,02; 0,10)	Uniforme continua
Horizonte del retorno	{1; 3; 5}	Categórico
Pasos antes de aprender	{1.000; 2.000; 5.000}	Categórico
Niveles del codificador	4–64	Uniforme entera

La Tabla A.11 separa los factores de estudio y los valores fijos de los parámetros anteriores. La arquitectura se conserva dentro de cada estudio para evitar que RLlib 2.53 altere la arquitectura al almacenarla dentro de otros campos de configuración, según la decisión registrada en `experiments/marl_experiments/tuning/shared/architectures.py`. El límite de escala del codificador de espera acumulada por carril se calibra por escenario; su fijación no implica que el percentil utilizado sea superior a otras alternativas.

Tabla A.11: Factores de estudio y valores fijos documentados para la fase 1 sintética.

Factor	Valor o alternativa
Arquitectura por estudio	h128 o h256: dos capas de 128 o 256 unidades
Descuento	$\gamma = 0{,}99$
Medición de espera	Espera acumulada por carril (veh·s)
Límite de escala del codificador, 3×1	1184 veh·s
Límite de escala del codificador, 3×3	1136 veh·s
Límite de escala del codificador, $4 \times 4_H$	712 veh·s
Información observada	Observación local y máscara de acciones
Penalización KL	Activada en los métodos PPO

Los rangos y distribuciones documentan cómo se acotó la exploración. No se recuperó una justificación contemporánea para todos sus límites exactos, ni una comparación que validara las alternativas de cada fila. La calibración de espera y la separación de arquitecturas tienen un respaldo local identificable; los demás límites se conservan como decisiones del diseño exploratorio. Las propuestas adaptativas de TPE, las detenciones de ASHA y la única semilla de entrenamiento por escenario limitan las inferencias sobre sen-

sibilidad y variabilidad. La especificación no garantiza cobertura exhaustiva del espacio ni optimalidad global.

Tabla A.12: Correspondencia entre los parámetros de búsqueda y sus claves de configuración.

Parámetro	Clave en el código
Peso de recompensa vecinal	`neighborhood_relevance`
Tasa de aprendizaje	`lr`
Recorte del actor	`clip_param`
Parámetro de GAE	`lambda_gae`
Peso de entropía	`entropy_coeff`
Límite del gradiente	`grad_clip`
Coeficiente de penalización KL	`kl_coeff`
Objetivo de divergencia KL	`kl_target`
Cota de pérdida de valor	`vf_clip_param`
Recorridos de optimización	`num_epochs`
Episodios por lote	`train_batch_episodes`
Niveles del codificador	`encoder_intervals`
Tamaño del minilote	`minibatch_size`
Probabilidad de ordenación (HAPPO)	`greedy_selection_prob`
Transiciones por lote	`train_batch_size_per_learner`
Actualización de red objetivo	`target_network_update_freq`
Pasos para reducir exploración	`epsilon_timesteps`
Exploración final	`epsilon_final`
Horizonte del retorno	`n_step`
Pasos antes de aprender	`num_steps_sampled_before_learning_starts`

A.5.5. Semillas de fase 1 en las redes sintéticas

La Tabla A.13 reúne las semillas observadas en las configuraciones serializadas de fase 1 y las asociadas a los perfiles canónicos de generación de rutas. La semilla de entrenamiento inicializa el aprendizaje y la simulación SUMO durante el entrenamiento; la de evaluación controla SUMO en las evaluaciones diagnósticas.

Tabla A.13: Semillas por escenario sintético en la fase 1.

Escenario	Entrenamiento	Evaluación	Rutas
3×1	101	100101	1333938385
3×3	137	100137	810840844
$4 \times 4_H$	179	100179	1871007461

El código de fase 1 define 7001 como semilla TPE por defecto, independiente de las semillas de entrenamiento.

A.5.6. Arquitecturas y semillas de la búsqueda refinada sintética

Este apartado detalla la búsqueda refinada sintética, posterior a la prueba A–E y a la comparación A/C de MAPPO. Cada red deriva sus dominios de su propia fase 1.

Los límites de propuestas, iteraciones, detención anticipada y seguimiento se especifican en la Sección 3.4.4. El protocolo permite un ensayo concurrente por combinación. Los fallos, las detenciones anticipadas y las interrupciones consumen presupuesto; un *checkpoint* conservado no acredita por sí solo la admisibilidad del ensayo.

En la fase 1, las propuestas adaptativas de TPE y las detenciones de ASHA no reservaron una prueba en $\rho_{\text{coop}} = 0$. Sus registros no aíslan el efecto del peso vecinal ni demuestran que el valor local sea un óptimo.

Tabla A.14: Arquitecturas y semillas de la búsqueda refinada para las doce combinaciones sintéticas. La semilla de evaluación es común a los algoritmos del mismo escenario; las semillas de TPE no son réplicas de entrenamiento.

Algoritmo	Escenario	Arquitectura	Entrenamiento	Evaluación	TPE
IPPO	3×1	h256	910001	920001	930001
IPPO	3×3	h128	910002	920003	930002
IPPO	$4 \times 4_H$	h128	910003	920004	930003
MAPPO	3×1	h128	910004	920001	930004
MAPPO	3×3	h128	910005	920003	930005
MAPPO	$4 \times 4_H$	h128	910006	920004	930006
HAPPO	3×1	h256	910007	920001	930007
HAPPO	3×3	h256	910008	920003	930008
HAPPO	$4 \times 4_H$	h128	910009	920004	930009
IDQN	3×1	h256	910010	920001	930010
IDQN	3×3	h128	910011	920003	930011
IDQN	$4 \times 4_H$	h256	910012	920004	930012

Las arquitecturas h128 y h256 contienen dos capas ocultas de 128 y 256 unidades, respectivamente. La arquitectura asignada a cada combinación prevista se indica en la Tabla A.14. Son preferencias de búsqueda derivadas de la fase 1, no evidencia de superioridad bajo la recompensa local. Las semillas TPE controlan las propuestas; las semillas SUMO, la simulación. Ninguna sustituye una réplica de entrenamiento.

Admisibilidad y selección de candidatos

Para los candidatos sintéticos, la selección exige que el ensayo haya alcanzado 60 iteraciones, que sus métricas sean numéricas y finitas y que existan al menos 15 registros finitos de métricas de tránsito. También se comprueba que la configuración efectiva y el archivo del modelo final estén completos y puedan leerse. Por sí solo, el estado `COMPLETE` de Optuna indica que el ensayo terminó sin registrar un fallo, pero no garantiza el cumplimiento de estos requisitos.

La lista inicial de candidatos sintéticos se construye con `build_shortlist`, en `experiments/marl_experiments/tuning/phase2_refined/closure_audit.py`, de la copia `phase2-cluster` de `marl-tlc`. Entre los ensayos técnicamente admisibles se consideran aquellos con espera diagnóstica disponible. Se priorizan los que registran cero inicios de teletransporte y una CI diagnóstica de al menos 0,95; después se ordenan por menor espera diagnóstica y por el identificador de la política. Se toma el primero de cada arquitectura disponible y se completa la lista, hasta tres candidatos, con los restantes en ese orden. Este ordenamiento preliminar no sustituye los filtros del panel común de selección.

Cada candidato se evalúa con las semillas SUMO 950001, 950003 y 950007, comunes a los algoritmos de una misma red. Los tres episodios deben registrar cero inicios de teletransporte, una CI de al menos 0,95 y una cantidad de vehículos insertados igual o superior al 95 % de la referencia empírica para esa red y semilla.

Para cada red y semilla, la referencia de inserciones es el máximo observado entre los episodios del panel inicial, que reúne los candidatos de los cuatro algoritmos. La lista de candidatos y las semillas se conservan antes de iniciar el panel mediante `closure_panel.py`. Una vez reunidas sus evaluaciones, `select_recipes`, en `experiments/marl_experiments/tuning/phase2_refined/closure.py`, calcula ese máximo antes de aplicar los filtros y lo utiliza para todos los candidatos del panel. El campo `teleports` de estas evaluaciones corresponde a `teleport_starts`, obtenido mediante TraCI.

Entre quienes cumplen los tres filtros se elige el candidato con menor espera media en las tres evaluaciones. En caso de empate exacto, se priorizan la mayor CI media, el menor tiempo de entrenamiento registrado y, por último, el identificador de la política. Si no se puede completar la auditoría o faltan evaluaciones, la combinación se informa como incompleta; si ningún candidato cumple los filtros, se informa que no hay candidato admisible. El procedimiento de selección termina al identificar una configuración admisible. El entrenamiento final desde cero y su evaluación se describen en la Sección 3.5.1 de la metodología.

El criterio `final_declared_budget` del contrato de entrenamiento identifica el estado de la última iteración del presupuesto completo declarado en `training_iterations`. La comprobación del modelo restaurado exige que su número de iteración coincida con ese valor. El entrenamiento final adopta este criterio para elegir el *checkpoint*; los filtros de selección de las redes sintéticas se aplican al candidato que aporta la configuración, mientras que los diagnósticos del modelo final se interpretan en su evaluación independiente.

A.5.7. Dominios declarados y significado de los parámetros

Las Tablas A.15–A.18 presentan los doce dominios sintéticos declarados para la búsqueda refinada, uno por combinación de algoritmo, escenario sintético y arquitectura prevista. Los valores corresponden al archivo `experiments/marl_experiments/tuning/phase2_refined/informed_domains_rho0_v3.json`, localizado en la copia de trabajo

`phase2-cluster` del proyecto `marl-tlc`. La columna «Muestreo» indica el tipo de selección sin abreviaturas: uniforme continua, loguniforme, uniforme entera o categórico, con los significados descritos al presentar el espacio inicial. En el muestreo entero, $[a; b)$ permite los enteros desde a hasta $b - 1$: el extremo superior queda excluido. En los dominios continuos, los corchetes indican los límites declarados; no garantizan que se propongan sus extremos. Las llaves enumeran las únicas alternativas del muestreo categórico.

Tabla A.15: Dominios declarados para la búsqueda `phase2_refined` de HAPPO por escenario y arquitectura.

Parámetro	Muestreo	3×1 (h256)	3×3 (h256)	$4 \times 4_{\mathrm{H}}$ (h128)
Recorte del actor	Uniforme continua	[0,1; 0,22]	[0,1; 0,22]	[0,1; 0,22]
Niveles del codificador	Uniforme entera	[4; 27)	[5; 37)	[4; 65)
Peso de entropía	Uniforme continua	[0,0043479; 0,0079967]	[0; 0,01]	[0; 0,01]
Límite del gradiente	Loguniforme	[0,64487; 4,7566]	[0,26841; 1,3289]	[0,25; 5]
Probabilidad de ordenación	Uniforme continua	[0,40484; 0,82866]	[0,44174; 0,82189]	[0,48405; 0,77601]
Coeficiente de penalización KL	Loguniforme	[0,05; 0,5]	[0,066096; 0,19175]	[0,05; 0,5]
Objetivo de divergencia KL	Loguniforme	[0,015783; 0,03]	[0,005; 0,03]	[0,005; 0,03]
Parámetro de GAE	Uniforme continua	[0,88683; 0,93862]	[0,90514; 0,9443]	[0,88; 0,99]
Tasa de aprendizaje	Loguniforme	$[2{,}707 \times 10^{-4}; 1 \times 10^{-3}]$	$[3 \times 10^{-5}; 1 \times 10^{-3}]$	$[3 \times 10^{-5}; 1 \times 10^{-3}]$
Tamaño del minilote*	Categórico	{256; 512}	{128; 512}	{256; 512}
Recorridos de optimización	Uniforme entera	[5; 19)	[5; 19)	[5; 19)
Episodios por lote	Uniforme entera	[2; 13)	[2; 13)	[2; 13)
Cota de pérdida de valor	Loguniforme	[8,402; 18,471]	[6,674; 20]	[5; 11,218]

Tabla A.16: Dominios declarados para la búsqueda `phase2_refined` de IDQN por escenario y arquitectura.

Parámetro	Muestreo	3×1 (h256)	3×3 (h128)	$4 \times 4_{\mathrm{H}}$ (h256)
Niveles del codificador	Uniforme entera	[10; 62)	[7; 33)	[4; 65)
Exploración final	Uniforme continua	[0,02; 0,047523]	[0,023555; 0,066094]	[0,02; 0,1]
Pasos para reducir exploración	Categórico	{10.000; 20.000}	{10.000; 20.000}	{10.000; 20.000}
Límite del gradiente	Categórico	{0,5; 1; 2; 5; 10}	{0,5; 1; 2}	{1; 2; 5; 10}
Tasa de aprendizaje	Loguniforme	$[9{,}879 \times 10^{-5}; 1 \times 10^{-3}]$	$[1 \times 10^{-5}; 1 \times 10^{-3}]$	$[8{,}135 \times 10^{-5}; 7{,}889 \times 10^{-4}]$
Horizonte del retorno	Categórico	{3; 5}	{1; 3}	{1; 3; 5}
Pasos antes de aprender	Categórico	{1.000; 2.000; 5.000}	{1.000; 2.000; 5.000}	{1.000; 2.000; 5.000}
Actualización de red objetivo	Categórico	{500; 1.000; 2.000; 5.000}	{500; 2.000; 5.000}	{500; 1.000; 2.000}
Transiciones por lote	Categórico	{64; 128; 256}	{256; 512}	{64; 128; 256}

Tabla A.17: Dominios declarados para la búsqueda refinada de IPPO por escenario y arquitectura.

Parámetro	Muestreo	3×1 (h256)	3×3 (h128)	$4 \times 4_{\mathrm{H}}$ (h128)
Recorte del actor	Uniforme continua	[0,1; 0,22]	[0,1; 0,22]	[0,15327; 0,19443]
Niveles del codificador	Uniforme entera	[4; 65)	[4; 65)	[4; 65)
Peso de entropía	Uniforme continua	[0,0038889; 0,0095621]	[0,00067906; 0,0074136]	[0,0036258; 0,01]
Límite del gradiente	Loguniforme	[0,25; 5]	[0,25; 5]	[0,42722; 1,5143]
Coeficiente de penalización KL	Loguniforme	[0,055016; 0,21664]	[0,05; 0,2904]	[0,05; 0,5]
Objetivo de divergencia KL	Loguniforme	[0,005; 0,03]	[0,005; 0,03]	[0,005; 0,03]
Parámetro de GAE	Uniforme continua	[0,88; 0,99]	[0,89174; 0,96008]	[0,88; 0,99]
Tasa de aprendizaje	Loguniforme	$[3 \times 10^{-5}; 1 \times 10^{-3}]$	$[1{,}136 \times 10^{-4}; 9{,}113 \times 10^{-4}]$	$[1{,}322 \times 10^{-4}; 4{,}772 \times 10^{-4}]$
Tamaño del minilote	Categórico	{128; 512}	{128; 512}	{128; 512}
Recorridos de optimización	Uniforme entera	[5; 16)	[5; 16)	[5; 16)
Episodios por lote	Uniforme entera	[2; 13)	[2; 13)	[2; 13)
Cota de pérdida de valor	Loguniforme	[5; 20]	[5; 20]	[5; 20]

Tabla A.18: Dominios declarados para la búsqueda refinada de MAPPO por escenario y arquitectura.

Parámetro	Muestreo	3×1 (h128)	3×3 (h128)	$4 \times 4_{\mathrm{H}}$ (h128)
Recorte del actor	Uniforme continua	[0,1; 0,22]	[0,1; 0,22]	[0,1; 0,22]
Niveles del codificador	Uniforme entera	[4; 65)	[8; 45)	[4; 65)
Peso de entropía	Uniforme continua	[0,00015809; 0,0062478]	[0; 0,01]	[0,0021511; 0,0080125]
Límite del gradiente	Loguniforme	[0,28422; 0,80645]	[0,25; 5]	[1,1032; 5]
Coeficiente de penalización KL	Loguniforme	[0,05; 0,13242]	[0,05; 0,5]	[0,14905; 0,38494]
Objetivo de divergencia KL	Loguniforme	[0,005; 0,03]	[0,01384; 0,028938]	[0,005; 0,01363]
Parámetro de GAE	Uniforme continua	[0,88703; 0,92246]	[0,88; 0,99]	[0,88; 0,99]
Tasa de aprendizaje	Loguniforme	$[4{,}285 \times 10^{-5};\ 1{,}695 \times 10^{-4}]$	$[1{,}947 \times 10^{-4};\ 1 \times 10^{-3}]$	$[3 \times 10^{-5};\ 1 \times 10^{-3}]$
Tamaño del minilote	Categórico	{256; 512}	{128; 512}	{128; 256; 512}
Recorridos de optimización	Uniforme entera	[5; 16)	[6; 13)	[5; 16)
Episodios por lote	Uniforme entera	[2; 13)	[2; 13)	[2; 13)
Cota de pérdida de valor	Loguniforme	[5; 20]	[5; 20]	[5; 20]

El refinamiento sintético aplica las mismas reglas a las tres redes. Para cada combinación de algoritmo, escenario y arquitectura, requiere al menos diez ensayos de fase 1 que hayan completado el presupuesto sin errores, pertenezcan al dominio inicial y tengan un objetivo numérico y finito. Los ordena de menor a mayor por ese objetivo y, en caso de empate, por identificador.

Como vector inicial, utiliza la mediana de los parámetros numéricos y la moda de los categóricos entre los cinco mejores; esa combinación puede no coincidir con un ensayo histórico. La fase 2 entrena desde cero, sin incorporar puntuaciones, archivos de estado del modelo (*checkpoint*) ni bases Optuna de fase 1. Cada red conserva sus propios dominios, derivados de sus ensayos de fase 1.

En parámetros numéricos se parte del intervalo de los diez mejores ensayos, se amplía cada extremo en un 10 % del ancho del dominio original y se limita a sus fronteras. Los parámetros loguniformes se tratan en escala logarítmica. Se conserva el dominio original si el intervalo de los veinte mejores ensayos disponibles cubre al menos el 70 % de su ancho o si alguno de los diez mejores queda a una distancia de un extremo no mayor que el 5 % de ese ancho. Para los parámetros enteros se calcula el ancho entre el menor y el mayor valor admisibles; las distancias del 5 % y del 10 % se redondean hacia arriba, con un margen mínimo de una unidad para la ampliación. El extremo superior del dominio resultante se expresa como exclusivo.

En parámetros categóricos se retienen las alternativas de los veinte mejores ensayos disponibles. Si solo hay una, se añade la siguiente del dominio original o, si es la última, la anterior.

Las claves de configuración se identifican en la Tabla A.12. `kl_coeff` pondera la penalización KL y `kl_target` fija el objetivo usado para adaptar ese coeficiente. El asterisco de `minibatch_size` conserva la excepción de HAPPO: se procesa el lote completo por actor.

Para los métodos PPO, el tamaño objetivo del lote por componente de aprendizaje es `train_batch_episodes` multiplicado por $3600/5 = 720$ pasos; no incluye un factor por la cantidad de procesos de simulación. En IDQN, los contadores corresponden a pasos de entrenamiento o muestreo según RLlib, y el lote contiene transiciones. La cota `vf_clip_param` se aplica a la pérdida cuadrática según la Ecuación (A.4).

A.5.8. Antecedente de calibración del codificador urbano

El aprendizaje urbano exige recalibrar el codificador y adaptar la inicialización y los presupuestos de entrenamiento.

La calibración exploratoria del codificador se realizó sobre una versión previa de la red y la demanda, identificada como `v14`. Utilizó las semillas 5001 y 5002, 300 s de calentamiento, 7.200 s de control y una memoria de espera de 1.000 s. El percentil 99 del máximo por paso de la suma de esperas de los vehículos por carril produjo $M_{\text{lane}} = 5.396\,\text{veh} \cdot \text{s}$, frente a 712–1.184 veh · s en las redes sintéticas. El cálculo se conserva en `docs/mendoza_preparation/encoder_calibration.json` de `marl-tlc`. El valor no se transfiere al escenario de demanda final y programas fijos: su uso exige una nueva calibración.

A.6. Pruebas exploratorias de observación y recompensa

Este apartado documenta una exploración preliminar de formulaciones con MAPPO en $4 \times 4_H$ y una comparación pareada de formulaciones local y vecinal en las tres redes sintéticas. Estas pruebas se situaron entre las dos fases de búsqueda y se utilizaron como antecedente de la decisión de fijar la recompensa local en el protocolo refinado; no constituyen por sí solas una demostración de su superioridad. Son procedimientos exploratorios distintos del protocolo de comparación final de los cuatro algoritmos.

A.6.1. Exploración preliminar de formulaciones

En la etapa exploratoria se entrenaron cinco variantes (A–E) sobre la red $4 \times 4_H$ empleando MAPPO con arquitectura `h128` y tres semillas de entrenamiento durante 20 iteraciones por política, en episodios de 1.800 s precedidos por 300 s de calentamiento. La Tabla A.19 resume las variantes: A corresponde a la formulación local; B, C y D incorporan señales vecinales con distintas normalizaciones; y E evalúa una recompensa

local inspirada en el concepto de presión de PressLight [WCZ+19], mediante conteos de vehículos detenidos entre carriles de entrada y salida.

Tabla A.19: Variantes examinadas en la prueba preliminar sobre la red $4 \times 4_H$.

Variante	Observación	Recompensa
A	Local: fase activa y señales de carriles propios.	Diferencia local de espera acumulada ($\rho_{\text{coop}} = 0$).
B	Local y suma de espera acumulada de cada vecino.	Diferencia local y vecinal sin normalización por carriles ($\rho_{\text{coop}} = 0{,}1$).
C	Local y vecinal: espera media por carril de cada vecino.	Diferencia local y vecinal normalizada por carriles ($\rho_{\text{coop}} = 0{,}1$).
D	Local, suma de espera vecinal y $\ln(1 + m_j)$ de cada vecino.	Igual que C ($\rho_{\text{coop}} = 0{,}1$).
E	Local: fase activa y señales de carriles propios.	Negativo de la diferencia absoluta de vehículos detenidos entre carriles de entrada y salida.

En esta prueba, B y D incluyen ejecuciones completadas y no se clasifican como fallos técnicos. Esta constatación describe su estado de ejecución, no sus diferencias de desempeño.

A.6.2. Comparación local y vecinal multiescenario

La comparación utiliza una misma configuración de hiperparámetros de MAPPO con arquitectura `h128` en las tres redes sintéticas. Para el contraste pareado se adoptó la variante C, que normaliza por el número de carriles entrantes m_j tanto la observación como la recompensa vecinal; su elección frente a las variantes B y D no respondió a una regla estadística prefijada, por lo que la comparación evalúa únicamente C frente a A y no establece un orden general entre formulaciones vecinales.

En la versión conservada para esta comparación, las atribuciones almacenadas en otros carriles no se actualizan cuando vence la memoria, lo que puede subestimar la espera atribuida al carril actual. La salida de vehículos, los cambios de carril y el vencimiento de la ventana también pueden reducir la señal local sin que disminuya la espera acumulada por viaje. Esta última se evalúa con `TripInfo.waitingTime`, que acumula la espera durante todo el viaje sin esa ventana de olvido [Ecl26d].

En la variante C, el vector de observación local definido en la Ecuación (3.1) se amplía con un término codificado $e\big(W_j^{(t)}/m_j\big)$ por cada vecino directo $j \in \mathcal{N}(i)$, escalado según el umbral vecinal M_{vec} documentado en la Sección A.6.4.

La recompensa local $L_i^{(t)}$ se define en la Ecuación (3.2). En la variante C, cada agente i complementa esa señal con el promedio de las variaciones de espera de sus vecinos directos $j \in \mathcal{N}(i)$, normalizadas por el número de carriles entrantes m_j; el peso de cooperación se fija en $\rho_{\text{coop}} = 0{,}1$. Como todas las intersecciones controladas de los escenarios estu-

diados tienen al menos un vecino ($|\mathcal{N}(i)| \geq 1$), el término vecinal por carril $N_{i,\text{carril}}^{(t)}$ y la recompensa compuesta $R_i^{(t)}$ quedan definidos por:

$$N_{i,\text{carril}}^{(t)} = \frac{1}{|\mathcal{N}(i)|} \sum_{j \in \mathcal{N}(i)} \frac{L_j^{(t)}}{m_j}, \tag{A.1}$$

$$R_i^{(t)} = (1 - \rho_{\text{coop}}) L_i^{(t)} + \rho_{\text{coop}} N_{i,\text{carril}}^{(t)}, \tag{A.2}$$

Para un nodo aislado hipotético ($|\mathcal{N}(i)| = 0$), el código anula $N_{i,\text{carril}}^{(t)}$ y conserva $R_i^{(t)} = L_i^{(t)}$. Cada agente recibe su propia recompensa escalar durante el entrenamiento. El coeficiente ρ_{coop} pondera la combinación de señales de escalas distintas y no representa un porcentaje fijo de la recompensa resultante.

La Figura A.3 compara ambas formulaciones para un agente i con dos vecinos ilustrativos, j y k. En el panel (a), la variante A observa la fase propia p_i y los m_i carriles locales codificados, y recibe la recompensa local L_i. En el panel (b), la variante C añade la espera media por carril codificada de cada vecino directo, ampliando la entrada del actor y del crítico centralizado; su recompensa combina L_i y $N_{i,\text{carril}}$ con $\rho_{\text{coop}} = 0{,}1$.

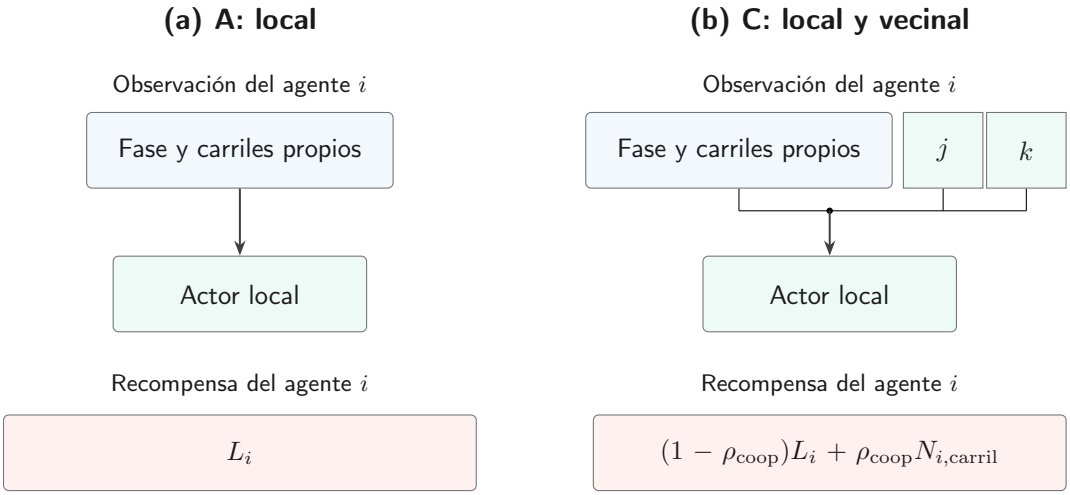


Figura A.3: Estructura de la observación del actor y de la señal de recompensa en MAPPO: (a) formulación local A; (b) formulación vecinal C.

La comparación A/C usa un diseño pareado: cada par de políticas reúne dos políticas, una por variante, emparejadas por la semilla utilizada durante el entrenamiento. El emparejamiento no implica igualdad de inicializaciones al cambiar las dimensiones de entrada. Se entrenaron 24 pares independientes por red sintética (72 pares y 144 políticas en total), durante 40 iteraciones por ejecución; para evaluar se retuvo el modelo de la última iteración.

A.6.3. Configuración fija de la comparación multiescenario

La Tabla A.20 conserva los hiperparámetros de MAPPO h128 seleccionados en un ensayo histórico de $4 \times 4_H$ y aplicados sin cambios entre las tres redes de tráfico. El ensayo `49cfbba0` está registrado en `rho_screening_recipes/mappo_4x4_H_h128.json` e incorporado a los manifiestos de campaña. Los valores continuos se muestran redondeados; la fuente conserva precisión completa.

La planificación usó una desviación de referencia cercana a dos segundos por vehículo y un intervalo del 95 % basado en t de Student, bajo supuestos de diferencias independientes y aproximadamente normales. Con 24 parejas, se esperaba una semiamplitud cercana a 0,85 segundos por vehículo.

Tabla A.20: Hiperparámetros fijos de aprendizaje de la comparación multiescenario.

Parámetro	Valor
Arquitectura	dos capas de 128 unidades
Tasa de aprendizaje (`lr`)	$4,95235885 \times 10^{-5}$
Recorte del actor (`clip_param`)	0,20148266
GAE (`lambda_gae`)	0,90059980
Coeficiente de entropía	0,00483113
Recorte del gradiente	1,48846291
Coeficiente KL	0,24180060
Objetivo KL	0,01053851
Cota de pérdida de valor	10,11299284
Recorridos de optimización	8
Episodios por lote	3
Tamaño del minilote	128
Niveles del codificador (I)	17
Descuento (γ)	0,99

La comparación fija el peso de la recompensa vecinal en cero para la variante local y en 0,1 para la vecinal; también asigna observación local o vecinal y normaliza por carriles, según la condición. Los límites de escala del codificador corresponden a cada escenario. Los tres episodios de cada lote representan $3 \times (3600/5) = 2160$ pasos de entorno por componente de aprendizaje. El número de procesos de simulación no multiplica este tamaño de lote.

Los manifiestos de la comparación registran SUMO 1.26.0, Ray 2.54.1 y PyTorch 2.10.0 con CUDA 12.8. Estas versiones corresponden a esa campaña y no se atribuyen automáticamente a las búsquedas históricas. Los archivos `manifest.json` de cada par conservan su configuración y versiones efectivas.

A.6.4. Calibraciones y semillas

El límite de escala local se calculó con las semillas 42–44; para 3×1, 3×3 y $4 \times 4_H$ se obtuvieron 1184, 1136 y 712, respectivamente. La calibración de la señal de espera vecinal incorporada en la observación C utilizó las semillas 51001–51003 y produjo límites de escala de 9660, 5329 y 4652 en esas redes. Los límites locales se expresan en veh·s y los vecinales en veh·s por carril. En ambos casos se empleó el percentil 99 y 300 segundos de calentamiento. Para la señal vecinal, el percentil se calculó sobre la medida media agrupada por intersección y paso. Estos valores corresponden a escalas de señales codificadas, no a tiempos máximos de viaje ni a valores de recompensa.

La comparación en las tres redes utiliza las semillas 61001–61024 para el entrenamiento y 71001–71005 para la evaluación. Las semillas de evaluación son comunes a las dos variantes y se mantienen separadas de las de entrenamiento.

La calibración vecinal específica se conserva junto con la configuración de la comparación; otros archivos de calibración pueden corresponder a diseños distintos.

A.6.5. Evaluación de las formulaciones

Cada una de las 144 políticas entrenadas en la comparación pareada (24 pares por cada una de las tres redes sintéticas) se evaluó sobre cinco réplicas independientes utilizando las semillas de SUMO 71001 a 71005 —comunes a ambas variantes y disjuntas de las semillas de entrenamiento—, totalizando 720 episodios de evaluación en la ventana $[t_{\text{inicio}}, t_{\text{fin}}) = [300, 3.900)$ s tras restaurar el estado posterior a los 300 s de calentamiento.

A.6.6. Análisis por pares y criterio de decisión

Siguiendo las recomendaciones metodológicas para inferencia estadística en aprendizaje por refuerzo profundo [ASC+21], la unidad de observación independiente es el par de entrenamiento $s \in \{1, \ldots, 24\}$, mientras que las cinco evaluaciones ($q \in \{1, \ldots, 5\}$) se promedian dentro de cada política para reducir la varianza de simulación. Sea $w_{s,b,q}$ la espera media por vehículo insertado ($\bar{w}_{\text{ins}}$) del par s bajo la variante $b \in \{A, C\}$ en la semilla de evaluación q. La media por política $\bar{w}_{s,b}$, la diferencia absoluta pareada d_s y el cambio relativo pareado z_s se definen como:

$$\begin{aligned} \bar{w}_{s,b} &= \frac{1}{5} \sum_{q=1}^{5} w_{s,b,q}, \\ d_s = \bar{w}_{s,C} - \bar{w}_{s,A}, &\qquad z_s = \frac{\bar{w}_{s,C} - \bar{w}_{s,A}}{\bar{w}_{s,A}}, \end{aligned} \tag{A.3}$$

d_s se expresa en segundos por vehículo y z_s es adimensional; sus valores negativos indican una menor espera de C respecto de A. Para la tasa de completitud CI se calcula la diferencia pareada $d_{\text{CI},s} = \overline{\text{CI}}_{s,C} - \overline{\text{CI}}_{s,A}$. Los estimadores puntuales por red son los promedios muestrales entre los 24 pares: $\bar{d}$, $\bar{z}$ y $\bar{d}_{\text{CI}}$. Si $\bar{w}_{s,A} = 0$, se conserva d_s y se informa z_s como

indefinido; en ese caso no se emite la decisión basada en el efecto relativo.

La incertidumbre muestral se cuantifica mediante *bootstrap* no paramétrico con 20.000 remuestreos con reemplazo de los 24 pares de cada red. Se reportan intervalos de confianza percentiles al 95 % y al 98,33 % (percentiles 2,5 y 97,5; aproximadamente 0,83 y 99,17, respectivamente). El nivel del 98,33 % aplica la corrección de Bonferroni al nivel nominal de 0,05 entre los tres contrastes, uno por cada red (0,05/3), para cada medida por separado; no se ajusta conjuntamente entre métricas. Como análisis de sensibilidad se calcula también un intervalo basado en t de Student con 24 diferencias pareadas, bajo el supuesto de diferencias independientes y aproximadamente normales. Ambos métodos dan aproximaciones cuya cobertura no está garantizada; los valores extremos se conservan para revisar su influencia.

Se adopta una decisión favorable a la incorporación de acoplamiento vecinal (variante C) en una red si y solo si se verifican simultáneamente tres condiciones prácticas:

- **Reducción relevante de la espera:** el extremo superior del intervalo de confianza del 98,33 % para el cambio relativo medio $\bar{z}$ es estrictamente menor que $-0{,}05$ (reducción de al menos el 5 %).
- **Preservación de la completitud (CI):** el extremo inferior del intervalo de confianza del 98,33 % para la diferencia media $\bar{d}_{\mathrm{CI}}$ es superior a $-0{,}005$ (merma máxima admisible de 0,5 puntos porcentuales).
- **Ausencia de penalización por teletransportes:** el número de inicios de teletransporte de la variante C no supera al de la variante A en ninguna evaluación pareada con igual semilla.

La decisión requiere los 24 pares completos de cada red y sus cinco evaluaciones por política. Si faltan pares, métricas o contadores de teletransporte, el análisis se informa como incompleto y no se emite una decisión favorable. Las tres redes sintéticas (3×1, 3×3 y $4 \times 4_H$) se analizan por separado. El criterio no fija un umbral de inserciones ni incluye el retraso previo al ingreso; para interpretar una decisión favorable como una mejora de la atención a la demanda, deben examinarse también esas medidas.

En la implementación, el campo `mean_acc_waiting_time` registra en cada paso de decisión la espera acumulada en los carriles del agente dividida por la cantidad de vehículos presentes. Cuando no hay vehículos, el valor del paso es cero. Para calcular el Gini, el código promedia estos valores a lo largo del control para cada agente y da igual peso a todos los agentes. La restauración del estado posterior al calentamiento no almacena los generadores aleatorios (`-save-state.rng`) de SUMO; por tanto, restaurar el estado vehicular no garantiza repetir exactamente las secuencias microscópicas individuales.

El protocolo original de la campaña, identificado en `docs/PROTOCOLO_COOPERACION_MULTIESCENARIO.md`, incluye las tres redes. El informe histórico, en `cooperation_`

`multiscenario_20260920/report/INFORME.md`, presenta como análisis principal 48 parejas de 3×1 y $4 \times 4_H$. El mismo informe separa los datos de 3×3 después de revisar los resultados porque su entrenamiento tuvo una dinámica distinta; señala que esa decisión de presentación no estaba fijada de antemano y que los registros de esa red se conservaron aparte. El criterio histórico de presentación se distingue del alcance metodológico adoptado aquí, que analiza por separado las tres redes; por tanto, no implica una exclusión previa de 3×3.

A.6.7. Alcance y limitaciones de la comparación

El contraste A/C modifica conjuntamente la observación y la recompensa vecinales y aumenta la dimensión de entrada del actor y del crítico centralizado. Por ello, no aísla el efecto individual de cada componente ni el de la información vecinal frente al aumento del número de parámetros. Tampoco anticipa el desempeño de variantes con búsquedas de hiperparámetros independientes.

La evidencia se limita a MAPPO, por lo que permite comparar A y C, pero no ordenar las formulaciones vecinales en general. La planificación muestral se basó en una diferencia absoluta y un intervalo del 95 %; la regla de decisión usa el efecto relativo y un intervalo del 98,33 %. Por esa diferencia, el cálculo muestral no asegura la precisión requerida por la regla final.

A.7. Detalles del aprendizaje y de la codificación

En los módulos de aprendizaje propios de MAPPO y HAPPO, $V_{b,i}$ es la predicción del crítico para el agente i en la muestra b y $y_{b,i}$ es su valor objetivo. Se denotan por N el número de agentes, por B la cantidad de muestras válidas del lote y por $c_v = \texttt{vf_clip_param}$ la cota superior configurada. Primero se calcula el error cuadrático promedio entre agentes de cada muestra, ℓ_b; después se limita al intervalo $[0, c_v]$ y se promedian las pérdidas de las muestras válidas para obtener la pérdida final del crítico, $\mathcal{L}_V$:

$$\ell_b = \frac{1}{N}\sum_{i=1}^{N}(V_{b,i} - y_{b,i})^2, \qquad \mathcal{L}_V = \frac{1}{B}\sum_{b=1}^{B}\text{mín}\{c_v, \text{máx}(0, \ell_b)\}. \tag{A.4}$$

Las muestras válidas son las que la máscara del lote no excluye del cálculo. Este recorte del error cuadrático no es el *value clipping* convencional de PPO, que compara predicciones de valor recortadas y no recortadas. Como el error se promedia entre agentes antes de aplicar la cota, una muestra saturada deja de contribuir al ajuste de todas las salidas del crítico, lo que puede afectar las estimaciones de valor y las ventajas que guían a los actores; la frecuencia de saturación no se cuantifica en los registros descritos en este trabajo.

En el aprendiz de HAPPO de la versión congelada inspeccionada, el crítico se actualiza al comienzo de cada *epoch* con el lote completo. Se aplica un paso de gradiente por actor y época. Las ventajas individuales estandarizadas ya calculadas inicializan los factores

de reponderación M; estos se reinician en cada *epoch*, y las ventajas no se recalculan durante la secuencia de actores. Antes de actualizar actores, el código construye un orden entero de agentes. En cada turno, `greedy_selection_prob` determina la probabilidad de elegir, entre los agentes pendientes, el que tiene la mayor media del valor absoluto de su factor inicial; de lo contrario, elige uno al azar. Esta regla ordena a los actores para su actualización, no selecciona la fase semafórica. El orden no se vuelve a sortear después de reponderar factores.

Tras actualizar un actor, el código calcula para la acción de la muestra la razón entre su probabilidad bajo el actor actualizado y su probabilidad bajo la política recolectora. Esa razón multiplica los factores de los agentes que aún esperan su turno. La reponderación no ejecuta una actualización de gradiente adicional para esos actores. Estas reglas describen la adaptación de HAPPO utilizada en la tesina.

Zhong et al. encuadran HAPPO como una instancia de HAML y demuestran mejora monótona del retorno conjunto y convergencia bajo las condiciones del marco, que incluyen una recompensa compartida en un juego cooperativo. Las ventajas por agente no constituyen por sí solas una diferencia con ese planteo: HAPPO utiliza una descomposición por agentes de la ventaja conjunta. En esta adaptación, los objetivos de valor y las ventajas se calculan a partir de recompensas específicas por agente, en un juego parcialmente observable. Al faltar el retorno común, las garantías teóricas no se aplican directamente a la formulación experimental [ZKF+24].

A.7.1. Desarrollo algebraico del codificador

En las ecuaciones siguientes, $x \geq 0$ y $M_{\text{lane}} > 0$ representan los valores numéricos de la espera acumulada por carril y de su límite de escala, expresados en veh·s. La entrada normalizada es $\hat{x} = \min(1, x/M_{\text{lane}}) \in [0, 1]$. Para $I \geq 2$ niveles discretos se define $L = (I-1)/M_{\text{lane}}$. En los dominios utilizados, $M_{\text{lane}} > I - 1$, por lo que $0 < L < 1$. La mezcla entre las componentes logarítmica y lineal queda dada por:

$$g(\hat{x}) = (1 - L)\frac{\log_2\left(\frac{\hat{x}}{L} + 1\right)}{\log_2\left(\frac{1}{L} + 1\right)} + L\hat{x}, \tag{A.5}$$

y el nivel entero codificado $e(x) \in \{0, 1, \ldots, I-1\}$ se obtiene escalando por $I - 1$, redondeando hacia arriba y acotando al nivel máximo:

$$e(x) = \min\{I - 1, \text{ceil}((I-1)g(\hat{x}))\}. \tag{A.6}$$

Para la observación vecinal, se aplica la misma función sobre la espera media por carril W_j/m_j, empleando la cota de escala vecinal M_{vec} (en veh·s por carril).

Definiendo el coeficiente logarítmico ponderado $F = (1 - L)(I - 1)/\log_2(1/L + 1)$, para cualquier valor en el rango $0 \leq x < M_{\text{lane}}$ la transformación implementada en código

se computa equivalentemente como:

$$e(x) = \text{ceil}\left(F \cdot \log_2\left(\frac{x}{M_{\text{lane}} \cdot L} + 1\right) + L^2 \cdot x\right), \tag{A.7}$$

mientras que para $x \geq M_{\text{lane}}$ se asigna directamente el nivel máximo $I - 1$.

La Figura A.4 muestra las contribuciones logarítmica y lineal ya ponderadas y su suma $g(\hat{x})$, antes del escalado y del redondeo. Ambos ejes son adimensionales: la abscisa representa la espera normalizada y la ordenada, cada contribución o su suma. El ejemplo ilustra la transformación y no un resultado de control.

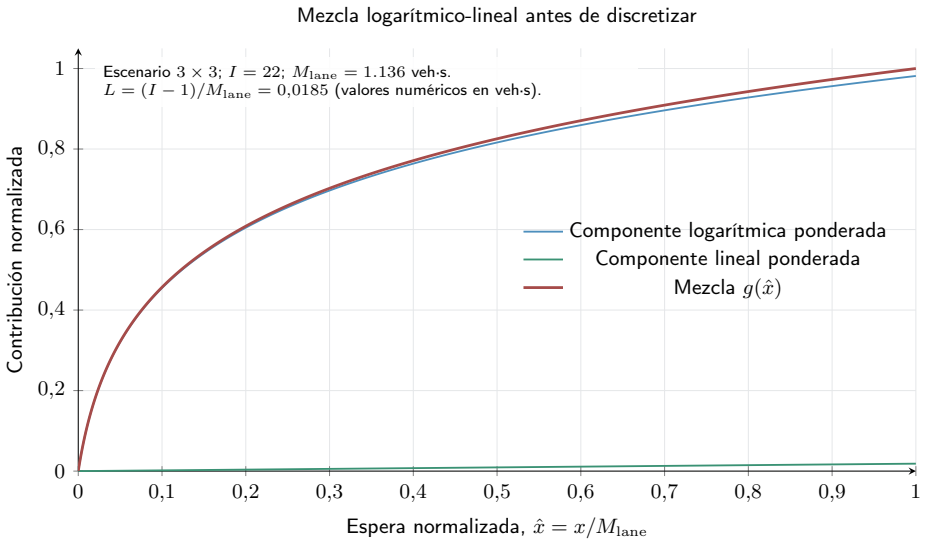


Figura A.4: Ejemplo ilustrativo con $I = 22$ y límite de escala $M_{\text{lane}} = 1.136$ veh·s calibrado para el escenario 3×3; $I = 22$ no corresponde a la configuración de la comparación A/C.

A.7.2. Aplicación de la máscara de acciones

En cada decisión, $\mathcal{A}_i^{\text{adm}}(t)$ es el subconjunto de acciones permitidas por la señal vigente. La máscara binaria $b_i(a,t)$ vale uno si a pertenece a ese conjunto y cero en caso contrario. Si $z_i(a,t)$ es la puntuación no normalizada (*logit*) asignada por el actor, la puntuación enmascarada $\widetilde{z}_i(a,t)$ se obtiene sumando el logaritmo natural de la máscara:

$$\widetilde{z}_i(a,t) = z_i(a,t) + \log b_i(a,t), \qquad b_i(a,t) = \begin{cases} 1 & \text{si } a \in \mathcal{A}_i^{\text{adm}}(t) \\ 0 & \text{si } a \notin \mathcal{A}_i^{\text{adm}}(t) \end{cases} \tag{A.8}$$

Con $\log(0) = -\infty$, las acciones no permitidas reciben probabilidad cero después de normalizar la política. La implementación sustituye el infinito por una puntuación finita muy baja y requiere al menos una acción admisible. Los algoritmos PPO aplican la máscara a las puntuaciones de política; IDQN filtra las acciones al seleccionarlas y evaluarlas.

A.7.3. Preparación de las figuras de escenarios

Las redes sintéticas se representan con TikZ a partir de los XML de SUMO mediante `metodologia_generar_redes.py`. El generador conserva los hashes de las fuentes, verifica los conteos de agentes, tramos y carriles y representa los sentidos de circulación. Las conexiones entre centros de nodos se muestran con anchos convencionales y escala propia por panel. El mapa de Mendoza balance se construyó a partir de la red XML y ubica los controladores y el acceso TAZ 28; la cámara 169 está fuera del dominio y no se le asigna una posición en la figura. La vista completa de las zonas se presenta por separado en la Figura A.6.

A.7.4. Vistas documentales de los escenarios

La Figura A.5 permite consultar la distribución temporal de los programas sintéticos de referencia. Los intervalos V_i, A_i y R corresponden a verde, amarillo y todo rojo, respectivamente. La Figura A.6 representa las TAZ del escenario balance mediante sus tramos asociados; las marcas no son límites territoriales.

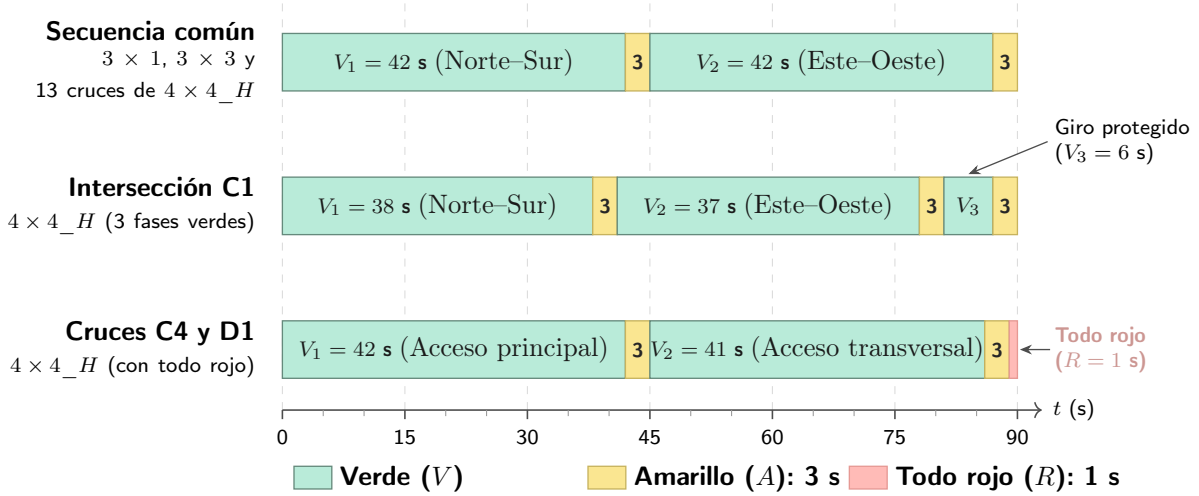


Figura A.5: Distribución de los intervalos de verde, amarillo y todo rojo en los ciclos de referencia de 90 segundos.

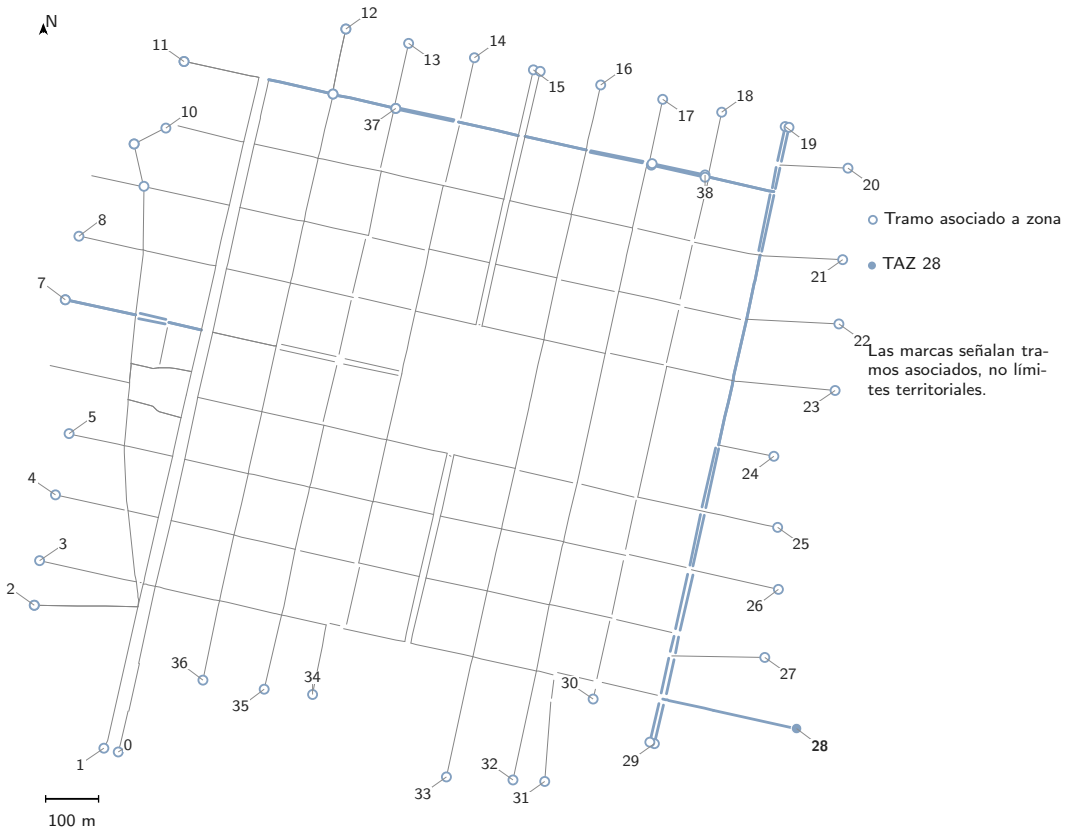


Figura A.6: Zonas de análisis de tránsito de Mendoza balance, representadas mediante sus tramos asociados. Los identificadores van de 0 a 38, salvo 6 y 9; las marcas no representan límites territoriales.

Bibliografía

[ACS24] Albrecht, Stefano V., Filippos Christianos y Lukas Schäfer: *Multi-Agent Reinforcement Learning: Foundations and Modern Approaches*. MIT Press, 2024. `https://www.marl-book.com/`, Consultado en 2025.

[AHL16] Abel, David, D. Ellis Hershkowitz y Michael L. Littman: *Near Optimal Behavior via Approximate State Abstraction*. En *Proceedings of the 33rd International Conference on Machine Learning*, volumen 48 de *Proceedings of Machine Learning Research*, páginas 2915–2923. PMLR, 2016.

[ALBBW+18] Alvarez Lopez, Pablo, Michael Behrisch, Laura Bieker-Walz, Jakob Erdmann, Yun Pang Flötteröd, Robert Hilbrich, Leonhard Lücken, Johannes Rummel, Peter Wagner y Evamarie Wießner: *Microscopic Traffic Simulation using SUMO*. En *2018 21st International Conference on Intelligent Transportation Systems (ITSC)*, páginas 2575–2582. IEEE, 2018.

[AOS20] Amato, Christopher, Frans A. Oliehoek y Matthijs T.J. Spaan: *A Survey of Decentralized Partially Observable Markov Decision Processes and Applications*. Journal of Artificial Intelligence Research, 69:1–72, 2020.

[AS22] Ault, James y Guni Sharon: *Cooperative Multi-agent Reinforcement Learning Applied to Multi-intersection Traffic Signal Control*. En *Proceedings of the Third Workshop on Data-driven Intelligent Transportation, co-located with CIKM '22*, 2022. `https://people.engr.tamu.edu/guni/papers/CIKM22-MATCS.pdf`, Fuente: [7, 8] Destaca el "éxito limitado"de SARL y los enfoques independientes en redes.

[ASC+21] Agarwal, Rishabh, Max Schwarzer, Pablo Samuel Castro, Aaron C. Courville y Marc G. Bellemare: *Deep Reinforcement Learning at the Edge of the Statistical Precipice*. En *Advances in Neural Information Processing Systems 34*, páginas 29304–29320, 2021. `https://proceedings.neurips.cc/paper_files/paper/2021/hash/f514cec81cb148559cf475e7426eed5e-Abstract.html`.

[Aso18] Asociación de Fábricas Argentinas de Componentes: *Flota circulante en Argentina 2017*. Informe técnico, Asociación de Fábricas Argentinas de

Componentes, mayo 2018. https://cdn.motor1.com/pdf-files/afac-informe-parque-circulante-2017pdf.pdf, Informe elaborado con datos de AFAC y Promotive.

[Aso26] Asociación de Fábricas Argentinas de Componentes: *Flota vehicular circulante en Argentina*. Informe técnico, Asociación de Fábricas Argentinas de Componentes, 2026. https://www.automotrix.com.ar/adm/enviosmasivos/Plantillas/PRENSA/2026/AFAC_PRENSA_FLOTACIRCULANTE_2025.pdf, Datos al cierre de 2025; informe elaborado en el marco del convenio entre AFAC y Promotive S.A.

[ASY+19] Akiba, Takuya, Shotaro Sano, Toshihiko Yanase, Takeru Ohta y Masanori Koyama: *Optuna: A next-generation hyperparameter optimization framework*. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, páginas 2623–2631, 2019.

[BB24] Bishop, Christopher M. y Hugh Bishop: *Deep Learning: Foundations and Concepts*. Springer, Cham, 2024.

[BBBK11] Bergstra, James S., Rémi Bardenet, Yoshua Bengio y Balázs Kégl: *Algorithms for Hyper-Parameter Optimization*. En *Advances in Neural Information Processing Systems 24*, 2011. https://proceedings.neurips.cc/paper/2011/hash/86e8f7ab32cfd12577bc2619bc635690-Abstract.html.

[BV02] Bowling, Michael y Manuela Veloso: *Multiagent learning using a variable learning rate*. Artificial Intelligence, 136(2):215–250, 2002.

[CWCL19] Chu, Tianshu, Jie Wang, Lara Codecà y Zhaojian Li: *Multi-agent deep reinforcement learning for large-scale traffic signal control*. IEEE Transactions on Intelligent Transportation Systems, 21(3):1086–1095, 2019.

[CYL+24] Chen, Wubing, Shangdong Yang, Wenbin Li, Yujing Hu, Xiao Liu y Yang Gao: *Learning Multi-Intersection Traffic Signal Control via Coevolutionary Multi-Agent Reinforcement Learning*. IEEE Transactions on Intelligent Transportation Systems, 25(11):15947–15963, 2024.

[CyMR18] Mayor R., Rafael Cal y: *Ingeniería de tránsito: Fundamentos y aplicaciones*. Alfaomega, 9na edición, 2018.

[DLR26] DLR – Institute of Transportation Systems: *SUMO User Documentation*, 2026. https://sumo.dlr.de/docs/, Documentación web consultada en 2026.

[DLSZ26] Deng, Maojiang, Shoufeng Lu, Jiazhao Shi y Wen Zhang: *Adaptive Traffic Signal Control Optimization Using a Novel Road Partition and Multi-Channel State Representation Method*. Urban Lifeline, 4(1):9, 2026.

[dWGM+20] Witt, Christian Schroeder de, Tarun Gupta, Denys Makoviichuk, Viktor Maksimov, Edward Ivanov, Michael Schmid, Gregory Yakovlev, Philip Torr *y cols.*: *Is independent learning all you need in the starcraft multi-agent challenge?* arXiv preprint arXiv:2011.09533, 2020.

[Ecl26a] Eclipse SUMO: *SUMO Documentation: Randomness*. `https://sumo.dlr.de/docs/Simulation/Randomness.html`, 2026. Documentación en línea, consultada el 8 de octubre de 2026.

[Ecl26b] Eclipse SUMO: *SUMO Documentation: Summary*. `https://sumo.dlr.de/docs/Simulation/Output/Summary.html`, 2026. Documentación en línea, consultada el 15 de octubre de 2026.

[Ecl26c] Eclipse SUMO: *SUMO Documentation: TraCI: Vehicle Value Retrieval*. `https://sumo.dlr.de/docs/TraCI/Vehicle_Value_Retrieval.html`, 2026. Documentación en línea, consultada el 8 de octubre de 2026.

[Ecl26d] Eclipse SUMO: *SUMO Documentation: TripInfo*. `https://sumo.dlr.de/docs/Simulation/Output/TripInfo.html`, 2026. Documentación en línea, consultada el 8 de octubre de 2026.

[ELR23] Eimer, Theresa, Marius Lindauer y Roberta Raileanu: *Hyperparameters in Reinforcement Learning and How To Tune Them*. En *Proceedings of the 40th International Conference on Machine Learning*, volumen 202 de *Proceedings of Machine Learning Research*, páginas 9104–9149. PMLR, 2023. `https://proceedings.mlr.press/v202/eimer23a.html`.

[FA11] Fernández A., Rodrigo: *Elementos de la teoría del tráfico vehicular*. Fondo Editorial de la Pontificia Universidad Católica del Perú, 2011.

[Fed08] Federal Highway Administration: *Traffic Signal Timing Manual*. Informe técnico FHWA-HOP-08-024, Federal Highway Administration, Office of Operations, 2008. Primera edición. Capítulos 4: Traffic Signal Design y 6: Coordination. Disponible en: `https://ops.fhwa.dot.gov/publications/fhwahop08024/`.

[FNF+17] Foerster, Jakob, Nantas Nardelli, Gregory Farquhar, Philip H.S. Torr, Pushmeet Kohli y Shimon Whiteson: *Stabilising Experience Replay for*

Deep Multi-Agent Reinforcement Learning. En *Proceedings of the 34th International Conference on Machine Learning (ICML)*, páginas 1146–1155. PMLR, 2017.

[FYX+23] Fang, Jie, Ya You, Mengyun Xu, Juanmeizi Wang y Sibin Cai: *Multi-Objective Traffic Signal Control Using Network-Wide Agent Coordinated Reinforcement Learning*. Expert Systems with Applications, 229:120535, 2023.

[GBC16] Goodfellow, Ian, Yoshua Bengio y Aaron Courville: *Deep Learning*. MIT Press, Cambridge, MA, 2016. `https://www.deeplearningbook.org/`.

[GR18] Genders, Wade y Saiedeh Razavi: *Evaluating Reinforcement Learning State Representations for Adaptive Traffic Signal Control*. Procedia Computer Science, 130:26–33, 2018.

[HHA22] Haddad, Tarek Amine, Djalal Hedjazi y Sofiane Aouag: *A Deep Reinforcement Learning-Based Cooperative Approach for Multi-Intersection Traffic Signal Control*. Engineering Applications of Artificial Intelligence, 114:105019, 2022.

[JLW+24] Jiang, Haoyuan, Ziyue Li, Hua Wei, Xuantang Xiong, Jingqing Ruan, Jiaming Lu, Hangyu Mao y Rui Zhao: *X-Light: Cross-City Traffic Signal Control Using Transformer on Transformer as Meta Multi-Agent Reinforcement Learner*. En *Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI)*, páginas 94–102, 2024.

[KCW+22] Kuba, Jakub Grudzien, Ruiqing Chen, Muning Wen, Ying Wen, Fanglei Sun, Jun Wang y Yaodong Yang: *Trust region policy optimisation in multi-agent reinforcement learning*. En *International Conference on Learning Representations (ICLR)*, 2022. `https://arxiv.org/abs/2109.11251`.

[KKBA23] Kolat, Máté, Bálint Kővári, Tamás Bécsi y Szilárd Aradi: *Multi-Agent Reinforcement Learning for Traffic Signal Control: A Cooperative Approach*. Sustainability, 15(4):3479, 2023.

[KL02] Kakade, Sham y John Langford: *Approximately optimal reinforcement learning*. En *International Conference on Machine Learning (ICML)*, páginas 267–274, 2002.

[Kra98] Krauß, Stefan: *Microscopic Modeling of Traffic Flow: Investigation of Collision Free Vehicle Dynamics*. DLR-Forschungsbericht 98-08, Deutsches Zentrum für Luft- und Raumfahrt, 1998. `https://elib.dlr.de/8380/`.

[KT03] Konda, Vijay R. y John N. Tsitsiklis: *On Actor-Critic Algorithms*. SIAM Journal on Control and Optimization, 42(4):1143–1166, 2003.

[Law15] Law, Averill M.: *Statistical Analysis of Simulation Output Data: The Practical State of the Art*. En *Proceedings of the 2015 Winter Simulation Conference*, páginas 1810–1819, 2015. `https://informs-sim.org/wsc15papers/188.pdf`.

[LFYZ25] Lu, Qiong, Haoda Fang, Zhangcheng Yin y Guliang Zhu: *HAPS-PPO: A Multi-Agent Reinforcement Learning Architecture for Coordinated Regional Control of Traffic Signals in Heterogeneous Road Networks*. Applied Sciences, 15(20):10945, 2025.

[LJR+20] Li, Liam, Kevin Jamieson, Afshin Rostamizadeh, Ekaterina Gonina, Jonathan Ben-Tzur, Moritz Hardt, Benjamin Recht y Ameet Talwalkar: *A system for massively parallel hyperparameter tuning*. En *Proceedings of Machine Learning and Systems (MLSys)*, volumen 2, páginas 230–246, 2020.

[LLN+18a] Liang, Eric, Richard Liaw, Robert Nishihara, Philipp Moritz, Roy Fox, Ken Goldberg, Joseph Gonzalez, Michael Jordan y Ion Stoica: *RLlib: Abstractions for distributed reinforcement learning*. En *International Conference on Machine Learning (ICML)*, páginas 3053–3062. PMLR, 2018.

[LLN+18b] Liaw, Richard, Eric Liang, Robert Nishihara, Philipp Moritz, Joseph E Gonzalez y Ion Stoica: *Tune: A research platform for distributed model selection and training*. arXiv preprint arXiv:1807.05118, 2018.

[LML+25] Liang, Jiaxin, Haotian Miao, Kai Li, Jianheng Tan, Xi Wang, Rui Luo y Yueqiu Jiang: *A Review of Multi-Agent Reinforcement Learning Algorithms*. Electronics, 14(4):820, 2025. `https://doi.org/10.3390/electronics14040820`.

[LWT+17] Lowe, Ryan, Yi Wu, Aviv Tamar, Jean Harb, Pieter Abbeel y Igor Mordatch: *Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments*. En *Advances in Neural Information Processing Systems (NeurIPS)*, páginas 6379–6390, 2017.

[LZF+25] Liu, Wanting, Chengwei Zhang, Wanqing Fang, Kailing Zhou, Yihong Li, Furui Zhan, Qi Wang, Wanli Xue y Rong Chen: *Vehicle-Level Fairness-Oriented Constrained Multi-Agent Reinforcement Learning for Adaptive Traffic Signal Control*. IEEE Transactions on Intelligent Transportation Systems, 26(4):4878–4890, 2025.

[MKS+15] Mnih, V., K. Kavukcuoglu, D. Silver, A. A. Rusu, J. Veness, M. G. Bellemare, A. Graves, M. Riedmiller, A. K. Fidjeland, G. Ostrovski, S. Petersen, C. Beattie, A. Sadik, I. Antonoglou, H. King, D. Kumaran, D. Wierstra, S. Legg y D. Hassabis: *Human-level control through deep reinforcement learning*. Nature, 518(7540):529–533, 2015. https://doi.org/10.1038/nature14236.

[MMLK25] Michailidis, Panagiotis, Iakovos Michailidis, Charalampos Rafail Lazaridis y Elias Kosmatopoulos: *Traffic Signal Control via Reinforcement Learning: A Review on Applications and Innovations*. Infrastructures, 10(5):114, 2025. Fuente: [4, 5] Revisión que documenta la evolución de RL como framework para TSC.

[PGM+19] Paszke, Adam, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Köpf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai y Soumith Chintala: *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. En *Advances in Neural Information Processing Systems 32*, páginas 8026–8037, 2019. NeurIPS 2019. https://proceedings.neurips.cc/paper/2019/hash/bdbca288fee7f92f2bfa9f7012727740-Abstract.html.

[PW16] Pande, Anurag y Brian Wolshon: *Traffic Engineering Handbook*. John Wiley & Sons, Inc., 7th edición, 2016.

[Ray26] Ray Team: *Key Concepts*. Ray RLlib Documentation, 2026. https://docs.ray.io/en/latest/rllib/key-concepts.html, Consultado el 26 de octubre de 2026.

[RDZ+24] Ren, Fuyue, Wei Dong, Xiaodong Zhao, Fan Zhang, Yaguang Kong y Qiang Yang: *Two-Layer Coordinated Reinforcement Learning for Traffic Signal Control in Traffic Network*. Expert Systems with Applications, 235:121111, 2024.

[RSDW+18] Rashid, Tabish, Mikayel Samvelyan, Christian Schroeder De Witt, Gregory Farquhar, Jakob Foerster y Shimon Whiteson: *QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning*. En *Proceedings of the 35th International Conference on Machine Learning (ICML)*, páginas 4295–4304. PMLR, 2018.

[Sar13] Sargent, Robert G.: *Verification and validation of simulation models*. Journal of Simulation, 7(1):12–24, 2013.

[SB18] Sutton, R.S. y A.G. Barto: *Reinforcement learning: An introduction*. The MIT Press, Cambridge, MA, 2nd edición, 2018.

[Sha53] Shapley, Lloyd S: *Stochastic games*. Proceedings of the National Academy of Sciences, 39(10):1095–1100, 1953.

[SLA+15] Schulman, John, Sergey Levine, Pieter Abbeel, Michael Jordan y Philipp Moritz: *Trust region policy optimization*. En *International Conference on Machine Learning (ICML)*, páginas 1889–1897. PMLR, 2015.

[SLG+18] Sunehag, Peter, Guy Lever, Audrunas Gruslys, Wojciech M. Czarnecki, Vinicius Zambaldi, Max Jaderberg, Marc Lanctot, Nicolas Sonnerat, Joel Z. Leibo, Karl Tuyls y Thore Graepel: *Value-Decomposition Networks For Cooperative Multi-Agent Learning*. En *Proceedings of the 17th International Conference on Autonomous Agents and MultiAgent Systems (AAMAS)*, páginas 2085–2087. International Foundation for Autonomous Agents and Multiagent Systems, 2018.

[SML+16] Schulman, John, Philipp Moritz, Sergey Levine, Michael Jordan y Pieter Abbeel: *High-dimensional continuous control using generalized advantage estimation*. En *International Conference on Learning Representations (ICLR)*, 2016.

[SQAS16] Schaul, Tom, John Quan, Ioannis Antonoglou y David Silver: *Prioritized Experience Replay*. En *International Conference on Learning Representations*, 2016. `https://arxiv.org/abs/1511.05952`.

[SWD+17] Schulman, John, Filip Wolski, Prafulla Dhariwal, Alec Radford y Oleg Klimov: *Proximal policy optimization algorithms*. arXiv preprint arXiv:1707.06347, 2017.

[TMK+17] Tampuu, Ardi, Tambet Matiisen, Dorian Kodelja, Ilya Zauss, Kristjan Korjus, Juhan Aru, Jaan Birk y Raul Vicente: *Multiagent cooperation and competition with deep reinforcement learning*. PloS one, 12(4):e0172395, 2017.

[Tok24] Toko: *Manual de uso del clúster Toko*. `https://toko.uncu.edu.ar/files/Manual_Toko-20240401.pdf`, 2024.

[vZW80] Zuylen, Henk J. van y Luis G. Willumsen: *The most likely trip matrix estimated from traffic counts*. Transportation Research Part B: Methodological, 14(3):281–293, 1980.

[W+19] Wei, H. *y cols.*: *A survey on traffic signal control methods*, 2019. Available at: https://arxiv.org/abs/1904.08117.

[WCZ+19] Wei, Hua, Chacha Chen, Guanjie Zheng, Kan Wu, Vikash Gayah, Kai Xu y Zhenhui Li: *PressLight: Learning Max Pressure Control to Coordinate Traffic Signals in Arterial Network*. En *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, páginas 1290–1298, 2019.

[Wie00] Wiering, Marco A: *Multi-agent reinforcement learning for traffic light control*. Machine learning, 2000.

[WVW19] Wunderlich, Karl, Meenakshy Vasudevan y Peiwei Wang: *Traffic Analysis Toolbox Volume III: Guidelines for Applying Traffic Microsimulation Modeling Software. 2019 Update to the 2004 Version*. Informe técnico FHWA-HOP-18-036, Federal Highway Administration, Office of Operations, Abril 2019. https://ops.fhwa.dot.gov/publications/fhwahop18036/index.htm.

[WWS+22] Wu, Qiang, Jianqing Wu, Jun Shen, Bo Du, Akbar Telikani, Mahdi Fahmideh y Chao Liang: *Distributed Agent-Based Deep Reinforcement Learning for Large Scale Traffic Signal Control*. Knowledge-Based Systems, 241:108304, 2022.

[WXZ+19] Wei, Hua, Nan Xu, Huichu Zhang, Guanjie Zheng, Xinshi Zang, Chacha Chen, Weinan Zhang, Yanmin Zhu, Kai Xu y Zhenhui Li: *CoLight: Learning Network-level Cooperation for Traffic Signal Control*. En *Proceedings of the 28th ACM International Conference on Information and Knowledge Management (CIKM)*, páginas 1913–1922, 2019.

[WZK+23] Wang, Xihuai, Lingpan Zheng, Jakub Grudzien Kuba, Ruiqing Chen, Li Shen, Yidong Cao, Jun Wang y Yaodong Yang: *Order matters: Agent-by-agent policy optimization*. En *International Conference on Learning Representations (ICLR)*, 2023.

[Yan23] Yang, Shantian: *Hierarchical Graph Multi-Agent Reinforcement Learning for Traffic Signal Control*. Information Sciences, 634:55–72, 2023.

[YVV+22] Yu, Chao, Akash Velu, Eugene Vinitsky, Jiaxuan Gao, Yu Wang, Alexandre Bayen y Yi Wu: *The surprising effectiveness of ppo in cooperative multi-agent games*. Advances in Neural Information Processing Systems, 35:24611–24624, 2022.

[ZKF+24] Zhong, Yifan, Jakub Grudzien Kuba, Xidong Feng, Siyi Hu, Jiaming Ji y Yaodong Yang: *Heterogeneous-Agent Reinforcement Learning*. Journal of Machine Learning Research, 25:1–67, 2024. https://www.jmlr.org/papers/v25/23-0488.html.

[ZLFS24] Zhang, Yifeng, Peizhuo Li, Mingfeng Fan y Guillaume Sartoretti: *HeteroLight: A General and Efficient Learning Approach for Heterogeneous Traffic Signal Control*. En *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, páginas 1010–1017, 2024.

[ZLYZ23] Zhou, Mengdi, Xiaoteng Li, Yaodong Yang y Weinan Zhang: *A Survey on Centralized Training for Decentralized Execution in Multi-Agent Reinforcement Learning*. Artificial Intelligence Review, 2023.

[ZWL24] Zhang, Haipeng, Zhiwen Wang y Na Li: *MATLight: Traffic Signal Coordinated Control Algorithm Based on Heterogeneous-Agent Mirror Learning With Transformer*. En *Proceedings of the 23rd International Conference on Autonomous Agents and Multiagent Systems (AAMAS)*, páginas 2582–2584, 2024.